

Kausalanalyse und Machinelles Lernen mit R

Ein Leitfaden für reproduzierbare Forschung

Martin C. Arnold, Christoph Hanck

2023-11-01

Inhaltsverzeichnis

1 Start	5
2 Statistische Programmierung mit R	6
2.1 Lange, weite und “tidy” Datenformate	7
2.2 Pinguine und Pipes	10
2.2.1 <code>dplyr::mutate()</code>	11
2.2.2 <code>dplyr::select()</code>	12
2.2.3 <code>dplyr::filter()</code>	13
2.2.4 <code>dplyr::summarise()</code>	15
2.2.5 <code>dplyr::arrange()</code>	16
2.2.6 Operationen mit gruppierten Datensätzen	17
2.3 Eine explorative Analyse mit <code>ggplot2</code>	19
3 Regression	23
3.1 Binäre Abhängige Variable	23
3.1.1 Das Lineare Wahrscheinlichkeitsmodell	23
3.1.2 Probit-Regression	24
3.1.3 Logistische Regression	26
3.1.4 Schätzung mit R	26
3.2 Modellierung von Zählvariablen mit Poisson-Regression	29
3.2.1 Poisson-Verteilung	29
3.2.2 Der Regressionsansatz	30
3.2.3 Modellanpassung	31
3.2.4 Interpretation der Koeffizienten	32
4 Matching	36
4.1 <i>Balance</i> : Vergleichbarkeit von Behandlungs- und Kontrollgruppe	38
4.1.1 Matching durch Gewichtung	42
4.1.2 Entropy Balancing	48
4.1.3 Mehrere Matching-Variablen und der Propensity Score	50
4.2 Selektierende Matching-Verfahren	57
4.2.1 Exaktes Matching	58
4.2.2 Coarsened Exact Matching	59
4.2.3 Matching mit der Mahalanobis-Distanz	60
4.2.4 Propensity Score Matching	64
4.3 Schätzung und Inferenz für den Behandlungseffekt nach Matching	69
4.3.1 Cluster-robuste Standardfehler	72
4.4 Bootstrap-Schätzung kausaler Effekte bei Matching	76
4.5 Regression, Matching und Doubly-Robust-Schätzung	83

5 Panel-Daten	88
5.1 Pooled Regression und unbeobachtbare Heterogenität	88
5.2 Regression in Differenzen	95
5.3 Fixed-Effects-Regression	99
5.3.1 Zeit-Fixed-Effects	101
5.4 Random Effects	103
5.4.1 Verzerrung bei Endogenität	108
5.5 Beispiel: Einkommen und Demokratie	111
6 IV-Regression	117
6.1 Der einfache lineare IV-Schätzer	117
6.1.1 Identifizierbarer Behandlungseffekt	121
6.2 2SLS-Verfahren	121
6.2.1 Äquivalenz von 2SLS und einfacher IV-Schätzer	122
6.2.2 Wozu 2SLS?	122
6.3 Beispiel: Der schwache Staat, die Bauern und die Mafia	129
6.3.1 Identifikationsstrategie	129
6.4 Case Study: Ökonomische Schocks und Bürgerkriege	130
7 Difference-in-Differences	152
7.1 Einordnung im Potential Outcomes Framework	153
7.2 Schätzung des ATT mit DID	155
7.3 Schätzung von DID-Forschungsdesigns mit R	159
7.4 Case Study: Effekt von Steuererleichterungen auf Erwerbsbeteiligung	165
7.4.1 Schätzungen des ATT mit linearen Modellen	170
7.4.2 Probit-Spezifikationen	178
7.5 Case Study: Effekt von Polizeipräsenz auf Autodiebstähle	184
7.5.1 Trend-Vergleich	185
7.5.2 Two-Way-Fixed-Effects-Schätzungen	192
7.5.3 Placebo-Tests	200
7.5.4 Weitere Robustness-Checks	204
7.6 Zusammenfassung	212
8 Regression Discontinuity Designs	213
8.1 Sharp Regression Discontinuity Design	214
8.2 Manipulation am Schwellenwert	219
8.2.1 Case Study: Amtsinhaber-Vorteil (Lee 2008)	222
8.3 Fuzzy Regression Discontinuity Design	231
8.4 Case Study: Protestantische Arbeitsethik	234
8.4.1 Aufbereitung der Daten	236
8.4.2 Deskriptive Statistiken	238
8.4.3 Modellspezifikation und First-Stage-Ergebnisse	240
8.4.4 Second-Stage-Ergebnisse	246
8.4.5 Addendum: FRDD-Schätzung mit <code>rdrobust()</code>	249

9 Regularisierte Regression	253
9.1 Ridge Regression	254
9.1.1 Eigenschaften des Schätzers	256
9.1.2 Ridge Regression mit <code>glmnet</code>	259
9.1.3 Beispiel: Vorhersage von Abschlussnoten in Mathe	266
9.2 Lasso Regression	273
9.2.1 Lasso ist Soft Thresholding	274
9.2.2 Berechnung der Lasso-Lösung mit dem LARS-Algorithmus	277
9.2.3 Wahl des Regularisierungsparameters λ für den Lasso-Schätzer	280
9.3 Vergleich von Lasso- und Ridge-Regression mit Simulation	285
9.3.1 Prognosegüte in diversen Szenarien	285
9.3.2 Visualisierung des Bias-Variance-Tradeoffs bei Prognosen	291
9.4 Inferenz für Treatment-Effekt-Schätzung mit vielen Variablen	297
9.4.1 Case Study: Makroökonomisches Wachstum	304
10 Machine Learning	312
11 Synthetic Control	313
11.1 Schätzung von Interventionseffekten mit SCM	314
11.2 Case Study: Ökonomische Kosten des Brexit	316
11.2.1 Placebo-Tests: Grafische Inferenz	329
11.2.2 Statistische Inferenz	339
Literatur	342

1 Start

2 Statistische Programmierung mit R

Dieses Kapitel ist *nicht* als umfassende Einführung in R gedacht, sondern behandelt Kernfunktionen aus der Paketsammlung `tidyverse`. Wenngleich die Inhalte deutlich über ein Hallo-Welt-Beispiel¹ hinausgehen, betrachten wir hier grundlegene Funktionen für Datenmanipulation und Visualisierung. Diese sind Voraussetzung für das Verständnis fortgeschrittener Code-Bausteine in späteren Kapiteln. Falls Sie bereits über Grundkenntnisse im Umgang mit `tidyverse` verfügen, können Sie dieses Kapitel überspringen. Sollten Sie nicht oder nur teilweise mit den hier gezeigten Befehlen vertraut sein oder keinerlei Erfahrung mit R haben, empfiehlt sich vorab eine Erarbeitung bzw. Wiederholung der Inhalte. Nachstehende Ressourcen finden wir hilfreich:

- Feedbackgestütze interaktive Übungsaufgaben bei DataCamp², bspw.
 - [Einführung in R](#)
 - [Introduction to Data Visualization with ggplot2](#)
 - [Data Manipulation with dplyr](#)
- Open-source-Literatur wie
 - der umfangreiche Leitfaden von [Ellis und Mayer \(2023\)](#)
 - [R for Data Science](#)
 - [Hands-On Programming with R](#)

Wir laden zunächst die Paketsammlung `tidyverse`. Für die Reproduktion mit dem `R GUI` oder mit `RStudio` muss das Paket vorab mit `install.packages()` installiert werden. In den interaktiven R-Konsolen in diesem Kapitel (und im Rest des Buchs) sind die benötigten R-Pakete bereits installiert *und* geladen, sofern nicht anders beschrieben.

```
# Paket tidyverse installieren  
# install.packages("tidyverse")
```

¹<https://de.wikipedia.org/wiki/Hallo-Welt-Programm>

²Ein Teil des hier angebotenen Katalogs (exklusive *Einführung in R*) ist kostenpflichtig.

```
# Paket 'tidyverse' laden  
library(tidyverse)
```

Für das Verständnis von Code-Chunks ist es hilfreich, Zwischenergebnisse explizit zu evaluieren und in der Konsole auszugeben. Hierfür umschließen wir häufig Code-Zeilen mit runden Klammern. Der nächste Chunk illustriert dies für die Variable `x`.

```
# Variable definieren...  
x <- pi  
# ... und evaluieren  
x  
  
# Äquivalent:  
(  
  x <- pi  
)
```

2.1 Lange, weite und “tidy” Datenformate

Wir betrachten den in Tabelle 2.1 dargestellten Datensatz *Klausurergebnisse*.

Tabelle 2.1: Datensatz *Klausurergebnisse*

Name	Mikro	Makro	Mathe
Tim	NA	1.3	3
Lena	1	3	NA
Ricarda	2	1.7	1.3
Simon	2.3	3.3	NA

Der Datensatz ist noch nicht in der R-Arbeitsumgebung verfügbar. Mit der Funktion `tribble()` können wir Tabelle 2.1 händisch als R-Objekt der Klasse `tibble` definieren

```
# 'klasurergebnisse' als tibble definieren  
(  
  klausurergebnisse <- tribble(
```

```

~Name,    ~Mikro, ~Makro, ~Mathe,
"Tim",      NA,     1.3,     3.0,
"Lenा",     1.0,     3.0,     NA,
"Ricarda", 2.0,     1.7,     1.3,
"Simon",    2.3,     3.3,     NA
)
)

```

`klausurergebnisse` enthält die Klausurnoten der vier Studierenden (Beobachtungen) spaltenweise *pro Modul*, d.h. die Spaltennamen **Mikro**, **Makro** und **Mathe** sind Ausprägungen der Variable *Modul*. Der Datensatz liegt also *nicht* im s.g. *Tidy-Format* vor.

💡 Tidy-Format

Tidy-Format: Jede Spalte ist *eine* Variable, jede Reihe ist *eine* Beobachtung und jede Zelle enthält einen *einen* Wert. Datensätze im Tidy-Format sind häufig lang: Die Zeilendimension ist größer als die Spaltendimension.

Das Tidy-Format ist hilfreich für statistische Analysen mit `tidyverse`-Funktionen wie bspw. `ggplot()`. Wir nutzen die Funktion `tidyr::pivot_longer()`, um `klausurergebnisse` ein (langes) Tidy-Format zu transformieren.

```

# 'klausurergebnisse' in Tidy-Format überführen
(
  long <- pivot_longer(
    data = klausurergebnisse,
    cols = Mikro:Mathe,
    names_to = "Modul",
    values_to = "Note"
  )
)

```

Beachte, dass die Spalte **Name** die Zugehörigkeit der Ausprägungen (**Note**) jeder Variable (**Modul**) zu einer Beobachtung identifiziert. Mit dieser Information können wir den langen Datensatz wieder in das ursprüngliche (weite) Format zurückführen. Wir nutzen hierzu `tidyr::pivot_wider()`.

```
# langes Format in das Ausgangsformat transformieren
(
  wide <- pivot_wider(
    data = long,
    id_cols = "Name",
    names_from = "Modul",
    values_from = "Note"
  )
)
```

Wenn die Zuweisung von Zwischenergebnissen in Variablen nicht benötigt wird, kann eine Verkettung von Funktionsaufrufen die Verständlichkeit des Codes verbessern. Hierzu wird der Pipe-Operator `%>%` genutzt. Wir wiederholen die Transformationen mit den `tidyverse::pivot_*`-Funktion bei Verwendung von `%>%`.

```
# langes Format mit %>%
(
  long <- klausurergebnisse %>%
    pivot_longer(
      cols = Mikro:Mathe,
      names_to = "Modul",
      values_to = "Note"
    )
)

# weites Format mit %>%
(
  wide <- long %>%
    pivot_wider(
      id_cols = "Name",
      names_from = "Modul",
      values_from = "Note"
    )
)
```

Ein Beispiel für den Nachteil des weiten Formats im Umgang mit `tidyverse`-Paketen ist die Funktion `tidyverse::drop_na()`. Diese entfernt sämtliche *Zeilen* eines Datensatzes, die NA-Einträge (d.h. fehlende Werte) aufweisen. Beachte,

dass diese Operation im ursprünglichen weiten Format zum Entfernen ganzer Beobachtungen aus `wide` führt.

```
# NA-Einträge aus dem "weiten" Format entfernen  
wide %>%  
  drop_na()
```

Im Tidy-Format `long` hingegen bleiben die übrigen Informationen betroffener Beobachtungen erhalten.

```
# NA-Einträge aus dem "langen" Format entfernen  
long %>%  
  drop_na()
```

2.2 Pinguine und Pipes

In diesem Abschnitt zeigen wir die Verwendung häufig verwendeter `dplyr`-Funktionen (s.g. *Verben*) für die Transformation von Datensätzen: `mutate()`, `select()`, `filter()`, `summarise()` und `arrange()`.

Für die Illustration verwenden wir den Datensatz `penguins` aus dem R-Paket `palmerpenguins`. Dieser Datensatz wurde im Zeitraum 2007 bis 2009 von Dr. Kristen Gorman im Rahmen des *Palmer Station Long Term Ecological Research Program* zusammengetragen und enthält Größenmessungen für drei Pinguinarten, die auf den Inseln des [Palmer-Archipels](#) in der Antarktis beobachtet wurden.

```
# Paket 'palmerpenguins' installieren  
# install.packages("palmerpenguins")  
  
# Paket 'palmerpenguins' laden  
library(palmerpenguins)
```

Mit `data()` wird der Datensatz in der Arbeitsumgebung verfügbar gemacht. Wir nutzen `glimpse()`, um einen Überblick zu erhalten.

```
# Datensatz in der Arbeitsumgebung verfügbar machen
data(penguins)

# Übersicht anzeigen lassen
glimpse(penguins)
```

2.2.1 dplyr::mutate()

Mit `mutate()` können bestehende Variablen überschrieben oder neue Variablen als Funktion bestehender Variablen definiert werden. `mutate()` operiert in der Spaltendimension des Datensatz.

Wir definieren eine neue Variable `body_mass_kg` als Transformation `body_mass_g/1000`.

```
# Neue Variable mit Gewicht in Kg definieren
penguins %>%
  mutate(
    body_mass_kg = body_mass_g/1000
  ) %>%
  glimpse()
```

Mit `across()` kann die dieselbe Operation auf mehrere Variablen angewendet werden.

Im nachstehenden Beispiel ändern wir den typ (`type`) der Variablen `species`, `island`, `sex` und `year` zu `character`.

```
# species, island, sex und year in Typ 'character' umwandeln
penguins %>%
  mutate(
    across(
      c(species, island, sex, year),
      .fns = as.character
    )
  ) %>%
  glimpse()
```

`transmute()` ist eine Variante von `mutate()`, die lediglich die transformierten Variablen beibehält.

```
# Nur transformierte Variablen behalten
penguins %>%
  transmute(
    body_mass_kg = body_mass_g/1000
  )
```

2.2.2 dplyr::select()

Mit `select()` werden Variablen aus dem Datensatz ausgewählt. Dies geschieht entweder über den Variablennamen...

```
# 'species' auswählen
penguins %>%
  select(species)
```

... oder über eine Indexmenge.³

```
# Teilmenge von Variablen per Index auswählen
penguins %>%
  select(
    c(1, 2, 3)
  )
```

Variablen können anhand eines Muster im Namen selektiert werden. Die Selektion von `ends_with("mm")` bezieht nur Variablen mit Endung `mm` im Namen ein:

```
# Nur in mm gemessene Variablen auslesen
penguins %>%
  select(
    ends_with("mm")
  )
```

³Hilfreich: `dplyr::pull()` selektiert eine Variable und wandelt diese in einen Vektor um.

Mit `where()` können wir Variablen aufgrund bestimmter Eigenschaften ihrer Ausprägungen selektieren.

```
# Nur numerische Variablen auswählen
penguins %>%
  select(
    where(is.numeric)
  )
```

2.2.3 dplyr::filter()

Das Verb `filter()` filtert den Datensatz in der Zeilendimension. So können Beobachtungen ausgewählt werden, deren Merkmalsausprägungen bestimmte Kriterien erfüllen. Hierzu muss `filter()` ein logischer (`logical`) Ausdruck übergeben werden. Häufig erfolgt dies über Vergleichsoperatoren.

```
# Nur Pinguine mit bill_length_mm >= 39
penguins %>%
  filter(
    bill_length_mm >= 39
  )
```

```
# Nur Pinguine mit bill_length_mm <= 40
penguins %>%
  filter(
    bill_length_mm <= 40
  )
```

Oft ist es praktisch, mehrere Kriterien zu kombinieren.

```
# Kombinierter Filter -- Variante 1
penguins %>%
  filter(
    bill_length_mm >= 39 & bill_length_mm <= 40
  )
```

Analog: komma-getrennte Kriterien werden intern über den Und-Operator (`&`) verknüpft.

```
# Kombinierter Filter -- Variante 2
penguins %>%
  filter(
    bill_length_mm >= 39,
    bill_length_mm <= 40
  )
```

Ähnlich wie bei `select()` verwenden wir häufig nützliche Funktionen, welche die Interpretation des Codes erleichtern. `dplyr::between()` erlaubt filtern innerhalb eines Intervals.

```
# Filtern mit Hilfsfunktion
penguins %>%
  filter(
    between(
      bill_length_mm, left = 39, right = 40
    )
  )
```

Mit diesen Verben sind wir bereits in der Lage, den Datensatz gemäß folgender Vorschrift zu bereinigen:

1. Entfernen der Maßeinheiten aus den Variablennamen
2. Entfernen von Pinguinen mit fehlenden Werten (`NA`)
3. Entfernen von Pinguinen mit einem Gewicht *oberhalb* des 95%-Stichprobenquantils

```
# Schritt 1
(
  penguins_cleaned <- penguins %>%
    rename(
      bill_length = bill_length_mm,
      bill_depth = bill_depth_mm,
      flipper_length = flipper_length_mm,
      body_mass = body_mass_g
    )
)
```

```
# Schritt 2
(
  penguins_cleaned <- penguins_cleaned %>%
    drop_na()
)
```

```
# Schritt 3
penguins_cleaned %>%
  filter(
    body_mass < quantile(body_mass, probs = .95)
  ) %>%
  glimpse()
```

Durch die Verkettung mit `%>%` können wir sämtliche Schritte für die Bereinigung ohne das Abspeichern von Zwischenergebnissen durchführen.

```
# Verketteter Funktionsaufruf für Datensatzbereinigung
penguins_cleaned <- penguins %>%
  rename(
    bill_length = bill_length_mm,
    bill_depth = bill_depth_mm,
    flipper_length = flipper_length_mm,
    body_mass = body_mass_g
  ) %>%
  drop_na() %>%
  filter(
    body_mass < quantile(body_mass, .95)
  )

penguins_cleaned %>%
  glimpse()
```

2.2.4 `dplyr::summarise()`

Das Verb `summarise()` fasst Variablen über Beobachtungen hinweg zusammen. Der nachstehende Code-Chunk erzeugt eine Tabelle mit Stichprobenmittelwert und -standardabweichung von `flipper_length_mm`.⁴ Um zu vermeiden, dass

⁴`dplyr::summarise()` darf nicht mit `base::summary()` verwechselt werden!

die Auswertung aufgrund fehlender Werte (NA) in `flipper_length_mm` scheitert, lassen wir NAs mit `na.rm = TRUE` bei der Berechnung unberücksichtigt (wir verwenden weiterhin den unbereinigten Datensatz `penguins`).

```
# statistische Zusammenfassung mit 'summarise()'
penguins %>%
  select(flipper_length_mm) %>%
  summarise(
    mean = mean(flipper_length_mm, na.rm = TRUE),
    sd = sd(flipper_length_mm, na.rm = TRUE)
  )
```

Varianten von `summarise()` können über mehrere Variablen angewendet werden. Wir verwenden `across()` und `where()`, um lediglich numerische Variablen mit den in der Liste definierten Funktionen zusammenzufassen. Beachte, dass `\(x) mean(x)` eine anonyme Funktion definiert.

```
penguins %>%
  summarise(
    across(
      where(is.numeric),
      .fns = list(
        mean = \(x) mean(x, na.rm = TRUE),
        sd = \(x) sd(x, na.rm = TRUE)
      )
    )
  ) %>%
  glimpse()
```

2.2.5 dplyr::arrange()

Mit `arrange()` können Datensätze in Abhängigkeit der beobachteten Ausprägungen von Variablen sortiert werden.

```
# Datensatz aufsteigend nach 'body_mass_g' sortieren
penguins %>%
  arrange(body_mass_g)
```

Die Funktion `dplyr::desc()` kehrt die Reihenfolge zu einer absteigenden Sortierung um.

```
# Absteigende Sortierung nach 'body_mass_g'  
penguins %>%  
  arrange(  
    desc(body_mass_g)  
)
```

Komplexe Sortier-Muster werden durch Übergabe von Variablennamen in der gewünschten Reihenfolge erreicht.

```
# Erst Sortierung nach 'sex', dann gruppenweise absteigend  
# nach 'body_mass_g' sortieren  
penguins %>%  
  arrange(  
    sex, desc(body_mass_g)  
)
```

2.2.6 Operationen mit gruppierten Datensätzen

Für manche Transformationen ist eine Gruppierung der Daten hilfreich. Wir illustrieren nachfolgend die unterschiedlichen Verhaltensweisen ausgewählter Verben durch Vergleiche von gruppierten und nicht-gruppierten Anwendungen.

```
# Datensatz gruppieren  
penguins_grouped <- penguins %>%  
  group_by(species)  
  
# Datensatz hat nun die Eigenschaft 'Groups'  
glimpse(penguins_grouped)
```

`species` hat drei Ausprägungen. Entsprechend ist `penguins_grouped` nun in drei Gruppen eingeteilt.

Bei gruppierten Datensätzen fasst `summarise()` die Variablen pro Gruppe zusammen.

```
# summarise -- ungruppiert:  
penguins %>%  
  summarise(  
    across(  
      where(is.numeric), \((x) mean(x, na.rm = T)  
    )  
  )
```

```
# summarise -- gruppiert:  
penguins_grouped %>%  
  summarise(  
    across(  
      where(is.numeric),  
      ~ mean(., na.rm = T)  
    )  
  )
```

`mutate()` definiert bzw. transformiert für jede Gruppe separat. Im dies zu veranschaulichen, ziehen wir eine Zufallsstichprobe von 10 Pinguinen aus der Datensatz.

```
# Zufallsstichprobe generieren  
set.seed(123)  
(  
  penguins_sample <- penguins %>%  
    slice_sample(n = 10)  
)
```

```
# mutate() -- ungruppiert:  
penguins_sample %>%  
  transmute(  
    mean = mean(bill_length_mm)  
)
```

Für den ungruppierten Datensatz berechnet `mutate()` das Stichprobenmittel von `bill_length_mm` über alle zehn Datenpunkte und weiß diesen Wert jeweils in der Variable `mean` zu.

```
# mutate() -- gruppiert
penguins_sample %>%
  group_by(species) %>%
  transmute(
    mean = mean(bill_length_mm)
  )
```

Bei gruppierten Daten berechnet `mutate()` das Stichprobenmittel *pro Gruppe* und weist die Mittelwerte entsprechend zu.

2.3 Eine explorative Analyse mit ggplot2

Der bereinigte Datensatz `penguins_cleaned` eignet sich gut für eine graphische Auswertung mit dem R-Paket `ggplot2`, welches Bestandteil des `tidyverse` ist. Nachfolgend untersuchen wir Zusammenhänge zwischen den Körpermaßen der Pinguine.

Wir erstellen zunächst einen einfachen Punkteplot des Gewichts (`body_mass`) und der Schnabeltiefe (`bill_depth`).

```
# Punkteplot: body_mass vs. bill_depth
penguins_cleaned %>%
  ggplot(
    mapping = aes(
      x = body_mass,
      y = bill_depth
    )
  ) +
  geom_point()
```

Die Grafik zeigt einen positiven Zusammenhang zwischen dem Gewicht und der Schnabeltiefe. Als nächstes passen wir den Code so an, dass die Datenpunkte entsprechend der Art (`species`) eingefärbt sind.

```
# Punkteplot: Farbliche Darstellung verschiedener Arten
penguins_cleaned %>%
  ggplot(
    mapping = aes(
```

```

    x = body_mass,
    y = bill_depth,
    color = species
)
) +
geom_point()

```

Offenbar gibt es deutliche Unterschiede in der (gemeinsamen) Verteilung von Gewicht und Schnabeltiefe zwischen den verschiedenen Arten.

Um den Zusammenhang zwischen Gewicht und Schnabeltiefe zu untersuchen, schätzen wir lineare Regressionen

$$body_mass = \beta_0 + \beta_1 bill_depth + u$$

separat für jede der drei Pinguinarten mit der KQ-Methode. Anschließend zeichnen wir die geschätzten Regressionsgeraden ein.

```

# Lineare Regression per Art
penguins_cleaned %>%
  ggplot(
    aes(
      x = body_mass,
      y = bill_depth,
      color = species
    )
  ) +
  geom_point() +
  geom_smooth(method = "lm", se = F)

```

Die Schätzungen bekräftigen die Vermutung, dass der lineare Zusammenhang zwischen Gewicht und Schnabeltiefe sich nicht zwischen den verschiedenen Pinguinarten unterscheidet: Pinguine der Art *Gentoo* sind im Mittel schwerer als Pinguine der übrigen Arten, haben jedoch eine geringere Schnabeltiefe.

Der nachfolgende Code fügt der Grafik eine Regressionsline *über alle* Arten hinzu. Wir setzen hierbei das Argument `inherit_aes = FALSE` und legen damit fest, dass die Regression für `body_mass` und `bill_depth` ohne Differenzierung per `species` durchgeführt wird.

```

# Zusatz: Globale Regression
penguins_cleaned %>%
  ggplot(
    mapping = aes(
      x = body_mass,
      y = bill_depth,
      color = species
    )
  ) +
  geom_point() +
  geom_smooth(method = "lm", se = F) +
  # Regression für alle Datenpunkte
  geom_smooth(
    mapping = aes(
      x = body_mass,
      y = bill_depth
    ),
    method = "lm",
    se = F,
    inherit.aes = F
  )

```

Offenbar ist die vorherige Analyse per Spezies sinnvoller: Die Regression über alle Arten suggeriert einen negativen Zusammenhang zwischen Gewicht und Schnabeltiefe.

Facetting mit `facet_wrap()` erlaubt eine Untersuchung des Zusammenhangs je Insel (`island`), auf der die Messung erfolgt ist.

```

# Facettierung des per In
penguins_cleaned %>%
  ggplot(
    mapping = aes(
      x = body_mass,
      y = bill_depth,
      color = species)
  ) +
  geom_point() +
  geom_smooth(method = "lm", se = F) +
  facet_wrap(~ island)

```

Wir sehen, dass es hinsichtlich des Zusammenhangs von Gewicht und Schnabeltiefe keine wesentlichen Diskrepanzen zwischen den drei Inseln gibt. Darüber hinaus lässt sich anhand der Facetten leicht erkennen, wie die drei Arten über die Inseln verteilt sind.

3 Regression

```
library(tidyverse)
library(cowplot)
```

3.1 Binäre Abhängige Variable

3.1.1 Das Lineare Wahrscheinlichkeitsmodell

Das lineare Regressionsmodell

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i$$

mit einer binären abhängigen Variablen $Y_i \in \{0, 1\}$ wird als *lineares Wahrscheinlichkeitsmodell* bezeichnet. Wie üblich modellieren wie den Erwartungswert der abhängigen Variable gegeben der Regressoren X_1, \dots, X_k als lineare Funktion, d.h.

$$E(Y|X_1, X_2, \dots, X_k) = P(Y = 1|X_1, X_2, \dots, X_k).$$

Da Y eine binäre Variable ist, gilt hier

$$P(Y = 1|X_1, X_2, \dots, X_k) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k.$$

Das lineare Wahrscheinlichkeitsmodell beschreibt also die *Wahrscheinlichkeit*, dass $Y = 1$ als lineare Funktion der Regressoren: β_j misst die Änderung in der Wahrscheinlichkeit das $Y_i = 1$, unter der Bedingung, dass die anderen $k - 1$ Regressoren konstant gehalten werden. Genau wie in der gewöhnlichen multiplen Regression können die β_j mit der KQ-Methode geschätzt werden.

Aufgrund der Beschränktheit der Y_i auf $\{0, 1\}$ sind die u_i heteroskedastisch. Folglich sollten Inferenzstatistiken mit robusten Standardfehlern berechnet

werden. Weiterhin ist zu beachten, dass R^2 in den meisten Anwendungen von linearen Wahrscheinlichkeitsmodellen keine hilfreiche Interpretation hat, da das geschätzte Modell die Daten nicht perfekt erklären kann, wenn die abhängige Variable binär, aber die Regressoren kontinuierlich verteilt sind.

Das lineare Wahrscheinlichkeitsmodell hat einen wesentlichen Nachteil: Wir nehmen an, dass die bedingte Wahrscheinlichkeitsfunktion linear ist. Daher ist $P(Y = 1|X_1, \dots, X_k)$ nicht auf das für Wahrscheinlichkeiten definierte Intervall $[0, 1]$ beschränkt, sodass das angepasste Modell für extreme Regressorwerte keine sinnvolle Interpretation haben kann.

Diese Gegebenheit verlangt nach einem Ansatz, der eine nichtlineare Funktion verwendet, um die bedingte Wahrscheinlichkeitsfunktion einer binären abhängigen Variable zu modellieren. Häufig verwendete Methoden sind Probit- und Logit-Regression.

3.1.2 Probit-Regression

Bei der Probit-Regression wird die Standardnormalverteilungsfunktion $\Phi(\cdot)$ verwendet, um die Regressionsfunktion bei einer binären abhängigen Variable zu modellieren. Wir nehmen an, dass

$$E(Y|X) = P(Y = 1|X) = \Phi(\beta_0 + \beta_1 X). \quad (3.1)$$

$\beta_0 + \beta_1 X$ in (3.1) ist hier ein *Quantil* z der Standardnormalverteilung,

$$\Phi(z) = P(Z \leq z), \quad Z \sim \mathcal{N}(0, 1), \quad (3.2)$$

sodass der Koeffizient β_1 in (3.1) die Änderung in z misst, die mit einer Änderung von einer Einheit in X verbunden ist. Obwohl der Effekt einer Änderung in X auf z linear ist, ist der Zusammenhang zwischen z und der abhängigen Variable Y *nicht linear*: Φ ist eine nicht-lineare Funktion von X (vgl. Abbildung 3.1)!

```
# N(0,1)-Verteilungsfunktion
ggplot() +
  geom_function(fun = pnorm) +
  scale_x_continuous(
    name = "z",
    limits = c(-4, 4)
  ) +
```

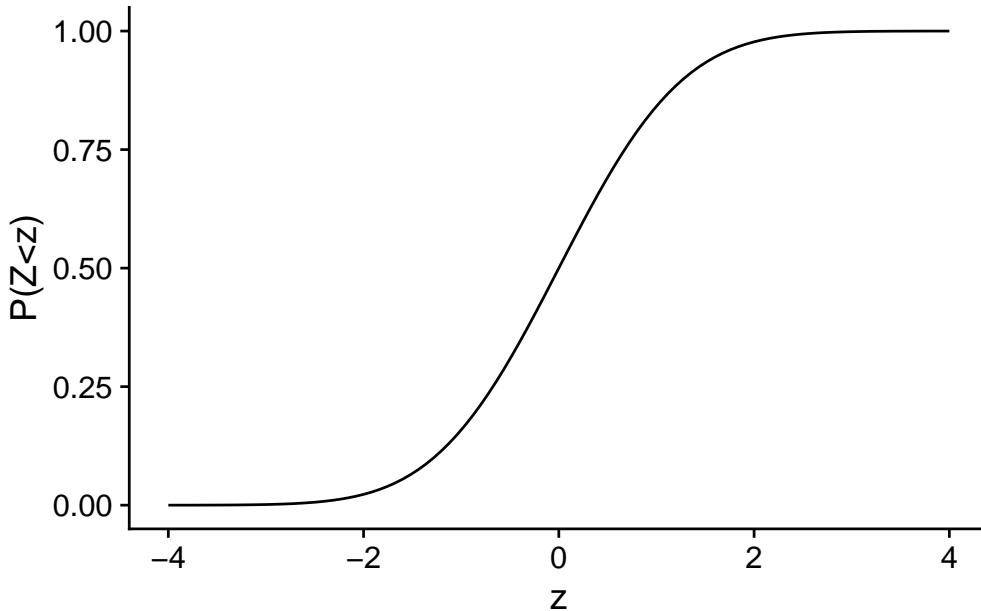


Abbildung 3.1: Verteilungsfunktion einer $N(0,1)$ -Zufallsvariable

```
scale_y_continuous(name = "P(Z<z)") +
theme_cowplot()
```

Da die abhängige Variable eine nichtlineare Funktion der Regressoren ist, hat der Koeffizient von X keine einfache Interpretation. Die Änderung in der Wahrscheinlichkeit, dass $Y = 1$ ist, durch eine Änderung in X (partieller Effekt) kann berechnet werden als:

$$\frac{\partial E(Y|X)}{\partial X} = \frac{\partial P(Y = 1|X)}{\partial X} = \frac{\partial \Phi(\beta_0 + \beta_1 X)}{\partial X} = \phi(\beta_0 + \beta_1 X)\beta_1, \quad (3.3)$$

wobei $\phi(\cdot)$ die Dichtefunktion der Standardnormalverteilung ist. In empirischen Anwendungen wird der partielle Effekt häufig als Differenz in geschätzten Wahrscheinlichkeiten angegeben:

1. Berechne die geschätzte Wahrscheinlichkeit, dass $Y = 1$ für einen Bezugswert X .
2. Berechne die geschätzte Wahrscheinlichkeit, dass $Y = 1$ für $X + \Delta X$.
3. Berechne die Differenz zwischen den geschätzten Wahrscheinlichkeiten.

Wie im linearen Wahrscheinlichkeitsmodell kann das Modell (3.1) auf eine Probit-Regression mit mehreren Regressoren X_j , $j = 1, \dots, k$ verallgemeinert werden, um das Risiko einer Verzerrung durch ausgelassene Variablen zu

mindern. Die Schritte 1 bis 3 für die Berechnung des partiellen Effekts einer Änderung in X_j erfolgen dann unter der Annahme, dass die übrigen $k - 1$ Regressoren konstant gehalten werden, wobei der partielle Effekt von den jeweiligen Regressorwerten abhängt.

3.1.3 Logistische Regression

3.1.4 Schätzung mit R

```
# Daten simulieren
set.seed(1234)

n <- 2000 # Stichprobengröße

simdata <- tibble(
  X = rnorm(n = n, mean = 5, sd = 2), # Regressor
  P = pnorm(0.75 * X - 4 + rnorm(n)), # + Rauschen
)

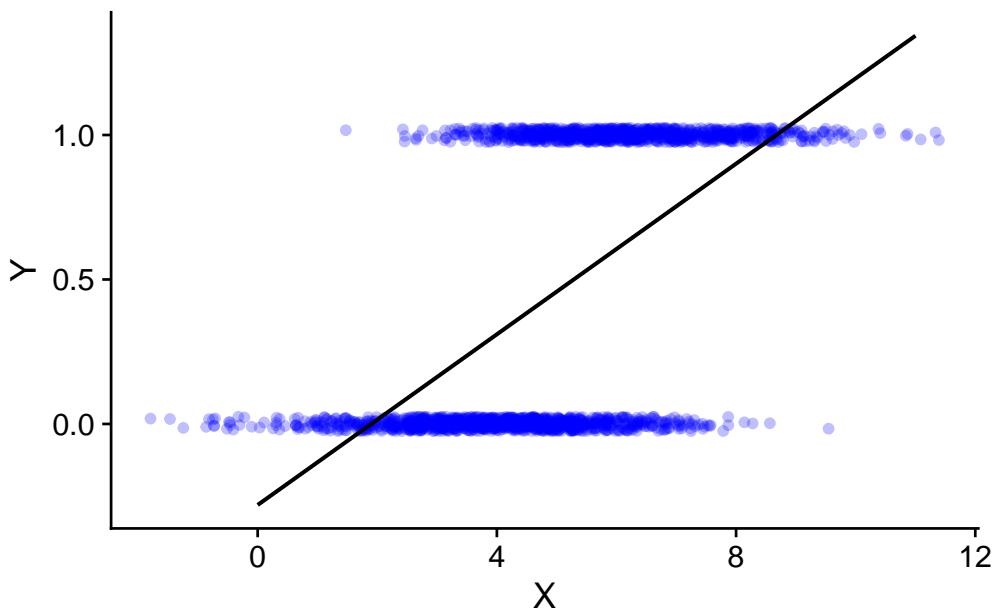
# Binäre Outcome-Variable hinzufügen
simdata <- simdata %>%
  mutate(Y = as.integer(runif(n) < P))
```

```
# lineares Wahrscheinlichkeitsmodell schätzen
mod_lp <- lm(formula = Y ~ X, data = simdata)
```

```
# geschätzte Wahrscheinlichkeitsfunktion
# für lineares Modell
X <- seq(0, 11, 0.01)

pred <- tibble(
  X = X,
  LP = predict(
    object = mod_lp,
    newdata = tibble(X)
  )
)
```

```
# geschätztes lineares Modell plotten
simdata %>%
  ggplot(mapping = aes(x = X, y = Y)) +
  geom_point(
    position = position_jitter(
      height = .025,
      seed = 1234
    ),
    alpha = .25,
    color = "blue"
  ) +
  geom_line(
    data = pred,
    mapping = aes(y = LP),
    lwd = .75
  ) +
  theme_cowplot()
```

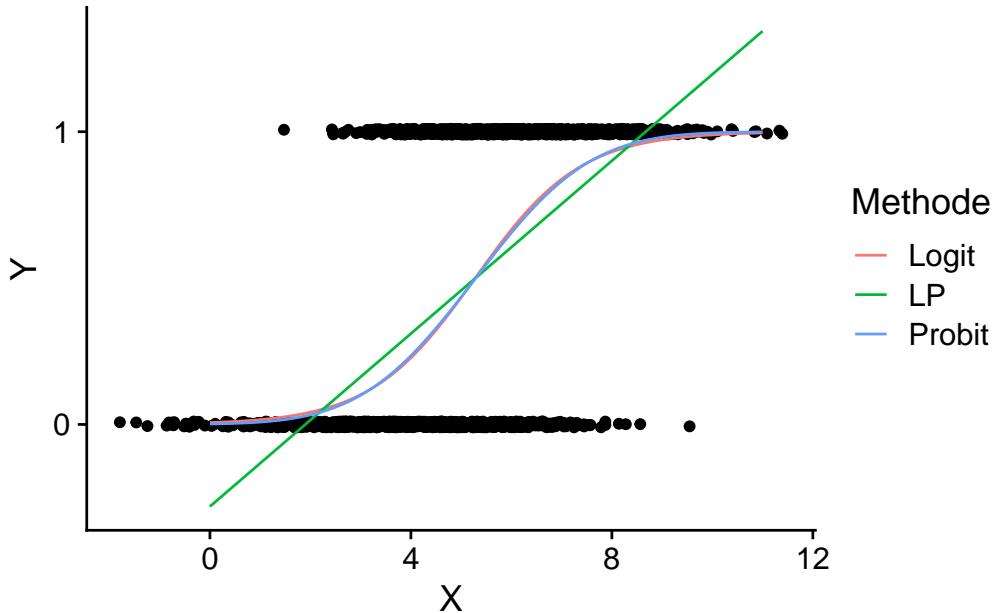


```
# Probit-Modell schätzen
mod_probit <- glm(
  formula = Y ~ X,
  data = simdata,
  family = binomial(link = "probit")
)
```

```
# Logit-Modell schätzen
mod_logit <- glm(
  formula = Y ~ X,
  data = simdata,
  family = binomial(link = "logit")
)
```

```
# gesch. WSK-Funktion für Probit- und Logit-Modelle
pred <- pred %>%
  mutate(
    Probit = predict(mod_probit, tibble(X), type = "response"),
    Logit = predict(mod_logit, tibble(X), type = "response")
  ) %>%
  pivot_longer(
    cols = LP:Logit,
    names_to = "Methode",
    values_to = "Wsk"
  )
```

```
# Vergleich mit linearem Modell
simdata %>%
  ggplot(mapping = aes(x = X, y = Y) ) +
  geom_point(
    position = position_jitter(
      height = .01,
      seed = 1234
    )
  ) +
  geom_line(
    data = pred,
    mapping = aes(y = Wsk, color = Methode)
  ) +
  scale_y_continuous(breaks = c(0, 1)) +
  theme_cowplot()
```



3.2 Modellierung von Zählvariablen mit Poisson-Regression

Die Poisson-Regression ist ein statistisches Modell, das verwendet wird, um Zählvariablen (d.h. Variablen, die diskrete, nicht-negative Werte annehmen) zu modellieren, insbesondere wenn die Zählwerte eine Poisson-Verteilung aufweisen. Dieses Modell wird häufig in Fällen verwendet, in denen die abhängige Variable die Anzahl der Ereignisse in einem bestimmten Zeitraum oder Raum beschreibt, wie z.B. die Anzahl der Verkehrsunfälle in einer Stadt innerhalb eines Monats.

3.2.1 Poisson-Verteilung

Eine Zufallsvariable Y folgt einer Poisson-Verteilung mit Parameter λ , wenn ihre Wahrscheinlichkeitsverteilung gegeben ist durch:

$$P(Y = y) = \frac{\lambda^y e^{-\lambda}}{y!} \quad \text{für } y = 0, 1, 2, \dots \quad (3.4)$$

Hierbei ist λ sowohl der Mittelwert als auch die Varianz der Verteilung ($\mathbb{E}[Y] = \text{Var}(Y) = \lambda$).

```

n <- 500
dat <- tibble(
  Y = rpois(n = n, lambda = 5)
)

```

```

ggplot(
  data = dat,
  mapping = aes(x = Y)
) +
  geom_histogram(
    mapping = aes(y = after_stat(density)),
    binwidth = 1,
    color = "white"
) +
  geom_line(
    data = tibble(
      X = 0:13,
      Y = dpois(x = X, lambda = 5)
    ),
    mapping = aes(x = X, y = Y),
    color = "red"
) +
  theme_cowplot()

```

3.2.2 Der Regressionsansatz

In der Poisson-Regression modellieren wir den Erwartungswert der abhängigen Variable Y als eine Funktion der unabhängigen Variablen $\mathbf{X} = (X_1, X_2, \dots, X_k)$. Der Erwartungswert von Y wird durch den Parameter λ repräsentiert, der wiederum eine Funktion der unabhängigen Variablen ist. Die Beziehung wird typischerweise durch eine logarithmische Verknüpfungsfunktion beschrieben:

$$\log(\lambda_i) = \mathbf{X}_i^\top \boldsymbol{\beta} \quad (3.5)$$

Dies kann auch als

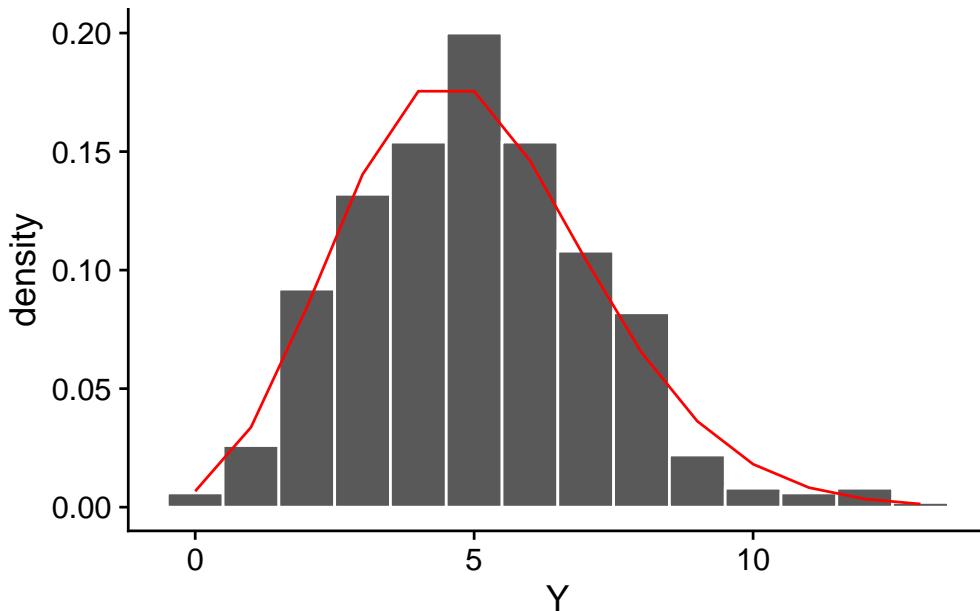


Abbildung 3.2: Stichprobenverteilung und Poisson-Dichtefunktion

$$\lambda_i = \exp(\mathbf{X}_i^\top \boldsymbol{\beta}) \quad (3.6)$$

geschrieben werden, wobei:

- λ_i der Erwartungswert von Y für Beobachtung i ,
- \mathbf{X}_i der Vektor der unabhängigen Variablen für Beobachtung i und
- $\boldsymbol{\beta}$ der Vektor der Regressionskoeffizienten ist.

3.2.3 Modellanpassung

Die Parameter $\boldsymbol{\beta}$ werden durch Maximum-Likelihood-Schätzung (MLE) geschätzt. Die Likelihood-Funktion für n Beobachtungen ist gegeben durch

$$L(\boldsymbol{\beta}) = \prod_{i=1}^n \frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!}. \quad (3.7)$$

Die Log-Likelihood-Funktion ist daher

$$\mathcal{L}(\boldsymbol{\beta}) = \sum_{i=1}^n (y_i \log(\lambda_i) - \lambda_i - \log(y_i!)) \quad (3.8)$$

Da $\lambda_i = \exp(\mathbf{X}_i^\top \boldsymbol{\beta})$, wird die Log-Likelihood-Funktion zu

$$\mathcal{L}(\boldsymbol{\beta}) = \sum_{i=1}^n \left(y_i (\mathbf{X}_i^\top \boldsymbol{\beta}) - \exp(\mathbf{X}_i^\top \boldsymbol{\beta}) - \log(y_i!) \right) \quad (3.9)$$

Den Maximum-Likelihood-Schätzer $\hat{\boldsymbol{\beta}}$ erhalten wir durch Maximierung der Log-Likelihoodfunktion $\mathcal{L}(\boldsymbol{\beta})$. Eine R-Implementierung finden wir in `stats::glm()`.

3.2.4 Interpretation der Koeffizienten

Die Koeffizienten $\boldsymbol{\beta}$ in der Poisson-Regression haben eine log-lineare Beziehung zur Zählvariable. Für einen bestimmten Koeffizienten β_j ist die Interpretation wie folgt:

- Ein Anstieg der unabhängigen Variable X_j um eine Einheit führt zu einer Änderung des *Logarithmus* des Erwartungswertes von Y um β_j .
- Der Erwartungswert λ ändert sich *multiplikativ* um $\exp(\beta_j)$.

Angenommen, wir haben eine unabhängige Variable X (z.B. die Anzahl der durchgeführten Werbekampagnen) und eine Zählvariable Y (z.B. die Anzahl der Verkäufe). Das Modell könnte wie folgt aussehen:

$$\log(\lambda) = \beta_0 + \beta_1 X \quad (3.10)$$

Wenn $\beta_1 = 0.5$, bedeutet dies, dass jede zusätzliche Werbekampagne die erwartete Anzahl der Verkäufe um einen Faktor von $\exp(0.5) \approx 1.65$ erhöht. Das heißt, die *Rate* der Verkäufe steigt um 65% für jede zusätzliche Werbekampagne.

```
# Setze den Zufallszahlengenerator für Reproduzierbarkeit
#set.seed(1234)

# Anzahl der Beobachtungen
```

```

n <- 500

# Simuliere die unabhängige Variable X (Anzahl der
# Werbekampagnen)
X <- sample(1:8, replace = T, size = n)

# Setze die wahren Parameter für das Modell
beta_1 <- 0.4 # Koeffizient für X

# Berechne den Erwartungswert lambda basierend auf dem Modell
lambda <- exp(2 + beta_1 * X)

# Simuliere die abhängige Variable Y (Anzahl der Verkäufe) als
# Poisson-verteilte Zufallsvariable
Y <- rpois(n, lambda = lambda)

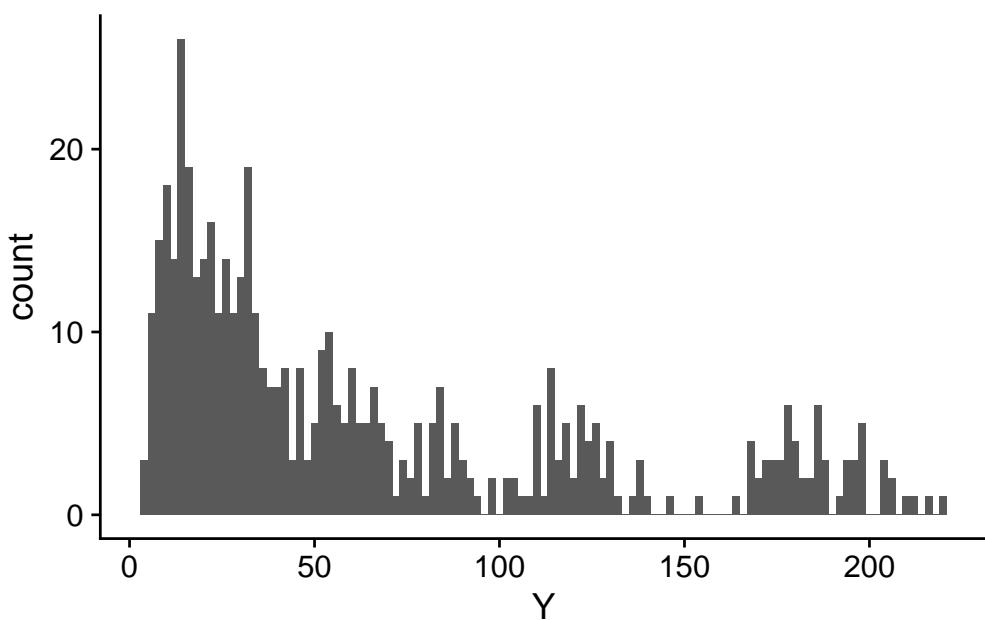
dat <- tibble(X = X, Y = Y)

```

```

ggplot(
  data = dat,
  mapping = aes(x = Y)
) +
  geom_histogram(binwidth = 2) +
  theme_cowplot()

```



```

# Poisson-Regression schätzen
model <- glm(
  formula = Y ~ X,
  family = poisson(link = "log"),
  data = dat
)

# Zusammenfassung des gesch. Modells
summary(model)

```

Call:
`glm(formula = Y ~ X, family = poisson(link = "log"), data = dat)`

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.996150	0.019432	102.7	<2e-16 ***
X	0.402650	0.002977	135.3	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 22952.0 on 499 degrees of freedom
Residual deviance: 527.4 on 498 degrees of freedom
AIC: 3329.2

Number of Fisher Scoring iterations: 4

```

# Vorhersagen
dat$predicted <- predict(model, type = "response")

# Simulierte Daten und Schätzungen
ggplot(
  data = dat,
  mapping = aes(x = X, y = Y)
) +
  geom_point(
    mapping = aes(color = "Simulierte Daten"),

```

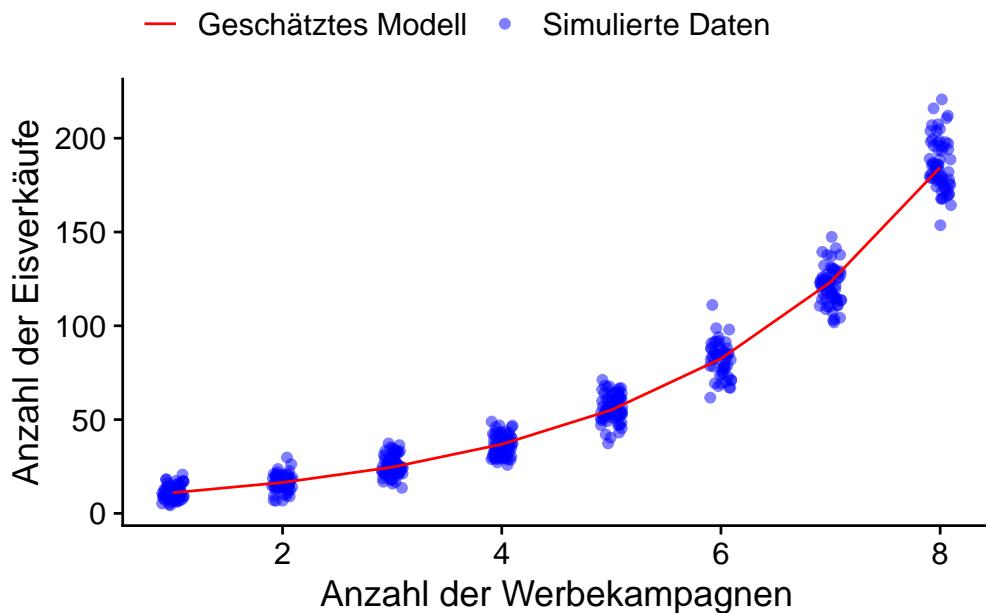


Abbildung 3.3: Simulierte Daten und angepasstes Poisson-Modell

```

alpha = 0.5,
position = position_jitter(width = .1)
) +
geom_line(
  aes(y = predicted, color = "Geschätztes Modell")
) +
labs(
  x = "Anzahl der Werbekampagnen",
  y = "Anzahl der Eisverkäufe"
) +
scale_color_manual(
  "",
  values = c(
    "Simulierte Daten" = "blue",
    "Geschätztes Modell" = "red"
  )
) +
theme_cowplot() +
theme(legend.position = "top")

```

4 Matching

```
#| context: setup
# create dataset directory
dir.create("datasets")
# Download the dataset
download.file(
  "https://raw.githubusercontent.com/mca91/causal_data/main/darkmode.csv",
  'datasets/darkmode.csv',
)
```

```
#| context: setup
library(dplyr)
# make darkmode available using read.csv for now
# because there's some issue with readr::read_csv
# I can't fix right now
darkmode <- read.csv(
  file = "datasets/darkmode.csv",
  colClasses = c("numeric", "logical", "numeric", "numeric",
  "numeric"))
options(pillar.bold = TRUE, pillar.subtle = FALSE)
```

In randomisierten kontrollierten Studien stellt eine randomisierte Behandlung sicher, dass die Individuen beider Gruppen im Mittel vergleichbar sind, dass heißt es gibt keine systematischen Unterschiede der Studiensubjekte hinsichtlich der Verteilung von Charakteristika zwischen den Gruppen. Dann ist es plausibel eine beobachtete mittlere Differenz in der Outcome-Variable alleine auf die Behandlung zurückzuführen.

In der Praxis, insbesondere in ökonomischen Studien, sind randomisierte kontrollierte Studien aus ethischen und/oder finanziellen Gründen nicht durchführbar. Stattdessen werden nicht-experimentelle Daten genutzt, die jedoch nur sehr selten eine Vergleichbarkeit von Behandlungs- und Kontrollgruppe gewährleisten.

In diesem Kapitel betrachten wir Methoden, die in solchen Forschungsdesigns – bei hinreichenden Informationen über die Studiensubjekte – eine Schätzung kausaler Effekte ermöglichen, indem eine statistische Vergleichbarkeit von Behandlungs- und Kontrollgruppe hergestellt wird. Dies kann durch eine gezielte Gewichtung von Beobachtungen anhand individueller Merkmale bei der Schätzung des Behandlungseffekts erfolgen. Andere etablierte Methoden schätzen den kausalen Effekt nach Selektion von vergleichbaren Teilmengen von Subjekten beider Gruppen aus der ursprünglichen Stichprobe, sogenanntes *selektierendes Matching*.

Da Matching Beobachtungen basierend auf beobachtbaren Merkmalen vergleicht, kann die Wahrscheinlichkeit einer verzerrten Schätzung des kausalen Effekt durch falsche Modellspezifikationen geringer sein als für eine Schätzung des Effekts anhand multipler Regression. Weiterhin basieren Matching-Methoden nicht auf der Annahme eines linearen Zusammenhangs zwischen Kovariablen und der erklärenden Variable und können für die Schätzung unterschiedlicher Spezifikationen von Behandlungseffekten herangezogen werden.

Für die Gültigkeit eines Schätzers basierend auf Matching sind zwei Annahmen erforderlich.

1. **Bedingte Unabhängigkeit.** Seien $Y_i^{(0)}$ und $Y_i^{(1)}$ potentielle Ergebnisse der Outcome-Variable Y für ein Subjekt i mit $B_i = 0$ (keine Zuweisung zur Behandlung) beziehungsweise $B_i = 1$ (Behandlung) und X_i die beobachteten Kovariablen. Wir nehmen an, dass

$$\{Y_i^{(0)}, Y_i^{(1)}\} \perp B_i | X_i, \quad (4.1)$$

d.h. die Behandlungszuweisung/-selektion ist unabhängig von den potentiellen Ergebnissen $Y_i^{(0)}$ und $Y_i^{(1)}$, wenn wir für die Kovariablen X kontrollieren.

2. **Überlappung.** Für jede mögliche Kombination von Kovariablen X_i gibt es eine positive Wahrscheinlichkeit < 1 , sowohl zur Behandlungsgruppe ($B_i = 1$) als auch zur Kontrollgruppe ($B_i = 0$) zugewiesen zu werden,

$$0 < P(B_i = 1 | X_i) < 1, \quad (4.2)$$

d.h. keine Beobachtung hat eine Behandlungswahrscheinlichkeit von exakt 0 oder 1.

Annahme 1 stellt sicher, dass die Zuweisung zur Behandlungsgruppe nach Kontrolle für die Kovariablen X als zufällig betracht werden kann. Somit ist es möglich den kausalen Effekt der Behandlung zu identifizieren, indem wir hinsichtlich der Kovariablen X ähnliche Subjekte (vgl. Annahme 2) aus Kontroll- und Behandlungsgruppe vergleichen.

Annahme 2 setzt voraus, dass es eine ausreichende Überlappung in den Verteilungen der Kovariablen zwischen Behandlungs- und Kontrollgruppe gibt. Dann ist sichergestellt, dass für jedes Subjekt in einer Gruppe ein hinsichtlich seiner Charakteristika vergleichbares Subjekt in der anderen Gruppe geben kann, sodass ein Vergleich möglich ist.

4.1 ***Balance: Vergleichbarkeit von Behandlungs- und Kontrollgruppe***

Der Lehrstuhl für Ökonometrie an der Universität Duisburg-Essen betreibt einen Ökonometrie-Blog und interessiert sich für den kausalen Effekt der Einführung eines [darkmode](#) auf die Verweildauer der User auf der Webseite. Die Webseite ist zwar nicht-kommerziell, hat sich allerdings insb. für die Aquise internationaler Studierender für den Studiengang MSc. Econometrics als wichtiges Marketing-Instrument erwiesen. Ein anprechendes Design wird daher als hoch-relevant erachtet.

Idealerweise sollte der Effekt des Design-Relaunches auf die Nutzungsintensität in einem kontrollierten randomisierten Experiment untersucht werden. Hierbei würden wir Nutzern zufällig das neue oder das alte Design zuweisen und den Effekt als Differenz des durchschnittlichen Verweildauer für die Gruppen bestimmen. Eine solche Studie ist jedoch aus technischen und finanziellen Gründen nicht realisierbar, sodass die Auswirkungen des darkmode mit vorliegenden nicht-experimentellen Nutzungsstatistiken für die Webseite geschätzt werden sollen.

Die Nutzungsstatistiken sind im Datensatz [*darkmode.csv*](#) enthalten und sollen der Analyse des Effekts des darkmode (`dark_mode`) auf die Verweildauer der Leser auf der Webseite (`read_time`) dienen.

Tabelle 4.1 zeigt die Definitionen der Variablen in *darkmode.csv*.

Tabelle 4.1: Variablen im Datensatz *darkmode*

Variable	Beschreibung
read_time	Lesezeit (Minuten/Woche)
dark_mode	Indikator: Beobachtung nach Einführung darkmode
male	Indikator: Individuum männlich
age	Alter (in Jahren)
hours	Bisherige Verweildauer auf der Seite

Für die Analyse lesen wir zunächst den Datensatz *darkmode.csv* mit `readr::read_csv()` ein und verschaffen uns einen Überblick über die verfügbaren Variablen.

```
# Paket `tidyverse` laden
library(tidyverse)

# Datensatz 'darkmode' einlesen
darkmode <- read_csv(
  file = "datasets/darkmode.csv"
)
```

`dark_mode` hat den Typ `logical`. Mit `dplyr::mutate_all()` können wir komfortabel alle Spalten in den Typ `numeric` transformieren.

```
# Alle Variablen zu typ 'numeric' formatieren...
darkmode <- darkmode %>%
  mutate_all(.funs = as.numeric)

# ... und überprüfen
glimpse(darkmode)
```

```
Rows: 300
Columns: 5
$ read_time <dbl> 14.4, 15.4, 20.9, 20.0, 21.5, 19.5, 22.0,
17.4, 23.6, 15.7, ~
$ dark_mode <dbl> 0, 0, 1, 0, 1, 0, 1, 0, 0, 0, 1, 0, 1, 1,
1, 1, 0, 0, 0, ~
$ male      <dbl> 0, 1, 0, 0, 0, 0, 0, 0, 0, 1, 0, 1, 0,
1, 0, 1, 0, 0, ~
```

```
$ age      <dbl> 43, 55, 23, 41, 29, 64, 18, 53, 59, 53, 43,
38, 42, 23, 39, ~
$ hours    <dbl> 65.6, 125.4, 642.6, 129.1, 190.2, 185.3,
333.5, 279.3, 1302.~
```

Eine naive Schätzung des durchschnittlichen Behandlungseffekts (ATE) $\hat{\tau}^{\text{naiv}}$ erhalten wir als Mittelwertdifferenz von `read_time` für die Behandlungsgruppe (`dark_mode == 1`) und die Kontrollgruppe (`dark_mode == 0`)

$$\hat{\tau}^{\text{naiv}} = \overline{\text{read_time}}_{\text{Behandlung}} - \overline{\text{read_time}}_{\text{Kontrolle}}. \quad (4.3)$$

Diese Berechnung ist schnell mit R durchgeführt.

```
# Naiver Schätzer für ATE:
# Differenz der Gruppen-Durchschnitte

# Outcome in Behandlungsgruppe
read_time_mTG <- darkmode %>%
  filter(dark_mode == 1) %>%
  pull("read_time")

# Outcome in Kontrollgruppe
read_time_mKG <- darkmode %>%
  filter(dark_mode == 0) %>%
  pull("read_time")

# Mittelwert-Differenz
mean(read_time_mTG) - mean(read_time_mKG)
```

```
[1] -0.4446331
```

Die Schätzung ergibt einen negativen Behandlungseffekt, mit der Interpretation, dass das neue Design zu einer Reduktion der Lesezeit um etwa 0.44 Minuten pro Woche führt. Dieses Ergebnis ist allerdings zweifelhaft, weil eine Isolierung des Behandlungseffekts aufgrund von Backdoor-Pfaden im DGP vermutlich nicht gewährleistet ist. Ein Indikator hierfür sind systematische Unterschiede hinsichtlich von (möglicherweise unbeobachtbaren) Charakteristika von Kontrollgruppe und Behandlungsgruppe.

Da die User sich beim Aufrufen der Seite aktiv für oder gegen den das neue Design entscheiden müssen (und somit selektieren, ob Sie in der Behandlungs-

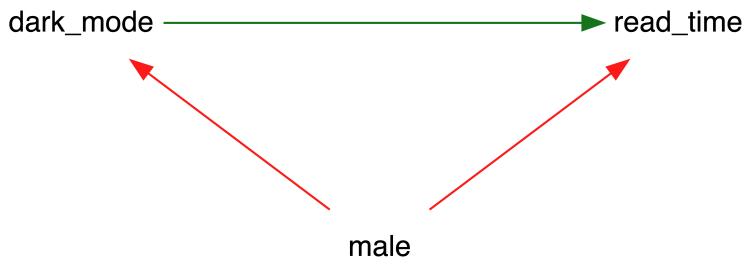


Abbildung 4.1: Backdoor durch ‘male’ im Website-Design-Bespiel

oder Kontrollgruppe landen), liegt wahrscheinlich *Confounding* vor: Unsere Hypothese ist zunächst, dass männliche User eine durchschnittlich längere Lesezeit aufweisen *und* mit größerer Wahrscheinlichkeit auf das neue Design wechseln als nicht-männliche Leser. Dann ist `male` eine Backdoor-Variable. Diese Situation ist unter der Annahme, dass nur diese Faktoren den DGP bestimmen, in Abbildung 4.1 dargestellt.

Der DGP in Abbildung 4.1 führt zu einer verzerrten Schätzung des kausalen Effekts von `dark_mode` auf `read_time` mit (4.3), wenn das Verhältnis von männlichen und nicht-männlichen Usern in Behandlungs- und Kontrollgruppe nicht ausgeglichen ist. Wir überprüfen dies mit R.

```

# Anteile männlicher und nicht-männlicher User
(
  anteile <- darkmode %>%
  group_by(dark_mode) %>%
  summarise(
    gesamt = n(),
    ant_m = mean(male),
    ant_nm = 1 - ant_m,
    anz_m = sum(male),
    anz_nm = gesamt - anz_m
  )
)

# A tibble: 2 x 6
  dark_mode gesamt ant_m ant_nm anz_m anz_nm
  <dbl>     <int> <dbl>   <dbl> <dbl>   <dbl>
1       0      151  0.338   0.662    51     100
2       1      149  0.658   0.342    98      51

```

Die Zusammenfassung `anteile_m` zeigt, dass der Anteil männlicher User in der Behandlungsgruppe deutlich höher ist als in der Kontrollgruppe.

4.1.1 Matching durch Gewichtung

Matching eliminiert die Variation von `male` zwischen den Gruppen. Eine Möglichkeit hierfür ist die Gewichtung der Beobachtungen in der Kontrollgruppe entsprechend der Anteile von Männern und Nicht-Männern in der Behandlungsgruppe, sodass die Vergleichbarkeit mit der Behandlungsgruppe hinsichtlich des Geschlechts gewährleistet ist. Dies wird in der Literatur als *Balance* bezeichnet. Der Behandlungseffekt wird dann analog zu (4.3) geschätzt.

Die Gewichte für Beobachtungen in der Kontrollgruppe w_i werden berechnet als

$$w_i = \begin{cases} \text{ant_m}_B / \text{anz_m}_K, & \text{falls male}_i = 1 \\ \text{ant_nm}_B / \text{anz_nm}_K, & \text{sonst.} \end{cases} \quad (4.4)$$

Anhand der Formel für einen gewichteten Durchschnitt,

$$\bar{X}_w = \frac{\sum_i w_i \cdot X_i}{\sum_i w_i}, \quad (4.5)$$

berechnen wir die gewichteten Mittelwerte für `male` und `read_time` in der Kontrollgruppe.

```
# Anteile und Anzahlen aus `anteile` auslesen
anz_m_K <- anteile %>%
  filter(dark_mode == 0) %>% pull(anz_m)

anz_nm_K <- anteile %>%
  filter(dark_mode == 0) %>% pull(anz_nm)

ant_m_B <- anteile %>%
  filter(dark_mode == 1) %>% pull(ant_m)

ant_nm_B <- anteile %>%
  filter(dark_mode == 1) %>% pull(ant_nm)
```

```
# Gewichtete Mittel für Kontrollgruppe berechnen
(
```

```

gew_K <- darkmode %>%
  filter(dark_mode == 0) %>%
  select(read_time, male) %>%
  mutate(w = ifelse(
    male == 1,
    ant_m_B/anz_m_K,
    ant_nm_B/anz_nm_K)
  ) %>%
  summarise(
    male_k = sum(male * w) / sum(w),
    mean_read_time_wK = sum(read_time * w) / sum(w)
  )
)

```

```

# A tibble: 1 x 2
  male_k  mean_read_time_wK
  <dbl>      <dbl>
1 0.658      18.1

```

Ein Vergleich des gewichteten Mittelwertes von `male` in der Kontrollgruppe mit dem Mittelwert in der Behandlungsgruppe (`male_k`) zeigt, dass die Gewichte die Variation in `male` zwischen beiden Gruppen eliminieren, sodass die Backdoor durch `male` geschlossen ist. Mit `wmean_read_time_K` haben wir einen entsprechend gewichteten Mittelwert der Verweildauer für die Kontrollgruppe berechnet. Wir schätzen den Behandlungseffekt nun als

$$\hat{\tau}^w = \overline{\text{read_time}}_B - \overline{\text{read_time}}_{w,K}. \quad (4.6)$$

```
mean(read_time_mTG) - gew_K$mean_read_time_wK
```

```
[1] 0.6383579
```

Entgegen der naiven Schätzung andhand von (4.3) erhalten wir nach Matching für `male` eine positive Schätzung des Behandlungseffekts von etwa 0.64.

Die Schätzung des Behandlungseffekts anhand von (4.6) entspricht dem geschätzten Koeffizienten $\hat{\beta}_1$ aus einer gewichteten KQ-Regression im Modell

$$\text{read_time} = \beta_0 + \beta_1 \text{dark_mode} + u,$$

wobei die Beobachtungen der Kontrollgruppe wie in (4.4) gewichtet werden und $w_i = 1$ für Beobachtungen der Behandlungsgruppe ist. Wir überprüfen dies mit R.

```
darkmode_w <- darkmode %>%
  mutate(
    w = case_when(
      male == 1 & dark_mode == 0 ~ ant_m_B/anz_m_K,
      male == 0 & dark_mode == 0 ~ ant_nm_B/anz_nm_K,
      T ~ 1
    )
  )

lm(read_time ~ dark_mode, weights = w, data = darkmode_w) %>%
  summary()
```

Call:

```
lm(formula = read_time ~ dark_mode, data = darkmode_w, weights =
w)
```

Weighted Residuals:

Min	1Q	Median	3Q	Max
-11.4302	-0.6929	0.0814	0.7230	12.8698

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	18.0918	3.4796	5.199	3.72e-07 ***
dark_mode	0.6384	3.4912	0.183	0.855

Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
	0.1	' '	1	

Residual standard error: 3.48 on 298 degrees of freedom

Multiple R-squared: 0.0001122, Adjusted R-squared: -0.003243

F-statistic: 0.03343 on 1 and 298 DF, p-value: 0.855

Der geschätzte Koeffizient von `dark_mode` entspricht $\hat{\tau}^w$.

Da `male` eine binäre Variable ist, reduziert sich eine Beurteilung der Vergleichbarkeit der Verteilungen von `male` in Behandlungs- und Kontrollgruppe auf einen simplen Vergleich des Männeranteils beider Gruppen. In der Praxis gibt

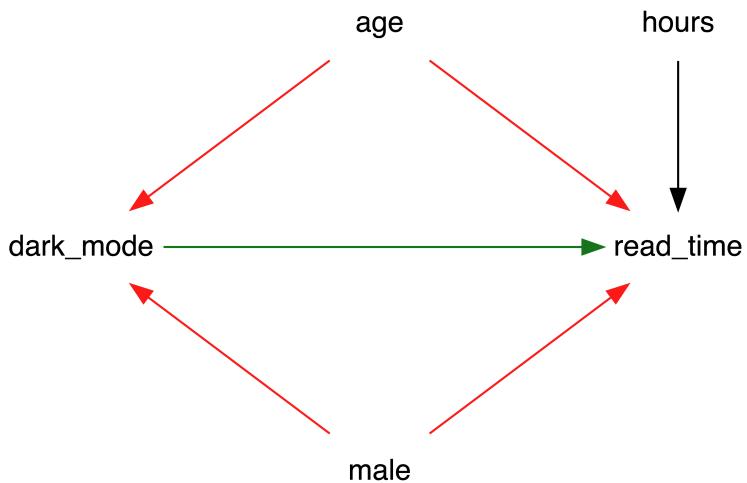


Abbildung 4.2: Erweiterter DGP im Website-Design-Beispiel

es meist eine Vielzahl potentieller Backdoor-Variablen, die zudem kontinuierlich verteilt sind. Es scheint plausibel, dass das Alter der Nutzer sowohl die Akzeptanz des Design-Updates als auch die Lesezeit beeinflusst. Die bisherige Verweildauer ist mindestens eine plausible Determinante der Lesezeit.

Der erweiterte DGP ist in Abbildung Abbildung 4.2 dargestellt, wobei der zusätzliche Backdoor-Pfad durch `age` ebenfalls mit roten Pfeilen gekennzeichnet sind.

Die Beurteilung der *Balance* von Kontrollgruppe und Behandlungsgruppe kann durch eine grafische Gegenüberstellung der empirischen Verteilungen der Kovariablen beider Gruppen erfolgen. Wir visualisieren die empirischen Verteilungen mit `ggplot2`. Hierzu standardisieren wir `age` und `hours` zunächst mit `scale()`.

```

# Datensatz für graphische Darstellung formatieren
darkmode_p <- darkmode %>%
  # Standardisierung mit 'scale()'
  mutate(
    dark_mode = as_factor(dark_mode),
    age = scale(age),
    hours = scale(hours)
  )

head(darkmode_p)

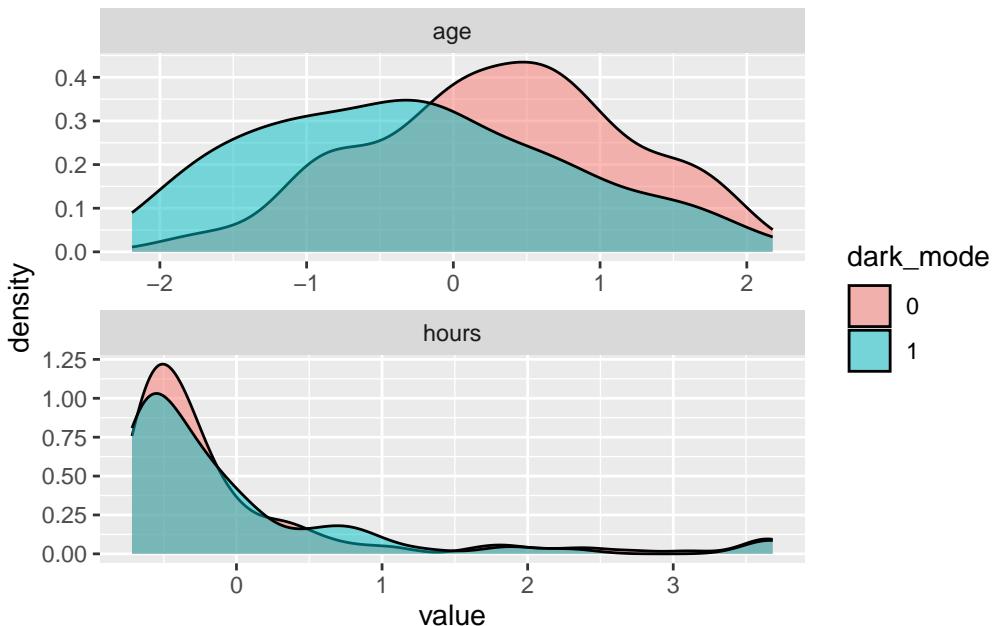
```

```
# A tibble: 6 x 5
  read_time dark_mode male age[,1] hours[,1]
  <dbl> <fct>    <dbl>   <dbl>    <dbl>
1 14.4 0        0  0.0377 -0.591
2 15.4 0        1  1.11   -0.459
3 20.9 1        0 -1.74   0.684
4 20     0        0 -0.141 -0.451
5 21.5 1        0 -1.21   -0.316
6 19.5 0        0  1.91   -0.327
```

Für `age` und `hours` eignen sich die geschätzten Dichtefunktionen für einen Vergleich der Verteilungen in Behandlungs- und Kontrollgruppe.

```
# Vergleich mit Dichteschätzungen
darkmode_p %>%
  select(dark_mode, hours, age) %>%
  # in langes Format überführen
  pivot_longer(cols = c(-dark_mode)) %>%

  ggplot(
    aes(x = value, fill = dark_mode)
  ) +
  geom_density(alpha = .5) +
  facet_wrap(
    facets = ~ name,
    scales = "free",
    nrow = 2
  )
```



Die graphische Analyse zeigt deutliche Unterschiede in den Verteilungen von `age` zwischen Kontroll- und Behandlungsgruppe. Für einen Beurteilung mit deskriptiven Statistiken wird häufig eine sogenannte *Balance Table* herangezogen. Wir berechnen diese für `age`, `hours` und `male` mit `cobalt::bal.tab()`

```
library(cobalt)

# Balance table mit 'cobalt::bal.tab()'
bal.tab(
  x = darkmode %>%
    select(age, hours, male),
  treat = darkmode$dark_mode,
  # berechne SMD für KG und TG:
  disp = "m",
  s.d.denom = "pooled"
)
```

Balance Measures

	Type	M.0.Un	M.1.Un	Diff.Un
age	Contin.	46.0132	39.0940	-0.6469
hours	Contin.	337.7775	328.5738	-0.0203
male	Binary	0.3377	0.6577	0.3200

Sample sizes

	Control	Treated
All	151	149

Die Einträge `M.0.Un` und `M.1.Un` zeigen die jeweiligen Stichprobenmittelwerte der Variablen für Kontroll- und Behandlungsgruppe. `Diff.Un` gibt eine standardisierte Mittelwertdifferenz *SMD* an, wobei

$$SMD_j := \left(\bar{X}_{j,B} - \bar{X}_{j,K} \right) / \sqrt{\frac{1}{2} \left(\widehat{\text{Var}}(X_{j,B}) + \widehat{\text{Var}}(X_{j,K}) \right)},$$

mit Stichprobenmitteln $\bar{X}_{j,B}$ und $\bar{X}_{j,K}$ und Stichprobenvarianzen $\widehat{\text{Var}}(X_{j,B})$ und $\widehat{\text{Var}}(X_{j,K})$ für eine kontinuierliche Kovariablen j .¹ Obwohl es keinen einheitlichen Schwellenwert für die standardisierte Differenz gibt, der ein erhebliches Ungleichgewicht anzeigen, gilt für kontinuierliche Variablen eine standardisierte (absolute) Differenz von weniger als 0.1 als Hinweis auf einen vernachlässigbaren Unterschied zwischen den Gruppen.

Die Balance Table weist also auf einen vernachlässigbaren Unterschied für `hours` hin und bestätigt den aus den Grafiken abgeleiteten Eindruck einer relevanten Differenzen für `age`.

4.1.2 Entropy Balancing

Entropy Balancing (Hainmueller 2012) ist eine weitere Methode zur Gewährleistung der Vergleichbarkeit von Behandlungs- und Kontrollgruppe anhand von Gewichten. Das Verfahren nutzt Konzepte aus der [Informationstheorie](#) um die Gewichte für Subjekte in der Kontrollgruppe so anzupassen, dass die Verteilung der Matchingvariablen in der Kontrollgruppe die Verteilung in der Behandlungsgruppe möglichst gut approximiert. Dies geschieht unter der Restriktion, dass bestimmte empirische Momente (meist Mittelwerte und Varianzen) der Matchingvariablen exakt übereinstimmen. Mathematisch werden die Gewichte für Kontrollgruppenbeobachtungen durch Minimierung der [Kullback-Leibler-Divergenz](#) zwischen den Verteilungen gefunden, wobei die Divergenz ein Maß für den Unterschied von Wahrscheinlichkeitsverteilungen ist.

Entropy Balancing ist im R-Paket `WeightIt` implementiert. Wir zeigen, wie die benötigten Gewichte für eine Schätzungen des ATT im Website-Beispiel mit `WeightIt::wightit()` bestimmt werden können. Über das Argument `moments` legen wir fest, dass die Gewichte unter der Restriktion übereinstimmender Mittelwerte aller Matching-Variablen zwischen Behandlungs- und Kontrollgruppe erfolgen soll.

¹Siehe P. Austin (2011) für einen Überblick zu Balance-Statistiken.

```

library(WeightIt)

# Gewichte für Entropy Balancing
(
  W1 <- weightit(
    dark_mode ~ age + male + hours,
    data = darkmode,
    method = "ebal",
    estimand = "ATT",
    moments = 1
  )
)

```

A weightit object

- method: "ebal" (entropy balancing)
- number of obs.: 300
- sampling weights: none
- treatment: 2-category
- estimand: ATT (focal: 1)
- covariates: age, male, hours

Wir schätzen den Behandlungseffekt nach Entropy Balancing mit gewichteter Regression.

```

# Mittelwert-Vergleich mit lm()
fit <- lm(
  formula = read_time ~ dark_mode,
  data = darkmode,
  weights = W1$weights
)
summary(fit)

```

Call:

```
lm(formula = read_time ~ dark_mode, data = darkmode, weights =
W1$weights)
```

Weighted Residuals:

Min	1Q	Median	3Q	Max
-16.6652	-2.3552	0.8786	2.9585	27.1808

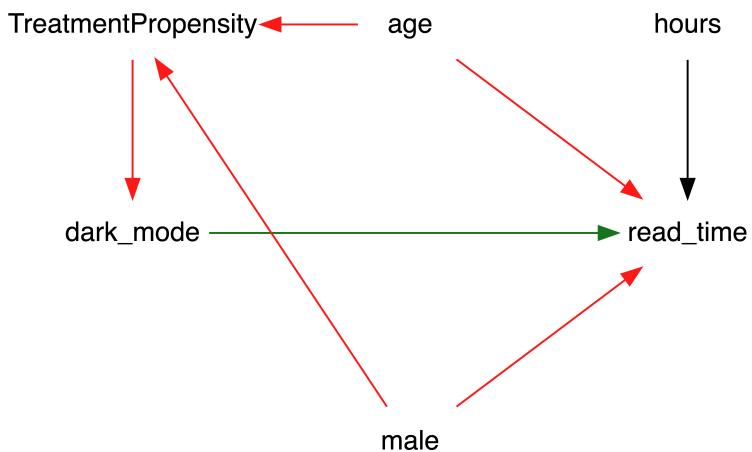


Abbildung 4.3: Propensity im Website-Design-Beispiel

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	17.7601	0.4093	43.395	<2e-16 ***
dark_mode	0.9701	0.5807	1.671	0.0959 .

Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
	0.1	' '	1	

Residual standard error: 5.029 on 298 degrees of freedom
 Multiple R-squared: 0.009278, Adjusted R-squared: 0.005953
 F-statistic: 2.791 on 1 and 298 DF, p-value: 0.09586

Beachte, dass die von `summary()` berechneten Standardfehler bei Entropy Balancing ungültig sind. In Abschnitt Kapitel 4.4 erläutern wir die Berechnung von Standardfehlern für Matching-Schätzer mit dem Bootstrap.

4.1.3 Mehrere Matching-Variablen und der Propensity Score

Bei mehreren Backdoor-Variablen kann eine Gewichtung anhand der Behandlungswahrscheinlichkeit (*Treatment Propensity*) erfolgen. Die Idee hierbei ist, dass der DGP wie in Abbildung 4.3 dargestellt werden kann.

Hierbei beeinflussen die Backdoor-Variablen *age* und *male* die Behandlungsvariable *dark_mode* lediglich durch die Behandlungswahrscheinlichkeit *Treatment Propensity*. Diese Darstellung zeigt, dass die mehrdimensionale Information bzgl. der Ähnlichkeit von Subjekten hinsichtlich der beobachteten Kovariablen in

einer einzigen Variable zusammengefasst werden kann. Die Backdoor-Pfade können daher geschlossen werden, indem wir Subjekte anhand von *Treatment Propensity* derart gewichten, dass beide Gruppen hinsichtlich der Verteilung der Behandlungswahrscheinlichkeit vergleichbar sind. Betrachte erneut (4.1) und beachte, dass

$$Y_i = Y_i^{(1)} D_i + Y_i^{(0)} (1 - D_i). \quad (4.7)$$

Rosenbaum und Rubin (1983) zeigen, dass es hinsichtlich (4.1) äquivalent ist für die *Treatment Propensity* $P_i(X_i) := P(B_i = 1|X_i = x)$ zu kontrollieren, d.h.

$$\{Y_i^{(1)}, Y_i^{(0)}\} \perp B_i | X_i \Leftrightarrow \{Y_i^{(1)}, Y_i^{(0)}\} \perp B_i | P_i(X_i). \quad (4.8)$$

Der Behandlungseffekt kann so als Differenz von gewichteten Gruppenmittelwerten berechnet werden, mit inversem Wahrscheinlichkeitsgewicht (IPW) $w_{i,B} = 1/P_i(X_i)$ für Beobachtungen in der Behandlungsgruppe und $w_{i,K} = 1/(1 - P_i(X_i))$ für Beobachtungen in der Kontrollgruppe,

$$\tau^{\text{IPW}} = \frac{1}{n} \sum_{i=1}^n \left[\frac{B_i Y_i}{P_i(X_i)} - \frac{(1 - B_i) Y_i}{1 - P_i(X_i)} \right]. \quad (4.9)$$

Grundsätzlich ist *Treatment Propensity* eine nicht beobachtbare Variable und muss daher aus den Daten geschätzt werden. Eine geschätzte Behandlungswahrscheinlichkeiten $\hat{P}_i(X_i)$ wird als *Propensity Score* bezeichnet. In der Praxis erfolgt die Schätzung von *Propensity Scores* meist mit logistischer Regression. Ein erwartungstreuer Schätzer des ATE ist

$$\hat{\tau}^{\text{IPW}} = \frac{1}{n} \sum_{i=1}^n \left[\frac{B_i Y_i}{\hat{P}_i(X_i)} - \frac{(1 - B_i) Y_i}{1 - \hat{P}_i(X_i)} \right]. \quad (4.10)$$

Hirano, Imbens, und Ridder (2003) diskutieren Alternativen zu (4.10) für die Schätzung anderer Typen von Behandlungseffekten.

Wir schätzen nachfolgend die *Propensity Scores* für unser Anwendungsbeispiel, erläutern die Berechnung der Gewichte sowie die Schätzung von Behandlungseffekten mit gewichteter Regression. Hierbei betrachten wir eine Variante von (4.10) mit normalisierten Gewichten $\tilde{w}_{i,B} = w_{i,B} / \sum_i w_{i,B}$ und $\tilde{w}_{i,K} = w_{i,K} / \sum_i w_{i,K}$ die sich jeweils zu 1 summieren.² Dies ergibt den Hájek-

²Eine Normalisierung der Gewichte reduziert die Varianz des Schätzers, vgl. Hirano, Imbens, und Ridder (2003)

Schätzer³

$$\hat{\tau}_N^{\text{IPW}} = \frac{\sum_i \tilde{w}_{i,B} Y_i}{\sum_i \tilde{w}_{i,B}} - \frac{\sum_i \tilde{w}_{i,K} Y_i}{\sum_i \tilde{w}_{i,K}}. \quad (4.11)$$

Zunächst Schätzen wir ein logistisches Regressionsmodell mit `age`, `male` und `hours` als erklärende Variablen für `dark_mode`.

```
# Logit-Modell mit 'glm()' schätzen
(
  darkmode_ps_logit <- glm(
    formula = dark_mode ~ age + male + hours,
    data = darkmode,
    family = binomial
  )
)
```

```
Call: glm(formula = dark_mode ~ age + male + hours, family =
binomial,
  data = darkmode)

Coefficients:
(Intercept)      age       male      hours
2.330e+00   -7.330e-02   1.623e+00  -9.293e-05

Degrees of Freedom: 299 Total (i.e. Null); 296 Residual
Null Deviance: 415.9
Residual Deviance: 346.4 AIC: 354.4
```

Die *Propensity Scores* erhalten wir als angepasste Werte aus der Regression `darkmode_ps_logit` mit `fitted()`. Wir erweitern den Datensatz mit den Ergebnissen.

```
# Datensatz um Propensity Scores erweitern
(
  darkmode_probs <-
    darkmode %>%
    mutate(
```

³Siehe Hájek (1971).

```

    PS = fitted(darkmode_ps_logit)
  )
)

# A tibble: 300 x 6
  read_time dark_mode male   age  hours      PS
  <dbl>     <dbl> <dbl> <dbl> <dbl> <dbl>
1 14.4       0     0    43   65.6 0.304
2 15.4       0     1    55  125.  0.478
3 20.9       1     0    23   643.  0.642
4 20          0     0    41   129.  0.335
5 21.5       1     0    29   190.  0.547
6 19.5       0     0    64   185.  0.0849
7 22          1     0    18   334.  0.727
8 17.4       0     0    53   279.  0.171
9 23.6       0     0    59   1303. 0.108
10 15.7      0     0    53   16.1  0.174
# i 290 more rows

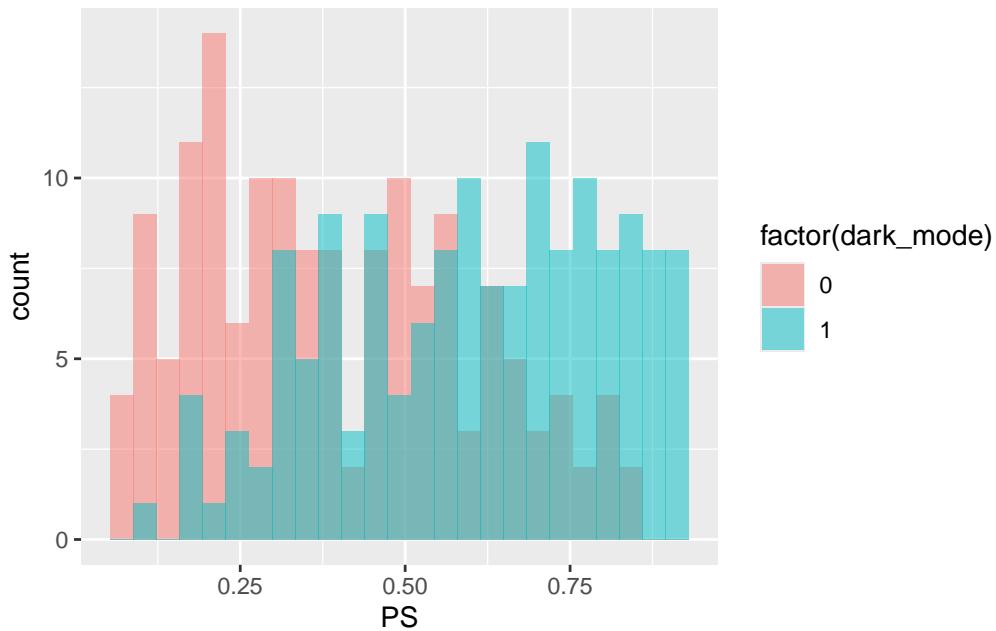
```

Zur Beurteilung der Überlappung (vgl. Annahme (4.2) können wir die Verteilung der *Propensity Scores* nach Behandlungs-Indikator mit Histogrammen visualisieren.

```

# Überlappung prüfen:
# Histogramme der PS nach Treatment-Indikator
darkmode_probs %>%
  ggplot(
    mapping = aes(
      x = PS,
      fill = factor(dark_mode)
    )
  ) +
  geom_histogram(
    alpha = .5,
    bins = 25,
    position = "identity"
  )

```



Ein Vergleich der Histogramme zeigt, dass die Überlappung der *Propensity Scores* in der linken Flanken der Verteilungen der Kontrollgruppe und in der rechten Flanke der Behandlungsgruppe schlechter wird. Wir entfernen zunächst Beobachtungen aus der Stichprobe deren *Propensity Scores* wenig bzw. keine Überlappung aufweisen.

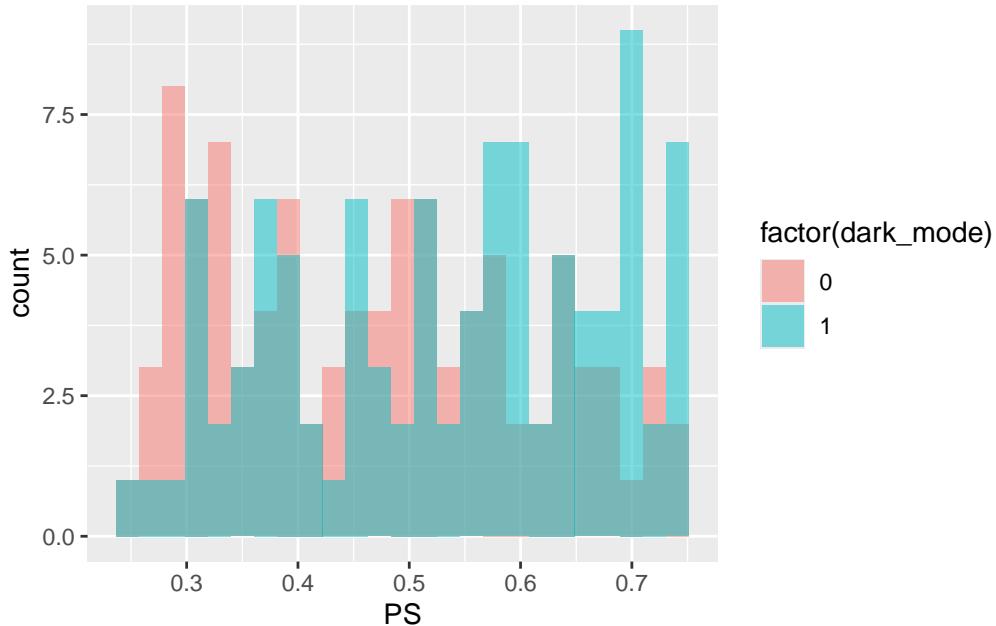
```
# Datensatz nach PS trimmen
darkmode_probs <- darkmode_probs %>%
  filter(
    between(
      x = PS,
      left = .25,
      right = .75
    )
  )
```

```
# Überlappung nach trimming prüfen:
# Dichteschätzung der PS nach Treatment-Indikator
darkmode_probs %>%
  ggplot(
    mapping = aes(
      x = PS,
      fill = factor(dark_mode))
  ) +
```

```

geom_histogram(
  alpha = .5,
  bins = 25,
  position = "identity"
)

```



IPWs anhand der *Propensity Scores* können schnell mit der Vorschrift

$$\text{IPW} = \frac{\text{dark_mode}}{\text{PS}} + \frac{1 - \text{dark_mode}}{1 - \text{PS}}, \quad (4.12)$$

berechnet werden.

```

# Datensatz um IPWs erweitern
darkmode_IPW <- darkmode_probs %>%
  mutate(
    IPW = dark_mode / PS + (1 - dark_mode) / (1 - PS)
  )

darkmode_IPW %>%
  select(IPW)

```

```

# A tibble: 194 x 1
  IPW
  <dbl>

```

```

1 1.44
2 1.91
3 1.56
4 1.50
5 1.83
6 1.38
7 1.43
8 1.47
9 2.71
10 1.42
# i 184 more rows

```

Eine Schätzung des durchschnittlichen Behandlungseffekts gemäß (4.11) implementieren wir mit `dplyr`.

```

darkmode_IPW %>%
  group_by(dark_mode) %>%
  mutate(w = IPW / sum(IPW)) %>%
  summarise(weighted_mean = sum(read_time * w)) %>%
  summarise(diff = diff(weighted_mean))

```

```

# A tibble: 1 x 1
  diff
  <dbl>
1 1.90

```

Diese Schätzung des Behandlungseffekts ist äquivalent zur gewichteten KQ-Schätzung anhand eines einfachen linearen Regressionsmodells.

```

# Mit IPWs gewichteter KQ-Schaetzer berechnet den ATE
model_ipw <- lm(
  formula = read_time ~ dark_mode,
  data = darkmode_IPW,
  weights = IPW
)

summary(model_ipw)

```

Call:

```
lm(formula = read_time ~ dark_mode, data = darkmode_IPW, weights = IPW)
```

Weighted Residuals:

Min	1Q	Median	3Q	Max
-18.5086	-4.4579	0.6096	4.1345	20.4566

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)							
(Intercept)	17.9709	0.4942	36.362	< 2e-16 ***							
dark_mode	1.9011	0.6952	2.735	0.00683 **							

Signif. codes:	0	'***'	0.001	'**'	0.01	'*'	0.05	'. '	0.1	' '	1

Residual standard error: 6.913 on 192 degrees of freedom

Multiple R-squared: 0.03749, Adjusted R-squared: 0.03248

F-statistic: 7.478 on 1 and 192 DF, p-value: 0.006829

Unsere Schätzung des ATE ist der geschätzte Koeffizient von `dark_mode`. Die ausgegebenen Standardfehler und Inferenzstatistiken sind jedoch *ungültig* aufgrund der Gewichtung mit IPWs, den inversen *geschätzten* Wahrscheinlichkeiten für eine Behandlung. Der Grund hierfür ist, dass die Berechnung der Standardfehler in `summary()` die zusätzliche Unsicherheit durch die geschätzten *Propensity Scores* nicht berücksichtigt! Später im Kapitel erläutern wir die Berechnung gültiger Standardfehler für IPW-Schätzer basierend auf *Propensity Scores* mit dem Bootstrap.

4.2 Selektierende Matching-Verfahren

Das grundsätzliche Konzept von selektierendem Matching wird in der nachstehenden interaktiven Grafik veranschaulicht. Hier betrachten wir beobachtete Ausprägungen von zwei (unabhängig und identisch verteilten) Matching-Variablen für Subjekte in der Behandlungsgruppe (blau) sowie Kontrollgruppe (rot). Als Matches qualifizieren sich sämtliche Beobachtungen der anderen Gruppe, deren [Euklidische Distanz](#) zu dem ausgewählten Punkt das über den Slider eingestellte Maximum *Caliper* nicht überschreitet.⁴ Diese Region wird durch den gestrichelten Kreis gekennzeichnet und kann über den zugehörigen Slider angepasst werden. Per Klick auf eine Beobachtung werden Matches aus

⁴Es handelt sich hierbei um einen Spezialfall von Matching anhand der Mahalanobis-Distanz.

der anderen Gruppe durch eine verbindende Linie und farbliches Hervorheben kenntlich gemacht. Mit dem Slider für k wird festgelegt, dass nur die nahesten k qualifizierten Beobachtungen als Matches behandelt werden. Die Grafik illustriert insbesondere, dass Beobachtungen in Abhängigkeit von k und Caliper falls gewünscht mehrfach (s.g. Matching mit Zurücklegen) oder gar nicht gematcht werden können.

Für die nachfolgenden Code-Beispiele verwenden wir das R-Paket `MatchIt`. `MatchIt::matchit()` nutzt standardmäßig Eins-zu-Eins-Matching (ohne Zurücklegen) von Beobachtungen der Treatment-Gruppe mit Beobachtungen der Kontrollgruppe.⁵ Die für das Matching zu verwendenden Variablen werden über das Argument `formula` als Funktion des Behandlungsindikators definiert. `matchit()` bereitet das Objekt für eine Schätzung des ATT mit einer geeigneten Funktionen, s. `?matchit` und hier insb. die Erläuterungen der Argumente `replace = F`, `ratio = 1` und `estimand = "ATT"` für Details. Mit `cobalt::balt.tab()` erhalten wir eine *balance table* für den gematchten Datensatz.

Wir zeigen als nächstes, wie `MatchIt::matchit()` für Matching anhand der Regressoren `age`, `hours`, und `male` in unserem Website-Beispiel für unterschiedliche Varianten durchgeführt werden kann.

4.2.1 Exaktes Matching

Exaktes Matching ordnet einem Subjekt aus der Behandlungsgruppe ein oder mehrere Subjekte aus der Kontrollgruppe zu, wenn die beobachteten Ausprägung der Matching-Variablen *exakt* übereinstimmen. Hierbei muss die ‘Distanz’ zwischen den Ausprägung der Matching-Variablen folglich 0 sein. Dieses Verfahren findet meist bei ausschließlich diskret verteilten Merkmalen Anwendung. Bei kontinuierlich verteilten Merkmalen (vgl. die obige interaktive Grafik) sind exakte Matches zwar theoretisch unmöglich, ergeben sich jedoch in der Praxis aus der Datenerfassung, bspw. durch Rundungsfehler. In `matchit()` erhalten wir exaktes Ein-zu-eins-Matching mit `method = "exact"`.

```
library(MatchIt)

# Exaktes Eins-zu-Eins-Matching durchführen
res_em <- matchit(
  formula = dark_mode ~ age + male + hours,
```

⁵Dieses Schema zielt auf eine Schätzung des ATT ab.

```

    data = darkmode,
    estimand = "ATT",
    method = "exact"
)

```

Error in `matchit()`:
! No exact matches were found.

```
res_em
```

Error in eval(expr, envir, enclos): object 'res_em' not found

Aufgrund der kontinuierliche Verteilten Variable `hours` gibt es in unserem Website-Beispiel keine exakten Matches. Dieses Verfahren ist hier folglich ungeeignet.

4.2.2 Coarsened Exact Matching

Bei dieser Methode werden kontinuierliche Matching-Variablen grob (Engl. *coarse*) klassiert, ähnlich wie bei einem Histogram. Diese Diskretisierung ermöglicht es exakte Übereinstimmungen zwischen Behandlungs- und Kontrollgruppenbeobachtungen hinsichtlich ihrer klassierten Ausprägungen zu finden. Sowohl Behandlungs- als auch Kontrollbeobachtungen die mindestens einen exakten Match haben, werden Teil des gematchten Datensatzes. In `matchit()` wird Coarsened Exact Matching mit `method = "cem"` durchgeführt. Über das Argument `cutpoints` geben wir an, dass `hours` in 6 Klassen und `age` in 4 Klassen eingeteilt werden soll.⁶ Mit `k1k = TRUE` erfolgt Eins-zu-eins-Matching: Bei mehreren exakten Matches wird die Beobachtung mit der geringsten Mahalanobis-Distanz (für die unklassierten Matching-Variablen) gewählt.

```

# Coarsened Exact Matching
res_CEM <- matchit(
  formula = dark_mode ~ age + male + hours,
  data = darkmode,
  estimand = "ATT",
  method = "cem",
  k2k = TRUE,
  cutpoints = list(

```

⁶Diese Werte wurden ad-hoc gewählt da sie zu einem guten Ergebnis führen.

```

    "hours" = 6,
    "age" = 4
)
)
res_CEM

```

A matchit object

- method: Coarsened exact matching
- number of obs.: 300 (original), 164 (matched)
- target estimand: ATT
- covariates: age, male, hours

```
# Balance-Table Coarsened Exact Matching
bal.tab(res_CEM)
```

Balance Measures

	Type	Diff.	Adj
age	Contin.	0.0106	
male	Binary	0.0000	
hours	Contin.	-0.0135	

Sample sizes

	Control	Treated
All	151	149
Matched	82	82
Unmatched	69	67

Mit Coarsened Exact Matching erhalten wir einen Datensatz mit 82 Beobachtungen und guter Balance.

4.2.3 Matching mit der Mahalanobis-Distanz

Die Euklidische Distanz misst den direkten Abstand zwischen zwei Punkten und ist nicht invariant gegenüber Transformationen, insbesondere bei unterschiedlichen Skalierungen und bei Korrelation der Matching-Variablen. Die Mahalanobis-Distanz hingegen ist ein standardisiertes Distanzmaß, das unter Berücksichtigung der Varianz-Kovarianz-Struktur der Daten angibt, wie viele Standardabweichungen zwei Datenpunkte voneinander entfernt sind. Die

Mahalanobis-Distanz ist invariant gegenüber linearen Transformationen (Skalierung, Translation und Rotation) der Daten und bietet ein genaueres Maß für die Unähnlichkeit zweier Beobachtungen hinsichtlich ihrer Ausprägungen der Matching-Variablen.

Betrachte die Datenpunkte $P_1 = (X_1, Y_1)'$ und $P_2 = (X_2, Y_2)'$ für die Matching-Variablen X und Y . Die Mahalanobis-Distanz zwischen P_1 und P_2 ist definiert als

$$d_M(P_1, P_2) = \sqrt{(P_1 - P_2)' \mathbf{S}^{-1} (P_1 - P_2)},$$

wobei \mathbf{S} die Varianz-Kovarianz-Matrix von X und Y ist. Die Mahalanobis-Distanz $d_M(P_1, P_2)$ ist also die Euklidische Distanz zwischen den standardisierten Datenpunkten.

In empirischen Anwendungen ersetzen wir die (unbekannten) Komponenten der Varianz-Kovarianz-Matrix durch Stichprobenvarianten. Dies ergibt die Formel

$$\hat{d}_M(P_1, P_2) = \sqrt{\begin{pmatrix} X_1 - X_2 \\ Y_1 - Y_2 \end{pmatrix}' \begin{pmatrix} \widehat{\text{Var}}(X^2) & \widehat{\text{Cov}}(X, Y) \\ \widehat{\text{Cov}}(X, Y) & \widehat{\text{Var}}(Y^2) \end{pmatrix}^{-1} \begin{pmatrix} X_1 - X_2 \\ Y_1 - Y_2 \end{pmatrix}}.$$

Die nachstehende interaktive Grafik zeigt Beobachtungen zweier Matching-Variablen, die aus einer bivariaten Normalverteilung mit positiver Korrelation generiert wurden. Diese bivariate Verteilung ist identisch für Beobachtungen aus der Kontrollgruppe (rot) und Beobachtungen aus der Behandlungsgruppe (blau). Für die ausgewählte Beobachtung aus der Behandlungsgruppe (schwarzer Rand) werden potentielle Matches in der Kontrollgruppe innerhalb der vorgegebenen Mahalanobis-Distanz in Cyan kenntlich gemacht. Beachte, dass die Mahalanobis-Distanz Varianzen und Kovarianzen der Daten berücksichtigt, sodass die gematchten Beobachtungen in einem elliptischen Bereich um die betrachtete behandelte Beobachtung liegen. Eine Euklidische Distanz hingegen (gestrichelte Linie) ignoriert die Skalierung der Daten.

Für Eins-zu-Eins-Matching im Website-Beispiel anhand der Mahalanobis-Distanz mit `matchit()` setzen wir `distance = "mahalanobis"` und wählen `method = "nearest"`. Mit diesen Parametern wird jeder Behandlung aus der Behandlungsgruppe die gemäß d_M am ehesten vergleichbarste Beobachtung aus der Kontrollgruppe zugewiesen, wobei keine mehrfachen Matches zulässig sind.



```
# 1:1 Mahalanobis-Distanz-Matching
res_maha <- matchit(
  formula = dark_mode ~ age + male + hours,
  data = darkmode,
  estimand = "ATT",
  distance = "mahalanobis",
  method = "nearest"
)
res_maha
```

A matchit object

- method: 1:1 nearest neighbor matching without replacement
- distance: Mahalanobis
- number of obs.: 300 (original), 298 (matched)
- target estimand: ATT
- covariates: age, male, hours

```
# Balance-Table für 1:1 Mahalanobis-Matching
bal.tab(res_maha)
```

Balance Measures

	Type	Diff.	Adj
age	Contin.	-0.5826	
male	Binary	0.3154	
hours	Contin.	0.0106	

Sample sizes

	Control	Treated
All	151	149
Matched	149	149
Unmatched	2	0

Die Ergebnisse zeigen, dass für sämtliche 149 Beobachtungen aus der Behandlungsgruppe ein individueller Match in der Kontrollgruppe gefunden werden konnte. Es werden lediglich 2 Beobachtungen der 151 Beobachtungen in der Kontrollgruppe nicht gematcht.

Entsprechend zeigt die Balance-Table eine ähnliche Diskrepanz beider Gruppen hinsichtlich der Matching-Variablen an.

Mahalanobis-Distanz mit Caliper .25 für Propensity Scores basierend auf logistischer Regression

Für eine strengeres Matching-Kriterium kann ein *Caliper*, d.h. eine maximal zulässige Distanz, herangezogen werden. Die Mahalanobis-Distanz hat jedoch keine einheitliche Skala: Ob eine Distanz als groß oder klein betrachten werden kann, hängt von der Anzahl der Matching-Variablen und dem Überlappungsgrad zwischen den Gruppen ab. Daher wird die Beschränkung durch einen Caliper nicht auf \hat{d}_M sondern auf Propensity Scores angewendet.

Im nächsten Code-Beispiel spezifizieren wir mit `distance = "glm"`, dass Propensity Scores gemäß der Vorschrift in `formula` geschätzt werden. Mit `mahvars = ~ age + male + hours` legen wir die Matching-Variablen für die Berechnung von \hat{d}_M fest. `caliper = .25` legt fest, dass lediglich Beobachtungen der Kontrollgruppe bei einer absoluten Differenz der Propensity Scores von höchstens 0.25 Standardabweichungen als Match für eine Beobachtung in der Behandlungsgruppe qualifiziert sind.

```
#| context: setup
# Logit-Modell mit 'glm()' schätzen
(
  darkmode_ps_logit <- glm(
    formula = dark_mode ~ age + male + hours,
    data = darkmode,
    family = binomial
  )
)
```

```
# Mahalanobis-Matchig mit PS-Caliper
res_mahaC <- matchit(
  formula = dark_mode ~ age + male + hours,
  data = darkmode,
  distance = "glm",
  estimand = "ATT",
  method = "nearest",
  mahvars = ~ age + male + hours,
  caliper = .25
)
res_mahaC
```

```

A matchit object
- method: 1:1 nearest neighbor matching without replacement
- distance: Mahalanobis [matching]
  Propensity score [caliper]
  - estimated with logistic regression
- caliper: <distance> (0.058)
- number of obs.: 300 (original), 208 (matched)
- target estimand: ATT
- covariates: age, male, hours

```

```

# Balance Table
bal.tab(res_mahaC)

```

Balance Measures

	Type	Diff.	Adj
distance	Distance	0.1812	
age	Contin.	-0.1176	
male	Binary	0.0481	
hours	Contin.	-0.0001	

Sample sizes

	Control	Treated
All	151	149
Matched	104	104
Unmatched	47	45

Die Balance-Table zeigt einen deutlichen Effekt der Beschränkung qualifizierter Beobachtungen durch `caliper = .25`: Aufgrund der oberen Grenze für die Propensity-Score-Differenz von 0.058 wird für lediglich 104 Beobachtungen aus der Behandlungsgruppe ein individueller Match in der Kontrollgruppe gefunden.⁷ Weiterhin finden wir eine verbesserte Balance für den gematchten Datensatz.

4.2.4 Propensity Score Matching

Eine gängige Variante ist Matching ausschließlich anhand von Propensity Scores innerhalb eines Calipers.

⁷Die durch `caliper` implizierte Obergrenze ergibt sich als `.25 * sd(fitted(darkmode_ps_logit))`.

```

# 1:1 Matching mit PS und Caliper
res_PSC <- matchit(
  formula = dark_mode ~ age + male + hours,
  data = darkmode,
  estimand = "ATT",
  distance = "glm",
  method = "nearest",
  caliper = .25
)
res_PSC

```

A matchit object

- method: 1:1 nearest neighbor matching without replacement
- distance: Propensity score [caliper]
 - estimated with logistic regression
- caliper: <distance> (0.058)
- number of obs.: 300 (original), 208 (matched)
- target estimand: ATT
- covariates: age, male, hours

```

# Balance Table
bal.tab(res_PSC)

```

Balance Measures

	Type	Diff.	Adj
distance	Distance	0.1640	
age	Contin.	-0.0976	
male	Binary	0.0481	
hours	Contin.	0.0134	

Sample sizes

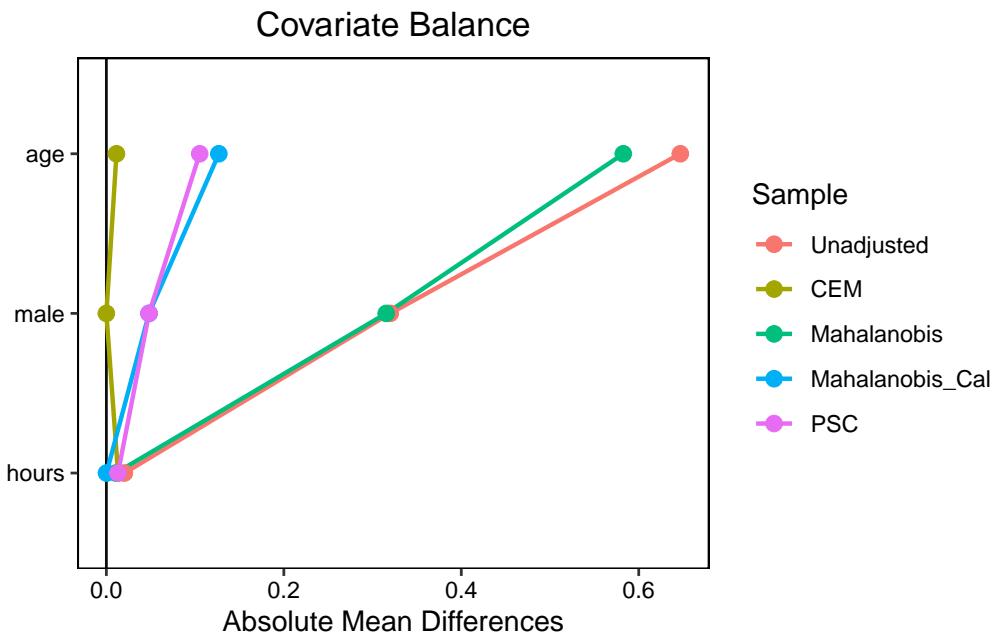
	Control	Treated
All	151	149
Matched	104	104
Unmatched	47	45

Laut Balance-Table führt Eins-zu-Eins-Matching basierend auf Propensity Scores zu einem Datensatz mit 104 gematchten Beobachtungen in der Behandlungsgruppe. Hinsichtlich der standardisierten Mittelwertdifferenz (Diff. Adj) erzielt diese Methode die beste Balance unter den betrachteten Ansätzen.

Vergleich der Balance verschiedener Verfahren mit Love-Plot

Standardisierte Mittelwertdifferenzen für verschiedene Matching-Verfahren können grafisch mit einem Love-Plot (Love 2004) veranschaulicht werden. Hierzu nutzen wir `cobalt::love.plot()` und übergeben die mit `matchit()` generierten Objekte im Argument `weights`.

```
# Love-Plot für
love.plot(
  x = dark_mode ~ age + male + hours,
  weights = list(
    CEM = res_CEM,
    Mahalanobis = res_maha,
    Mahalanobis_Cal = res_mahaC,
    PSC = res_PSC
  ),
  data = darkmode,
  line = T,
  # absolute Mittelwertdifferenz plotten
  abs = T
)
```



Die Grafik zeigt, dass Coarsened Exact Matching (CEM) unter allen betrachteten Verfahren die Stichprobe mit der besten Balance ergibt. Diesen gematchten Datensatz erhalten wir mit `MatchIt::match.data()`.

```
# gematchten Datensatz zuweisen
darkmode_matched_CEM <- match.data(res_CEM)
head(darkmode_matched_CEM)

# A tibble: 6 x 7
  read_time dark_mode male   age hours weights subclass
    <dbl>      <dbl> <dbl> <dbl> <dbl>    <dbl> <fct>
1     15.4        0     1    55   125.      1  26
2     20.9        1     0    23   643.      1  70
3     21.5        1     0    29   190.      1  79
4     22          1     0    18   334.      1  80
5     17.4        0     0    53   279.      1  11
6     20.4        0     0    43   138.      1  9
```

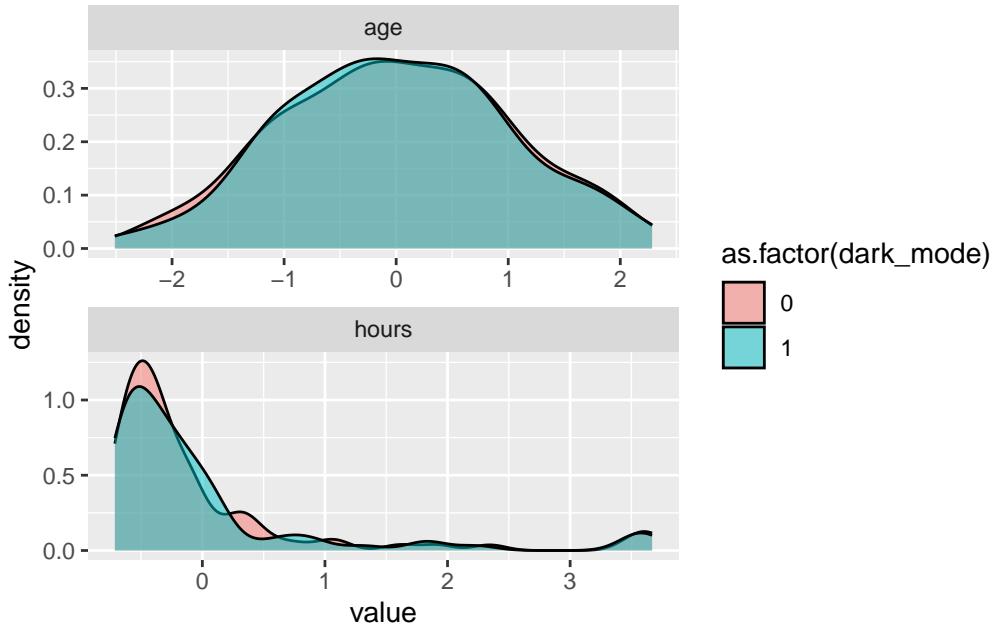
`darkmode_matched` enthält Gewichte (`weights`) für die jeweilige Gruppe zu denen gemachte Beobachtungen gehören (`subclass`). Dies ist relevant, falls Beobachtungen mehrfach gematcht werden. Wegen Eins-zu-eins-Matching *ohne* Zurücklegen gibt es in unserem Beispiel 82 Beobachtungspaare und sämtliche Gewichte sind 1. Die Berücksichtigung der Gewicht in den nachfolgenden Aufrufen von Schätzfunktionen (bspw. `lm()`) ist daher nicht nötig und erfolgt lediglich zur Illustration der grundsätzlichen Vorgehensweise.

Eine Wiederholung der grafischen Analyse in Kapitel 4.1 zeigt eine deutlich verbesserte Vergleichbarkeit hinsichtlich der Verteilung der Matching-Variablen in `darkmode_matched`.

```
darkmode_matched_CEM %>%
  group_by(dark_mode) %>%
  select(age, hours) %>%
  mutate_all(scale) %>%
  pivot_longer(cols = c(-dark_mode)) %>%

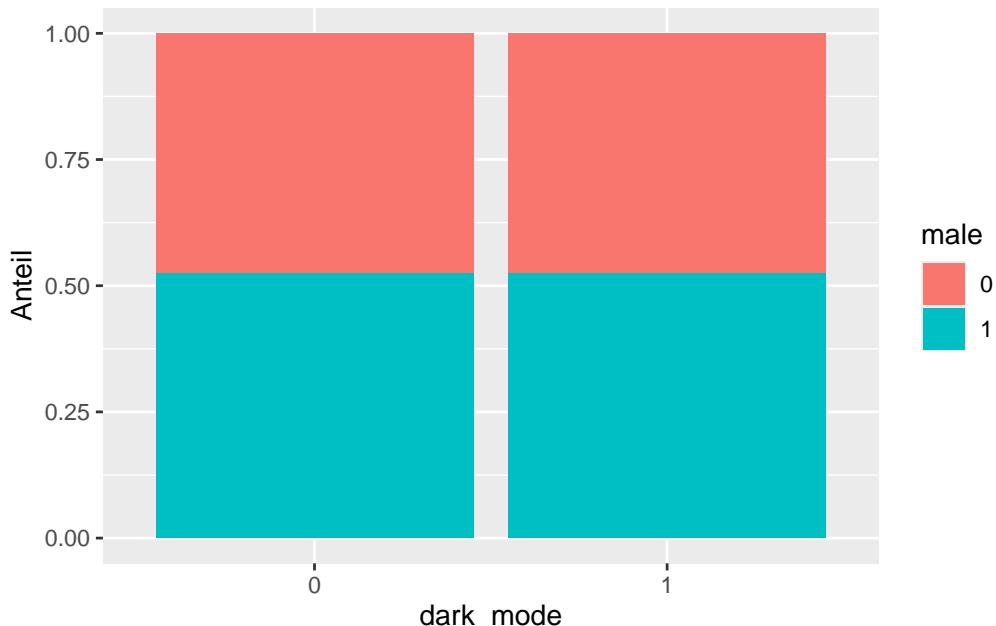
  ggplot(
    aes(x = value, fill = as.factor(dark_mode))
  ) +
  geom_density(alpha = .5) +
  facet_wrap(
    facets = ~ name,
    scales = "free",
```

```
nrow = 3  
)
```



```
darkmode_matched_CEM %>%  
  group_by(dark_mode) %>%  
  mutate(  
    male = as.factor(male),  
    dark_mode = as.factor(dark_mode)  
) %>%
```

```
ggplot(  
  aes(x = dark_mode, fill = male)  
) +  
  geom_bar(position = "fill") +  
  ylab("Anteil")
```



Wir beobachten eine bessere Balance bei `age` und `hours`. Insbesondere ist `male` für Kontroll- und Behandlungsgruppe ausgeglichen.

4.3 Schätzung und Inferenz für den Behandlungseffekt nach Matching

Wir schätzen nun den Behandlungseffekt von `dark_mode` auf `read_time` für die mit CEM und Propensity Score Matching ermittelten Datensätzen und vergleichen die Ergebnisse anschließend mit einer Regressionsschätzung ohne Matching.

Wir kombinieren die Matching-Verfahren mit linearer Regression, d.h. wir schätzen den Behandlungseffekt anhand des gematchten Datensatzes als Mittelwertdifferenz nach zusätzlicher Kontrolle für die Matching-Variablen. Diese Kombination von Matching mit Regression wird in der Literatur als *Regression Adjustment* bezeichnet und ist insbesondere hilfreich, wenn Backdoors mit Matching geschlossen werden sollen, der kausale Effekt jedoch nur unter Verwendung einer nicht-trivialen Regressionsfunktion ermittelt werden kann. Zum Beispiel kann bei einer kontinuierlichen Behandlungsvariable und einem nicht-linearen Zusammenhang mit Y der kausale Effekt nicht durch einen bloßen Mittelwertvergleich erfasst werden, sondern erfordert eine adäquate Modellierung dieses Zusammenhangs in der Regressionsfunktion. Die zusätzliche Kontrolle für Matching-Variablen kann die Varianz der Schätzung verringern.

und das Risiko einer verzerrten Schätzung abmildern, falls nach Matching noch Unterschiede in der Balance von Behandlungs- und Kontrollgruppe vorliegen.

```
# ATT mit linearem Modell schätzen: CEM Datensatz
ATT_mod_CEM <- lm(
  formula = read_time ~ age + male + hours + dark_mode,
  data = darkmode_matched_CEM,
  weights = weights
)

summary(ATT_mod_CEM)
```

Call:

```
lm(formula = read_time ~ age + male + hours + dark_mode, data =
darkmode_matched_CEM,
  weights = weights)
```

Residuals:

Min	1Q	Median	3Q	Max
-8.9310	-2.3856	-0.0194	2.5407	14.0020

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)							
(Intercept)	16.6088953	1.5255529	10.887	< 2e-16 ***							
age	0.0380982	0.0344699	1.105	0.27072							
male	-4.0915725	0.6858131	-5.966	1.53e-08 ***							
hours	0.0050129	0.0006977	7.185	2.45e-11 ***							
dark_mode	1.6532234	0.6149439	2.688	0.00794 **							

Signif. codes:	0	'***'	0.001	'**'	0.01	'*'	0.05	'. '	0.1	' '	1

Residual standard error: 3.937 on 159 degrees of freedom

Multiple R-squared: 0.414, Adjusted R-squared: 0.3992

F-statistic: 28.08 on 4 and 159 DF, p-value: < 2.2e-16

```
# Datensatz für Propensity Score Matching zuweisen
darkmode_matched_PSC <- match.data(res_PSC)

# ATT mit linearem Modell schätzen: PSM Datensatz
```

```

ATT_mod_PSC <- lm(
  formula = read_time ~ age + male + hours + dark_mode,
  data = darkmode_matched_PSC,
  weights = weights
)

summary(ATT_mod_PSC)

```

Call:

```
lm(formula = read_time ~ age + male + hours + dark_mode, data =
darkmode_matched_PSC,
weights = weights)
```

Residuals:

Min	1Q	Median	3Q	Max
-9.972	-2.605	-0.044	2.587	14.951

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)							
(Intercept)	17.3654519	1.2762648	13.606	< 2e-16 ***							
age	0.0283941	0.0301484	0.942	0.34741							
male	-3.9858702	0.6480072	-6.151	4.03e-09 ***							
hours	0.0046119	0.0006685	6.899	6.53e-11 ***							
dark_mode	1.6346636	0.5769812	2.833	0.00507 **							

Signif. codes:	0	'***'	0.001	'**'	0.01	'*'	0.05	'. '	0.1	' '	1

Residual standard error: 4.141 on 203 degrees of freedom

Multiple R-squared: 0.3171, Adjusted R-squared: 0.3037

F-statistic: 23.57 on 4 and 203 DF, p-value: 5.098e-16

```

# ATT mit linearem Modell ohne Matching
ATT_mod_org <- lm(
  formula = read_time ~ age + male + hours + dark_mode,
  data = darkmode
)

summary(ATT_mod_org)

```

```

Call:
lm(formula = read_time ~ age + male + hours + dark_mode, data =
darkmode)

Residuals:
    Min      1Q  Median      3Q     Max 
-10.2697 -2.6710  0.0164  2.5909 14.5739 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 16.859075   1.082303 15.577 < 2e-16 ***
age          0.051332   0.022215  2.311  0.02154 *  
male        -4.485545   0.498957 -8.990 < 2e-16 *** 
hours         0.004348   0.000516  8.427 1.58e-15 *** 
dark_mode     1.385810   0.523793  2.646  0.00859 ** 
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Residual standard error: 4.03 on 295 degrees of freedom
Multiple R-squared: 0.3434, Adjusted R-squared: 0.3345
F-statistic: 38.57 on 4 and 295 DF, p-value: < 2.2e-16

Beachte, dass für die gematchten Datensätze jeweils ein durchschnittlicher Behandlungseffekt für die Beobachtungen *mit* erfolgter Behandlung ermittelt wird: In sämtlichen oben gezeigten Matchibg-Verfahren werden mit `estimand = "ATT"` vergleichbarere Kontrollbeobachtungen für die behandelten Beobachtungen ermittelt. Wir schätzen den Effekt der Behandlung, indem wir die Ergebnisse von behandelten Personen mit denen von gematchten Personen vergleichen, die keine Behandlung erhalten haben. Diese Vergleichsgruppe dient als Ersatz für den hypothetischen Zustand der Behandlungsgruppe, wenn keine Behandlung erfolgt wäre. Dies entspricht der Definition eines ATT — ein average treatment effect *on the treated*.

4.3.1 Cluster-robuste Standardfehler

Für Matching-Verfahren sind die mit `summary()` berechneten Standardfehler (und damit auch Konfidenzintervalle, t-Statistiken und p-Werte) für den Behandlungseffekt *grundsätzlich ungültig*. Je nach Matching-Verfahren liegen unterschiedliche Quellen von Schätzunsicherheit vor, die bei der Berechnung

von Standardfehlern zusätzlich zu der “üblichen” Stichproben-Variabilität berücksichtigt werden müssen. Gründe hierfür sind der Matching-Prozess ansich oder weitere Unsicherheit durch die Schätzung zusätzlicher Parameter, etwa bei der Berechnung von Propensity Scores mit logistischer Regression. Eine weitere Ursache zusätzlicher Variation durch den Matching-Prozess, die wir bisher nicht näher betrachtet haben entsteht durch Zurücklegen, d.h. wenn Beobachtungen mehrfach gematcht werden können. Auch dieser Faktor wird in der von `summary()` verwendeten Formel für den Standardfehler des Effekt-Schätzers nicht berücksichtigt.

Die Standardfehlerberechnung für Matching-Schätzer von Behandlungseffekten ist ein Gegenstand aktueller methodischer Forschung. P. C. Austin und Small (2014) und A. Abadie und Spiess (2022) belegen die Gültigkeit von cluster-robusten Standardfehlern mit Clustering auf Ebene der Beobachtungsgruppen (`subclass` im output von `match.data()`) bei Matching ohne Zurücklegen. Für Matching anhand von Propensity Scores (auch mit Zurücklegen) zeigt Imbens (2016), dass ignorieren der zusätzlichen Unsicherheit durch die Schätzung der Propensity Scores zu konservativer Inferenz für den ATE anhand eines cluster-robusten Standardfehlerschätzers führt, jedoch ungültige Inferenz für die Schätzung des ATT bedeuten kann. Ähnlich zu P. C. Austin und Small (2014) deuten die Ergebnisse der Simulationsstudie von Bodory u. a. (2020) jedoch auf grundsätzlich bessere Eigenschaften der Schätzung hin, wenn die Standardfehler *nicht* für die Schätzung der Propensity Scores adjustiert werden.

Weiterhin ist die Kontrolle für Kovariablen mit Erklärungskraft für die Outcome-Variable und für die Matching-Variablen mit *Regression Adjustment* (vgl. Kapitel 4.3) für die Schätzung des Behandlungseffekts nach Matching eine etablierte Strategie, vgl. Hill und Reiter (2006) und A. Abadie und Spiess (2022). So können die Varianz der Schätzung und das Risiko einer Verzerrung der Standardfehler aufgrund verbleibender Imbalance von Behandlungs- und Kontrollgruppe nach Matching verringert werden.

Zur Demonstration von (cluster)-robuster Inferenz und für eine tabellarische Zusammenfassung der Ergebnisse nutzen wir die Pakete `marginaleffects` und `modelsummary`. Mit `marginaleffects::avg_comparisons()` können p-Werte und Kofindenzintervalle unter Berücksichtigung von robuster Standardfehlern und der Gewichte aus dem Matching-Verfahren berechnet werden.

```
library(marginaleffects)

# Inferenz: Multiple Regression, ungematchter Datensatz
```

```

(
  sum_orig <- avg_comparisons(
    model = ATT_mod_org,
    variables = "dark_mode",
    # Heteroskedastische-robuste SE:
    vcov = "HC3",
    # Identifizierung der Kontrollgruppe:
    newdata = subset(darkmode, dark_mode == 1)
  )
)

```

Term	Contrast	Estimate	Std. Error	z	Pr(> z)
S 2.5 % 97.5 %					
dark_mode mean(1) - mean(0)		1.39	0.537	2.58	0.00988
6.7 0.333 2.44					

Columns: term, contrast, estimate, std.error, statistic,
 p.value, s.value, conf.low, conf.high, predicted_lo,
 predicted_hi, predicted
 Type: response

```

# Inferenz: Multiple Regression bei CEM
(
  sum_CEM <- avg_comparisons(
    model = ATT_mod_CEM ,
    variables = "dark_mode",
    # Cluster-robuste SE
    vcov = ~ subclass,
    newdata = subset(darkmode_matched_CEM, dark_mode == 1),
    wts = "weights"
  )
)

```

Term	Contrast	Estimate	Std. Error	z	Pr(> z)
S 2.5 % 97.5 %					
dark_mode mean(1) - mean(0)		1.65	0.549	3.01	0.00262
8.6 0.576 2.73					

```
Columns: term, contrast, estimate, std.error, statistic,
p.value, s.value, conf.low, conf.high, predicted_lo,
predicted_hi, predicted
Type: response
```

```
# Inferenz: Multiple Regression bei PSM
(
  sum_PSC <- avg_comparisons(
    model = ATT_mod_PSC ,
    variables = "dark_mode",
    vcov = ~ subclass,
    newdata = subset(darkmode_matched_PSC, dark_mode == 1),
    wts = "weights"
  )
)
```

Term	Contrast	Estimate	Std. Error	z	Pr(> z)
S 2.5 % 97.5 %					
dark_mode mean(1) - mean(0)		1.63	0.565	2.89	0.00381
8.0 0.527 2.74					

```
Columns: term, contrast, estimate, std.error, statistic,
p.value, s.value, conf.low, conf.high, predicted_lo,
predicted_hi, predicted
Type: response
```

Wir fassen die Ergebnisse mit `modelsummary::modelsummary()` tabellarisch zusammen.

```
library(modelsummary)

# Tabellarische Zusammenfassung erzeugen
modelsummary(
  models = list(
    "Kein Matching" = sum_orig,
    "Coarsened Exact" = sum_CEM,
    "Propensity Scores" = sum_PSC
  ),
```

```

stars = T,
gof_map = "nobs",
output = "gt"
) %>%
tabopts()

```

	Kein Matching	Coarsened Exact	Propensity Scores
dark_mode	1.386** (0.537)	1.653** (0.549)	1.635** (0.565)
Num.Obs.	300	164	208

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

4.4 Bootstrap-Schätzung kausaler Effekte bei Matching

Ein Bootstrap-Verfahren generiert mit Resampling (wiederholtes Ziehen mit Zurücklegen) aus dem Original-Datensatz (viele) künstliche Datensätze, für die der Schätzer (d.h. das gesamte Verfahren inkl. Matching!) jeweils berechnet wird. Die Verteilung der so gewonnenen Bootstrap-Schätzwerte approximiert die wahre, unbekannte Stichprobenverteilung des Schätzers des Behandlungseffekts. Mit dieser simulierten Verteilung können wir Inferenz betreiben: Wir können einen Bootstrap-Punktschätzer des Behandlungseffekts (Stichprobenmittel der Bootstrap-Schätzungen) sowie Standardfehler (Standardabweichung der der Bootstrap-Schätzungen) und p-Werte berechnen.

Der Bootstrap kann hilfreich sein, wenn unklar ist, wie Standardfehler für die Unsicherheit des Matching-Prozesses zu adjustieren sind, um gültige Inferenzstatistiken zu erhalten. A. Abadie und Imbens (2008) zeigen analytisch, dass der Standard-Bootstrap die Stichprobenverteilung für Schätzer kausaler Effekte anhand von gematchten Datensätzen (d.h. bei Zuordnung/Selektion von Beobachtungen mit Matching) nicht korrekt abbilden kann. Grundsätzlich problematisch hierbei ist, wenn der Bootstrap eine verzerrte Schätzung produziert und/oder zu kleine Standardfehler liefert. A. Abadie und Imbens (2008) belegen die Tendenz des Bootstraps zu *konservative* (d.h. zu große) Standardfehler zu produzieren. Simulationsnachweise (Bodory u. a. 2020; Hill und Reiter 2006; P. C. Austin und Small 2014; P. C. Austin und Stuart 2017) finden, dass Bootstrap-Standardfehler u.a. bei Propensity Score Matching mit

Zurücklegen leicht konservativ sind somit das gewünschte nominale Signifikanzniveau eines Bootstrap-Hypothesentests nicht überschritten wird, weshalb der Standard-Bootstrap trotz seiner Schwächen in der empirischen Forschung oft angewendet wird.

Wir betrachten als nächstes einen Bootstrap-Algorithmus für Inferenz bezüglich eines kausalen Effekts nach Matching und demonstrieren die Schätzung anhand unseres Website-Beispiels für den ATT nach Propensity-Score-Matching.

Algorithmus: Bootstrap-Schätzer für Matching mit Regression Adjustment

1. Generiere eine Bootstrap-Stichprobe durch N Züge *mit Zurücklegen* aus der N -elementigen originalen Stichprobe.
2. Wende das Matching-Verfahren für die Bootstrap-Stichprobe an. Schätze den Behandlungseffekt β anhand der gematchten Stichprobe mit Regression. Speichere den Punktschätzer des Behandlungseffekts $\hat{\beta}_b^*$.
3. Führe die Schritte 1 und 2 für $b = 1, \dots, B$ aus, wobei B eine hinreichend große Anzahl von Bootstrap-Replikationen ist.
4. Berechne den Bootstrap-Schätzer des Behandlungseffekts $\bar{\beta}^* = \frac{1}{B} \sum_{b=1}^B \hat{\beta}_b^*$ und den Standardfehler $SE(\bar{\beta}^*) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\beta}_b^* - \bar{\beta}^*)^2}$. Berechne Inferenz-Statistiken mit den üblichen Formeln.

Wir Implementieren nun einen Bootstrap-Schätzer des ATT im Website-Beispiel für Propensity-Score-Matching. Hierzu definieren wir eine R-Funktion `boot_fun()` für die Schritte 1 und 2 im obigen Algorithmus.

```
# Bootstrap-Funktion für Schritte 1 und 2
boot_fun <- function(
  data, # originale Stichprobe
  i     # Indexmenge f. Bootstrap-Stichprobe
) {

  # Bootstrap-Stichprobe
  boot_data <- data[i, ]

  # 1:1 PS Matching
  match_res <- matchit(
```

```

    dark_mode ~ age + hours + male,
    estimand = "ATT",
    distance = "glm",
    method = "nearest",
    caliper = .25,
    data = boot_data
  )

# Gematchten Datensatz zuweisen
darkmode_matched <- match.data(
  object = match_res,
  data = boot_data
)

# Outcome-Modell schätzen
ATT_mod <- lm(
  formula = read_time ~ age + male + hours + dark_mode,
  data = darkmode_matched,
  weights = weights
)

# ATT-Schätzung zurückgeben
return(
  ATT_mod$coefficients["dark_mode"]
)
}

```

Wir berechnen nun eine Bootstrap-Schätzung des ATT von `dark_mode` auf `readingtime` nach Propensity Score Matching mit einem caliper von 0.25 sowie den zugehörigen Standardfehler und ein 95%-KI mit der zuvor definierten Funktion `boot_fun`.

```

library("boot")
set.seed(4321)

# Anz. Bootstrap-Replikationen
B <- 999

# Bootstrap durchführen

```

```
(  
  boot_out <- boot(darkmode, boot_fun, R = B)  
)
```

ORDINARY NONPARAMETRIC BOOTSTRAP

Call:

```
boot(data = darkmode, statistic = boot_fun, R = B)
```

Bootstrap Statistics :

original	bias	std. error
t1* 1.634664	-0.08144129	0.5935746

Den Bootstrap-Schätzer des ATT sowie den Bootstrap-Standardfehler berechnen wir mit `mean()` und `sd()` anhand der 999 Bootstrap-Replikationen in `boot_out$t`.

Beachte, dass der Bootstrap-Schätzer des Behandlungseffekts nicht unmittelbar von `boot()` ausgegeben wird. `original` ist die Schätzung anhand der gesamten Stichprobe (d.h. ohne Bootstrap) und `bias` ist die Differenz zwischen dieser Schätzung und dem Mittelwert der Bootstrap-Schätzungen.

```
# Bootstrap-Schätzer für den Treatment-Effekt  
mean(boot_out$t)
```

```
[1] 1.553222
```

```
# bootstrap - original = bias  
mean(boot_out$t) - boot_out$t0
```

```
dark_mode  
-0.08144129
```

Wir können prüfen, dass die Berechnung des Standardfehlers dem Stichprobenstandardabweichung der Bootstrap-Schätzungen entspricht.

```
# Bootstrap-Standardfehler  
sd(boot_out$t)
```

```
[1] 0.5935746
```

Ein 95%-Konfidenzintervall für den kausalen Effekt erhalten wir mit `boot::boot.ci()`.⁸

```
# 95% Bootstrap-KI für den Treatment-Effekt  
boot.ci(  
  boot.out = boot_out,  
  type = "bca",  
  conf = .95  
)
```

```
BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS  
Based on 999 bootstrap replicates
```

CALL :

```
boot.ci(boot.out = boot_out, conf = 0.95, type = "bca")
```

Intervals :

Level BCa

95% (0.527, 2.839)

Calculations and Intervals on Original Scale

Beachte, dass der Bootstrap-Standardfehler sowie das Bootstrap-Konfidenzintervall nahe der mit `avg_comarisons` berechneten Werte für `sum_PSC` sind.

Bootstrap-Standardfehler für IPW-Schätzer des ATE berechnen

Die Bootstrap-Funktion `boot_fun` kann leicht für eine Schätzung des Standardfehlers für den IPW-Schätzer des ATE aus Kapitel 4.1.3 angepasst werden. Statt einer Matching-Prozedur berechnen wir hierzu für B Bootstrap-Stichproben den Schätzer $\hat{\tau}^{\text{IPW}}$ mit Trimming der Propensity Scores.

⁸`type = "bca"` (bias-corrected accelerated) ist eine gängige Implementierung für die Berechnung des Konfidenz-Intervalls.

```

# IPW estimation with regression adjustment
IPW_boot <- function(
  data,
  i
) {

  # Bootstrap-Stichprobe erstellen
  data_boot <- data %>%
    slice(i)

  # Logistische Regression
  glm_fit <- glm(
    formula = dark_mode ~ age + hours + male,
    data = data_boot,
    family = binomial
  )

  # Propensity Scores berechnen
  data_boot <- data_boot %>%
    mutate(
      ps = predict(glm_fit, type = 'response')
    )

  # Beobachtungen anhand Propensity Scores trimmen
  data_boot <- data_boot %>%
    filter(
      between(
        x = ps,
        left = .2,
        right = .7
      )
    )

  # IPW berechnen
  data_boot <- data_boot %>%
    mutate(
      ipw = case_when(
        dark_mode == 1 ~ 1 / ps,
        dark_mode == 0 ~ 1 / (1 - ps))
    )
}

```

```

    )

# Gewichtete Mittelwerte der Gruppen
w_means <- data_boot %>%
  group_by(dark_mode) %>%
  summarize(m = weighted.mean(read_time, w = ipw)) %>%
  arrange(dark_mode)

# ATT-Schätzwert
return(w_means$m[2] - w_means$m[1])
}

```

```

set.seed(1234)
# Bootstrap für IPW durchführen
(
  b_IPW <- boot(
    data = darkmode,
    statistic = IPW_boot,
    R = 999
  )
)

```

ORDINARY NONPARAMETRIC BOOTSTRAP

Call:
`boot(data = darkmode, statistic = IPW_boot, R = 999)`

Bootstrap Statistics :

	original	bias	std. error
t1*	1.962849	0.06297654	0.6599891

```

# Bootstrap-Schätzer und Standardfehler berechnen
mean(b_IPW$t)

```

[1] 2.025826

```
sd(b_IPW$t)
```

```
[1] 0.6599891
```

In diesem Fall ist der Bootstrap-Standardfehler von ca. 0.66 gut mit dem anhand von `summary(model_ipw)` berechneten Standardfehler vergleichbar. Ein 95%-Konfidenzintervall für den ATE erhalten wir wie zuvor mit `boot.ci()`.

```
# 95% Bootstrap-KI für den ATE
boot.ci(b_IPW, type = "bca")
```

```
BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS
Based on 999 bootstrap replicates
```

```
CALL :
boot.ci(boot.out = b_IPW, type = "bca")
```

```
Intervals :
Level      BCa
95%  ( 0.563,  3.134 )
Calculations and Intervals on Original Scale
```

4.5 Regression, Matching und Doubly-Robust-Schätzung

Als *Doubly-Robust-Schätzer* bezeichnet man Methoden, die bei Fehlspezifikationen im Matching-Verfahrens *oder* der funktionalen Form der Regressionsfunktion für die Outcome-Variable eine zuverlässige Schätzungen des kausalen Effekts ermöglichen.⁹ Unter der Voraussetzung, dass die verwendeten Matching-Variablen sämtliche Backdoors schließen, ist so mit Doubly-Robust-Schätzung eine konsistente Schätzung des Behandlungseffekts unter abgeschwächten Annahmen gewährleistet. Dies macht Doubly-Robust-Schätzer besonders nützlich in Forschungskontexten, in denen präzise Modellspezifikationen herausfordernd sind.

Der von Wooldridge (2010) vorgeschlagene Doubly-Robust-Schätzer (IPWRA) für den ATE erreicht seine vorteilhaften Eigenschaften durch eine geschickte Kombination von IPW und Regression Adjustment.

⁹Bspw. kann eine falsche funktionale Form bei logistischer Regression eine verzerrte Schätzung von Propensity Scores und damit eine unzureichende Balance bedeuten.

Algorithmus: IPWRA-Schätzer des ATE

Vgl. Wooldridge (2010).

1. Berechne IPW anhand von Propensity Score mit logistischer Regression unter Verwendung der Matching-Variablen.
2. Regression Adjustment:
 - (a) Schätze lediglich für die *Behandlungsgruppe* eine mit den IPW gewichtete Regressionspezifikation der Outcome-Variable mit Kontrolle für die Matching-Variablen.
 - (b) Wiederhole Schritt A für *Kontrollgruppe*.
3. Berechne Vorhersagen der Outcome-Variable für die angepassten Modelle aus 2 (a) und 2 (b) anhand des *gesamten* Datensatzes.
4. Schätze den ATE als Mittelwert-Differenz der Vorhersagen aus Schritt 3.

Wir implementieren den Doubly-Robust-Schätzer des ATE von Wooldridge (2010) für das Website-Beispiel in der Funktion `IPWRA()` unter Adaption des Schemas von `IPW_boot()`.

```
# IPW estimation with regression adjustment
IPWRA <- function(
  data,
  i = i) {

  # Bootstrap-Stichprobe zuweisen
  b_data <- data %>%
    slice(i)

  # Logistische Regression
  glm_fit <- glm(
    formula = dark_mode ~ age + hours + male,
    data = b_data,
    family = binomial(link = 'logit')
  )

  # Propensity Scores berechnen
  b_data <- b_data %>%
```

```

    mutate(ps = predict(glm_fit, type = 'response')))

# Propensity Scores trimmen
b_data <- b_data %>%
  filter(
    between(
      x = ps,
      left = .2,
      right = .7
    )
  )

# IPW berechnen
b_data <- b_data %>%
  mutate(
    IPW = case_when(
      dark_mode == 1 ~ 1 / ps,
      dark_mode == 0 ~ 1 / (1 - ps)
    )
  )

# Regression Adjustment:

# Schätzung des Behandlungseffekts für die ges. Stichprobe
# mit Modell für Behandlungsgruppe
mtreat <- b_data %>%
  filter(dark_mode == 1) %>%
  lm(read_time ~ age + hours + male, data = ., weights =
    ~ .$IPW) %>%
  predict(newdata = b_data) %>%
  mean()

# Schätzung des Behandlungseffekts für die ges. Stichprobe
# mit Modell für Kontrollgruppe
mcont <- b_data %>%
  filter(dark_mode == 0) %>%
  lm(read_time ~ age + hours + male, data = ., weights =
    ~ .$ipw) %>%
  predict(newdata = b_data) %>%
  mean()

```

```

# Regression adjusted ATE-Schätzer
return(mtreat - mcont)
}

```

Schätzung des ATE mit IPWRA():

```
IPWRA(data = darkmode, i = 1:nrow(darkmode))
```

```
[1] 1.96847
```

Wie bei $\hat{\tau}^{\text{IPW}}$ gibt es keine formale Darstellung des Standardfehlers für den IPWRA-Schätzer, sodass auch hier der Bootstrap genutzt werden sollte.

```

set.seed(1234)

# Bootstrap für IPWRA durchführen
(
  b_IPWRA <- boot(
    data = darkmode,
    statistic = IPWRA,
    R = B
  )
)

```

ORDINARY NONPARAMETRIC BOOTSTRAP

Call:

```
boot(data = darkmode, statistic = IPWRA, R = B)
```

```

Bootstrap Statistics :
      original     bias   std. error
t1*  1.96847 -0.001270721  0.5960465

```

Wir berechnen die interessierenden Statistiken analog zu der Vorgehensweise in Kapitel 4.4.

```
# Bootstrap-IPWRA-Schätzer des ATE  
mean(b_IPWRA$t)
```

```
[1] 1.967199
```

```
# Bootstrap-Standardfehler  
sd(b_IPWRA$t)
```

```
[1] 0.5960465
```

```
# 95%-Bootstrap-KI für den ATE  
boot.ci(b_IPWRA, type = "bca")
```

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS

Based on 999 bootstrap replicates

CALL :

```
boot.ci(boot.out = b_IPWRA, type = "bca")
```

Intervals :

Level BCa

95% (0.787, 3.098)

Calculations and Intervals on Original Scale

Die Bootstrap-Schätzung des ATE mit IPWRA ist mit den Ergebnissen für die Bootstrap-Variante von $\hat{\tau}^{\text{IPW}}$ vergleichbar, hat allerdings einen etwas kleineren Standardfehler und ist somit genauer.

5 Panel-Daten

5.1 Pooled Regression und unbeobachtbare Heterogenität

Ein Panel-Datensatz enthält Beobachtungen von n Einheiten für (bis zu) T Zeitpunkte, wobei $t = 1, \dots, T$. Betrachte das Panel-Modell

$$Y_{it} = \beta_0 + \beta_1 B_{it} + \beta_2 X_i + \beta_3 U_i + \epsilon_{it}, \quad (5.1)$$

wobei U_i unbeobachtete und X_i beobachtete, **zeitlich-invariante** Heterogenitäten zwischen den Beobachtungseinheiten $i = 1, \dots, n$ sind. Wie zuvor ist B_{it} die Behandlungsvariable und β_1 der interessierende kausale Effekt einer Veränderung von B_{it} auf Y_{it} .

Angenommen wir beobachten Y_{it} und B_{it} für $T = 1$, also für eine Periode. Bei Korrelation zwischen den **unbeobachtbaren** zeit-invarianten Effekten U_i und der Behandlungsvariable B_{it} kann der kausale Effekt β_1 in nicht identifiziert werden. Diese Situation ist in Abbildung 5.1 dargestellt.

Abbildung 5.1 zeigt Backdoors durch die U_i , die wir mit einer “naiven” KQ-Schätzung der fehlspezifizierten Regression

$$Y_{it} = \beta_0 + \beta_1 B_{it} + \beta_2 X_i + \varepsilon_{it}, \quad t = 1, \quad (5.2)$$

nicht schließen können.

Wir betrachten nun eine Generalisierung von Abbildung 5.1 für $T = 2$ Perioden, dargestellt in Abbildung 5.2.

Der in Abbildung 5.2 gezeigte Zusammenhang führt (idealerweise) zwar zu einer Verdoppelung des Beobachtungsumfangs, jedoch besteht weiterhin das in Abbildung 5.1 gezeigte Endogenitätsproblem, falls die Regression (5.2) nun anhand einer Zusammenlegung (**Pooling**) der Beobachtungen für $t \in \{1, 2\}$

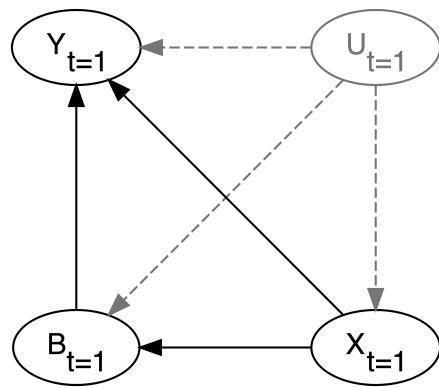


Abbildung 5.1: Backdoors durch beobachtete und unbeobachtete Variablen

geschätzt wird:¹ Die unbeobachteten zeit-invarianten Einflüsse U_i verursachen auch für Periode $t = 2$ Backdoor-Pfade.

In diesem Kapitel betrachten wir Panel-Verfahren, welche den kausalen Effekt in Abbildung 5.2 und Verallgemeinerungen hiervon schätzen können. Analog zu Querschnittsdaten können die hier betrachteten Panel-Schätzer Endogenitäten aufgrund simultaner Kausalität oder nicht beheben. In solchen Szenarien können Panel-Methoden in Kombination mit einer Schätzstrategie basierend auf Instrument-Variablen hilfreich sein. Wir betrachten solche Schätzer in den empirischen Beispielen in Kapitel 6.

Bevor wir diese Panel-Verfahren erläutern, veranschaulichen wir die verzerrte Schätzung eines Behandlungseffekts mit *Pooled Regression* für einen simulierten Datensatz `paneldata.csv`, der Beobachtungen von $n = 12$ Einheiten zu $T = 8$ Perioden beinhaltet. Alle Einheiten weisen unbeobachtbare zeit-invariante Heterogenitäten auf, die mit B_{it} korellieren. Der wahre Behandlungseffekt beträgt $\beta_1 = -1$ für alle n Einheiten.²

Wir lesen zunächst den Datensatz ein und selektieren die benötigten Variablen.

```
# Datensatz 'paneldata.csv' einlesen
paneldata <- read_csv("datasets/paneldata.csv") %>%
  select(X, Y, ID, time, col)
```

¹Pooled Regression kann auch berechnet werden, wenn nicht für alle n Einheiten jeweils T Beobachtungen vorliegen (unbalanced Panel).

²Der (R code für den) DGP ist [diesem StackExchange-Post](#) entnommen.

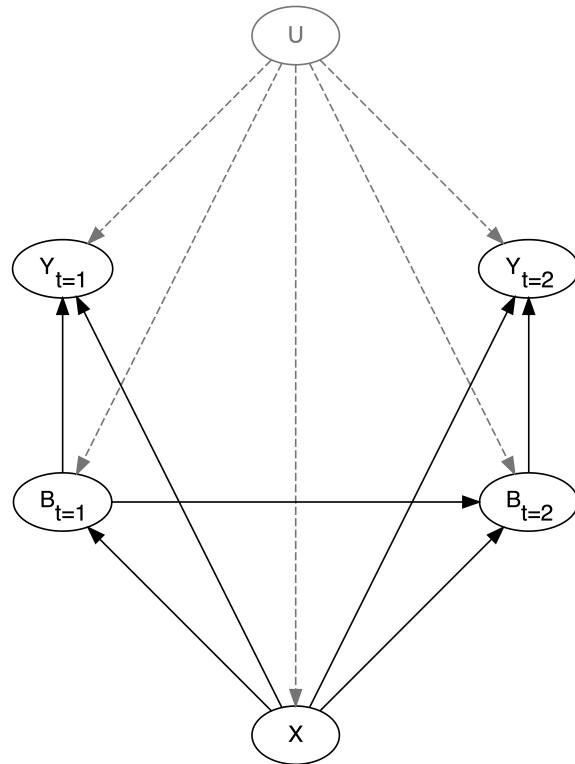


Abbildung 5.2: Panel-Design mit Backdoors durch beobachtete und unbeobachtete zeit-invariante Variablen

```
# Panel-Dimensionen bestimmen
paneldata %>%
  summarise(
    N = unique(ID) %>% length(),
    T = unique(time) %>% length()
  )
```

```
# A tibble: 1 x 2
  N     T
  <int> <int>
1    12     8
```

Mit der Funktion `plm::is.pbalanced()` überprüfen wir, ob im Panel-Datensatz für alle beobachteten Einheiten die gleiche Anzahl an Beobachtungsperioden vorliegt (*balanced panel*).³

³Fehlende Beobachtungen sind typischerweise mit einem NA-Wert gekennzeichnet. Der Differenz-Schätzer kann auch berechnet werden, wenn der Datensatz nicht ausgeglichen (*unbalanced*) ist.

```

library(plm)

# Datensatz balanced?
is.pbalanced(
  x = paneldata,
  index = c("ID", "time")
)

```

[1] TRUE

Zunächst schätzen wir eine Pooled Regression für die ersten beiden Zeitperioden, basierend auf einem entsprechend gefilterten Datensatz.⁴

```

# Subsetting der Daten für 2 Perioden (t = {1, 2})
paneldata_T2 <- paneldata %>%
  filter(
    dplyr::between(time, 1, 2)
)

```

Für die Schätzung von (5.2) nutzen wir `fixest::feols()`.

```

library(fixest)

# Naive KQ-Schätzung für t = {1, 2}
panel_KQ <- feols(
  fml = Y ~ X,
  data = paneldata_T2
)

summary(panel_KQ)

```

```

OLS estimation, Dep. Var.: Y
Observations: 24
Standard-errors: IID
Estimate Std. Error  t value  Pr(>|t|)
(Intercept) -2.50547   1.481150 -1.69157 1.0485e-01
X            3.80692   0.194202 19.60295 2.0252e-15 ***

```

⁴Wir verweisen nachfolgend explizit auf Funktionen aus `dplyr`, falls Funktionen aus `plm` identische Namen haben.

```

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 3.28785  Adj. R2: 0.943388

```

Die Schätzung von β_1 ist 3.81 und weist auf eine deutliche Verzerrung hin. Wir illustrieren die Problematik in Abbildung 5.3, in dem wir die für die Regression verwendeten Daten (Kreise) sowie die Beobachtungen späterer Perioden (Kreuze) nach Gruppenzugehörigkeit einfärben und die Schätzung der Pooled Regression abtragen.

```

library(cowplot)

# Plot: Naiver KQ-Schätzer für t = 1, 2
ggplot(
  mapping = aes(x = X, y = Y)
) +
  geom_point(
    data = paneldata %>%
      filter(time > 2),
    mapping = aes(color = col),
    pch = 3,
    show.legend = F
) +
  geom_point(
    data = paneldata %>%
      filter(time %in% 1:2),
    mapping = aes(color = col),
    show.legend = F
) +
# Naive KQ-Schätzung für t = 1, 2
  geom_smooth(
    data = paneldata %>%
      filter(time %in% 1),
    method = "lm",
    se = F,
    col = "black"
) +
  scale_color_identity() +
  theme_cowplot()

```

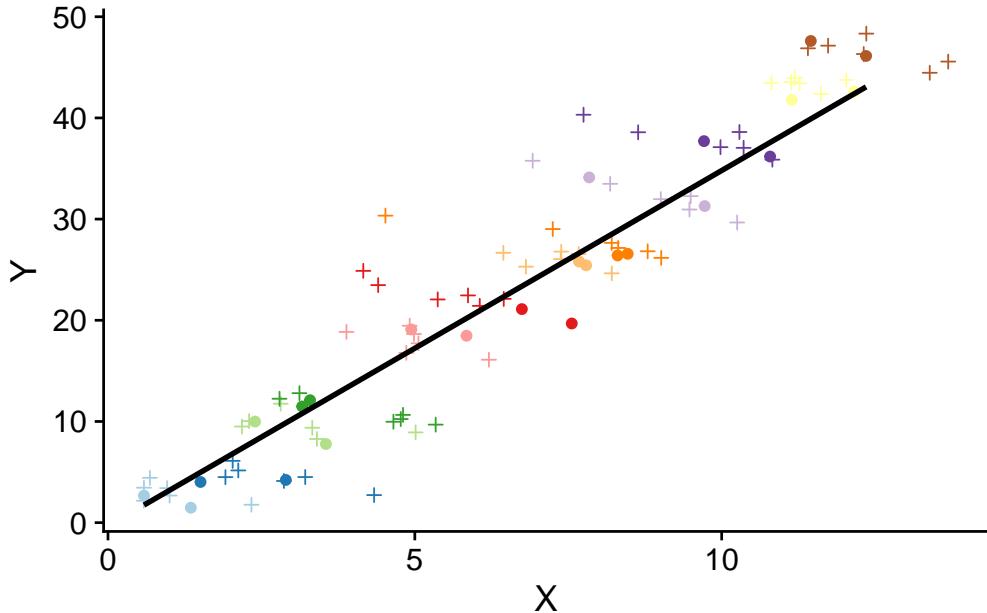


Abbildung 5.3: paneldaten.csv – Pooled Regression für $t = 1, 2$

Abbildung 5.3 zeigt einen negativen Verlauf des Zusammenhangs zwischen X und Y anhand der Variation der Beobachtungen *innerhalb* der farblich gekennzeichneten Gruppen. Dieser negative Zusammenhang kann aufgrund der Endogenität von X nicht erfasst werden.

Eine Erweiterung der Regression auf sämtliche Perioden (Pooling aller $n \times T = 12 \times 8 = 96$ Beobachtungen) erhöht lediglich die Präzision der Schätzung (geringer Standardfehler von $\hat{\beta}_1$), nicht aber die Endogenität, vgl. Abbildung 5.4.

```
# Naive KQ-Schätzung für t = 1, ..., 8
panel_KQ <- feols(
  fml = Y ~ X,
  data = paneldata
)

summary(panel_KQ)
```

```
OLS estimation, Dep. Var.: Y
Observations: 96
Standard-errors: IID
Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.45318   1.008859 -1.44042   0.15307
X            3.76470   0.134364 28.01868 < 2.2e-16 ***
---
```

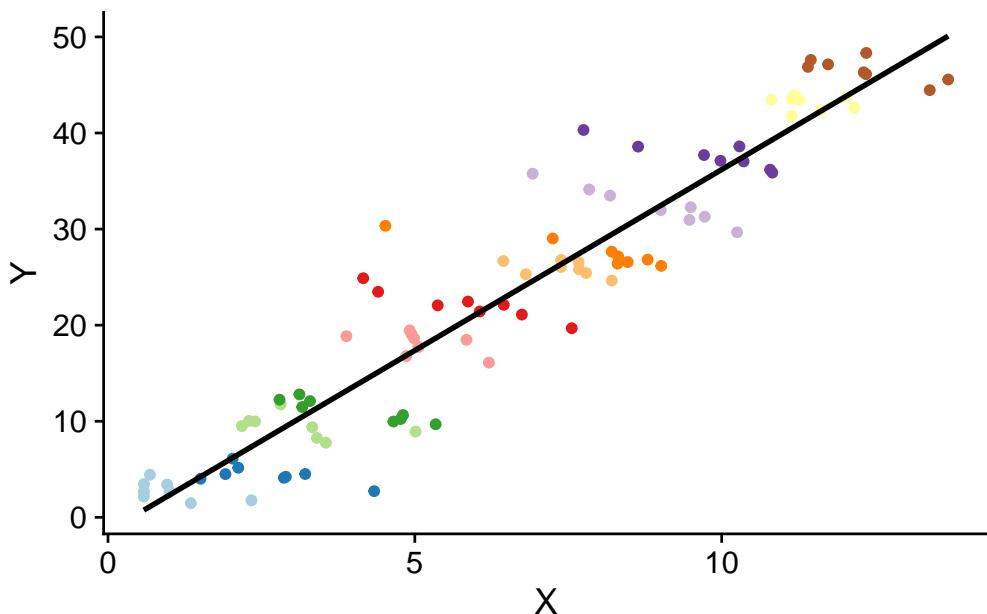


Abbildung 5.4: paneldaten.csv – Pooled Regression für $t = 1, \dots, 8$

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 4.63461   Adj. R2: 0.891928
```

```
# Plot: Naiver KQ-Schätzer für  $t = 1, \dots, 8$ 
ggplot(
  data = paneldata,
  mapping = aes(x = X, y = Y)
) +
  geom_point(
    mapping = aes(color = col),
    show.legend = F
) +
# Pooled Schätzung
  geom_smooth(
    data = paneldata,
    method = "lm",
    se = F,
    col = "black"
) +
  scale_color_identity() +
  theme_cowplot()
```

5.2 Regression in Differenzen

Wir betrachten zunächst den in Abbildung 5.2 dargestellten DGP für $T = 2$ Zeitperioden. In dieser Situation können Backdoors durch U anhand einer simplen Transformation von Modell (5.4) geschlossen werden: Regression der Zeit-Differenzen zwischen den Perioden $t = 2$ und $t = 1$,

$$\Delta Y_{it} = \beta_1 \Delta B_{it} + e_{it}, \quad i = 1, \dots, n, \quad t = 1, 2, \quad (5.3)$$

wobei $\Delta Y_{it} := Y_{i2} - Y_{i1}$ und $e_{it} := \epsilon_{i2} - \epsilon_{i1}$ für $t = 2$. Beachte, dass $\Delta U_i = \Delta X_i = 0$. Differenzieren ergibt also ein Modell, in dem weder für X_i noch für die (unbeobachtbaren) U_i kontrolliert werden muss, damit β_1 identifiziert werden kann. Der Behandlungseffekt β_1 kann mit KQ geschätzt werden.

Zur Transformation der Regressoren in `fixest::feols()` verwenden wir den Operator `d()`. Dieser benötigt die im Argument `panel.id` als Formel spezifizierten Identifikationsvariablen für Einheiten (ID) und Zeitpunkte (time).

```
# Panel-Schätzer: KQ-Regression in Differenzen
panel_diff <- feols(
  fml = d(Y) ~ d(X) - 1,
  data = paneldata %>%
    filter(
      dplyr::between(time, 1, 2)
    ),
  panel.id = ~ ID + time
)

summary(panel_diff)
```

```
OLS estimation, Dep. Var.: d(Y, 1)
Observations: 12
Standard-errors: Clustered (ID)

      Estimate Std. Error   t value Pr(>|t|)
d(X, 1) -1.03205   0.326838 -3.15767 0.0091166 **

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.907432  Adj. R2: 0.509923
```

Die Schätzung anhand der Regression in Differenzen liegt nahe beim wahren Behandlungseffekt $\beta_1 = -1$. Abbildung Abbildung 5.5 zeigt die ersten

Differenzen der Daten und den mit KQ geschätzten Zusammenhang.

```
# Transformation zu Differenzen
paneldata_diff <- paneldata %>%
  mutate(
    DeltaX = X - dplyr::lag(X),
    DeltaY = Y - dplyr::lag(Y)
  ) %>%
  drop_na()

# Plot: KQ-Schätzer für Differenzen
ggplot(
  mapping = aes(x = DeltaX, y = DeltaY)
) +
  geom_point(
    data = paneldata_diff %>%
      filter(time > 2),
    mapping = aes(color = col),
    pch = 3,
    show.legend = F
  ) +
  geom_point(
    data = paneldata_diff %>%
      filter(time == 2),
    mapping = aes(color = col),
    show.legend = F
  ) +
  geom_smooth(
    data = paneldata_diff %>%
      filter(time == 2),
    method = "lm",
    se = F,
    color = "black"
  ) +
  scale_color_identity() +
  theme_cowplot()
```

Wie für die Pooled Regression können wir den Differenzen-Schätzer für den gesamten Datensatz berechnen.

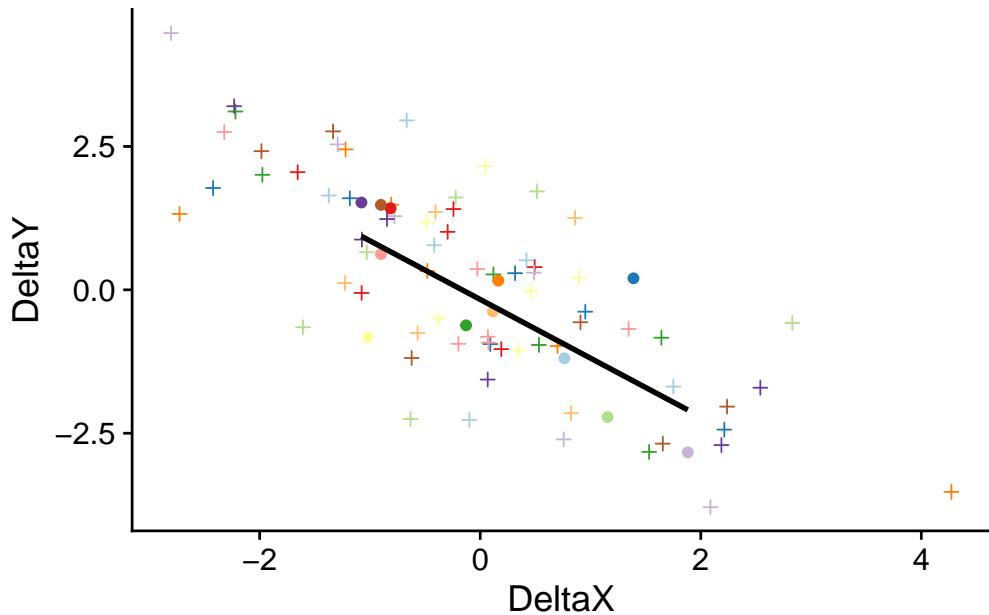


Abbildung 5.5: paneldaten.csv – Regression in Differenzen für $t = 2$

```
# Panel-Schätzer: KQ-Regression in Differenzen
panel_diff <- feols(
  fml = d(Y) ~ d(X) - 1,
  data = paneldata,
  panel.id = ~ ID + time
)

summary(panel_diff)
```

```
OLS estimation, Dep. Var.: d(Y, 1)
Observations: 84
Standard-errors: Clustered (ID)
      Estimate Std. Error t value Pr(>|t|)
d(X, 1) -0.982042  0.135217 -7.26269 1.6178e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 1.12641   Adj. R2: 0.571235
```

Beachte, dass der Standardfehler der Schätzers etwas größer ist als für den KQ-Schätzer in der Pooled Regression. Grund hierfür ist der Verlust von 12 Beobachtungen bei der Bildung der $T - 1 = 7$ Differenzen.

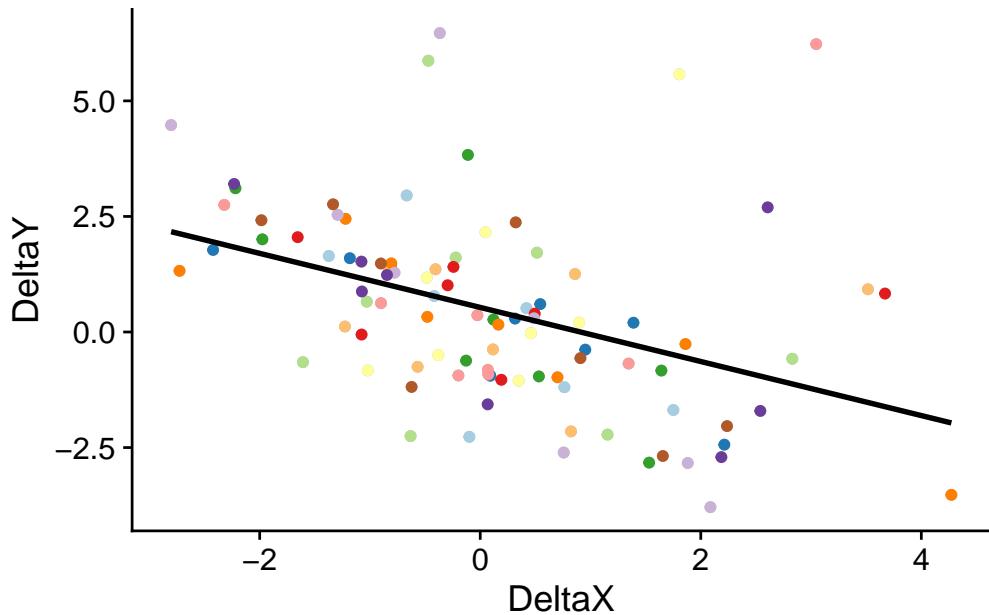


Abbildung 5.6: paneldaten.csv – Regression in Differenzen für $t = 1, \dots, 8$

```
# Plot: KQ-Schätzer in Differenzen (alle t)
ggplot(
  data = paneldata_diff,
  mapping = aes(x = DeltaX, y = DeltaY)
) +
  geom_point(
    color = "gray",
    show.legend = F
) +
  geom_point(
    mapping = aes(color = col),
    show.legend = F
) +
  geom_smooth(
    method = "lm",
    se = F,
    color = "black"
) +
  scale_color_identity() +
  theme_cowplot()
```

5.3 Fixed-Effects-Regression

Die Regression in Differenzen hat den Nachteil, dass einheiten-spezifische Effekte nicht geschätzt werden können. Weiterhin impliziert die Differenzbildung einen Verlust des Beobachtungsumfangs bei der Schätzung des kausalen Effekts.⁵ Für den Datensatz `paneldata.csv` verlieren wir daher 1/8 der Stichprobe. Abhängig von der empirischen Fragestellung und der Datenverfügbarkeit kann Fixed-Effects-Regression eine nützliche Alternative zu Regression in Differenzen sein, wenn Panel-Daten mit $T \geq 2$ vorliegen.

Wir betrachten erneut Modell (5.1) und definieren

$$\delta_i = \beta_0 + \beta_3 U_i.$$

Nach einsetzen in (5.1) erhalten wir das Modell

$$Y_{it} = \delta_i + \beta_1 B_{it} + \beta_2 X_i + \epsilon_{it}, \quad (5.4)$$

mit einheiten-spezifischen Konstanten δ_i , $i = 1, \dots, n$. Die δ_i können als individuelle Achsenabschnitte (“feste Effekte”) interpretieren werden, weshalb Modell (5.4) auch als “Fixed-Effects-Modell” bezeichnet wird.⁶

Für die Vermeidung von Backdoors in den δ_i subtrahieren wir die einheiten-spezifische Mittelwerte von den Komponenten (Within-Transformation),

$$\begin{aligned} Y_{it} - \bar{Y}_i &= (\delta_i - \bar{\delta}_i) + \beta_1 (B_{it} - \bar{B}_i) + \beta_2 (X_i - \bar{X}_i) + (\epsilon_{it} - \bar{\epsilon}_i) \\ \tilde{Y}_{it} &= \beta_1 \tilde{B}_{it} + \tilde{\epsilon}_{it}. \end{aligned} \quad (5.5)$$

Der Fixed-Effects-Schätzer von β_1 ist der KQ-Schätzer in (5.5). Ähnlich wie für den Differenzen-Schätzer eliminieren die Mittelwert-Differenzen $\delta_i - \bar{\delta}_i = 0$ und $X_i - \bar{X}_i = 0$ den Einfluss zeit-invarianter Variablen.

Das Modell (5.4) kann weiterhin als eine Regression mit $n-1$ Dummy-Variablen und einer Konstante umgeschrieben werden,

$$Y_{it} = \beta_0 + \beta_2 B_{it} + \beta_2 X_i + \gamma_2 D_i^{(2)} + \gamma_3 D_i^{(3)} + \cdots + \gamma_n D_i^{(n)} + \epsilon_{it}. \quad (5.6)$$

Die Darstellung (5.6) hat n verschiedene Achsenabschnitte – einen für jede Beobachtungseinheit – und kann ebenfalls mit KQ geschätzt werden.⁷ Die

⁵Eine Reduktion des Beobachtungsumfangs erhöht die Varianz der Schätzung.

⁶Eine Modellierung mit gruppen-spezifischen Achsenabschnitten scheint in Abbildung 5.4 plausibel.

⁷Für $n-1$ Einheiten ist der individuelle Achsenabschnitt damit $\beta_0 + \gamma_i$ und für *eine* Einheit β_0 . Diese Einheit (hier $i = 1$) wird auch als *Referenzkategorie* bezeichnet. Alternativ kann

Modelle (5.4) und (5.6) sind also gleichwertige Darstellungen eines Modells, dass (unbeobachtbare) zeit-invariante Heterogenität berücksichtigt.⁸ Beachte, dass die Schätzung der Koeffizienten *beobachtbarer* zeit-invarianter Regressoren X_i lediglich in Modell (5.6) möglich ist.

Fixed-Effects-Regressionen können mit `fixest::feols()` geschätzt werden. Je nach Spezifikation des Formula-Arguments (`fml`) wird ein effizienter Algorithmus für eine Variante von (5.4) angewandt. Für `panedata.csv` erhalten wir mit `fml = Y ~ X | ID` per Referenz des Indikators `ID` eine Schätzung mit Berechnung der einheiten-spezifischen Effekte.

```
# Fixed-Effects-Schätzung
panel_FE <- feols(
  fml = Y ~ X | ID,
  data = panedata
)

summary(panel_FE)
```

```
OLS estimation, Dep. Var.: Y
Observations: 96
Fixed-effects: ID: 12
Standard-errors: Clustered (ID)
    Estimate Std. Error t value Pr(>|t|)
X -1.04507    0.10473 -9.97865 7.5526e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.746006   Adj. R2: 0.996829
        Within R2: 0.602694
```

Die Zusammenfassung der Schätzung zeigt einen signifikanten Koeffizienten, der mit einer Schätzung von -1.05 nahe beim wahren Wert von -1 liegt. Die geschätzten einheiten-spezifischen Effekte können mit `fixest::fixef()` ausgelesen werden.

```
# Geschätzte Fixed Effects (Einheiten) auslesen
fixest::fixef(panel_FE)
```

⁸ das Modell mit n Dummies und *ohne* die Konstante β_0 geschrieben werden.

⁸Der Ansatz (5.6) wird in der Literatur auch als *Least Squares Dummy Variables* (LSDV) Regression bezeichnet.

```

$ID
      1       2       3       4       5       6
      7       8
3.814550 7.149097 12.716507 15.319130 23.458442 28.239634
33.659734 35.729516
      9      10      11      12
41.701817 47.911623 55.044052 59.445967

attr("class")
[1] "fixest.fixef" "list"
attr("exponential")
[1] FALSE

```

5.3.1 Zeit-Fixed-Effects

Neben zeit-invarianten Heterogenitäten zwischen den Beobachtungseinheiten können beobachtbare und unbeobachtbare Einflüsse vorliegen, die nicht zwischen den Einheiten, jedoch über die Zeit variieren. Ein DGP mit solchen zeitabhängigen Heterogenitäten ist in Abbildung 5.7 für $T = 2$ dargestellt.⁹

Für beobachtbare zeitabhängige Backdoor-Variablen X_t kann durch Aufnahme dieser in die Regression (5.4) kontrolliert werden. Analog zum Fixed-Effects-Ansatz mit einheiten-spezifischen Konstanten können Backdoors durch unbeobachtbare zeitabhängige Einflüsse U_t durch Kontrolle für perioden-spezifische Dummies $D_t^{(t)}$ (Time Fixed Effects) vermieden werden. Das Modell lautet dann

$$Y_{it} = \beta_0 + \beta_1 B_{it} + \beta_2 X_t + \lambda_2 D_t^{(2)} + \dots + \lambda_T D_t^{(T)} + \epsilon_{it}.$$

In empirischen Anwendung ist es häufig plausibel, für zeit- und einheiten-spezifische Effekte zu kontrollieren. Der entsprechende Regressionsansatz wird als *Two Way Fixed Effects* (TWFE) bezeichnet.

Ein TWFE-Modell für `paneldata.csv` kann mit `feols()` leicht unter Angabe der Identifikationsvariable der Zeitperioden (`time`) innerhalb des `fml`-Arguments geschätzt werden.

⁹Zur Vereinfachung der Interpretierbarkeit vernachlässigt das DAG in Abbildung 5.7 zeitlich konstante Variablen.

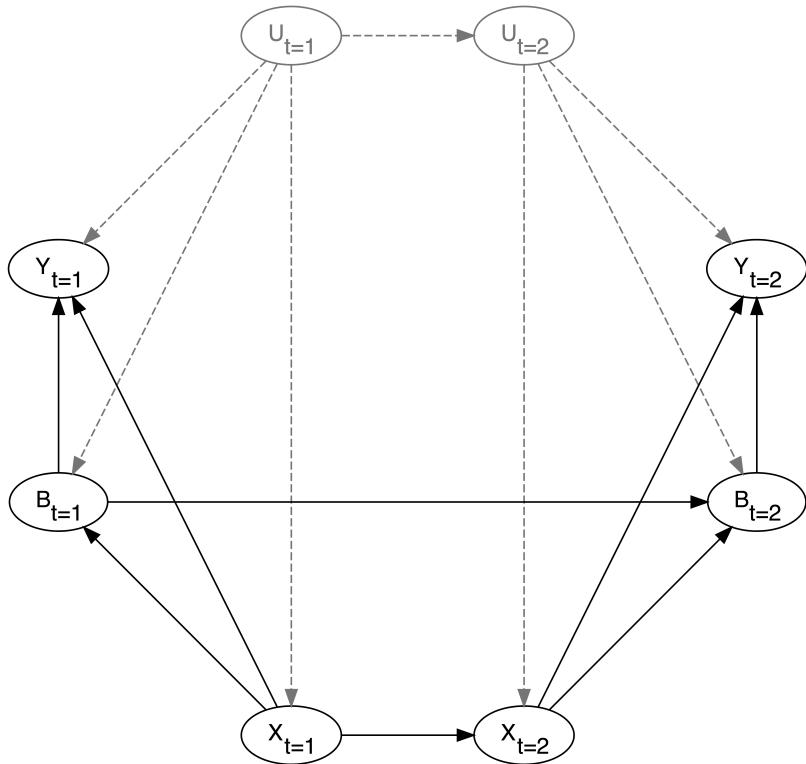


Abbildung 5.7: Panel-Design mit Backdoors durch beobachtete und unbeobachtete zeitabhängige Variablen

```
# TWFE-Schätzung
panel_TWFE <- feols(
  fml = Y ~ X | ID + time,
  data = paneldata
)

summary(panel_TWFE)
```

OLS estimation, Dep. Var.: Y
 Observations: 96
 Fixed-effects: ID: 12, time: 8
 Standard-errors: Clustered (ID)
 Estimate Std. Error t value Pr(>|t|)
 X -1.01411 0.096129 -10.5495 4.3209e-07 ***

 Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
 RMSE: 0.655695 Adj. R2: 0.997325
 Within R2: 0.636218

```

# Geschätzte Fixed Effects (Einheiten + Zeit) auslesen
fixest::fixef(panel_TWFE)

$ID
 1          2          3          4          5          6
 7          8
3.608414 6.893444 12.445006 15.020731 23.126151 27.884480
33.255238 35.311437
 9         10         11         12
41.252680 47.433690 54.515757 58.889276

$time
 1          2          3          4          5
 6
0.00000000 -0.16836639 0.84624725 0.09109152 0.45843997
-0.38103581
 7          8
0.24023573 0.31186366

attr("class")
[1] "fixest.fixef" "list"
attr("references")
 ID time
 0   1
attr("exponential")
[1] FALSE

```

5.4 Random Effects

Der Fixed-Effects-Ansatz behandelt die einheiten-spezifischen Effekte δ_i in Modell (5.4) als konstante Parameter. Das einfache Random-Effects-Modell lautet

$$Y_{it} = \beta_0 + \beta_1 B_{it} + \varepsilon_{it},$$

wobei sich der Fehlerterm ε_{it} aus dem zufälligen individuellen Effekt δ_i und dem unabhängigen Fehler ϵ_{it} zusammensetzt,

$$\varepsilon_{it} = \alpha_i + \epsilon_{it}.$$

Der Random-Effects-Ansatz betrachtet die δ_i als *Zufallsvariablen* mit einer gemeinsamen (Normal)Verteilung, unter der Annahme, dass die δ_i *nicht* mit den erklärenden Variablen korrelieren.¹⁰ Falls diese Annahme erfüllt ist, ist der Random-Random-Effects-Schätzer effizienter als der Fixed-Effects-Schätzer: Der mittlere quadratische Fehler der Schätzung ist geringer.¹¹

Für ein Beispiel simulieren wir Daten gemäß der Vorschrift

$$y_{it} = \alpha_i + \beta B_{it} + \epsilon_{it}, \quad (5.7)$$

wobei α_i die individuellen Zufallseffekte. Wir wählen

$$\begin{aligned}\alpha_i &\stackrel{u.i.v}{\sim} N(0, 2.5^2), \\ \beta_1 &= -1, \\ X_{it} &\sim N(0, 1), \\ \epsilon_{it} &\stackrel{u.i.v}{\sim} N(0, 0.75^2).\end{aligned}$$

Wie in `paneldata.csv` erzeugen wir Daten für $n = 12$ Individuen, die zu $T = 8$ Zeitperioden beobachtet werden. Mit diesen Komponenten wird die Outcome-Variable y_{it} wie in (5.7) generiert. Der nachstehende Code erzeugt die Daten als Matrizen für `X` und `y`, die anschließend in ein langes Datenformat (`tibble`) umgewandelt werden.

```
library(plm)

set.seed(1234)

# Parameter
n <- 12 # Individuen
m <- 8 # Perioden
beta <- -1 # Behandlungseffekt
sigma_alpha <- 2.5 # SD für RE
sigma_epsilon <- 0.75 # SD für Fehler

# Random Effects
alpha <- rnorm(n, mean = 0, sd = sigma_alpha)

# Matrizen
```

¹⁰Weiterhin dürfen die δ_i nicht mit dem Fehler ϵ_{it} korrelieren.

¹¹Die Schätzung erfolgt oft mit der [Maximum-Likelihood-Methode](#).

```

X <- matrix(NA, nrow = m, ncol = n)
y <- matrix(NA, nrow = m, ncol = n)

# Simulation
for (i in 1:n) {
  for (t in 1:m) {
    X[t, i] <- rnorm(1, mean = 0, sd = 1)
    epsilon_it <- rnorm(1, mean = 0, sd = sigma_epsilon)
    y[t, i] <- alpha[i] + beta * X[t, i] + epsilon_it
  }
}

# tibble erzeugen
RE_paneldata <- tibble(
  id = factor(rep(1:n, each = m)),
  time = rep(1:m, times = n),
  X = as.vector(X),
  y = as.vector(y)
)

```

Für die Anpassung des Random-Effect-Schätzers an den simulierten Datensatz `RE_paneldata` nutzen wir `plm::plm()` mit `model = "random"`.

```

# Random-Effects-Modell anpassen
panel_RE <- plm(
  formula = y ~ X,
  data = RE_paneldata,
  index = c("id", "time"),
  model = "random"
)

summary(panel_RE)

```

Oneway (individual) effect Random Effect Model
 (Swamy-Arora's transformation)

Call:
`plm(formula = y ~ X, data = RE_paneldata, model = "random",
 index = c("id",`

```
"time"))
```

Balanced Panel: n = 12, T = 8, N = 96

Effects:

```
var std.dev share
idiosyncratic 0.5221 0.7226 0.13
individual     3.4801 1.8655 0.87
theta: 0.8643
```

Residuals:

Min.	1st Qu.	Median	3rd Qu.	Max.
-2.019439	-0.351116	0.017785	0.420719	2.109010

Coefficients:

	Estimate	Std. Error	z-value	Pr(> z)
(Intercept)	-1.156573	0.552747	-2.0924	0.0364 *
X	-0.996175	0.075859	-13.1320	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares: 143.86

Residual Sum of Squares: 50.753

R-Squared: 0.64721

Adj. R-Squared: 0.64346

Chisq: 172.45 on 1 DF, p-value: < 2.22e-16

Die Schätzung zeigt eine gute Anpassung an die Daten und der geschätzte Behandlungseffekt liegt mit -0.996 nahe am wahren Koeffizienten $\beta_1 = -1$.

Mit `plm::ranef()` erhalten wir *Differenzen* der geschätzten einheiten-spezifischen Effekte vom geschätzten Erwartungswert der unterstellten gemeinsamen Verteilung.

```
# Gesch. Random Effects auslesen
# (Differenzen zum geschätzten Mittelwert der gem. Verteilung)
ranef(panel_RE)
```

1	2	3	4	5
6				

```

-1.92217199  1.24364147  3.27470045 -4.12524574  2.00235610
2.71903482
    7          8          9          10         11
12
-0.17492965 -0.50237866  0.01435925 -1.03252985  0.16092971
-1.65776590

```

Für die grafische Darstellung der Schätzung berechnen wir zunächst mit `fitted()` die angepassten Werte. Für ein mit `plm()` geschätztes Random-Effects-Modell werden die individuellen Effekte von `fitted()` nicht berücksichtigt und müssen daher manuell hinzugefügt werden. Hierfür lesen wir zunächst den geschätzten Erwartungswert der gemeinsamen Verteilung $\hat{\beta}_0$ aus und addieren anschließend die von `ranef()` ausgegebenen Differenzen der individuellen Effekte gruppenweise.

```

# Gesch. Erwartungswert der gem. Verteilung
hat_beta_0 <- panel_RE$coefficients[1]

# Gesch. Random Effects berücksichtigen
RE_paneldata <- RE_paneldata %>%
  mutate(
    fitted_RE =
      fitted(panel_RE)
    + hat_beta_0
    + rep(ranef(panel_RE), each = 8)
  )

```

```

ggplot(
  data = RE_paneldata,
  mapping =
    aes(
      x = X,
      y = y,
      col = id
    )
) +
  geom_point(show.legend = F) +
  geom_line(
    mapping = aes(y = fitted_RE, group = id),
    show.legend = F

```

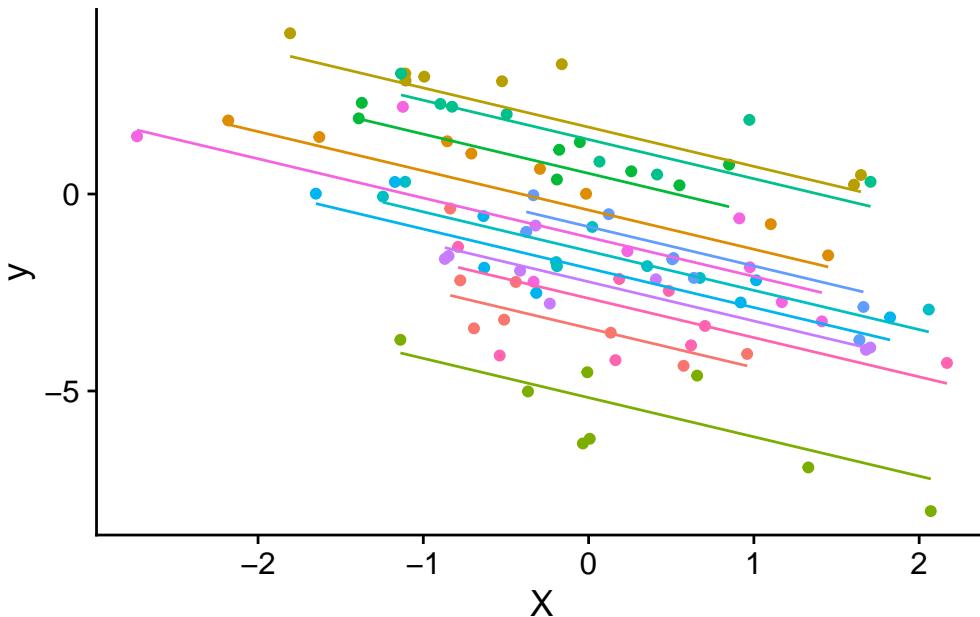


Abbildung 5.8: RE_paneldata – Random-Effects-Schätzung für simulierte Daten

```
) +
  theme_cowplot()
```

Die Random-Effects-Methode findet bei kausalen Analyse in empirischen Anwendungen selten Anwendung, weil die Annahme von Unkorreliertheit mit den erklärenden Regressoren oft unplausibel ist. Falls diese Annahme (wie in den DAGs Abbildung 5.1 und Abbildung 5.2) verletzt ist, kann Random Effects die entsprechenden Backdoors nicht schließen: Der Random-Effects-Schätzer ist dann verzerrt und inkonsistent, ähnlich wie der naive KQ-Schätzer in einer Pooled Regression.

5.4.1 Verzerrung bei Endogenität

Zur Illustration der Verzerrung des Random-Effect-Schätzers bei Endogenität von erklärenden Variablen verwenden wir erneut den Datensatz `paneldata.csv`

```
# Random-Effects-Schätzung für `paneldata`
panel_RE <- plm(
  formula = Y ~ X,
  model = "random",
```

```

index = c("ID", "time"),
data = paneldata
)

summary(panel_RE)

```

Oneway (individual) effect Random Effect Model
(Swamy-Arora's transformation)

Call:

```
plm(formula = Y ~ X, data = paneldata, model = "random", index =
c("ID",
"time"))
```

Balanced Panel: n = 12, T = 8, N = 96

Effects:

var	std.dev	share
idiosyncratic	0.6437	0.8023
individual	2.1732	1.4742
theta:	0.811	

Residuals:

Min.	1st Qu.	Median	3rd Qu.	Max.
-6.0355	-1.9888	-0.1651	1.9196	6.4374

Coefficients:

	Estimate	Std. Error	z-value	Pr(> z)
(Intercept)	18.34586	2.31566	7.9225	2.328e-15 ***
X	0.77031	0.26346	2.9238	0.003458 **

Signif. codes:	0	'***'	0.001	'**'
	0.01	'*'	0.05	'.'
	0.1	' '	1	

Total Sum of Squares: 818.14

Residual Sum of Squares: 749.94

R-Squared: 0.083362

Adj. R-Squared: 0.07361

Chisq: 8.54862 on 1 DF, p-value: 0.0034579

Offenbar weicht der Random-Effects-Schätzer des Effects von X auf Y deutlich

vom wahren Parameter $\beta_1 = -1$ ab. Diese Abweichung ist auf die Endogenität von X zurückzuführen.

Die nächste Grafik vergleicht die Schätzungen des Behandlungseffekts für den Datensatz `paneldata.csv` mit Pooling (schwarze Linie), Fixed Effects (farbige Linien) und Random Effects (gestrichelte schwarze Linie). Vorab erweitern wir `paneldata` um die angepassten Werte für die Fixed- und die Random-Effects-Schätzung in `panel_FE` und `panel_RE`.¹²

```
paneldata <- paneldata %>%
  mutate(
    # Vorhergesagte Werte für FE-Schätzung
    yhat_FE = fitted(panel_FE),
    # Vorhergesagte Werte für RE-Schätzung
    yhat_RE = predict(panel_RE)
  )
```

```
ggplot(
  data = paneldata,
  mapping = aes(x = X, y = Y)
) +
  geom_point(
    mapping = aes(color = col),
    show.legend = F
  ) +
  # Pooling
  geom_smooth(
    method = "lm",
    se = F,
    col = "black"
  ) +
  # Fixed Effects
  geom_line(
    mapping = aes(y = yhat_FE, group = ID, col = col),
    show.legend = F
  ) +
  # Random Effects
  geom_line(
```

¹²Für bessere Lesbarkeit erzeugen wir hier mit `predict()` eine Regressionsgerade, deren Achsenabschnitt dem geschätzten Erwartungswert der Random-Effects-Verteilung entspricht.

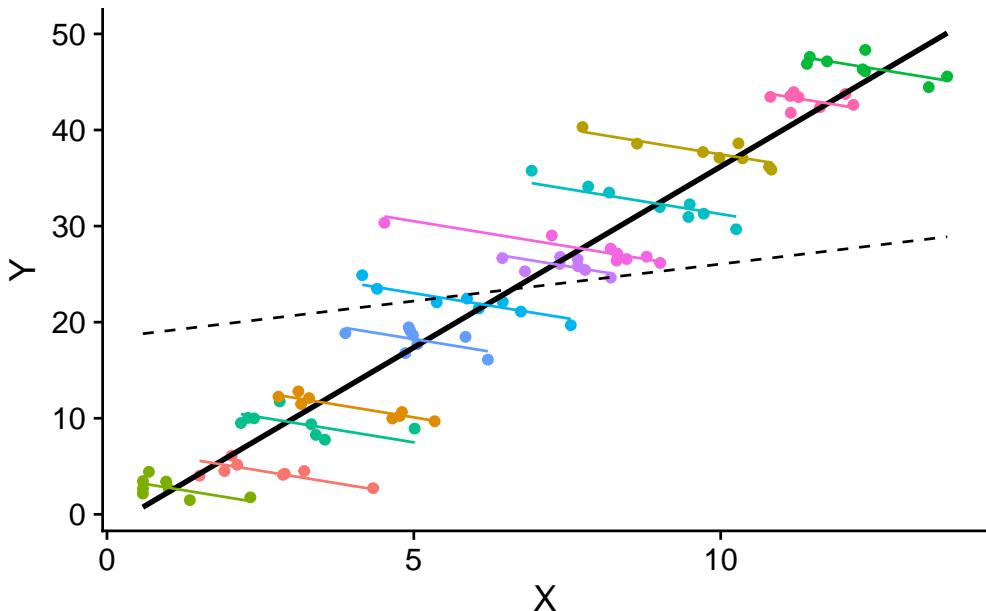


Abbildung 5.9: `paneldaten.csv` – Vergleich von Schätzern bei Einheiten mit endogenen Effekten

```

mapping = aes(y = yhat_RE,
lty = "dashed",
show.legend = F
) +
theme_cowplot()

```

Interaktive Illustration von Panel-Schätzern

Die nachfolgende interaktive Illustration erlaubt einen Vergleich der in Abbildung 5.9 geplotteten geschätzten Regressionsfunktionen für `paneldata.csv` mit dem wahren DGP (Show truth) unter Reproduktion der in Abbildung 5.9 gezeigten Komponenten.

5.5 Beispiel: Einkommen und Demokratie

Eine Vielzahl polit-ökonomischer Standardwerke und Studien (bspw. Dahl 1971; Huntington 1991; Rueschemeyer, Stephens, und Stephens 1992) liefert vermeindliche Belege für einen zentralen Grundsatz der [Modernisierungstheorie](#):

Ein höheres Pro-Kopf-Einkommen erhöht die Nachfrage der Bevölkerung nach politischer Freiheit und demokratischen Institutionen. Acemoglu u. a. (2008a) argumentieren, dass der in derartigen länderübergreifenden Analysen mit Pooling häufig als positiv geschätzte Zusammenhang zwischen Einkommen und Demokratisierung nicht kausal interpretiert werden sollte. Ein Grund hierfür ist, dass (unbeobachtbare) ausgelassene länderspezifische Faktoren, die sowohl die ökonomische Entwicklung als auch die Stärke demokratischer Institutionen beeinflussen, wahrscheinlich sind. Um diese mögliche Ursache für Endogenität des Zusammenhangs

$$\text{Demokratisierung}_i = \beta_0 + \beta_1 \text{PK-Einkommen}_i + \epsilon_i \quad (5.8)$$

zu adressieren, nutzen Acemoglu u. a. (2008a) einen Panel-Regressionsansatz ähnlich zu

$$\text{Demokratisierung}_{it} = \delta_i + \beta_1 \text{PK-Einkommen}_{it} + \epsilon_{it} \quad (5.9)$$

mit Fixed Effects δ_i , die für länderspezifische zeit-invariante Einflüsse kontrollieren.

Das Knergebnis von Acemoglu u. a. (2008a) ist, dass es *keinen* kausalen Zusammenhang zwischen dem Einkommen (Wirtschaftswachstum) und der Demokratisierung gibt. Die Autoren zeigen, dass historische und geografische Faktoren, die sowohl das Einkommen als auch die politischen Institutionen beeinflussen, den beobachteten Zusammenhang verzerrn können.

Für die nachfolgenden Code-Beispiele nutzen wir einen Auszug des Datensatzes aus dem Replikationspaket zu Acemoglu u. a. (2008a), siehe Acemoglu u. a. (2008b).

Wir lesen zunächst den Datensatz `Acemogluetal2008.csv` ein.

```
acem <- readxl::read_xls(
  ~"/Downloads/113251-V1/Income-and-Democracy-Data-AER-adjustment.xls",
  sheet = "5 Year Panel"
)

acem <- acem %>%
  filter(
    dplyr::between(year, 1955, 2000),
```

```
) %>%  
arrange(year)
```

```
# Pooling  
feols(  
  fml = fhpolrigaug ~ lrgdpch,  
  panel.id = ~ country + year,  
  data = acem,  
)
```

```
OLS estimation, Dep. Var.: fhpolrigaug  
Observations: 1,090  
Standard-errors: Clustered (country)  
Estimate Std. Error t value Pr(>|t|)  
(Intercept) -1.210494 0.094546 -12.8032 < 2.2e-16 ***  
lrgdpch 0.217745 0.011194 19.4518 < 2.2e-16 ***  
---  
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
RMSE: 0.273788 Adj. R2: 0.404579
```

```
acem_f <- acem %>%  
  filter(year %in% c(1970, 1995)) %>%  
  group_by(code) %>%  
  summarise(  
    dlrgdpch = diff(lrgdpch),  
    dfhpolrigaug = diff(fhpolrigaug)  
  ) %>%  
  drop_na()  
  
lm(  
  formula = dfhpolrigaug ~ dlrgdpch,  
  data = acem_f  
) %>%  
  summary()
```

```
Call:  
lm(formula = dfhpolrigaug ~ dlrgdpch, data = acem_f)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.9582	-0.1541	-0.1172	0.2081	0.7079

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.12629	0.04008	3.151	0.00214 **
dlrgdpch	0.03298	0.06354	0.519	0.60486

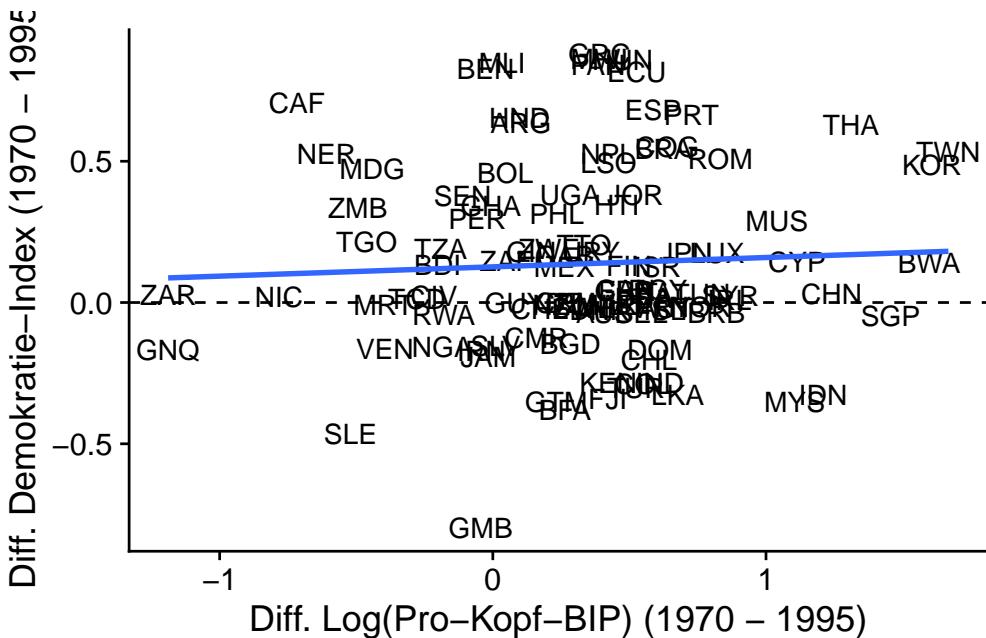
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3422 on 101 degrees of freedom

Multiple R-squared: 0.00266, Adjusted R-squared: -0.007214

F-statistic: 0.2694 on 1 and 101 DF, p-value: 0.6049

```
ggplot(
  data = acem_f,
  mapping = aes(
    x = dlrgdpch,
    y = dfhpolrigaug
  )
  +
  geom_hline(yintercept = 0, lty = 2) +
  geom_text(
    mapping = aes(label = code),
    position = position_jitter(
      height = .05,
      seed = 1234
    )
  +
  geom_smooth(method = "lm", se = F) +
  labs(
    x = "Diff. Log(Pro-Kopf-BIP) (1970 - 1995)",
    y = "Diff. Demokratie-Index (1970 - 1995)"
  +
  theme_cowplot()
```



```
# time + country fixed effects
feols(
  fml = fhpolrigaug ~ 1(fhpolrigaug) + 1(lrgdpch)
  | year + country,
  panel.id = ~ country + year,
  cluster = ~ country,
  data = acem,
)
```

```
OLS estimation, Dep. Var.: fhpolrigaug
Observations: 955
Fixed-effects: year: 9, country: 150
Standard-errors: Clustered (country)

      Estimate Std. Error t value Pr(>|t|)
1(fhpolrigaug, 1) 0.377490  0.048071 7.852772 7.4009e-13 ***
1(lrgdpch, 1)     0.008417  0.031587 0.266461 7.9025e-01
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.16588   Adj. R2: 0.748871
Within R2: 0.140859
```

```
# time-fixed effects
feols(
  fml = fhpolrigaug ~ 1(fhpolrigaug) + 1(lrgdpch)
```

```

| year,
panel.id = ~ country + year,
cluster = ~ country,
data = acem,
)

OLS estimation, Dep. Var.: fhpolrigaug
Observations: 955
Fixed-effects: year: 9
Standard-errors: Clustered (country)
              Estimate Std. Error  t value  Pr(>|t|)
l(fhpolrigaug, 1) 0.702504   0.036023 19.50147 < 2.2e-16 ***
l(lrgdpch, 1)     0.073042   0.009861  7.40714 8.8791e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.191614    Adj. R2: 0.7178
           Within R2: 0.705629

```

6 IV-Regression

Wie in Kapitel 3 erläutert, können Regressionsmodelle unter Endogenitätsproblemen leiden: Der Fehlerterm in unserem Regressionsmodell ist mit dem/den interessierenden Regressor(en) korreliert, sodass der zugehörige Koeffizient inkonsistent geschätzt wird und damit nicht als kausaler Effekt interpretiert werden darf. Die häufigsten Ursachen für Endogenität, die in empirischen Anwendungen auftreten, sind ausgelassene Variablen, Messfehler und simultane Kausalität.

Durch Hinzufügen potenziell relevanter Variablen in die Regression kann das Risiko einer verzerrten Schätzung des interessierenden kausalen Effekts anhand multipler Regression verringert werden. Wenn jedoch wichtige ausgelassene Variablen unbeobachtbar (U) sind oder aus anderen Gründen nicht zur Verfügung stehen, kann multiple Regression die Endogenität nicht beheben. Diese Problematik ergibt sich insbesondere bei simultaner Kausalität: Wenn die Kausalität von der Behandlungsvariable (B) zur Outcomevariable (Y) und umgekehrt verläuft, gibt es Backdoors, die nicht durch das Hinzufügen von Kontrollvariablen zum Regressionsmodell geschlossen werden können.

Eine allgemeinere Technik, um Backdoors aufgrund unbeobachtbarer Variablen zu schließen, ist die Regression mit Instrumentvariablen (IV). Bei IV-Regression wird exogene Variation in einer Instrumentvariablen (Z) verwendet, um den Teil der Variation in der Behandlungsvariable zu isolieren, der *nicht* durch unbeobachtbare Faktoren verursacht wird, die sowohl B als auch Y beeinflussen. Der kausale Effekt von B auf Y wird dann anhand dieser exogenen Variation in B geschätzt. Ein Forschungsdesign, in dem der kausale Effekt von B auf Y mit IV-Regression geschätzt werden kann, ist in Abbildung 6.1 dargestellt.

6.1 Der einfache lineare IV-Schätzer

Im folgenden nehmen wir an, dass sämtliche Zusammenhänge linear sind. Zunächst betrachten wir das einfache Regressionsmodell

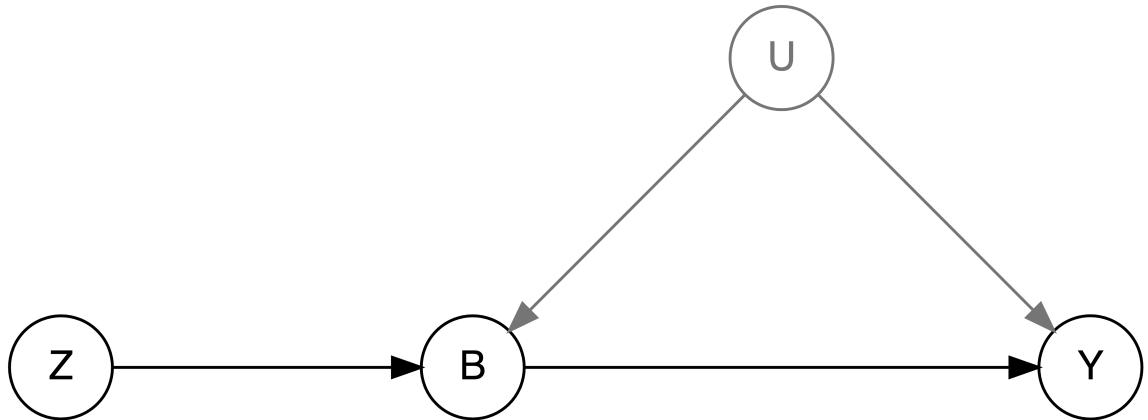


Abbildung 6.1: IV-Design bei Backdoor durch unb. Confounder-Variablen

$$Y_i = \beta_0 + \beta_1 B_i + u_i \quad , \quad i = 1, \dots, n, \quad (6.1)$$

wobei der Fehlerterm u_i mit dem Regressor B_i korreliert ist (d.h. B ist ein *endogener* Regressor), sodass der KQ-Schätzer für den kausalen Effekt β_1 inkonsistent ist.

Damit Z ein gültiges Instrument für B in dem in Abbildung 6.1 gezeigten Forschungsdesign ist, müssen die folgenden Bedingungen erfüllt sein:

Sei $\text{Cov}(A, B)$ die Kovarianz zwischen den Variablen A und B . Z muss zwei Bedingungen erfüllen, um ein gültiges Instrument zu sein:

- **1. Relevanz des Instruments für die endogene Variable**

B und Z müssen korreliert sein (Pfeil von Z nach B in Abbildung 6.1):

$$\text{Cov}(B, Z) \neq 0 \quad (6.2)$$

- **2. Exogenität des Instruments hinsichtlich der Outcome-Variable**

Das Instrument Z darf nicht mit dem Fehlerterm u in der Modellgleichung (6.1) korreliert sein (keine Pfade von Z nach Y außer durch B in Abbildung 6.1):

$$\text{Cov}(Z, u) = 0 \quad (6.3)$$

Unter diesen Annahmen erlaubt das Forschungsdesign die Anwendung des einfachsten IV-Ansatzes, wobei eine endogene Variable B durch eine Instrumentvariable Z *instrumentiert* wird. Die folgende Umformung zeigt, warum der kausale Effekt von B auf Y anhand der (Ko)Variation in diesen Variablen identifiziert werden kann:

$$\text{Cov}(Z, Y) = \text{Cov}(Z, \beta_0 + \beta_1 B + u) \quad (\text{Gl. (6.1)})$$

$$\text{Cov}(Z, Y) = \text{Cov}(Z, \beta_1 B + u) \quad (\beta_0 \text{ konstant})$$

$$\text{Cov}(Z, Y) = \beta_1 \text{Cov}(Z, B) \quad (\beta_1 \text{ konstant}, Z \text{ exogen})$$

$$\beta_1 = \frac{\text{Cov}(Z, Y)}{\text{Cov}(Z, B)} \quad (Z \text{ relevant})$$

Eine naheliegende Implementierung gemäß dieses Identifikationsprinzips ist der einfache IV-Schätzer

$$\widehat{\beta}_{\text{IV}} = \frac{\widehat{\text{Cov}}(Z, Y)}{\widehat{\text{Cov}}(Z, B)}, \quad (6.4)$$

wobei lediglich die Kovarianzfunktion $\text{Cov}(\cdot, \cdot)$ durch ihr Stichprobenäquivalent $\widehat{\text{Cov}}(\cdot, \cdot)$ ersetzt wird.

Erwartungswert und Konsistenz

Eine hilfreiche Darstellung von (6.4) ist

$$\widehat{\beta}_{\text{IV}} = \beta_1 + \frac{\sum_{i=1}^n (Z_i - \bar{Z}) u_i}{\sum_{i=1}^n (Z_i - \bar{Z}) B_i}.$$

Anhand dieser Form kann der Erwartungswert sowie das Verhalten für große Stichproben untersucht werden. Eine wichtige Eigenschaft ist

$$E(\hat{\beta}_{IV}) = \beta_1 + \underbrace{E\left(\frac{\sum_{i=1}^n (Z_i - \bar{Z}) u_i}{\sum_{i=1}^n (Z_i - \bar{Z}) B_i}\right)}_{\neq 0}, \quad (6.5)$$

sodass $\hat{\beta}_{IV}$ bei Endogenität von X ein *verzerrter Schätzer* von β_1 ist.¹ Glücklicherweise kann man zeigen, dass

$$\frac{\sum_{i=1}^n (Z_i - \bar{Z}) u_i}{\sum_{i=1}^n (Z_i - \bar{Z}) B_i} \rightarrow 0 \quad \text{für } n \rightarrow \infty$$

bei Gültigkeit der IV-Annahmen (6.2) und (6.3), d.h. $\hat{\beta}_{IV}$ ist ein *konsistenter Schätzer* für β_1 ,

$$\hat{\beta}_{IV} \rightarrow \beta_1 \quad \text{für } n \rightarrow \infty.$$

Schwache Instrumente

Beachte, dass die Annahme der Relevanz des Instruments für die Herleitung des Identifikationsprinzips und des Schätzers (6.4) von entscheidender Bedeutung ist: Sind Z und B unkorreliert, so ist $Cov(B, Z) = 0$ und β_1 damit nicht identifizierbar. Weiterhin würde $\widehat{Cov}(B, Z) \rightarrow 0$ wenn $n \rightarrow \infty$, sodass $\hat{\beta}_{IV} \rightarrow \infty$!

In empirischen Anwendungen ist $Cov(B, Z) = 0$ unwahrscheinlich. Die Kovarianz von B und Z kann jedoch gering sein. In diesem Fall bezeichnet man Z als ein *schwaches Instrument*. Anhand von Gleichung (6.4) können wir die Konsequenzen der Verwendung eines schachen Instruments ableiten: Ein sehr schwacher linearer Zusammenhang von B und Z — und damit tendenziell $\widehat{Cov}(B, Z) \approx 0$ — kann trotz Relevanz von Z zu einem Schätzer mit großer Varianz führen.

Die Relevanz eines Instruments kann mit einem Hypothesentests geprüft werden. Wie die “Stärke” eines Instruments beurteilt werden sollte, ist eine nicht-triviale Frage. Wir betrachten diesen Aspekt näher in Kapitel 6.2.

¹ Beachte, dass der endogene Regressor B_i mit u_i korreliert, sodass der Erwartungswert des Bruchs in (6.5) ungleich 0 ist.

6.1.1 Identifizierbarer Behandlungseffekt

Regression ermöglicht in der Regel die Schätzung eines durchschnittlichen Behandlungseffekts (ATE) für eine betrachtete Population mit heterogenen Behandlungseffekten (in Modell (6.1) unterstellen wir den empirisch unwahrscheinlichen Fall eines einheitlichen kausalen Effekts β_1). Das Adjustieren für Endogenität mit IV-Regression hat hier einen Preis: Beachte, dass im IV-Design ein Teil der beobachteten Variation der Behandlungsvariable B (wie in (6.1) angenommen) endogen ist und wir den Effekt von B auf Y anhand der *exogenen* Variation eines validen Instruments Z schätzen. Daher können wir grundsätzlich nur einen *lokalen* durchschnittlichen Behandlungseffekt (LATE) identifizieren: Der LATE ist eine gewichtete Variante des ATE, wobei Beobachtungen, deren Behandlung gut durch Z erklärt wird den größten Einfluss haben.²

6.2 2SLS-Verfahren

Der einfache IV-Schätzer (6.4) ist ein Spezialfall eines allgemeineren Regressionsverfahrens, das in zwei Schritten Durchgeführt wird. Im Fall von Modell (6.1) erfolgt die Schätzung anhand der folgenden einfachen Regressionen:

- **1. Stufe: Regression von B auf Z**

Regressiere die endogene Variable B auf das Instrument Z :

$$B_i = \alpha_0 + \alpha_1 Z_i + u_i, \quad 1, \dots, n. \quad (6.6)$$

Berechne die geschätzten Werte

$$\hat{B}_i = \hat{\alpha}_0 + \hat{\alpha}_1 Z_i. \quad (6.7)$$

Die \hat{B}_i aus dieser Regression sind “bereinigt”: Die Variation in den \hat{B}_i wird lediglich durch die exogene Variation in Z verursacht.

- **2. Stufe: Regression von Y auf \hat{B}**

Regressiere die Beobachtungen der abhängigen Variable Y_i auf die geschätzten Werte \hat{B}_i aus der 1. Stufe:

$$Y_i = \gamma_0 + \gamma_1 \hat{B}_i + e_i. \quad (6.8)$$

²Siehe Kapitel 10 und 19 in Huntington-Klein (2021) für nicht-technische Erläuterungen und Beispiel zu LATE.

Der geschätzte Koeffizient $\hat{\gamma}_1$ aus dieser Regression ist der Two-Stage-Least-Squares-Schätzer (2SLS-Schätzer) von β_1 .

6.2.1 Äquivalenz von 2SLS und einfacher IV-Schätzer

Der KQ-Schätzer von γ_1 in der 2. Stufe ist

$$\hat{\gamma}_1 = \frac{\sum(\hat{B}_i - \bar{\hat{B}})(Y_i - \bar{Y})}{\sum(\hat{B}_i - \bar{\hat{B}})^2} = \frac{\widehat{\text{Cov}}(\hat{B}, Y)}{\widehat{\text{Var}}(\hat{B}_i)}. \quad (6.9)$$

Da $\hat{B}_i = \hat{\alpha}_0 + \hat{\alpha}_1 Z_i$, die angepassten Werte aus der 1. Stufe, eine lineare Funktion von Z_i sind, können wir $\widehat{\text{Cov}}(\hat{B}, Y)$ wie folgt schreiben:

$$\widehat{\text{Cov}}(\hat{B}, Y) = \hat{\alpha}_1 \widehat{\text{Cov}}(Z, Y) \quad (6.10)$$

Eine ähnliche Umformung zeigt, dass

$$\widehat{\text{Var}}(\hat{B}) = \hat{\alpha}_1^2 \widehat{\text{Var}}(Z). \quad (6.11)$$

Kombinieren wir diese Ergebnisse, erhalten wir folgende Darstellung für den KQ-Schätzer von γ_1 in der 2. Stufe:

$$\hat{\gamma}_1 = \frac{\widehat{\text{Cov}}(\hat{B}, Y)}{\widehat{\text{Var}}(\hat{B})} = \frac{\hat{\alpha}_1 \widehat{\text{Cov}}(Z, Y)}{\hat{\alpha}_1^2 \widehat{\text{Var}}(Z)} = \frac{\widehat{\text{Cov}}(Z, Y)}{\hat{\alpha}_1 \widehat{\text{Var}}(Z)} \quad (6.12)$$

Der KQ-Schätzer von $\hat{\alpha}_1$ in der 1. Stufe ist definiert als $\hat{\alpha}_1 = \frac{\widehat{\text{Cov}}(Z, B)}{\widehat{\text{Var}}(Z)}$. Somit gilt

$$\hat{\gamma}_1 = \frac{\widehat{\text{Cov}}(Z, Y)}{\frac{\widehat{\text{Cov}}(Z, B)}{\widehat{\text{Var}}(Z)} \widehat{\text{Var}}(Z)} = \frac{\widehat{\text{Cov}}(Z, Y)}{\widehat{\text{Cov}}(Z, B)} = \hat{\beta}_{\text{IV}}. \quad (6.13)$$

6.2.2 Wozu 2SLS?

In der Praxis werden IV-Schätzungen mit statistischer Software häufig anhand einer Implementierung des 2SLS-Verfahren durchgeführt. Gründe hierfür sind:

- 1. Bedingte Exogenität.** Für den in Abbildung 6.1 dargestellten DGP ist die Exogenität von Z gegeben. In empirischen Anwendungen kann es jedoch schwierig sein, ein Instrument Z zu finden, dass plausibel nur

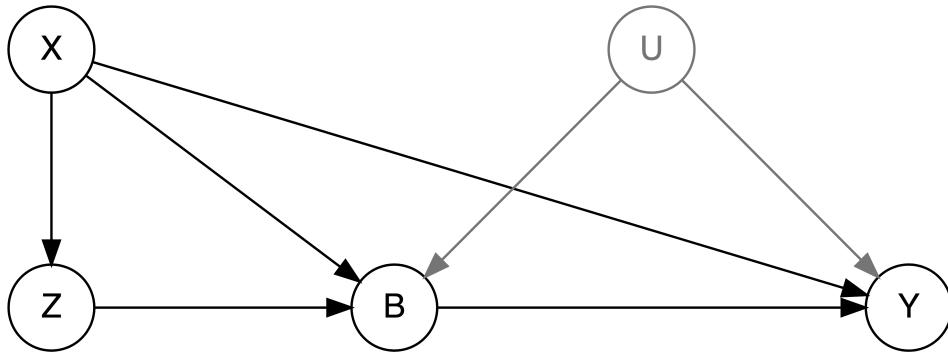


Abbildung 6.2: IV-Design mit beobachtbaren Confoundern

mit dem endogenen Regressor korreliert. Eine schwächere Bedingung als Exogenität ist Exogenität nach Kontrolle für *beobachtbare* gemeinsame Determinanten (X) von Z und Y.³

Diese Situation ist in Abbildung 6.2 dargestellt: Aufgrund der Pfeile von X zu Z und Y ist die Bedingung (6.3) verletzt. Durch Kontrolle für X in *beiden* Regressionen des 2SLS-Verfahrens können die Pfade durch X geschlossen werden.

2. **Mehrere endogene Variablen / Instrumente.** Der 2SLS-Ansatz kann leicht für mehrere endogene Variablen (und mehrere Instrumentvariablen) erweitert werden. Für jede der endogenen Variablen erfolgt hierbei eine separate Regression in der ersten Stufe des 2SLS-Verfahrens, wobei jeweils mehrere Instrumente verwendet werden und zusätzlich für beobachtbare Kovariablen X kontrolliert werden kann.

3. **Statistische Inferenz.** Die Berechnung von $\hat{\beta}_{IV}$ erfordert Sorgfalt bei der Konstruktion von Inferenzstatistiken. Die in Kapitel 6.2.1 gezeigte Äquivalenz impliziert, dass wir bei der Schätzung der Variabilität von $\hat{\beta}_{IV}$ die Unsicherheit aus den beiden KQ-Schätzungen des 2SLS-Verfahrens berücksichtigen müssen. Korrigierte Standardfehlerformeln können vergleichsweise einfach anhand der Regressionsdarstellung hergeleitet werden und sind statistischer Software implementiert (bspw. `ivreg` in R).

Weiterhin ermöglicht das Regressions-Framework diagnostische Tests. So kann die Relevanz von Instrumenten anhand von F-Tests für die Koeffizienten in den Regressionen der ersten Stufe des 2SLS-Verfahrens überprüft werden. Sofern mehr Instrumente als endogene Variablen vorliegen, kann die Exogenität der Instrumente getestet werden.

³Formal: $\text{Cov}(Z, u|X) = 0$.

Interaktive Illustrationen des 2SLS-Verfahren

Der DGP im nachfolgenden interaktiven Beispiel ist

$$\begin{aligned} X_i &= \gamma \cdot Z_i + v_i, \\ Y_i &= \beta_1 \cdot X_i + u_i, \end{aligned} \tag{6.14}$$

wobei $Z_i \sim N(0, .25^2)$. Die Fehlerterme v_i und u_i sind $N(0, 1)$ -verteilt und folgen einer gemeinsam Normalverteilung mit Korrelationsparameter ρ ,

$$\begin{pmatrix} v_i \\ u_i \end{pmatrix} \sim N \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right]. \tag{6.15}$$

Wir sind daran interessiert, den Parameter β_1 zu schätzen, um den Effekt von X auf Y zu bestimmen, wobei wir $n = 1000$ Beobachtungen von (X_i, Y_i, Z_i) verwenden.

Beachte, dass X_i eine Funktion der (exogenen) Variable Z_i und des Fehlerterms v_i ist. Wenn die Fehlerterme $(v_i, u_i)'$ im DGP (6.14) korreliert sind ($\rho \neq 0$), dann besteht Korrelation zwischen X_i und u_i . Dies impliziert, dass X ein endogener Regressor im “naiven” Regressionsmodell

$$Y_i = \beta_0 + \beta_1 X_i + e_i, \quad i = 1, \dots, N. \tag{6.16}$$

Der KQ-Schätzer von β_1 ist dann *verzerrt und inkonsistent*.

Wenn Z Erklärungskraft für X hat, d.h. $\gamma \neq 0$ mit $|\gamma|$ nicht zu klein gewählt ist (Z ist relevant), und Z nur über X auf Y wirkt (Z ist exogen in der Gleichung von Y_i), dann kann der kausale Effekt von X auf Y anhand einer Instrumentvariablen-Regression mit Z konsistent geschätzt werden.

Die folgende Interaktive Grafik berechnet den 2SLS-Schätzer Analog zu der in Kapitel 6.2 erläuterten Vorgehensweise:

1. Schätze das Regressionsmodell

$$X_i = \alpha_0 + \alpha_1 \cdot Z_i + \epsilon_i \tag{6.17}$$

und berechnen Sie die angepassten Werte \hat{X}_i . Dieser Schritt isoliert die exogene Variation in X_i , die auf Z_i zurückzuführen ist.

2. Schätzen den Effekt von X auf Y unter Verwendung von \hat{X}_i , dem exogenen Teil von X_i aus 1., in der Regression

$$Y_i = \delta_0 + \delta_1 \cdot \hat{X}_i + \varepsilon_i. \quad (6.18)$$

Der KQ-Schätzer $\hat{\delta}_1$ von δ_1 ist der 2SLS-Schätzer von β_1 .

Die Grafik illustriert das Verhalten des IV-Schätzers (lila Grade) im Vergleich zum KQ-Schätzer (gestrichelte Grade) und zum wahren Zusammenhang (grüne Grade) für eine simulierte Stichprobe (gegeben der gewählten Parameter) anhand der geschätzten Regressionslinien. Die voreingestellten Parameter-Kombinationen zeigen

- die Verzerrung von 2SLS, wenn Z ein schwaches Instrument für X ist,
- eine Situation in der X exogen ist (KQ ist unverzerrt), was zu vergleichbaren Schätzungen führt (sofern Z kein Schwaches Instrument ist)
- eine starke Verzerrung von KQ, wenn X endogen und irrelevant ($\beta_1 = 0$) ist.

Anhand der obigen interaktiven Grafik lässt sich zwar die Verzerrung der Schätzer einschätzen, jedoch nicht die Unsicherheit der Schätzung. Um die gesamte Verteilung der Schätzer in endlichen Stichproben zu illustrieren, zeigt die nachstehende Grafik Kerndichteschätzungen basierend auf N simulierte Stichproben der Größe n für den gewählten DGP.⁴ Die Applikation gibt weiterhin den R-Code für eine Simulation der Daten gemäß der gewählten Parameter aus.

Die voreingestellten Parameter-Kombinationen zeigen:

- Wenn Z ein schwaches Instrument ist, kann der IV-Schätzer verzerrt sein und eine deutlich größere Varianz als der KQ-Schätzer haben.
- Wenn X exogen ist, hat der IV-Schätzer eine größere Varianz als der KQ-Schätzer.
- Wenn die Endogenität von X „stark“ ist (hohe Korrelation von u und v), kann der IV-Schätzer auch in kleinen Stichproben hilfreich sein: IV hat eine deutlich geringere Verzerrung als KQ, aber eine größere Varianz.

⁴Beachte, dass die Simulation insbesondere für große N und n einige Sekunden dauern kann (grauer Balken am linken Rand zeigt laufende Berechnung an).

```
library(faux) # install.packages("faux")

set.seed(1234)

n <- 1000

errors <- rnorm_multi(
  n, mu = c(0, 0), sd = c(1, 1),
  r = -0.8, varnames = c("u", "v"),
)

Z <- rnorm(n, sd = .25)
X <- 2 * Z + errors$v
Y <- 0 * X + errors$u

the_data <- data.frame(X, Y)
```

```
library(cowplot)

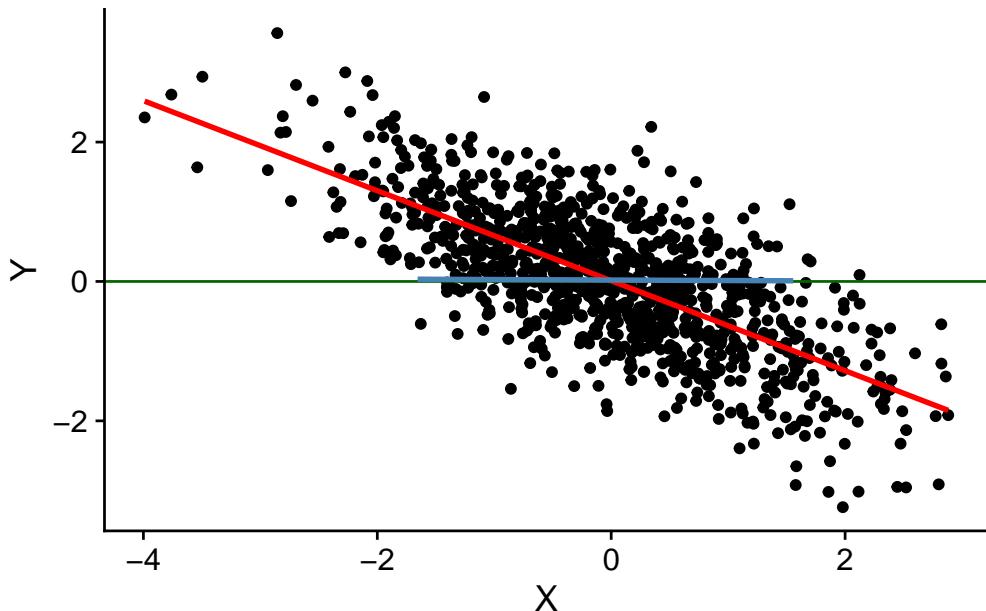
the_data %>%
  mutate(Xhat = lm(X ~ Z)$fitted) %>%

  ggplot(aes(x = X, y = Y)) +
  geom_point() +
  geom_smooth(
    method = "lm",
    se = FALSE,
    col = "red"
  ) +
  geom_hline(
    yintercept = 0,
    col = "darkgreen"
  ) +
  geom_smooth(
    mapping = aes(x = Xhat, y = Y),
    method = "lm",
    se = FALSE,
```

```

    col = "steelblue"
) +
theme_cowplot()

```



```

library(AER)

KQ_mod_sim <- lm(
  formula = Y ~ X,
  data = the_data
)

summary(KQ_mod_sim)

```

Call:

`lm(formula = Y ~ X, data = the_data)`

Residuals:

Min	1Q	Median	3Q	Max
-2.10480	-0.48829	0.00025	0.49527	2.42887

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.01074	0.02254	0.476	0.634

```

X           -0.64579    0.02025 -31.889   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.7128 on 998 degrees of freedom
Multiple R-squared:  0.5047,    Adjusted R-squared:  0.5042
F-statistic:  1017 on 1 and 998 DF,  p-value: < 2.2e-16

```

```

library(ivreg)

iv_mod_sim <- ivreg(
  formula = Y ~ X | Z,
  data = the_data
)

summary(iv_mod_sim)

```

Call:
`ivreg(formula = Y ~ X | Z, data = the_data)`

Residuals:

Min	1Q	Median	3Q	Max
-3.24501	-0.67660	0.01894	0.69021	3.52318

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.020535	0.031863	0.644	0.519
X	-0.007139	0.059949	-0.119	0.905

Diagnostic tests:

	df1	df2	statistic	p-value
Weak instruments	1	998	294.5	<2e-16 ***
Wu-Hausman	1	997	415.3	<2e-16 ***
Sargan	0	NA	NA	NA

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.007 on 998 degrees of freedom

Multiple R-Squared: 0.0111, Adjusted R-squared: 0.01011
Wald test: 0.01418 on 1 and 998 DF, p-value: 0.9052

6.3 Beispiel: Der schwache Staat, die Bauern und die Mafia

Acemoglu, De Feo, und De Luca (2020) untersuchen den Aufstieg und die Auswirkungen der sizilianischen Mafia gegen Ende des 19. Jahrhunderts. Die Studie argumentiert, dass das Wachstum der Mafia teilweise auf das Aufkommen sozialistischer Bauern-Organisationen (Fasci siciliani) zurückzuführen ist, die in einem Umfeld schwacher staatlicher Präsenz die Rechte der Bauern verteidigten. Grundbesitzer, Verwalter und lokale Politiker wandten sich also an die Mafia, um diese sozialistische "Bedrohung" zu bekämpfen und die Kontrolle über die landwirtschaftlich arbeitende Bevölkerung zu behalten. Die Studie identifiziert einen signifikanten (positiven) kausalen Zusammenhang zwischen dem Aufstieg der Fasci und der Ausbreitung der Mafia in Sizilien.

6.3.1 Identifikationsstrategie

Die Beziehung zwischen dem Aufkommen der Fasci und der Mafia-Aktivität im einfachen Regressionsmodell

$$\text{Mafia-Aktivität} = \beta_0 + \beta_1 \text{Fasci siciliani} + \varepsilon \quad (6.19)$$

ist aufgrund mehrerer Faktoren endogen:

1. **Externe Faktoren**, die sowohl die Entstehung der Fasci siciliani als auch der Mafia beeinflussen sind wahrscheinlich. Beispielsweise könnten wirtschaftliche Notlagen oder politische Instabilität sowohl die Organisation der Bauern als auch die Etablierung der Mafia begünstigen.
2. **Simultante Kasalität**: Die Präsenz der Fasci könnte die Mafia-Aktivitäten beeinflussen und umgekehrt: Intensive Mafia-Aktivitäten könnten die Notwendigkeit für Bauernorganisationen erhöhen, was wiederum die Mafia stärkt. Außerdem erschwert die zeitliche Nähe zwischen der Entstehung der Fasci und der Verbreitung der Mafia die Identifizierung der Kausalrichtung.

Wir können das Modell (6.19) um (messbare) unter 1. fallende Regressoren erweitern, um einer verzerrten Schätzung aufgrund relevanter ausgelassener

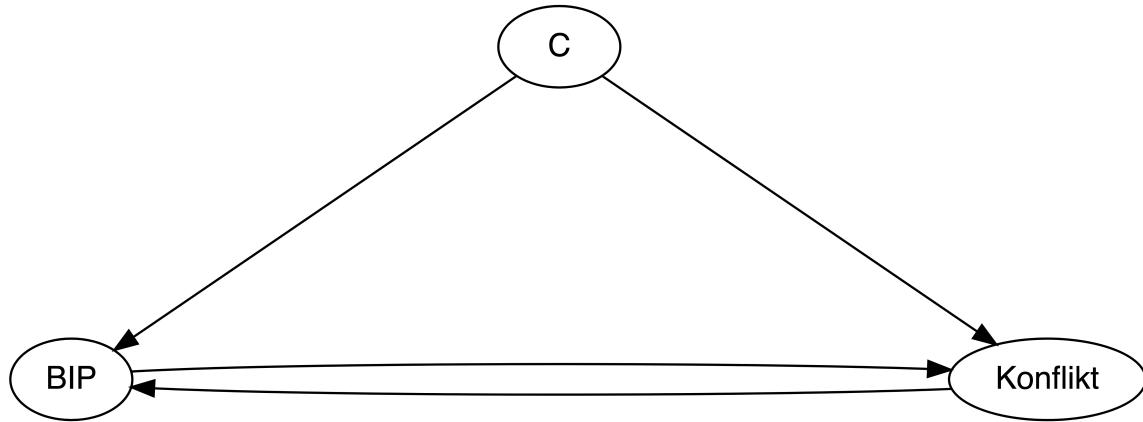


Abbildung 6.3: Simultane Kausalität zw. Kriegsrisiko und Wirtschaftslage

Variablen vorzubeugen. Eine Verzerrung aufgrund der in 2. beschriebenen simultanen Kausalität kann jedoch *nicht* durch multiple Regression vermieden werden.

Acemoglu, De Feo, und De Luca (2020) nutzen die folgende Identifikationsstrategie: Eine extreme Dürre im Jahr 1893 (insbesondere Regenausfall im Frühling) hatte einen erheblichen negativen Einfluss auf die landwirtschaftliche Produktion in Sizilien und verursachte große Not unter den Bauern, was die Entstehung der Fasci beförderte. Die Dürre kann als natürliches Experiment betrachtet werden, wobei durch die Variation in der Niederschlagsmenge (das Instrument) die Variation im Aufkommen von Fasci-Organisationen in verschiedenen Gemeinden isoliert werden kann, die unabhängig von der späteren Mafia-Aktivität ist. Anhand dieser exogenen Variation im Organisationsgrad der Bauern kann der Effekt auf die Entwicklung der Mafia identifiziert werden.

6.4 Case Study: Ökonomische Schocks und Bürgerkriege

Ein Kernproblem bei der Schätzung der kausalen Beziehung zwischen wirtschaftlichen Schocks und dem Auftreten von kriegerischen Auseinandersetzungen ist die Endogenität von Variablen, die wirtschaftliche Stabilität messen (vgl. Fearon und Laitin 2003). Beispielsweise kann eine Verschlechterung der wirtschaftlichen Bedingungen eines Landes die Wahrscheinlichkeit eines Konflikts im Inland erhöhen. Gleichzeitig beeinflussen kriegerische Handlung im Inland die wirtschaftliche Situation einer Volkswirtschaft negativ.

In der “Konfliktgleichung”

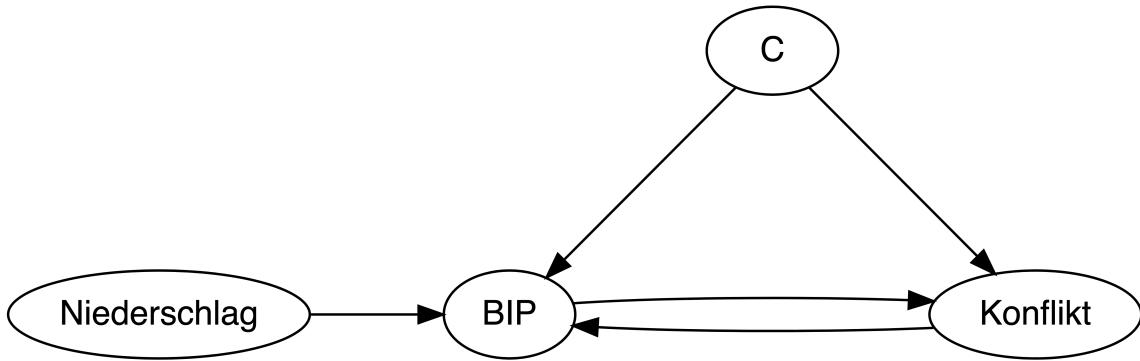


Abbildung 6.4: IV-Design bei simultaner Kausalität zw. Kriegsrisiko und Wirtschaftslage

$$\text{Konflikt-Wsk.} = \beta_0 + \beta_1 \Delta\text{BIP} + \text{Kontrollv.} + \epsilon \quad (6.20)$$

liegt dann Endogenität des Regressors für “wirtschaftliche Stabilität”, hier ΔBIP , aufgrund von simultaner Kausalität vor. Die multiple Regression (6.20) liefert dann eine verzerrte Schätzungen des interessierenden Effekts β_1 .

Miguel, Satyanath, und Sergenti (2004) untersuchen die kausale Beziehung zwischen wirtschaftlichen Schocks und dem Auftreten von Bürgerkriegen in 41 afrikanischen Sub-Sahara-Ländern für den Zeitraum von 1981 bis 1999.⁵ Hierbei adressieren die Autoren das Endogenitätsproblem in einem IV-Ansatz mit Instrumenten, die mit wirtschaftlichen Schocks korreliert sind, aber nicht unmittelbar mit der Wahrscheinlichkeit eines Bürgerkriegs zusammenhängen.

Die Identifikationsstrategie basiert auf metereologischen Faktoren: In den betrachteten Agrarökonomien sind Schocks in den Niederschlägen entscheidend für die Entwicklung des Bruttoinlandsprodukts. Ungünstige Wetterbedingungen, die landwirtschaftliche Erträge negativ beeinflussen, haben einen direkten (negativen) Effekt auf die wirtschaftliche Situation. Variation in der Regenmenge ist jedoch keine unmittelbare Determinante der Konfliktwahrscheinlichkeit und folglich exogen in Modellgleichung (6.20). Maße für die Veränderungen in der Niederschlagsmenge sind somit plausible Instrumente für endogene Variablen, die Veränderungen im Bruttoinlandsprodukt messen.

Anhand von Länder-Paneldaten mit Informationen über wirtschaftliche Indikatoren, Konflikt Ereignisse und Niederschläge, isolieren Miguel, Satyanath, und Sergenti (2004) in einem IV-Ansatz die exogene Variation der wirtschaftlichen

⁵Siehe `rainconflict$country %>% unique()`.

Entwicklung, d.h. Variation in Δ BIP die nicht mit dem Fehlerterm in der Konfliktgleichung korreliert ist. Die Ergebnisse ihrer 2SLS-Schätzungen zeigen, dass negative ökonomische Schocks die Wahrscheinlichkeit eines Bürgerkriegs signifikant erhöhen. Miguel, Satyanath, und Sergenti (2004) zeigen weiterhin, dass ihre Ergebnisse robust gegenüber verschiedenen Modell-Spezifikationen unter Berücksichtigung diverser Kontrollvariablen sind.

Wir reproduzieren nachfolgend die zentralen Ergebnisse von Miguel, Satyanath, und Sergenti (2004) anhand eines Auszugs (`rainconflict.csv`) aus dem der Studie zugrundeliegenden Datensatz. Der vollständige Datensatz ist, nach Registrierung, [hier](#) verfügbar.

```
library(readr)

# Datensatz 'rainconflict' einlesen
rainconflict <- read_csv2(
  file = "datasets/rainconflict.csv"
)

# Überblick verschaffen
glimpse(rainconflict)
```

Rows: 743
 Columns: 19
\$ any_prio <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
 0, 0, 1, 1, 1,~
\$ war_prio <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
 0, 0, 1, 0, 0,~
\$ ccode <dbl> 404, 404, 404, 404, 404, 404, 404, 404,
 404, 404, 404,~
\$ country <chr> "Guinea-Bissau", "Guinea-Bissau",
 "Guinea-Bissau", "Guinea--~
\$ gdp_g <dbl> 0.216560572, 0.104712047, -0.042654045,
 0.034653414, 0.0366~
\$ gdp_g_l <dbl> -0.152877718, 0.216560572, 0.104712047,
 -0.042654045, 0.034~
\$ GPCP_g <dbl> 0.170644149, 0.023161817, -0.215036541,
 0.098459557, 0.0185~
\$ GPCP_g_l <dbl> -0.048803251, 0.170644149, 0.023161817,
 -0.215036541, 0.098~

```

$ GPCP_g_fl  <dbl> 0.023161817, -0.215036541, 0.098459557,
0.018551834, 0.0545~
$ gdp_1979   <dbl> 0.556, 0.556, 0.556, 0.556, 0.556, 0.556,
0.556, 0.556, 0.5~
$ polity2l   <dbl> -7, -7, -7, -7, -8, -8, -8, -8, -8, -8, -6,
-6, -6, -6, 5, ~
$ polity2_IV <dbl> -7, -7, -7, -8, -8, -8, -8, -8, -8, -6, -6,
-6, -6, 5, 5, 5~
$ ethfrac    <dbl> 0.8037570, 0.8037570, 0.8037570, 0.8037570,
0.8037570, 0.80~
$ relfrac    <dbl> 0.5450, 0.5450, 0.5450, 0.5450, 0.5450,
0.5450, 0.5450, 0.5~
$ oil        <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, ~
$ lmtnest    <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, ~
$ lpop11     <dbl> 6.695799, 6.714170, 6.732211, 6.749931,
6.768493, 6.786717, ~
$ tot_100_g  <dbl> 0.3326812088, -0.0604966730, 0.0235692672,
0.6656700373, -0~
$ year       <dbl> 1981, 1982, 1983, 1984, 1985, 1986, 1987,
1988, 1989, 1990, ~

```

Tabelle 6.1: rainconflict – Polit-ökonomische Charakteristika afrikanischer Länder v. 1981 bis 1999

Variable	Beschreibung
any_prior	Dummyvariable: Konflikt mit mind. 25 Toten im Jahr t
war_prio	Dummyvariable: Konflikt mit mind. 1000 Toten im Jahr t
ccode	Länderkennung (numerisch)
country	Name des Landes
gdp_g	(BIP_t - BIP_t-1) / BIP_t-1
gdp_g_l	(BIP_t-1 - BIP_t-2) / BIP_t-2
GPCP_g	(Niederschlag_t - Niederschlag_t-1) / Niederschlag_t-1
GPCP_g_l	GPCP_g in t-1
GPCP_g_fl	GPCP_g in t+1
gdp_1979	Log Pro-Kopf-BIP in 1979
polity2_IV	Diff. zw. Demokratie- und Autokratie-Score im Jahr t (Skala v. -10 bis 10)
polity2l	polity2_IV im Jahr t-1 (Skala v. -10 bis 10)
ethfrac	Ethno-linguistische Fragmentierung (Anteil)

refrac	Religiöse Fragmentierung (Anteil)
oil	Dummy für Öl-exportierendes Land
lmtnest	Log Anteil Gebirgsregionen an Landesfläche
lpopl1	Log Bevölkerung im Jahr t-1
tot_100_g	Handelsbedingungen (Index, 1995 = 100)
year	Jahr der Beobachtung

```
# ccode zu Typ 'factor' transformieren
rainconflict <- rainconflict %>%
  mutate(
    ccode = as.factor(ccode)
  )
```

```
library(modelsummary)

# Statistische Zusammenfassung
datasummary(
  formula = All( rainconflict %>% select(-ccode, -year) )
  ~ (mean + sd) * Arguments(na.rm = TRUE)
  + N,
  fmt = 4,
  data = rainconflict
)
```

```
library(fixest)

# (1)
(
  rncnf_mod1 <- feols(
    fml = gdp_g ~ GPCP_g + GPCP_g_l,
    data = rainconflict,
    vcov = ~ ccode
  )
)
```

OLS estimation, Dep. Var.: gdp_g
 Observations: 743
 Standard-errors: Clustered (ccode)

Tabelle 6.2: rainconflict – Statistische Zusammenfassung

	mean	sd	N
any_prio	0.2678	0.4431	743
war_prio	0.1669	0.3731	743
gdp_g	-0.0048	0.0707	743
gdp_g_l	-0.0056	0.0724	743
GPCP_g	0.0182	0.2094	743
GPCP_g_l	0.0113	0.2067	743
GPCP_g_fl	0.0150	0.2107	743
gdp_1979	1.1639	0.9009	743
polity2l	-3.6083	5.5543	743
polity2_IV	-3.4035	5.5766	736
ethfrac	0.6546	0.2374	743
refrac	0.4868	0.1857	743
oil	0.1184	0.3233	743
lmtnest	1.5783	1.4334	743
lpopl1	8.7497	1.2068	743
tot_100_g	-0.0068	0.1552	661

```

Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.006147 0.002460 -2.49856 0.0166787 *
GPCP_g       0.055430 0.016301  3.40029 0.0015378 **
GPCP_g_l     0.034058 0.013213  2.57761 0.0137398 *
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.069815 Adj. R2: 0.02088

```

```

# (2)
rncnf_mod2 <- feols(
  fml = gdp_g ~ GPCP_g + GPCP_g_l
  + gdp_1979
  + polity2l
  + ethfrac
  + refrac
  + oil
  + lmtnest
  + lpopl1

```

```

+ year:ccode,
data = rainconflict,
vcov = ~ ccode
)

rncnf_mod2 %>%
print(n = 10)

```

OLS estimation, Dep. Var.: gdp_g
Observations: 743
Standard-errors: Clustered (ccode)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-8.380394	7.836789	-1.069366	0.2913157
GPCP_g	0.053402	0.016788	3.180892	0.0028359 **
GPCP_g_l	0.031518	0.013739	2.294105	0.0271135 *
gdp_1979	-0.568562	0.933728	-0.608916	0.5460230
polity21	-0.000462	0.000697	-0.661827	0.5118772
ethfrac	-0.290995	5.315419	-0.054745	0.9566138
relfrac	6.344474	6.277193	1.010718	0.3182264
oil	-0.022946	0.011735	-1.955363	0.0575517 .
lmtnest	-0.154883	0.950072	-0.163022	0.8713219
lpopl1	-0.103898	0.140671	-0.738588	0.4644693
... 41 coefficients remaining				

Signif. codes:	0 ***	0.001 **	0.01 *	0.05 .
RMSE:	0.067787	Adj. R2:	0.012893	1

```

# (3)
rncnf_mod3 <- feols(
  fml = gdp_g ~ GPCP_g + GPCP_g_l
  + year:ccode
  | ccode,
  data = rainconflict,
  vcov = ~ ccode
)

rncnf_mod3 %>%
print(n = 2)

```

OLS estimation, Dep. Var.: gdp_g
Observations: 743
Fixed-effects: ccode: 41
Standard-errors: Clustered (ccode)

	Estimate	Std. Error	t value	Pr(> t)
GPCP_g	0.048582	0.016523	2.94024	0.0054275 **
GPCP_g_l	0.028004	0.013779	2.03236	0.0487938 *
... 41 coefficients remaining				

Signif. codes:	0 ***	0.001 **	0.01 *	0.05 .
RMSE:	0.065802	Adj. R2:	0.023299	
		Within R2:	0.086915	

```
# (4)
rncnf_mod4 <- feols(
  fml = gdp_g ~ GPCP_g + GPCP_g_l + GPCP_g_fl
  + year:ccode
  | ccode,
  data = rainconflict,
  vcov = ~ ccode
)

rncnf_mod4 %>%
  print(n = 3)
```

OLS estimation, Dep. Var.: gdp_g
Observations: 743
Fixed-effects: ccode: 41
Standard-errors: Clustered (ccode)

	Estimate	Std. Error	t value	Pr(> t)
GPCP_g	0.048944	0.017837	2.743919	0.0090443 **
GPCP_g_l	0.028235	0.013783	2.048544	0.0471081 *
GPCP_g_fl	0.000617	0.018501	0.033337	0.9735719
... 41 coefficients remaining				

Signif. codes:	0 ***	0.001 **	0.01 *	0.05 .
RMSE:	0.065801	Adj. R2:	0.021818	
		Within R2:	0.086917	

```

# (5)
rncnf_mod5 <- feols(
  fml = gdp_g ~ GPCP_g + GPCP_g_l
  + tot_100_g
  + year:ccode
  | ccode,
  data = rainconflict,
  vcov = ~ ccode
)

rncnf_mod5 %>%
  print(n = 3)

```

OLS estimation, Dep. Var.: gdp_g
 Observations: 661
 Fixed-effects: ccode: 37
 Standard-errors: Clustered (ccode)

	Estimate	Std. Error	t value	Pr(> t)
GPCP_g	0.053124	0.017432	3.047509	0.0043049 **
GPCP_g_l	0.036616	0.014705	2.490060	0.0175258 *
tot_100_g	-0.002280	0.022286	-0.102318	0.9190722
... 37 coefficients remaining				

Signif. codes:	0 ***	0.001 **	0.01 *	0.05 .
RMSE:	0.059582	Adj. R2:	0.052542	
		Within R2:	0.114693	

```

# Tabellarischer Vergleich mit modelsummary()
# (Tabelle 3 in Ditella und Schargrodsky, 2004)
modelsummary(
  models = list(
    "(1)" = rncnf_mod1,
    "(2)" = rncnf_mod2,
    "(3)" = rncnf_mod3,
    "(4)" = rncnf_mod4,
    "(5)" = rncnf_mod5
  ),
  stars = T,
  coef omit = "^year.*$",

```

```

gof_omit = "^(?! (R2|Num.Obs.|FE.*))$).*",
output = "gt"
)

```

Tabelle 6.3: First-Stage-Regressionen für gdp_g

	(1)	(2)	(3)	(4)	(5)
(Intercept)	-0.006*	-8.380			
	(0.002)	(7.837)			
GPCP_g	0.055**	0.053**	0.049**	0.049**	0.053**
	(0.016)	(0.017)	(0.017)	(0.018)	(0.017)
GPCP_g_1	0.034*	0.032*	0.028*	0.028*	0.037*
	(0.013)	(0.014)	(0.014)	(0.014)	(0.015)
gdp_1979		-0.569			
		(0.934)			
polity2l		0.000			
		(0.001)			
ethfrac		-0.291			
		(5.315)			
refrac		6.344			
		(6.277)			
oil		-0.023+			
		(0.012)			
lmtnest		-0.155			
		(0.950)			
lpopl1		-0.104			
		(0.141)			
GPCP_g_fl			0.001		
			(0.019)		
tot_100_g				-0.002	
				(0.022)	
Num.Obs.	743	743	743	743	661
R2	0.024	0.079	0.133	0.133	0.162
FE: ccode			X	X	X

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

```

S1_res <- tibble(

```

```

x = residuals(
  feols(
    fml = GPCP_g ~ GPCP_g_1
    + year:ccode
    | ccode,
    data = rainconflict
  )
),

y = residuals(
  feols(
    fml = gdp_g ~ GPCP_g_1
    + year:ccode
    | ccode,
    data = rainconflict
  )
)

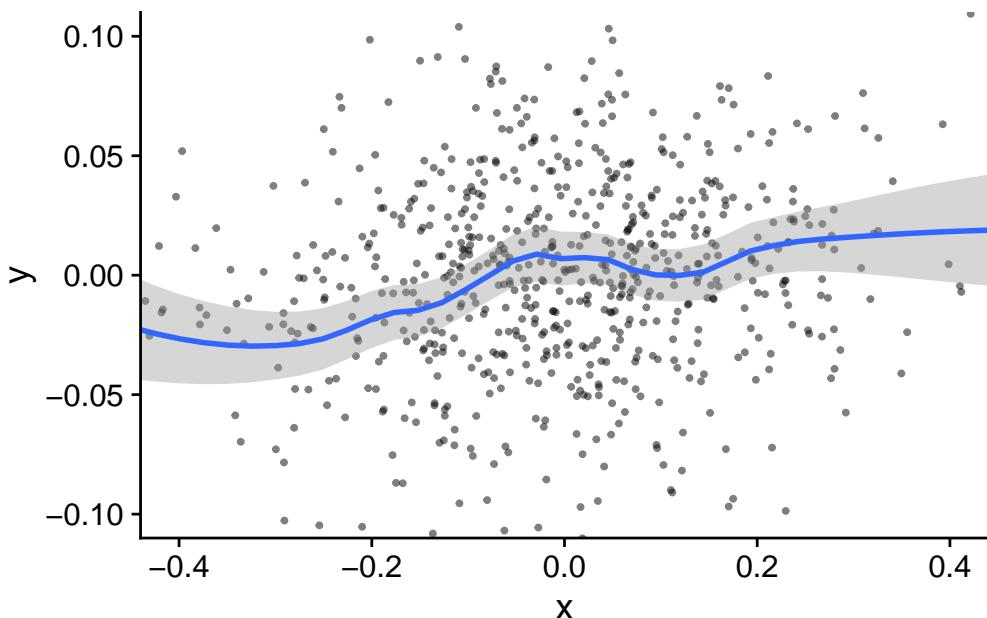
```

```

library(ggplot2)
library(cowplot)

ggplot(
  data = S1_res,
  mapping = aes(x = x, y = y)) +
  geom_point(
    size = .75,
    alpha = .5
  ) +
  geom_smooth(method = "loess", span = .5) +
  coord_cartesian(
    xlim = c(-.4, .4),
    ylim = c(-.1, .1)
  ) +
  theme_cowplot()

```



```
feols(
  fml = any_prio ~ GPCP_g + GPCP_g_1
  + year:ccode
  | ccode,
  data = rainconflict,
  vcov = ~ ccode
) %>%
  print(n = 2)
```

OLS estimation, Dep. Var.: any_prio
 Observations: 743
 Fixed-effects: ccode: 41
 Standard-errors: Clustered (ccode)

	Estimate	Std. Error	t value	Pr(> t)
GPCP_g	-0.023770	0.041969	-0.566373	0.57430
GPCP_g_1	-0.121936	0.050328	-2.422836	0.02002 *
... 41 coefficients remaining				

Signif. codes:	0 ***	0.001 **	0.01 *	0.05 .
RMSE:	0.239168	Adj. R2:	0.671564	
		Within R2:	0.374052	

```
feols(
  fml = war_prio ~ GPCP_g + GPCP_g_1
```

```

+ year:ccode
| ccode,
data = rainconflict,
vcov = ~ ccode
) %>%
print(n = 2)

```

OLS estimation, Dep. Var.: war_prio
Observations: 743
Fixed-effects: ccode: 41
Standard-errors: Clustered (ccode)

	Estimate	Std. Error	t value	Pr(> t)
GPCP_g	-0.062476	0.029051	-2.15060	0.037605 *
GPCP_g_l	-0.068689	0.030678	-2.23904	0.030783 *
... 41 coefficients remaining				

Signif. codes:	0 ***	0.001 **	0.01 *	0.05 .
RMSE:	0.204541	Adj. R2:	0.661198	
		Within R2:	0.385205	

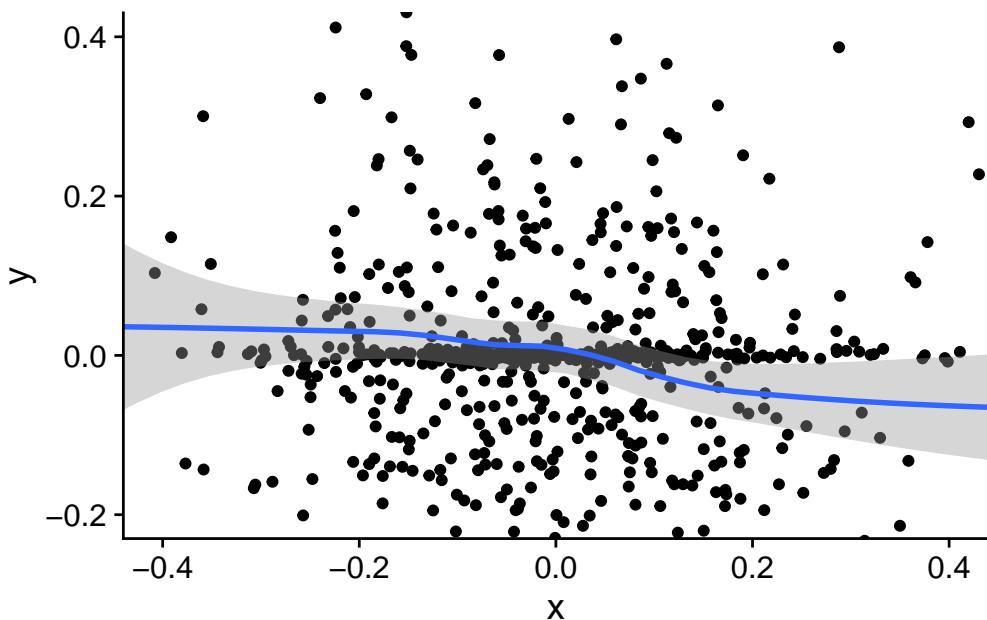
```

rf_res <- tibble(

  x = residuals(
    feols(
      fml = GPCP_g_l ~ GPCP_g
      + year:ccode
      | ccode,
      data = rainconflict
    )
  ),
  y = residuals(
    feols(
      fml = any_prio ~ GPCP_g
      + year:ccode
      | ccode,
      data = rainconflict
    )
  )
)
```

```
)
```

```
ggplot(  
  data = rf_res ,  
  mapping = aes(x = x, y = y)) +  
  geom_point(pch = 19) +  
  geom_smooth(method = "loess") +  
  coord_cartesian(  
    xlim = c(-.4, .4),  
    ylim = c(-.2, .4)  
) +  
  theme_cowplot()
```



```
# (1)  
mod_conf_probit <- feglm(  
  fml = any_prio ~  
    gdp_g +  
    gdp_g_l  
  + gdp_1979  
  + polity2l  
  + ethfrac  
  + refrac
```

```

+ oil
+ lmtnest
+ lpopl1
+ year,
data = rainconflict,
vcov = ~ ccode,
family = binomial(link = "probit")
)

library(marginalEffects)

mod_conf_probit_avge <- mod_conf_probit %>%
  avg_slopes()

# (2)
(
  mod_conf_ols <- feols(
    fml = any_prio ~
      gdp_g +
      gdp_g_l
    + gdp_1979
    + polity2l
    + ethfrac
    + refrac
    + oil
    + lmtnest
    + lpopl1
    + year,
    data = rainconflict,
    vcov = ~ ccode
  )
)

```

OLS estimation, Dep. Var.: any_prio
 Observations: 743
 Standard-errors: Clustered (ccode)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.381928	12.515620	-0.430017	0.669491
gdp_g	-0.332716	0.263400	-1.263157	0.213846

```

gdp_g_l      -0.084997  0.240857 -0.352894  0.726021
gdp_1979     -0.040662  0.049894 -0.814961  0.419921
polity21      0.000642  0.004515  0.142164  0.887664
ethfrac       0.230431  0.271367  0.849151  0.400851
refrac        -0.237764  0.241595 -0.984144  0.330961
oil           0.045297  0.211526  0.214144  0.831523
lmtnest       0.075811  0.039371  1.925548  0.061291 .
lpopl1        0.068052  0.051102  1.331675  0.190506
year          0.002483  0.006366  0.390106  0.698528
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.414086   Adj. R2: 0.113662

```

```

# (3)
feols(
  fml = any_prio ~ -1
  + gdp_g +
  gdp_g_l
  + gdp_1979
  + polity21
  + ethfrac
  + refrac
  + oil
  + lmtnest
  + lpopl1
  + i(ccode, year),
  data = rainconflict,
  vcov = ~ ccode
) %>%
  summary(n = 10)

```

```

OLS estimation, Dep. Var.: any_prio
Observations: 743
Standard-errors: Clustered (ccode)

              Estimate Std. Error    t value Pr(>|t|)
gdp_g        -0.387996  0.208988 -1.856550 0.070751 .
gdp_g_l      -0.086461  0.212442 -0.406986 0.686188
gdp_1979      2.287334  9.856030  0.232075 0.817663
polity21     -0.001355  0.004148 -0.326768 0.745547
ethfrac       43.124761 50.926744  0.846800 0.402145

```

```

relfrac      39.765573  63.751088  0.623763  0.536324
oil          0.006172   0.086301   0.071511  0.943347
lmtnest     -3.835094   7.462461  -0.513918  0.610137
lpopl1       1.211169   0.671842   1.802760  0.078964 .
ccode::404:year -0.033077   0.019564  -1.690721  0.098669 .
... 40 coefficients remaining
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.294151  Adj. R2: 0.526933

```

```

# (4)
feols(
  fml = any_prio ~ -1
  + gdp_g
  + gdp_g_l
  + i(ccode, year)
  | ccode,
  data = rainconflict,
  vcov = ~ ccode
) %>%
  summary(n = 10)

```

```

OLS estimation, Dep. Var.: any_prio
Observations: 743
Fixed-effects: ccode: 41
Standard-errors: Clustered (ccode)

      Estimate Std. Error    t value Pr(>|t|)
gdp_g      -0.210909  0.156046  -1.351587  0.18410
gdp_g_l      0.066801  0.158944   0.420279  0.67653
ccode::404:year  0.028626  0.001635  17.510274 < 2.2e-16 ***
ccode::420:year -0.015243  0.000745 -20.452968 < 2.2e-16 ***
ccode::432:year  0.007220  0.000373  19.349039 < 2.2e-16 ***
ccode::433:year  0.059746  0.000225 265.584211 < 2.2e-16 ***
ccode::434:year  0.000449  0.000485   0.924683  0.36068
ccode::435:year  0.000223  0.000544   0.410843  0.68338
ccode::436:year  0.035483  0.000574  61.802750 < 2.2e-16 ***
ccode::437:year  0.000284  0.001085   0.261893  0.79475
... 33 coefficients remaining
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

RMSE: 0.239816 Adj. R2: 0.669782
 Within R2: 0.370655

IV models

```
# (5)
feols(
  fml = any_prio ~
  + gdp_1979
  + polity2l
  + ethfrac
  + refrac
  + oil
  + lmtnest
  + lpopl1
  + i(ccode, year)
  | gdp_g + gdp_g_l ~ GPCP_g + GPCP_g_l,
  data = rainconflict,
  vcov = ~ ccode
) %>%
  summary(n = 10)
```

TSLS estimation - Dep. Var.: any_prio
 Endo. : gdp_g, gdp_g_l
 Instr. : GPCP_g, GPCP_g_l
Second stage: Dep. Var.: any_prio
Observations: 743
Standard-errors: Clustered (ccode)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-153.157460	60.518562	-2.530752	0.015419 *
fit_gdp_g	-1.343217	1.462578	-0.918390	0.363920
fit_gdp_g_l	-2.714015	1.036990	-2.617205	0.012453 *
gdp_1979	9.446193	11.069500	0.853353	0.398545
polity2l	-0.005806	0.004843	-1.198875	0.237631
ethfrac	83.847478	47.883805	1.751061	0.087601 .
refrac	95.038889	64.178048	1.480863	0.146478
oil	-0.058890	0.066111	-0.890779	0.378375
lmtnest	2.159746	7.025786	0.307403	0.760132
lpopl1	-0.336984	0.868944	-0.387809	0.700213
...	41 coefficients remaining			

```

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.346685  Adj. R2: 0.342806
F-test (1st stage), gdp_g : stat = 7.81825, p = 4.389e-4, on 2
and 692 DoF.
F-test (1st stage), gdp_g_l: stat = 5.56598, p = 0.003999, on 2
and 692 DoF.
Wu-Hausman: stat = 2.56365, p = 0.077756, on 2
and 690 DoF.

```

```

# (6)
feols(
  fml = any_prio ~
  + i(ccode, year)
  | ccode
  | gdp_g + gdp_g_l ~ GPCP_g + GPCP_g_l,
  data = rainconflict,
  vcov = ~ ccode
) %>%
  summary(n = 10)

```

```

TSLS estimation - Dep. Var.: any_prio
    Endo.      : gdp_g, gdp_g_l
    Instr.     : GPCP_g, GPCP_g_l
Second stage: Dep. Var.: any_prio
Observations: 743
Fixed-effects: ccode: 41
Standard-errors: Clustered (ccode)

            Estimate Std. Error   t value Pr(>|t|)
fit_gdp_g      -1.131763  1.362254 -0.830802 4.1102e-01
fit_gdp_g_l     -2.546473  1.070475 -2.378825 2.2230e-02 *
ccode::404:year  0.006632  0.013806  0.480372 6.3358e-01
ccode::420:year -0.005215  0.006294 -0.828648 4.1222e-01
ccode::432:year  0.012689  0.003059  4.148704 1.6945e-04 ***
ccode::433:year  0.063170  0.001807 34.960834 < 2.2e-16 ***
ccode::434:year  0.006202  0.004195  1.478344 1.4715e-01
ccode::435:year  0.008547  0.004353  1.963488 5.6568e-02 .
ccode::436:year  0.043387  0.004817  9.007338 3.5998e-11 ***
ccode::437:year  0.017506  0.008435  2.075379 4.4425e-02 *
... 33 coefficients remaining

```

```

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.302046      Adj. R2: 0.476172
                           Within R2: 0.001663
F-test (1st stage), gdp_g : stat = 6.67399, p = 0.001345, on 2
and 699 DoF.
F-test (1st stage), gdp_g_l: stat = 5.70442, p = 0.003488, on 2
and 699 DoF.
Wu-Hausman: stat = 3.14562, p = 0.043689, on 2
and 657 DoF.

```

```

# (7)
feols(
  fml = war_prio ~
    + i(ccode, year)
  | ccode
  | gdp_g + gdp_g_l ~ GPCP_g + GPCP_g_l,
  data = rainconflict,
  vcov = ~ ccode
) %>%
  summary(n = 10)

```

```

TSLS estimation - Dep. Var.: war_prio
                                      Endo.    : gdp_g, gdp_g_l
                                      Instr.   : GPCP_g, GPCP_g_l
Second stage: Dep. Var.: war_prio
Observations: 743
Fixed-effects: ccode: 41
Standard-errors: Clustered (ccode)

            Estimate Std. Error   t value Pr(>|t|)
fit_gdp_g     -1.479970  0.800386 -1.849071  0.071848 .
fit_gdp_g_l   -0.768785  0.678533 -1.133010  0.263956
ccode::404:year -0.001514  0.007526 -0.201188  0.841571
ccode::420:year  0.007088  0.003431  2.066077  0.045340 *
ccode::432:year  0.003375  0.001670  2.020730  0.050037 .
ccode::433:year  0.015992  0.000992 16.119071 < 2.2e-16 ***
ccode::434:year  0.004765  0.002306  2.065964  0.045351 *
ccode::435:year  0.004698  0.002393  1.963229  0.056599 .
ccode::436:year  0.005405  0.002624  2.059408  0.046005 *
ccode::437:year  0.008802  0.004699  1.872980  0.068392 .

```

```
... 33 coefficients remaining
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.228949      Adj. R2: 0.575516
                           Within R2: 0.229726
F-test (1st stage), gdp_g : stat = 6.67399, p = 0.001345, on 2
and 699 DoF.
F-test (1st stage), gdp_g_l: stat = 5.70442, p = 0.003488, on 2
and 699 DoF.
Wu-Hausman: stat = 1.46546, p = 0.231725, on 2
and 657 DoF.
```

```
library(modelsummary)

modelsummary(
  models = list(
    mod_conf_probit_avge,
    mod_conf_ols
  )
)
```

	(1)	(2)
ethfrac	0.220 (0.242)	0.230 (0.271)
gdp_1979	-0.063 (0.058)	-0.041 (0.050)
gdp_g	-0.350 (0.301)	-0.333 (0.263)
gdp_g_l	-0.127 (0.251)	-0.085 (0.241)
lmtnest	0.072 (0.036)	0.076 (0.039)
lpopl1	0.074 (0.049)	0.068 (0.051)
oil	0.015 (0.210)	0.045 (0.212)
polity2l	0.001 (0.005)	0.001 (0.005)
refrac	-0.271 (0.241)	-0.238 (0.242)
year	0.003 (0.006)	0.002 (0.006)
(Intercept)		-5.382 (12.516)
Num.Obs.	743	743
R2	0.122	0.126
R2 Adj.	0.099	0.114
AIC	779.8	820.4
BIC	830.6	871.1
RMSE	0.42	0.41
Std.Errors		by: ccode

7 Difference-in-Differences

Der Difference-in-Differences (DID) Ansatz erlaubt die Schätzung kausaler Effekte in quasi-experimentellen Forschungsdesigns, in denen Beobachtungen für Kontroll- und Behandlungsgruppe zu mindestens zwei Zeitpunkten vorliegen und die Behandlung zwischen diesen Zeitpunkten stattfindet: Wir beobachten sowohl die Kontroll- als auch die Behandlungsgruppe vor und nachdem die Behandlung erfolgt ist. Die Motivation für die Anwendung des DID-Ansatzes liegt in der Fähigkeit, typische Risiken einer Verzerrungen zu umgehen, die bei einfachen Vorher-Nachher-Vergleichen oder reinen Querschnittsvergleichen auftreten können. Die Kernidee ist eine Schätzung des ATT durch einen Vergleich durchschnittlicher Differenzen der Outcome-Variable beider Gruppen zwischen den Perioden vor und nach der Intervention. Abbildung 7.1 zeigt ein kausales Diagramm für ein Forschungsdesign, in dem DID den ATT identifizieren kann.

Abbildung 7.1 illustriert Confounding bei der Bestimmung des Behandlungseffekts durch Backdoors in der Zeit t und der Gruppenzugehörigkeit:

- **Zeit:** Der Behandlungszustand der behandelten Gruppe ändert sich durch die Intervention zwischen der Vor- und der Nachbehandlungsperiode. Die Outcome-Variable Y ändert sich für beide Gruppen über die Zeit hinweg.
- **Gruppenzugehörigkeit:** Die Gruppenzugehörigkeit legt fest, ob eine Behandlung erfolgt. Systematische Unterschiede zwischen Behandlungs- und Kontrollgruppe wirken sich auf die Outcome-Variable Y aus.

In einem DID-Ansatz ermöglicht die Beobachtung von Kontroll- und Behandlungsgruppen jeweils *bevor und nach* einer Intervention das Herausrechnen von systematischen Unterschieden zwischen Behandlungs- und Kontrollgruppe und von Zeiteffekten, sodass die Backdoors durch Gruppenzugehörigkeit und Zeit geschlossen. Die Schätzung eines durchschnittlichen Behandlungseffekts erfolgt hierbei unter der Annahme, dass die Outcome-Variable beider Gruppen *ohne die Intervention* einen hinreichend ähnlichen Verlauf aufweisen würde und damit die Kontrollgruppe ein plausibles Counterfactual für die Behandlungsgruppe darstellt.

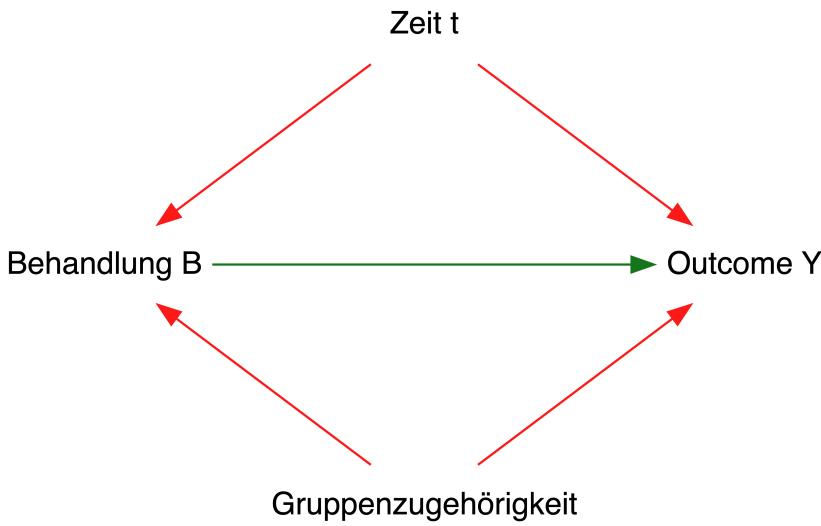


Abbildung 7.1: Kausales Diagramm für DID

7.1 Einordnung im Potential Outcomes Framework

Im Potential Outcomes Framework nehmen wir an, dass jede Einheit i in Abhängigkeit ihres Behandlungsstatus zwei potentielle Ergebnisse hat. Wir unterscheiden zwischen Beobachtungen in Behandlungs- und Kontrollgruppe:

- $Y_{i,B}(1)$: Y für Einheit i in der Behandlungsgruppe, wenn diese behandelt wird.
- $Y_{i,B}(0)$: Y für Einheit i in der Behandlungsgruppe, wenn diese *nicht* behandelt wird.
- $Y_{i,K}(1)$: Y für Einheit i in der Kontrollgruppe, wenn diese behandelt wird.
- $Y_{i,K}(0)$: Y für Einheit i in der Kontrollgruppe, wenn diese *nicht* behandelt wird.

In einem DID-Forschungsdesign hängen tatsächliche und potentielle Outcomes von der Zeit t ab: Die Behandlungsgruppe wird zwischen den Zeitpunkten $t = 0$ und $t = 1$ behandelt, während die Kontrollgruppe unbehandelt bleibt. Für die Identifizierung des Behandlungseffekts wird unterstellt, dass Y sich zwischen $t = 0$ und $t = 1$ in der Behandlungsgruppe *ohne eine Behandlung* (im Erwartungswert) mit demselben Trend entwickelt hätte, mit dem sich die Kontrollgruppe tatsächlich entwickelt hat (parallele Trends). Die Gültigkeit paralleler Trends ist entscheidend für die Validität der DID-Methode, da so sicherstellt ist, dass die beobachteten Unterschiede in den Ergebnissen auf die Behandlung zurückzuführen sind und nicht auf andere zeitgleich auftretende

Faktoren. Der Behandlungseffekt kann dann als eine *Differenz von Differenzen* geschrieben werden:

$$\begin{aligned}\beta_{DID} &= \left(E[Y_B(1)|t = 1] - E[Y_B(0)|t = 0] \right) \\ &\quad - \left(E[Y_K(0)|t = 1] - E[Y_K(0)|t = 0] \right)\end{aligned}\tag{7.1}$$

Der Effekt β_{DID} ist ein ATT, der über das Schließen der Backdoor in der Zeit (rote und blaue Differenzen der Erwartungswerte zwischen $t = 0$ und $t = 1$) sowie der Backdoor in der Gruppenzugehörigkeit (Differenz der Erwartungswert-Differenzen) identifiziert wird.

Eine Null-Ergänzung von (7.1) mit $E[Y_K(0)|t = 1] - E[Y_K(0)|t = 1]$ zeigt die Wichtigkeit der Gültigkeit paralleler Trends:

$$\begin{aligned}\beta_{DID} &= \left(E[Y_B(1)|t = 1] - E[Y_B(0)|t = 0] \right) - \left(E[Y_K(0)|t = 1] - E[Y_K(0)|t = 0] \right) \\ &\quad + E[Y_K(0)|t = 1] - E[Y_K(0)|t = 1] \\ &= \underbrace{E[Y_B(1)|t = 1] - E[Y_B(1)|t = 1]}_{=\text{ATT}} \\ &\quad + \underbrace{\left(E[Y_B(0)|t = 1] - E[Y_B(0)|t = 0] \right) - \left(E[Y_K(0)|t = 1] - E[Y_K(0)|t = 0] \right)}_{=\text{Verzerrung durch nicht-parallele Trends}}\end{aligned}$$

Diese Zerlegung zeigt, dass der ATT nur bei parallelen Trends identifiziert werden kann, d.h. wir benötigen

$$E[Y_B(0)|t = 1] - E[Y_B(0)|t = 0] = E[Y_K(0)|t = 1] - E[Y_K(0)|t = 0].$$

Beachte, dass $E[Y_B(0)|t = 1]$ der Erwartungswert des potentiellen Outcomes einer unbehandelten Behandlungsgruppe in $t = 1$ ist. Somit kann die Verzerrung durch nicht-parallele Trends nicht empirisch überprüft werden und muss ausschließlich durch das Forschungsdesign gewährleistet sein. In Anwendungen kann die Plausibilität der Annahme graphisch anhand geschätzter Trends in der Outcome-Variable oder durch Placebo-Tests untersucht werden.

Annahmen für DID

1. **Parallele Trends:** Die Trends in der Outcome Variable Y in Behandlungs- und Kontrollgruppe würden bis einschließlich $t = 1$ parallel verlaufen, wenn es keine Behandlung gäbe. Diese Annahme ist Voraussetzung dafür, dass Veränderungen im Outcome Y für die Behandlungsgruppe, die sich von Y für die Kontrollgruppe unterscheidet, ausschließlich dem Effekt der Behandlung zugeschrieben werden kann.
2. **Keine Interferenz und konsistente Behandlung (SUTVA):**
 - *Keine Interferenz:* Die Behandlung eines Individums hat keinen Einfluss auf das potentielle Outcome anderer Individuen, unabhängig von der Gruppenzugehörigkeit.
 - *Konsistente Behandlung:* Es gibt keine Variation in der Intensität oder Art der Behandlung innerhalb der Behandlungsgruppe.

7.2 Schätzung des ATT mit DID

Für die Schätzung von β_{DID} ersetzen wir die Erwartungswerte in (7.1) durch ihre Stichprobenmomente. Dies liefert den Schätzer

$$\hat{\beta}_{\text{DID}} = \left(\overline{Y_B(1)|t=1} - \overline{Y_B(0)|t=0} \right) - \left(\overline{Y_K(0)|t=1} - \overline{Y_K(0)|t=0} \right). \quad (7.2)$$

Die Implementierung von DID-Schätzern erfolgt meist anhand linearer Regression. Das Modell für zwei Zeitperioden ist

$$Y_{i,t} = \alpha + \beta_1 B_i + \beta_2 Z_t + \beta_3 (B_i \times Z_t) + \epsilon_{i,t}, \quad t \in \{0, 1\}, \quad (7.3)$$

wobei β_3 der interessierende Behandlungseffekt ist. Der Regressor $B_i \times Z_t$ ist die Interaktion zwischen der Behandlungsgruppenzugehörigkeit B_i und einem Indikator für den Zeitpunkt *nach* der Intervention, $Z_t = \mathbb{I}_{\{t=1\}}$. Beachte, dass wir in Modell (7.3) für Zeiteffekte und Gruppenzugehörig kontrollieren und damit die sich durch das Forschungsdesign ergebenden Backdoors (vgl. Abbildung 7.1) schließen.

Es ist $\hat{\beta}_3 = \hat{\beta}_{\text{DID}}$, d.h. der KQ-Schätzer von β_3 ist der DID-Schätzer des ATT und numerisch äquivalent zu (7.2). Die Berechnung von $\hat{\beta}_{\text{DID}}$ anhand von Modell (7.3) ist praktisch, da wir so Inferenzstatistiken mit etablierten R-Funktionen wie `summary()` und `lmtest::coeftest()` wie gewohnt berechnen können.

In empirischen Anwendungen stehen oft Datensätze mit mehreren Gruppen und mehr als zwei Beobachtungsperioden zur Verfügung. Beachte, dass das Modell (7.3) ein Spezialfall des allgemeinen Forschungsdesigns mit $t = 1, \dots, T$ für $T \geq 2$ Beobachtungsperioden und mehr als zwei Gruppen (mehrere Kontroll- und Behandlungsgruppen) ist. Eine dann häufig genutzte Modellspezifikation für die Schätzung des ATT mit DID ist eine Panel-Regression mit *Two-way Fixed Effects*,

$$Y_{i,t} = \theta_i + \eta_t + \beta_{\text{DID}}^{\text{TWFE}} D_{i,t} + \epsilon_{i,t}, \quad t = 1, \dots, T, \quad (7.4)$$

wobei θ_i und η_t Dummy-Variablen für Gruppen und Zeitperioden sind und $D_{i,t}$ der Behandlungsindikator ist. Dieses lineare Paneldaten-Modell kann komfortabel mit dem R-Paket `fixest` (s. `fixest::feols()`) implementiert werden. Bei mehreren Gruppen sollten cluster-robuste Standardfehler auf Gruppen-Ebene verwendet werden.

In Modell (7.4) identifiziert $\beta_{\text{DID}}^{\text{TWFE}}$ den ATE, sofern die Annahmen 1 (parallele Trends) und 2 (SUTVA) gelten. Damit die Annahme paralleler Trends gewährleistet ist, dürfen keine heterogenen Behandlungseffekte vorliegen, d.h. die Behandlungseffekte

- variieren nicht zwischen verschiedenen Gruppen
- sind unabhängig vom Zeitpunkt der Behandlung (relevant bei unterschiedlichen Behandlungszeitpunkten)
- entwickeln sich nicht dynamisch über die Zeit¹

Der Umgang mit heterogenen Behandlungseffekten ist Gegenstand der aktuellen ökonometrischen Forschung zu DID-Schätzern. Callaway und Sant'Anna (2021) schlagen eine nicht-parametrische Schätzung von gruppenspezifischen ATE zu verschiedenen Zeitpunkten vor, die zu einem globalen ATT zusammengefasst werden können.²

¹Siehe bspw. Goodman-Bacon (2021) für eine detaillierte Diskussion dieser Problematik.

²Die Methoden von Callaway und Sant'Anna (2021) sind im R-Paket `did` implementiert.

i Key Facts zum einfachen DID-Schätzer

- Im DID-Forschungsdesign kann der ATT durch einen Vergleich von *Differenzen* in den Ergebnissen vor und nach einer Behandlung zwischen Behandlungs- und Kontrollgruppen identifiziert werden.
- DID benötigt Beobachtungen einer Behandlungs- und einer Kontrollgruppe zu *mindestens* zwei verschiedenen Zeitpunkten, wobei der Behandlung zwischen diesen Zeitpunkten erfolgt.
- DID ist empfindlich gegenüber Verletzungen der Annahme, dass die zeitlichen Trends in der Outcome-Variable für die Behandlungs- und die Kontrollgruppen vor der Intervention parallel verlaufen.
- DID-Schätzer können in linearen Interaktionsmodellen mit Fixed Effects für Zeitperioden und Gruppenzugehörigkeit implementiert werden. Der interessierenden Effekt sind die Koeffizienten von Interaktionstermern zwischen den Indikatoren für die Nachbehandlungsperioden und für die Zugehörigkeit zu einer Behandlungsgruppe.
- In R können DID-Modelle mit `lm()` oder, in Fällen mit mehr als zwei Beobachtungsperioden, mit `fixest::feols()` geschätzt werden. In Forschungsdesigns mit mehreren Gruppen sollten cluster-robuste Standardfehler verwendet werden.

Die nachfolgende interaktive Grafik illustriert die Schätzung des ATT mit DID sowie die Verletzung der Annahme paralleler Trends anhand simulierter Daten für mehrere Zeitperioden. Der verwendete DID-Schätzer ist der KQ-Schätzer in Modell (7.3), d.h. wir betrachten ein Forschungsdesign in dem zwei Zeitperioden für die Schätzung verwendet werden, wobei die Behandlung zwischen diesen Perioden erfolgt.

Interaktive Elemente der Visualisierung

- Die Beobachtungen der Individuen zu 6 verschiedenen Zeitpunkten werden als Punkte dargestellt. Die Datenpunkte können mit *Zeige Daten* eingeblendet werden.
- Die geschätzten Trends beider Gruppen für den gesamten Beobachtungszeitraum und die Gruppenzugehörigkeit können mit *Zeige Trends* eingeblendet werden. Die Auswahl *Parallele Trends* stellt sicher, dass

beide Gruppen (mit Ausnahme des Behandlungseffekts in der Behandlungsgruppe) dem selben zeitlichen Trend folgen. Bei nicht-parallelen Trends folgt die Behandlungsgruppe einem positiven Trend mit größerer positiver Steigung als in der Kontrollgruppe.

- Die Behandlung erfolgt zwischen der mit dem Slider *Zeitpunkt* ausgewählten und der darauf folgenden Periode. Der tatsächliche Behandlungseffekt kann über den Slider *Effekt* festgelegt werden.

Anatomie der Schätzung des ATT bei *parallelen* Trends

- Wir illustrieren die Schätzen des ATT mit Formel (7.2). Kreise zeigen Mittelwerte für Kontroll- und Behandlungsgruppe *vor* der Intervention. Dreiecke zeigen Mittelwerte *nach* der Intervention.
- Die gestrichelte rote Linie zeigt den (kontrafaktischen) Verlauf der Behandlungsgruppe *ohne* Behandlung. Hierbei wird unterstellt, dass sich die Behandlungsgruppe mit demselben Trend *wie die Kontrollgruppe entwickelt hätte* (blaue Linie).
- Der geschätzte Behandlungseffekt wird als orangene vertikale Linie dargestellt. Dies ist die Differenz zwischen dem tatsächlichen post-Behandlungs-Mittelwert und dem kontrafaktischen Mittelwert der Behandlungsgruppe.

Anatomie der Schätzung des ATT bei *nicht-parallelen* Trends

- Für nicht-parallele Trends zeigt die Grafik den unterstellten kontrafaktischen Trend der Behandlungsgruppe als gestrichelte blaue linie. Der "tatsächliche" kontrafaktische Verlauf der Behandlungsgruppe wird als gestrichelte rote Linie dargestellt.
- Aufgrund des steileren (positiven) Trends in der Behandlungsgruppe ergibt sich eine *positive* Verzerrung von $\hat{\beta}_{DID}$. Diese Verzerrung wird durch die gestrichelte vertikale schwarze Linie kenntlich gemacht.
 - Für *positive* Behandlungseffekte wird der ATT *überschätzt*: die Verzerrung entspricht der Überlagerung der gestrichelten schwarzen linie mit der orangenen Linie des geschätzten Effekts.
 - Für *negative* Behandlungseffekte wird der ATT unterschätzt: die Verzerrung entspricht der gestrichelten schwarzen Linie oberhalb der orangenen Linie des geschätzten Effekts.

7.3 Schätzung von DID-Forschungsdesigns mit R

Wir erläutern nachfolgend die Schätzung von DID-Designs mit zwei Zeitperioden mit R und visualisieren die geschätzten Komponenten von $\hat{\beta}_{\text{DID}}$ ähnlich wie in der interaktiven Visualisierung. Hierzu erzeugen wir simulierte Daten gemäß der Vorschrift

$$Y_{i,t} = 2 + 3 \cdot Z_t + 5 \cdot B_i + 4 \cdot (Z_t \cdot B_i) + \epsilon_{i,t}$$
$$\epsilon_{i,t} \sim N(0, 1)$$
$$Z_t = \mathbb{I}_{\{t=1\}}$$
$$B_i = \mathbb{I}_{\{i \in \text{Behandlungsgruppe}\}},$$

wobei wir jeweils 100 Beobachtungen beider Gruppen zu beiden Zeitpunkten generieren.

```
library(tibble)
library(dplyr)

# Seed setzen
set.seed(1234)

# Anzahl der Beobachtungen (pro Gruppe u. Zeitpunkt)
n <- 100

# Daten simulieren
did_data <- tibble(
  Z = rep(rep(c(0, 1), each = n), times = 2),
  B = rep(c(0, 1), each = 2 * n),
  epsilon = rnorm(4 * n),
  outcome = 2 + 3 * Z + 5 * B + 4 * Z * B + epsilon
)

# Überblick
glimpse(did_data)
```

Rows: 400

Columns: 4

```

$ Z      <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, ~
$ B      <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, ~
$ epsilon <dbl> -1.20706575, 0.27742924, 1.08444118,
-2.34569770, 0.42912469, ~
$ outcome <dbl> 0.7929343, 2.2774292, 3.0844412, -0.3456977,
2.4291247, 2.5060~

```

Mit `lm()` implementieren wir ein einfaches Interaktionsmodell und lesen den geschätzten Effekt aus.

```

# Modell mit Regression schätzen
did_model <- lm(
  formula = outcome ~ Z * B,
  data = did_data
)

# Geschätzten ATE auslesen
(
  estimated_effect <- coef(did_model)["Z:B"]
)

```

```

Z:B
3.639286

```

Die Schätzung des Behandlungseffekts von 3.64 liegt nahe beim wahren Effekt von 4. Eine äquivalente Schätzung können wir mit `fixest::feols()` erhalten.

```

library(fixest)

# Interaktionsmodell mit feols() schätzen
feols(
  fml = outcome ~ Z * B,
  data = did_data
)

OLS estimation, Dep. Var.: outcome
Observations: 400
Standard-errors: IID

```

```

            Estimate Std. Error t value Pr(>|t|)
(Intercept) 1.84324   0.101233 18.2078 < 2.2e-16 ***
Z           3.19800   0.143166 22.3378 < 2.2e-16 ***
B           5.31137   0.143166 37.0994 < 2.2e-16 ***
Z:B         3.63929   0.202467 17.9747 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 1.00726  Adj. R2: 0.950969

```

Für eine Schätzung mit Two-way-fixed-effects modifizieren wir den Funktionsaufruf von `feols()`

```

# Two-way-FE-Regression
feols(
  fml = outcome ~ I(Z * B) | B + Z,
  data = did_data
)

```

OLS estimation, Dep. Var.: outcome
Observations: 400
Fixed-effects: B: 2, Z: 2
Standard-errors: Clustered (B)

	Estimate	Std. Error	t value	Pr(> t)
I(Z * B)	3.63929	4.2e-15	8.666101e+14	7.3461e-16 ***

Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.' 0.1 ' ' 1
RMSE:	1.00726	Adj. R2:	0.950969	
		Within R2:	0.449304	

Beachte, dass im Formel-Argument `fml` mit `I(Z * B)` lediglich der Interaktionseffekt als Regressor festgelegt wird. Fixe Effekte für Gruppenzugehörigkeit und Zeitpunkte werden durch den Zusatz `| B + Z` spezifiziert.³ Diese Reihenfolge führt zur Berechnung von cluster-robusten Standardfehlern auf Gruppen-Ebene (`B`). Wie erwartet können wir anhand des *t*-Tests die Nullhypothese $H_0: \beta_{DID} = 0$ zu jeden relevanten Signifikanzniveau ablehnen.

Für die Visualisierung der Schätzung mit `ggplot2::ggplot()` berechnen wir zunächst Stichprobenmittelwerte für die Outcome-Variable `y` beider Gruppen zu beiden Zeitpunkten.

³`I(Z * B)` statt `Z * B` stellt sicher, dass perfekte Multikollinearität aufgrund der Fixed-Effekts für `B` und `Z` vermieden wird.

```
# Stichprobenmittelwerte berechnen
options(digits = 4)
(
  means <- did_data %>%
    group_by(Z, B) %>%
    summarize(
      mean_outcome = mean(outcome),
      .groups = 'drop'
    )
)
```

```
# A tibble: 4 x 3
  Z     B mean_outcome
  <dbl> <dbl>      <dbl>
1 0     0       1.8
2 0     1       7.2
3 1     0       5.0
4 1     1      14.
```

Die Stichprobenmittelwerte in `means` ermöglichen uns die Schätzung von $E(Y_B(0)|t=2)$, das kontrafaktische erwartete Outcome (counterfactual) der Behandlungsgruppe zum Zeitpunkt $t=2$,

$$\begin{aligned}\overline{Y_B(0)|t=2} &= \overline{Y_B(0)|t=1} + \left(\overline{Y_K(0)|t=2} - \overline{Y_K(0)|t=1} \right) \\ &= 7.2 + (5.0 - 1.8) \\ &= 10.4.\end{aligned}$$

```
# Counterfactual für Behandlungsgruppe in t=1
(
  counterfactual <- means %>%
    filter(Z == 0 & B == 1) %>%
    pull(mean_outcome) +
    (
      means %>%
        filter(Z == 1 & B == 0) %>%
        pull(mean_outcome) -

```

```

means %>%
  filter(Z == 0 & B == 0) %>%
  pull(mean_outcome)
)
)

```

[1] 10.35

Der geschätzte Behandlungseffekt ist

$$\begin{aligned}\hat{\beta}_{DID} &= \overline{Y_B(1)|t=2} - \overline{Y_B(0)|t=2} \\ &= 14 - 10.4 \\ &= 3.6.\end{aligned}$$

Wir plotten die Daten mit ggplot2 und zeichnen die Trends sowie den geschätzten Behandlungseffekt ein.

```

# Simulierte daten plotten
did_data %>%
  ggplot(
    mapping = aes(
      x = factor(Z),
      y = outcome,
      color = factor(B),
      group = factor(B))
  ) +
  geom_point(
    position = position_jitter(
      width = .1,
      seed = 1234
    )
  ) +
  labs(
    x = "Zeitpunkt",
    y = "Outcome Y",
    color = "B"
  ) +
  scale_color_manual(

```

```

values = c("1" = "red", "0" = "blue")
) +
# Trendlinien einzeichnen
stat_summary(
  fun = mean,
  geom = "line",
  size = 1.5
) +
# Counterfactual für B-Gruppe einzeichnen
geom_segment(
  mapping = aes(
    x = 1,
    xend = 2,
    y = means$mean_outcome[
      means$Z == 0 & means$B == 1
    ],
    yend = counterfactual
  ),
  linetype = "dashed",
  color = "red",
  size = 1
) +
# gesch. Behandlungseffekt einzeichnen
geom_segment(
  mapping = aes(
    x = 2,
    xend = 2,
    y = counterfactual,
    yend = counterfactual + estimated_effect
  ),
  linetype = "dashed",
  color = "orange",
  size = 1) +
theme_cowplot() +
theme(legend.position = "top")

```

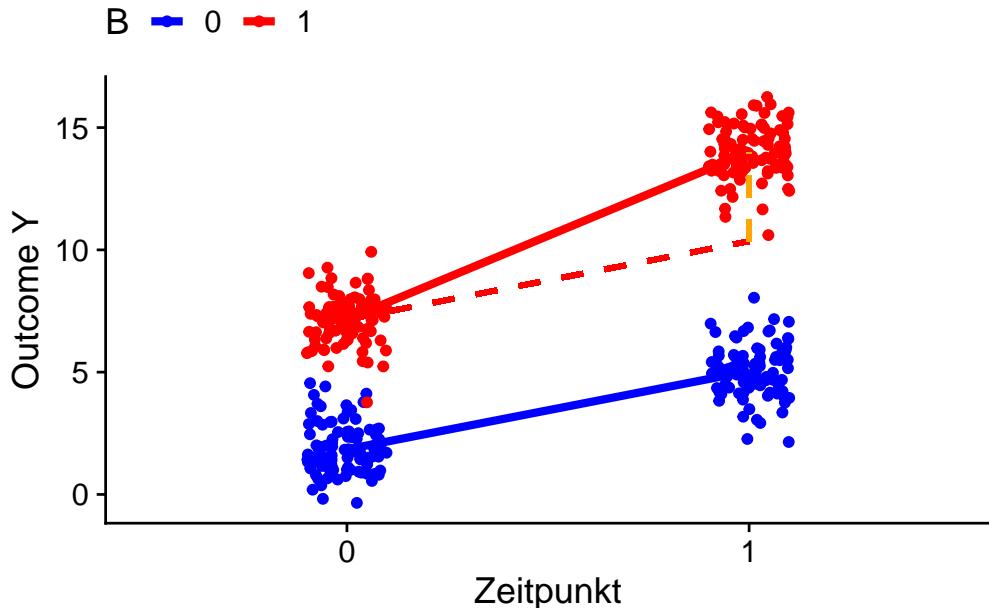


Abbildung 7.2: Einfache DID-Schätzung mit R für simulierte Daten

7.4 Case Study: Effekt von Steuererleichterungen auf Erwerbsbeteiligung

Der [Earned Income Tax Credit](#) (EITC) ist ein Steuerguthaben für US-Amerikanische Familien, die unterhalb einer gesetzlich festgelegten Einkommensgrenze liegen. Der genaue Betrag des EITC hängt gestaffelt vom Einkommen ab und, ähnlich zum Kindergeld in Deutschland, steigt mit der Anzahl der zu versorgenden Kinder. Ein wichtiger Unterschied zum Kindergeld ist, dass der EITC nicht beantragt werden muss: Qualifizierten Familien wird der Betrag automatisch durch die Behörden im Jahressteuerausgleich gutgeschrieben. Somit kann Selbstselektion in die Behandlungsgruppe ausgeschlossen werden, da sich die Behandlung ausschließlich durch die im Rahmen der EITC-Ausweitung geänderten Anspruchsgrundlagen ergibt.

Eissa und Liebman (1996) betrachten Veränderungen in der EITC-Gesetzgebung als Intervention, deren Auswirkungen mit sozio-ökonomischen Paneldaten in einem DID-Ansatz untersucht werden können. Die Studie analysiert die Auswirkungen der ersten Ausweitung des EITC im Jahr 1986 auf die Erwerbsbeteiligung und die Löhne von Müttern im erwerbsfähigen Alter. Diese Erweiterung erhöhte die gewährten Steuererleichterungen und die zur Qualifikation für das Programm zu unterschreitende Einkommensgrenze.

Ein zentraler Befund der Studie ist, dass die EITC-Ausweitung von 1986 einen statistisch signifikanten Anstieg der Arbeitsbeteiligung alleinerziehender Frauen

von geschätzten 3% bewirkt hat. Eissa und Liebman (1996) finden weiterhin signifikante positive Effekte auf die geleisteten Arbeitsstunden und Evidenz für Einkommensverbesserungen in dieser Gruppe. Die Studienergebnisse sind starke Evidenz, dass Maßnahmen wie der EITC effektiv dazu beitragen können, die Erwerbssituation in der Zielgruppe zu steigern und somit die wirtschafts- und sozialpolitische Ziele derartiger Programme realisierbar sind.

Im Jahr 1993 wurde das Programm erneut ausgeweitet: Vor 1993 gab es lediglich eine Einkommensstufe für Familien mit Kindern. 1993 wurde eine zusätzliche Stufe für Familien mit zwei oder mehr Kindern eingeführt, die damit einen höheren maximalen Kreditbetrag erhalten konnten als Familien mit nur einem Kind. Dies führte zu einer größeren steuerlichen Entlastung armutsbedrohter Familien.

Adireksombat (2010) untersucht die Effekte der zweiten EITC-Ausweitung ebenfalls mit einem DID Ansatz und findet Evidenz für einen Anstieg der Arbeitbeteiligung von etwa 5% in der Zielgruppe alleinerziehender Frauen mit mindestens 2 Kindern.

Zur Illustration der empirischen Anwendung von DID mit R untersuchen wir Effekte der EITC-Ausweitung von 1993 nachfolgend anhand eines ähnlichen Datensatzes aus dem [CPS](#) wie in der Studie von Adireksombat (2010). Diese Daten umfassen jährliche sozio-ökonomische Merkmale für US-amerikanische Frauen im Zeitraum von 1991 bis 1996 und sind in der Datei `eitc_data.csv` verfügbar.

Wir lesen den Datensatz zunächst ein.

```
library(readr)

# EITC-Datensatz einlesen
eitc_data <- read_csv("datasets/eitc_data.csv")
```

Eine Übersicht des Datensatzes `eitc_data` ist in Tabelle [7.1](#) dargestellt.

Tabelle 7.1: Sozi-ökonomische Variablen zu US-Familien aus dem CPS

Variable	Beschreibung
state	ID-Code Bundesstaat
year	Steuerjahr
urate	Arbeitslosenquote im Bundesstaat (%)
children	Anz. Kinder der Frau

nonwhite	Dummy für nicht-weiße Frauen
finc	Haushaltseinkommen im Steuerjahr (US-\$)
earn	Einkommen der Frau im Steuerjahr (US-\$)
age	Alter
ed	Ausbildungsniveau der Frau (Jahre)
work	Dummy für Berufstätigkeit
unearn	= Haushaltseinkommen - Einkommen der Frau (Tsd. US-\$)

Wir erweitern das `tibble`-Objekt zunächst um eine Dummy-Variable für Mütter (`anykids`), sowie spezifischere Dummies für Frauen mit einem Kind (`onechild`) oder mit zwei oder mehr Kindern (`twomorekids`). Weiterhin erzeugen wir einen Indikator für Beobachtungen *nach* der EITC-Ausweitung im Jahr 1993 (`after1993`).

```
# Dummies für Frauen mit Kindern
# und Post-Interventionsperiode hinzufügen
eitc_data <- eitc_data %>%
  mutate(
    onechild = if_else(children == 1, TRUE, FALSE),
    twomorekids = if_else(children >= 2, TRUE, FALSE),
    anykids = if_else(children > 0, TRUE, FALSE),
    after1993 = if_else(year > 1993, TRUE, FALSE)
  )
```

Einen Überblick über den modifizierten Datensatz erhalten wir mit `glimpse()`.

```
# Modifikationen kontrollieren
glimpse(eitc_data)
```

```
Rows: 13,746
Columns: 15
$ state      <dbl> 11, 12, 13, 14, 15, 16, 21, 22, 23, 31, 32,
33, 34, 35, 41~
$ year       <dbl> 1991, 1991, 1991, 1991, 1991, 1991, 1991,
1991, 1991, 1991~
$ urate       <dbl> 7.6, 7.2, 6.4, 9.1, 8.6, 6.8, 7.3, 6.7, 7.0,
6.4, 6.0, 7.2~
$ children    <dbl> 0, 1, 2, 0, 3, 1, 0, 0, 1, 2, 0, 2, 0, 0, 0,
```

```

$ nonwhite    <dbl> 1, 0, 0, 1, 1, 0, 1, 1, 1, 0, 0, 0, 0, 1,
0, 0, 0, 0~
$ finc         <dbl> 18714, 4839, 8178, 9370, 14707, 21605,
19147, 64312, 17676~
$ earn         <dbl> 18714.4, 471.4, 0.0, 0.0, 14706.6, 18854.6,
14141.0, 63802~
$ age          <dbl> 26, 22, 33, 43, 23, 53, 52, 51, 20, 32, 51,
29, 54, 28, 27~
$ ed           <dbl> 10, 9, 11, 11, 7, 7, 11, 11, 11, 11, 9, 10,
9, 11, 11, 7, ~
$ work         <dbl> 1, 1, 0, 0, 1, 1, 1, 1, 1, 1, 1, 0, 0, 0,
0, 0, 1, 1, 1~
$ unearn       <dbl> 0.0000, 4.3672, 8.1782, 9.3696, 0.0000,
2.7504, 5.0059, 0.~
$ onechild     <lgl> FALSE, TRUE, FALSE, FALSE, FALSE, TRUE,
FALSE, FALSE, TRUE~
$ twomorekids <lgl> FALSE, FALSE, TRUE, FALSE, TRUE, FALSE,
FALSE, FALSE, FALS~
$ anykids      <lgl> FALSE, TRUE, TRUE, FALSE, TRUE, TRUE, FALSE,
FALSE, TRUE, ~
$ after1993   <lgl> FALSE, FALSE, FALSE, FALSE, FALSE, FALSE,
FALSE, FALSE, FA~

```

Die Plausibilität der Annahme paralleler Trends können wir graphisch anhand einer Gegenüberstellung der *Beschäftigungsquote* (`avg.work = mean(work)`) für Frauen mit und ohne Kindern (`anykids`) über die Zeit (`year`) einschätzen. Wir gruppieren hierzu den Datensatz entsprechend und fassen die Outcome-Variable (`work`) gruppenweise zusammen.

```

# Zeitpunkt-Gruppen-Mittelwerte berechnen
(
  eitc_summarised <- eitc_data %>%
  group_by(year, anykids) %>%
  summarise(
    avg.work = mean(work)
  )
)

# A tibble: 12 x 3
# Groups:   year [6]

```

```

year anykids avg.work
<dbl> <lgl>      <dbl>
1 1991 FALSE      0.58
2 1991 TRUE       0.46
3 1992 FALSE      0.57
4 1992 TRUE       0.44
5 1993 FALSE      0.57
6 1993 TRUE       0.44
7 1994 FALSE      0.59
8 1994 TRUE       0.46
9 1995 FALSE      0.57
10 1995 TRUE      0.51
11 1996 FALSE     0.55
12 1996 TRUE      0.50

```

```

# Graphischer Vergleich der Trends
ggplot(data = eitc_summarised) +
  geom_line(
    mapping = aes(
      x = year,
      y = avg.work,
      col = anykids
    )
  ) +
  # Indikator für EITC-Erweiterung 1993
  geom_vline(
    xintercept = 1993,
    lty = "dashed"
  ) +
  scale_x_continuous("Jahr") +
  scale_y_continuous("Beschäftigungsquote") +
  scale_color_manual(
    values = c("TRUE" = "red", "FALSE" = "blue")
  ) +
  guides(color = guide_legend(title = "Kinder?")) +
  theme_cowplot()

```

Abbildung 7.3 zeigt, dass die Beschäftigungsquote für kinderlose Frauen deutlich oberhalb der Quote für Mütter verläuft. Die Trends vor der EITC-Ausweitung

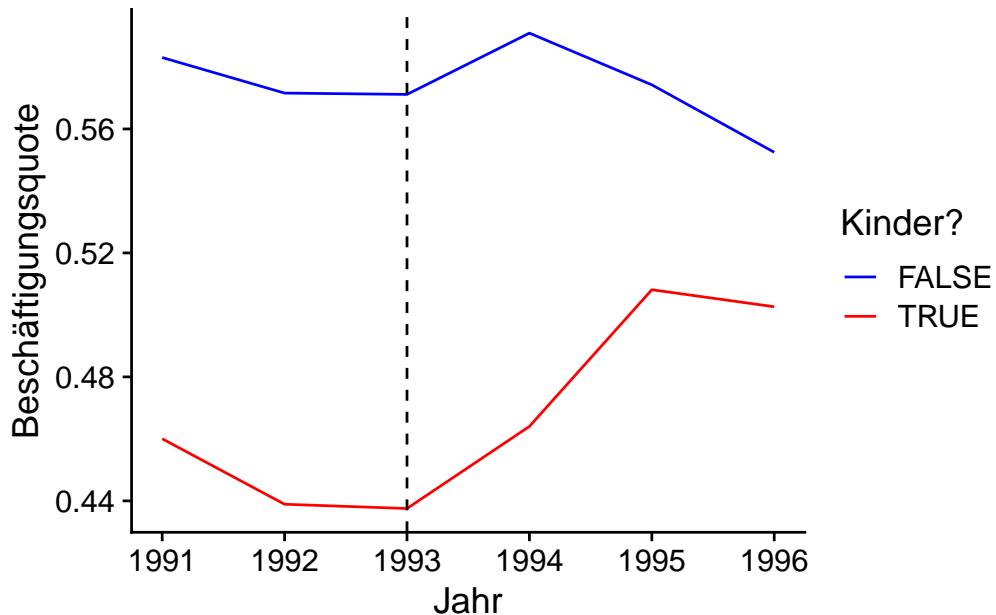


Abbildung 7.3: Trends in der Erwerbsbeteiligung US-amerikanischer Frauen im CPS-Datensatz

im Jahr 1993 sind sehr ähnlich, sodass eine parallele Entwicklung plausibel scheint.

7.4.1 Schätzungen des ATT mit linearen Modellen

Wir berechnen zunächst den Behandlungseffekt der für Frauen mit Kindern relativ zu kinderlosen Frauen gemäß (7.2), wobei wir jeweils *sämtliche* Perioden vor und nach der Behandlung einbeziehen. Dies führt zu den Ergebnissen in Tabelle 7.2, wobei

$$\hat{\beta}_{\text{DID}} = (\textcolor{red}{B} - \textcolor{red}{A}) - (\textcolor{blue}{D} - \textcolor{blue}{C}) \quad (7.5)$$

der geschätzte Behandlungseffekt ist.

Tabelle 7.2: `eitc_data`: Stichprobenmittelwerte für `work`

	v. EITC-Ausweitung	n. EITC-Ausweitung	Differenz
Kinder	$\textcolor{red}{A} = .446$	$\textcolor{red}{B} = .491$	$.045$
k. Kinder	$\textcolor{blue}{C} = .575$	$\textcolor{blue}{D} = .573$	$-.002$
$\hat{\beta}_{\text{DID}}$			$.047$

Die nachfolgenden Code-Chunks zeigen die Schritte zur Berechnung von $\hat{\beta}_{DID}$ mit R.

```
# A, B, C und D berechnen
(
  ABCD <- eitc_data %>%
    group_by(after1993, anykids) %>%
    summarise(avg.work = mean(work))
)
```

```
# A tibble: 4 x 3
# Groups:   after1993 [2]
  after1993 anykids avg.work
  <lgl>     <lgl>      <dbl>
1 FALSE      FALSE       0.58
2 FALSE      TRUE        0.45
3 TRUE       FALSE       0.57
4 TRUE       TRUE        0.49
```

```
# Differenzen bilden
DminusC <- ABCD %>%
  filter(anykids == FALSE) %>%
  pull(avg.work) %>%
  diff()
```

```
BminusA <- ABCD %>%
  filter(anykids == TRUE) %>%
  pull(avg.work) %>%
  diff()
```

```
# DID-Schätzung: Differenz der Stichprobenmittel-Differenzen
beta_DID_means <- BminusA - DminusC
beta_DID_means
```

```
[1] 0.04687
```

Durch Iteration von `summarise()` können wir diese Rechenschritte effizienter ausführen.

```
# Effizienter:
eitc_data %>%
  group_by(after1993, anykids) %>%
  summarise(avg.work = mean(work)) %>%
  summarise(diff_time = diff(avg.work)) %>%
  summarise(beta_DID_means = diff(diff_time)) %>%
  pull(beta_DID_means)
```

[1] 0.04687

Wir erhalten also eine positive Schätzung des Behandlungseffekts. Die Interpretation ist, dass die Ausweitung des EITC im Jahr 1993 zu einem Anstieg der Erwerbsbeteiligung in der Gruppe der Frauen mit Kindern von durchschnittlich 4.69% in den Folgeperioden geführt hat.

Für die Berechnung von Inferenzstatistiken bezüglich β_{DID} schätzen wir ein lineares Interaktionsmodell gemäß (7.3),

$$\text{work}_{i,t} = \beta_0 + \beta_1 \text{anykids}_{i,t} + \beta_2 \text{after1993}_t + \beta_3 (\text{anykids}_{i,t} \times \text{after1993}_t) + \epsilon_{i,t}. \quad (7.6)$$

```
# Equivalente Schätzung u. Inferenz
# mit linearem Interaktionsmodell
DiD_reg <- lm(
  formula = work ~ anykids * after1993,
  data = eitc_data
)
```

Der geschätzte Koeffizient des Interaktionsterms stimmt mit der händisch berechneten Schätzung überein.

```
tidy(DiD_reg) %>%
  filter(term == "anykidsTRUE:after1993TRUE") %>%
  pull(estimate)
```

[1] 0.04687

Mit `coeftest()` berechnen wir heteroskedastie-robuste Inferenzstatistiken.

```
# Robuste Inferenzstatistiken
coeftest(
  x = DiD_reg,
  vcov. = vcovHC,
  type = "HC1"
)
```

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.57546	0.00880	65.38	<2e-16

anykidsTRUE	-0.12950	0.01165	-11.12	<2e-16

after1993TRUE	-0.00207	0.01287	-0.16	0.8720
anykidsTRUE:after1993TRUE	0.04687	0.01714	2.73	0.0063
**				

Signif. codes:	0 *** 0.001 ** 0.01 * 0.05 . 0.1 ' ' 1			

Der Koeffizient des Interaktionsterms ist zum 1%-Niveau signifikant.
`fixest::feols()` liefert eine identische Schätzung.

```
library(fixest)
(
  DID_twoway <- feols(
    fml = work ~ anykids * after1993,
    data = eitc_data,
    vcov = "HC1"
  )
)
```

OLS estimation, Dep. Var.: work
Observations: 13,746
Standard-errors: Heteroskedasticity-robust

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.575460	0.008802	65.3756	<2.2e-16 ***

```

anykidsTRUE          -0.129498   0.011648 -11.1176 <
2.2e-16 ***
after1993TRUE       -0.002074   0.012873  -0.1611
0.8720396
anykidsTRUE:after1993TRUE 0.046873   0.017144   2.7342
0.0062619 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.496672   Adj. R2: 0.012384

```

Wir erweitern Modell (7.6) nun um Fixed Effekts für den US-Bundesstaat sowie das Jahr,

$$\text{work}_{i,t} = \theta_{\text{Staat}} + \eta_t + \beta_1 \text{anykids}_{i,t} + \beta_2 (\text{anykids}_{i,t} \times \text{after1993}_t) + \epsilon_{i,t}. \quad (7.7)$$

Anhand der Dummy-Variablen für Bundesstaaten (θ_{Staat}) und Jahre (η_t) kontrollieren wir für unbeobachtete zeitinvariante Unterschiede zwischen den Bundesstaaten sowie für allgemeine zeitliche Trends und Schocks, die alle Bundesstaaten in einem bestimmten Jahr betreffen. Dies schließt etwaige Backdoor-Pfade durch den Einfluss spezifischer Eigenschaften der Bundesstaaten (Kultur, Geografie, langfristige politische Einstellungen, etc.) und gemeinsamer zeitlicher Einflüsse.

```

library(fixest)
(
  DID_twoway <- feols(
    fml = work ~ anykids + I(anykids * after1993)
    | state + year,
    data = eitc_data
  )
)

OLS estimation, Dep. Var.: work
Observations: 13,746
Fixed-effects: state: 51,  year: 6
Standard-errors: Clustered (state)
Estimate Std. Error t value  Pr(>|t|)
```

```

anykidsTRUE           -0.12391    0.01593  -7.776 3.6952e-10
*** 
I(anykids * after1993) 0.04579    0.01656   2.765 7.9497e-03 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.489063      Adj. R2: 0.038633
                           Within R2: 0.011101

```

Die Schätzung des ATT bei Kontrolle für Zeit- und Bundesstaat-Effekte in (7.7) unterscheidet sich nur geringfügig gegenüber dem Ergebnis für das Modell (7.6). Beachte, dass der Behandlungseffekt auch bei geclusterten Standardfehlern auf Bundesstaaten-Ebene (`| state + year`) signifikant ist.

Ein weiterer Vorteil von DID-Schätzungen mit Regression ist die Möglichkeit zur Kontrolle für individuen-spezifische Kovariablen, um Backdoors aufgrund systematischer Unterschiede zwischen Kontroll- und Behandlungsgruppen zu vermeiden.

Wir erweitern Modell (7.8) um sozio-ökonomische Charakteristika der Frauen: Einen Dummy für nicht-weiße Frauen (`nonwhite`), quadratische Terme in Alter (`age`) und Ausbildungsniveau (`ed`) sowie weitere Einkünfte des Haushalts (`unearn`),

$$\begin{aligned}
\text{work}_{i,t} = & \theta_{\text{Staat}} + \eta_t \\
& + \beta_1 \text{anykids}_{i,t} + \beta_2 (\text{anykids}_{i,t} \times \text{after1993}_t) \\
& + \beta_3 \text{unearn} + \beta_4 \text{nonwhite} \\
& + \beta_5 \text{age} + \beta_6 \text{age}^2 + \beta_7 \text{ed} + \beta_8 \text{ed}^2 \\
& + \epsilon_{i,t}.
\end{aligned} \tag{7.8}$$

```

# Year-FE + State-FE + Kontrollvariablen
(
  DID_FE_controls <- feols(
    fml = work ~ anykids + I(anykids * after1993)

    + unearn + nonwhite
    + age + I(age^2)
    + ed + I(ed^2)

    | state + year,

```

```

    data = eitc_data
)
)

OLS estimation, Dep. Var.: work
Observations: 13,746
Fixed-effects: state: 51, year: 6
Standard-errors: Clustered (state)

Estimate Std. Error t value Pr(>|t|)
anykidsTRUE -0.119221 0.010673 -11.1709 3.4010e-15
***

I(anykids * after1993) 0.055755 0.014385 3.8759 3.1021e-04
***

unearn -0.017695 0.000959 -18.4575 < 2.2e-16
***

nonwhite -0.080399 0.028048 -2.8665 6.0589e-03
**

age 0.026323 0.003664 7.1847 3.0857e-09
***

I(age^2) -0.000316 0.000052 -6.0298 1.9673e-07
***

ed -0.004160 0.006270 -0.6634 5.1013e-01
I(ed^2) 0.001536 0.000535 2.8701 6.0002e-03
**

---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.46896 Adj. R2: 0.115657
Within R2: 0.090729

```

Die Schätzung von (7.8) ergibt mit 0.0558 eine etwas größere Schätzung eines positiven signifikanten Effekt der EITC-Ausweitung auf die Erwerbsbeteiligung von Müttern.

Wie oben erläutert, führte die EITC-Ausweitung von 1993 unter anderem ein Stufensystem für die Höhe des EITC in Abhängigkeit der Kinder-Anzahl ein, sodass unterschiedlich starke Anreize zur Aufnahme einer Beschäftigung für Mütter mit nur einem Kind und mehreren Kindern plausibel sind. Anhand der Dummy-Variablen für (genau) ein Kind (`onechild`) sowie zwei oder mehr Kinder (`twomorekids`) können wir eine differenziertere Schätzung des Effekts

hinsichtlich des Betreuungsaufwands erhalten. Hierzu modifizieren wir Modell (7.8) entsprechend:

$$\begin{aligned} \text{work}_{i,t} = & \theta_{\text{Staat}} + \eta_t \\ & + \beta_1 \text{onechild}_{i,t} + \beta_2 (\text{onechild}_{i,t} \times \text{after1993}_t) \\ & + \beta_3 \text{twomorechild}_{i,t} + \beta_4 (\text{twomorechild}_{i,t} \times \text{after1993}_t) \\ & + \beta_5 \text{unearn} + \beta_6 \text{nonwhite} + \beta_7 \text{age} + \beta_8 \text{age}^2 + \beta_9 \text{ed} + \beta_{10} \text{ed}^2 \\ & + \epsilon_{i,t}. \end{aligned} \quad (7.9)$$

```
# Differenzierung: onechild / twomorekids
(
  DID_FE_spec_controls <- feols(
    fml = work ~
      onechild + I(onechild * after1993)
      + twomorekids + I(twomorekids * after1993)

      + unearn + nonwhite
      + age + I(age^2)
      + ed + I(ed^2)

      | state + year,
    data = eitc_data
  )
)
```

OLS estimation, Dep. Var.: work
Observations: 13,746
Fixed-effects: state: 51, year: 6
Standard-errors: Clustered (state)

	Estimate	Std. Error	t value
	Pr(> t)		
onechildTRUE	-0.063581	0.013327	-4.7708
1.6319e-05 ***			
I(onechild * after1993)	0.040539	0.017829	2.2737
2.7311e-02 *			
twomorekidsTRUE	-0.161675	0.013127	-12.3166 <
2.2e-16 ***			

```

I(twomorekids * after1993)  0.064799   0.016411   3.9485
2.4649e-04 ***
unearn                      -0.017334   0.000992 -17.4790  <
2.2e-16 ***
nonwhite                     -0.073759   0.027833  -2.6501
1.0745e-02 *
age                          0.028990   0.003475   8.3433
4.9204e-11 ***
I(age^2)                     -0.000357   0.000049  -7.2889
2.1209e-09 ***
ed                           -0.003765   0.006350  -0.5929
5.5595e-01
I(ed^2)                      0.001517   0.000552   2.7474
8.3318e-03 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.467886      Adj. R2: 0.119572
Within R2: 0.094887

```

Die interessierenden geschätzten Koeffizienten von $I(\text{onechild} * \text{after1993})$ und $I(\text{twomorekids} * \text{after1993})$ sind 0.0405 und 0.0648. Auch hier sind die Koeffizienten signifikant von null verschieden. Der größere Koeffizient für den Effekt auf Mütter mit zwei oder mehr Kinder liefert Evidenz dafür, dass die Einführung der Zahlstufe für größere Familien im Rahmen der EITC-Ausweitung von 1993 tatsächlich einen etwas stärkeren Anreiz auf die Zielgruppe mit mehreren Kindern hatte.

7.4.2 Probit-Spezifikationen

In sämtlichen Modellen in Kapitel 7.4.1 haben wir $\text{work}_{i,t}$ als kontinuierliche Variable behandelt und den bedingten Erwartungswert als lineare Funktion modelliert. Da $\text{work}_{i,t}$ eine binäre Variable ist, haben wir damit implizit die bedingte Wahrscheinlichkeit der Erwerbsbeteiligung $P(\text{work}_{i,t} = 1 | \mathbf{x}_{i,t})$ modelliert. Wie in Kapitel 3.1.1 erläutert, kann ein solches lineares Wahrscheinlichkeitsmodell (LPM) einen nicht-linearen Verlauf der Wahrscheinlichkeitsfunktion $P(\text{work}_{i,t} = 1 | \mathbf{x}_{i,t})$ nicht exakt abbilden, wobei tatsächliche Behandlungseffekte unter- oder überschätzt werden können. In manchen Fällen können geschätzte Wahrscheinlichkeiten sogar außerhalb des Intervalls $[0, 1]$ liegen. Statt eines LPM sollte ein generalisiertes lineares Modell (GLM) verwendet werden.

Wir modellieren nachfolgend den Effekt der EITC-Anpassung auf die Wahrscheinlichkeit einer Erwerbsbeteiligung von Müttern mit Probit-Regression. Anstatt `stats::glm()` verwenden wir `fixest::feglm()`.⁴ Analog zu `fixest::feols()` erlaubt `fixest::feglm()` die Schätzung von Probit-Regressionen mit Fixed Effekts. Partielle Effekte können mit dem Paket `marginalEffects` berechnet werden. Wir schätzen zunächst eine Fixed-Effects-Probit-Regression analog zu (7.7), d.h.

$$\begin{aligned}\Phi^{-1} \left[P(\text{work}_{i,t} = 1 | \boldsymbol{x}_{i,t}) \right] &= \eta_t + \theta_{\text{Staat}} + \beta_1 \text{anykids}_{i,t} \\ &\quad + \beta_2 (\text{anykids}_{i,t} \times \text{after1993}_{i,t}).\end{aligned}\tag{7.10}$$

Für die Berechnung der partiellen Effekte mit `marginalEffects::avg_slopes()` definieren wir die interagierten Regressoren direkt im Datensatz.

```
# Interagierte Regressoren definieren
eitc_data <- eitc_data %>%
  mutate(
    int_anykids = anykids * after1993,
    int_onechild = onechild * after1993,
    int_twomore = twomorekids * after1993
  )
```

Die Struktur von `feglm()` folgt dem selben Schema wie `feols()`. Das zusätzliche Argument `family = binomial("probit")` legt die entsprechende Link-Funktion fest.

```
# Probit-Regression mit TWFE
(
  EITC_DID_probit <- feglm(
    fml = work ~ anykids + int_anykids
    | state + year,
    family = binomial("probit"),
    data = eitc_data
  )
)
```

⁴Eine weitere Option ist `alpaca::feglm()`.

```

GLM estimation, family = binomial, Dep. Var.: work
Observations: 13,746
Fixed-effects: state: 51, year: 6
Standard-errors: Clustered (state)

          Estimate Std. Error z value Pr(>|z|)
anykidsTRUE -0.3204    0.04212 -7.606 2.8361e-14 ***
int_anykids  0.1189    0.04276  2.780 5.4308e-03 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Log-Likelihood: -9,224.4  Adj. Pseudo R2: 0.025402
BIC: 19,001.5      Squared Cor.: 0.042557

```

Die Schätzung ergibt einen positiven Effekt für `int_anykids`. Wie im linearen Modell ist der Koeffizient von `int_anykids` signifikant. Beachte, dass dieser Koeffizient die geschätzte Änderung der *latenten Variable* des Probit-Modells misst und *nicht* direkt als Behandlungseffekt interpretiert werden darf. Stattdessen können wir mit `marginaleffects::avg_slopes()` den durchschnittlichen partiellen Effekt des Interaktionsterms für Frauen in der Behandlungsgruppe für die Jahre 1994 bis 1996 berechnen. `marginaleffects::datagrid()` setzt Variablen ohne spezifizierte Werte auf ihren Mittelwert (kontinuierlich) oder Modus (kategorisch). Der Modus von `state` ist 93 (California).

```

library(marginaleffects)

EITC_DID_probit %>%
  avg_slopes(
  variables = "int_anykids",
  newdata = datagrid(
    anykids = 1,
    year = 1994:1996
  )
)

```

Term	Contrast	Estimate	Std. Error	z	Pr(> z)
S 2.5 %					
int_anykids	mean(1) - mean(0)	0.0456	0.0161	2.83	0.00465
7.7 0.014					
97.5 %					
0.0771					

```

Columns: term, contrast, estimate, std.error, statistic,
p.value, s.value, conf.low, conf.high, predicted_lo,
predicted_hi, predicted
Type: response

```

Der geschätzte durchschnittliche partielle Effekt der EITC-Ausweitung für Mütter im Bundesstaat California für die Jahre 1994 bis 1996 ist eine Erhöhung der Wahrscheinlichkeit der Erwerbsbeteiligung um etwa 4.57%.

Analog zu Modell (7.9) kontrollieren wir in einer weiteren Regression zusätzlich für sozio-ökonomische Charakteristika und differenzieren zwischen dem Effekt für Frauen mit einem Kind und Müttern mit zwei oder mehr Kindern anhand des Modells

$$\begin{aligned}
\Phi^{-1} \left[P(\text{work}_{i,t} = 1) \right] = & \theta_{\text{Staat}} + \eta_t \\
& + \beta_1 \text{onechild}_{i,t} + \beta_2 (\text{onechild}_{i,t} \times \text{after1993}_t) \\
& + \beta_3 \text{twomorechild}_{i,t} + \beta_4 (\text{twomorechild}_{i,t} \times \text{after1993}_t) \\
& + \beta_5 \text{unearn} + \beta_6 \text{nonwhite} + \beta_7 \text{age} + \beta_8 \text{age}^2 + \beta_9 \text{ed} + \beta_{10} \text{ed}^2 \\
& + \epsilon_{i,t}.
\end{aligned} \tag{7.11}$$

```

# Probit-FE-Regression mit Kontrollvariablen
# und Differenzierung des Effekts
(
  EITC_DID_probit <- feglm(
    fml = work ~ onechild + int_onechild
    + twomorekids + int_twomore

    + unearn + nonwhite + age + ed
    + I(ed^2) + I(age^2)

    | year + state,
    family = binomial("probit"),
    data = eitc_data
  )
)

```

```

GLM estimation, family = binomial, Dep. Var.: work
Observations: 13,746
Fixed-effects: year: 6, state: 51
Standard-errors: Clustered (year)

              Estimate Std. Error   z value   Pr(>|z|) 
onechildTRUE -0.180374  0.029751 -6.0628 1.3378e-09 ***
int_onechild  0.120223  0.041680  2.8844 3.9218e-03 ** 
twomorekidsTRUE -0.436599  0.022144 -19.7165 < 2.2e-16 ***
int_twomore   0.183897  0.072453  2.5381 1.1144e-02 *  
unearn        -0.053551  0.003109 -17.2227 < 2.2e-16 *** 
nonwhite       -0.206060  0.026744 -7.7048 1.3105e-14 *** 
age            0.078925  0.006161 12.8110 < 2.2e-16 *** 
ed             -0.009102  0.028450 -0.3199 7.4903e-01 
I(ed^2)         0.004198  0.001867  2.2479 2.4580e-02 *  
I(age^2)        -0.000966  0.000082 -11.8142 < 2.2e-16 *** 
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Log-Likelihood: -8,586.0  Adj. Pseudo R2: 0.091602
BIC: 17,800.9  Squared Cor.: 0.145969

```

Wir können nun zwei partielle Effekte berechnen: 1. für `int_onechild` und 2. für `int_twomore`. Hierzu setzen wir jeweils die übrigen Dummy-Variablen mit Bezug zur Anzahl der Kinder auf null. Weiterhin setzen wir `nonwhite = 0`, d.h. wir betrachten den Effekt für weiße Frauen im Bundesstaat California, wobei die übrigen Regressoren den Wert der jeweiligen Stichprobenmittel haben.

```

# 1. Durchschn. Partieller Effekt onechild
EITC_DID_probit %>%
  avg_slopes(
    variable = "int_onechild",
    datagrid(
      onechild = 1,
      twomorekids = 0,
      int_twomore = 0,
      year = 1994:1996,
      nonwhite = 0
    )
  )

```

Term	Contrast	Estimate	Std. Error	z	Pr(> z)
S 2.5 %					
int_onechild	mean(1) - mean(0)	0.0411	0.0117	3.5	<0.001
11.1	0.0181				
97.5 %					
	0.0641				

Columns: term, contrast, estimate, std.error, statistic,
 p.value, s.value, conf.low, conf.high, predicted_lo,
 predicted_hi, predicted
 Type: response

```
# 1. Durchschn. Partieller Effekt twomore
EITC_DID_probit %>%
  avg_slopes(
    variable = "int_twomore",
   datagrid(
      int_onechild = 0,
      onechild = 0,
      twomorekids = 1,
      year = 1994:1996,
      nonwhite = 0
    )
  )
```

Term	Contrast	Estimate	Std. Error	z	Pr(> z)
S 2.5 %					
int_twomore	mean(1) - mean(0)	0.0616	0.0228	2.7	0.00687
7.2	0.0169				
97.5 %					
	0.106				

Columns: term, contrast, estimate, std.error, statistic,
 p.value, s.value, conf.low, conf.high, predicted_lo,
 predicted_hi, predicted
 Type: response

Ähnlich wie in Modell (7.9) erhalten wir signifikante positive Schätzungen.
 Der durchschnittliche Effekt für int_twomore ist mit einer Erhöhung der

Wahrscheinlichkeit zur Aufnahme einer Beschäftigung von etwa 6.16% etwas höher als die 4.11% für `int_onechild`.

7.5 Case Study: Effekt von Polizeipräsenz auf Autodiebstähle

Nach einem Terroranschlag auf das größte jüdische Gemeindezentrum in Buenos Aires am 18. Juli 1994 wurden sämtliche jüdische und muslimische Einrichtungen in der Stadt rund um die Uhr von der argentinischen Polizei geschützt. Somit führte dieses Ereignis zu einer geografischen quasi-experimentellen Allokation von Polizeikräften in Gegenden mit entsprechenden Einrichtungen. In einem Forschungsdesign, dass die lokale Straßenkriminalität Kriminalität erklären soll, kann die sich aus der Allokation ergebende Variation in der Polizeipräsenz als exogen angenommen werden. Di Tella und Schargrodsky (2004) nutzen diesen Umstand, um anhand von Polizeistatistiken und Daten zu Autodiebstählen in Buenos Aires vor und nach dem Terroranschlag den Effekt erhöhter Polizeipräsenz auf die Kriminalität in einem Difference-in-Differences-Ansatz zu untersuchen. Die Studienergebnisse deuten darauf hin, dass es einen starken abschreckenden Effekt von Polizeistreifen gibt, der sich nur in einem engen Umkreis um Häuserblocks in denen die Polizeipräsenz erhöht wurde, auswirkt.

In diesem Kapitel reproduzieren wir Kernergebnisse der Studie mit R. Die benötigten Daten sind auf der [Webseite der American Economic Association](#) verfügbar. Die Daten stammen aus drei nicht zusammenhängenden Stadtvierteln von Buenos Aires die etwa 3.2% der Stadtfläche ausmachen und 6.9% der Bevölkerung beherbergen, wobei sich jedem Viertel eine Polizeistation befindet. Bei den untersuchten Stadtvierteln handelt es sich um die Viertel mit der größten Anzahl jüdischer Einrichtungen in der Stadt. Der Großteil der Häuserblocks in diesen Vierteln (insgesamt 876 Blocks) liegen nicht in der Nähe einer geschützten Einrichtung. Blocks die mehr als zwei Blocks von einer geschützten Einrichtung entfernt liegen, bilden die Kontrollgruppe.

Wir verwenden nachfolgend den modifizierten Datensatz `polizeipraesenz.RDS`.

```
# Datensatz einlesen  
polizeipraesenz <- readRDS("datasets/polizeipraesenz.RDS")
```

Tabelle 7.3: `polizeipraesenz`: Autodiebstähle in Buenos Aires

Variable	Beschreibung
institut	Jüdische Einrichtung im Block
barrio	Stadtviertel
distanz	Entf. zu Block mit Einrichtung (in Blocks)
monat	Monat der Beobachtung
observ	ID-Variable für Block
totrob	Diebstähle pro Monat (normalisiert)

7.5.1 Trend-Vergleich

Zur Einschätzung der Annahme paralleler Trends berechnen wir zunächst die Durchschnittliche Anzahl an Autodiebstählen Blocks mit bzw. ohne jüdische Institutionen für die Monate April bis Dezember. Beachte, dass die Variable `monat` zwei Ausprägungen für den Monat des Anschlags aufweist: Juli (1 - 17) für die Juli-Tage vor dem Anschlag und für die verbleibenden Tage Juli (18 - 31).

```
# Trends berechnen
(
  polizeipraesenz_Trends <- polizeipraesenz %>%
    mutate(institut = as.factor(institut)) %>%
    group_by(monat, institut) %>%
    summarise(
      `Durchschn. Diebstähle` = mean(totrob)
    )
)
```

```
# A tibble: 20 x 3
# Groups:   monat [10]
  monat      institut `Durchschn. Diebstähle`
  <ord>      <fct>           <dbl>
1 April       0            0.11
2 April       1            0.12
3 Mai         0            0.10
4 Mai         1            0.088
5 Juni        0            0.076
6 Juni        1            0.13
```

7 Juli (1 - 17)	0	0.041
8 Juli (1 - 17)	1	0.020
9 Juli (18 - 31)	0	0.054
10 Juli (18 - 31)	1	0.027
11 August	0	0.11
12 August	1	0.047
13 September	0	0.099
14 September	1	0.014
15 Oktober	0	0.11
16 Oktober	1	0.061
17 November	0	0.10
18 November	1	0.027
19 Dezember	0	0.11
20 Dezember	1	0.027

Die in `polizeipraesenz_Trends` erfasste Trendentwicklung für Blocks in der Behandlungsgruppe (`institut == 1`) und in der Kontrollgruppe (`institut == 0`) plotten wir mit `ggplot2()`.

```
# Trends plotten
polizeipraesenz_Trends %>%
  ggplot(
    mapping = aes(
      x = monat,
      y = `Durchschn. Diebstähle`,
      color = institut,
      group = institut
    )
  ) +
  geom_line() +
  geom_vline(
    xintercept = "Juli (18 - 31)",
    lty = "dashed") +
  geom_point() +
  labs(
    x = "Monat",
    y = "Durchschn. Anz. Diebstähle / Monat"
  ) +
  theme_cowplot() +
  theme(
```

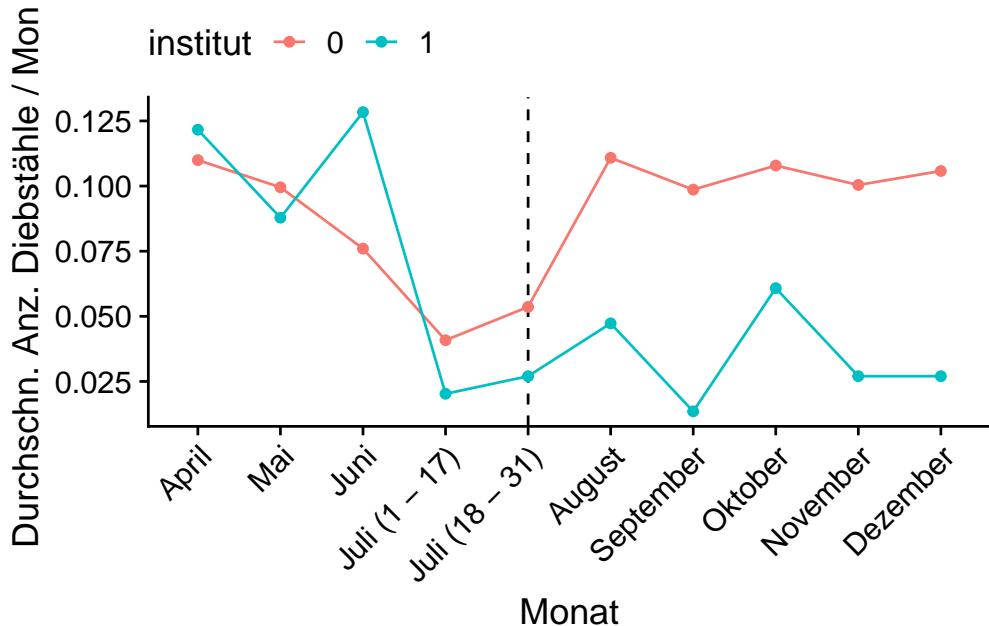


Abbildung 7.4: Geschätzte Trends für Autodiebstähle in Buenos Aires im Jahr 1994

```

axis.text.x = element_text(
  angle = 45,
  hjust = 1
),
legend.position = "top"
)

```

Abbildung 7.4 zeigt einen ähnlichen Verlauf der Trends für den Zeitraum unmittelbar vor dem Anschlag am 18. Juli.

Tabelle 2 in Di Tella und Schargrodsky (2004) präsentiert t-Tests für Unterschiede in der Mittleren Anzahl der Diebstähle pro Monat zwischen Blocks mit jüdischen Einrichtungen und verschiedenen distanz-basierten Untergruppen von Blocks ohne eine jüdische Einrichtung für jede Periode. Zur Reproduktion dieser Ergebnisse erstellen zunächst eine Listen-Spalten für die beobachteten Diebstähle in Abhängigkeit der Distanz zum nächsten Block mit einer jüdischen Einrichtung.

- **d2more** Zwei oder mehr Blocks entfernt
- **d2**: Zwei Blocks entfernt
- **d1**: Ein Block entfernt
- **same**: Jüdische Einrichtung im selben Block

```

(
  dat_listcol <- polizeipraesenz %>%
    group_by(observ, monat) %>%
    transmute(
      d2more = list(totrob[distanz > 2]),
      d2 = list(totrob[distanz == 2]),
      d1 = list(totrob[distanz == 1]),
      same = list(totrob[institut == 1])
    )
)

# A tibble: 8,760 x 6
# Groups:   observ, monat [8,760]
  observ monat d2more     d2      d1      same
  <dbl> <ord> <list>     <list>   <list>   <list>
1     870 April <dbl [0]> <dbl [0]> <dbl [1]> <dbl [0]>
2     851 April <dbl [0]> <dbl [1]> <dbl [0]> <dbl [0]>
3     843 April <dbl [0]> <dbl [0]> <dbl [0]> <dbl [1]>
4     796 April <dbl [0]> <dbl [0]> <dbl [1]> <dbl [0]>
5     790 April <dbl [0]> <dbl [0]> <dbl [0]> <dbl [1]>
6     789 April <dbl [0]> <dbl [0]> <dbl [1]> <dbl [0]>
7     844 April <dbl [0]> <dbl [0]> <dbl [0]> <dbl [1]>
8     858 April <dbl [0]> <dbl [0]> <dbl [1]> <dbl [0]>
9     787 April <dbl [0]> <dbl [0]> <dbl [1]> <dbl [0]>
10    850 April <dbl [0]> <dbl [0]> <dbl [1]> <dbl [0]>
# i 8,750 more rows

```

Mit `summarise()` können wir Stichprobenmittel und Standardabweichungen der Diebstähle in Blöcke dieser Kategorien für alle Perioden berechnen. Anschließend kombinieren wir die Ergebnisse jeweils mit `sprintf()` und formatieren das Ergebnis mit `modelsummary::modelsummary_df()`.⁵ Tabelle 7.4 Zeit die Spalten A bis D aus Tabelle 2 in Di Tella und Schargrodsky (2004).

```

library(modelsummary)

# Mittelwerte und Standardabweichungen
mean_sd <- dat_listcol %>%

```

⁵"%.4f\n%.4f" gibt das Format des resultierenden `character` an: Mittelwerte und SDs (in Klammern), gerundet auf vier Nachkommastellen. \n bewirkt einen Zeilenumbruch.

```

group_by(monat) %>%
summarise(
  across(
    d2more:same,
    .fns = list(
      mean = ~ mean(unlist(.)),
      sd = ~ sd(unlist(.))
    )
  ),
  .groups = "keep"
)

# Desk. Statistiken kombinieren
formatted_mean_sd <- mean_sd %>%
  transmute(
    monat,
    "D>2 (A)" = sprintf("%.4f\n(%.4f)", d2more_mean, d2more_sd),
    "same (B)" = sprintf("%.4f\n(%.4f)", same_mean, same_sd),
    "D1 (C)" = sprintf("%.4f\n(%.4f)", d1_mean, d1_sd),
    "D2 (D)" = sprintf("%.4f\n(%.4f)", d2_mean, d2_sd)
  )

# Tabelle mit modelsummary_df() ausgeben
modelsummary::datasummary_df(formatted_mean_sd)

```

Der nächste Chunk reproduziert die Spalten E bis F von Tabelle 2 in Di Tella und Schargrodsky (2004). Die Einträge sind Mittelwertdifferenzen (Standardfehler in Klammern) zwischen den betrachteten Gruppen von Blocks sowie Ergebnisse für t-Tests (Signifikanz-Sternchen) der Hypothese, dass die jeweilige mittlere Anzahl an Autodiebstählen nicht verschieden ist.

Wir definieren zunächst eine Funktion `format_ttest()`, die die gewünschten Statistiken aus einem mit `t.test()` berechneten Objekte ausliest und entsprechend formatiert. Anschließend nutzen wir diese Funktion, um die Daten in `dat_listcol` entsprechend der Definition in Di Tella und Schargrodsky (2004) für jeden Monat zusammenzufassen. Die Ergebnisse formatieren wir wieder mit `datasummary_df()`.

Tabelle 7.4: Deskriptive Statistiken für Diebstähle nach Entfernung zur nächsten jüdischen Einrichtung

monat	D>2 (A)	same (B)	D1 (C)	D2 (D)
April	0.0996(0.2481)	0.1216(0.3614)	0.1211(0.2879)	0.1228(0.2974)
Mai	0.1084(0.2357)	0.0878(0.2060)	0.0776(0.1817)	0.0973(0.2591)
Juni	0.0785(0.1961)	0.1284(0.2864)	0.0776(0.2151)	0.0697(0.1867)
Juli (1 - 17)	0.0393(0.1451)	0.0203(0.0692)	0.0590(0.2101)	0.0310(0.1419)
Juli (18 - 31)	0.0393(0.1460)	0.0270(0.0787)	0.0730(0.2177)	0.0686(0.2386)
August	0.1184(0.2871)	0.0473(0.1752)	0.0668(0.2197)	0.1272(0.3048)
September	0.1018(0.2566)	0.0135(0.0573)	0.0901(0.2761)	0.0985(0.2483)
Oktober	0.1211(0.2671)	0.0608(0.2157)	0.0978(0.2610)	0.0885(0.2367)
November	0.0962(0.2404)	0.0270(0.0787)	0.1102(0.2889)	0.1018(0.2177)
Dezember	0.1018(0.2682)	0.0270(0.0787)	0.1165(0.2782)	0.1062(0.2256)

```
# Funktion: Ergebnisse von t.test()
# mit Signifikanzsternchen
format_ttest <- function(ttest_result) {
  estimate <- diff(ttest_result$estimate)
  stderr <- ttest_result$stderr
  p_value <- ttest_result$p.value

  stars <- if (p_value < 0.001) {
    "***"
  } else if (p_value < 0.01) {
    "**"
  } else if (p_value < 0.05) {
    "*"
  } else {
    ""
  }

  sprintf("%.4f (%.4f)%s", estimate, stderr, stars)
}

# Berechnung der t-Tests, Formatierung der Ergebnisse
results <- dat_listcol %>%
  group_by(monat) %>%
```

Tabelle 7.5: Mittelwertdifferenzen in Autodiebstählen und t-Tests

monat	(E) Diff: B - A	(F) Diff: C - A	(G) Diff: D - A
April	0.0221 (0.0606)	0.0216 (0.0255)	0.0232 (0.0230)
Mai	-0.0206 (0.0356)	-0.0308 (0.0181)	-0.0111 (0.0205)
Juni	0.0498 (0.0480)	-0.0009 (0.0193)	-0.0088 (0.0155)
Juli (1 - 17)	-0.0190 (0.0133)	0.0197 (0.0179)	-0.0083 (0.0116)
Juli (18 - 31)	-0.0122 (0.0146)	0.0337 (0.0185)	0.0293 (0.0173)
August	-0.0711 (0.0318)*	-0.0516 (0.0220)*	0.0088 (0.0244)
September	-0.0883 (0.0153)***	-0.0117 (0.0249)	-0.0033 (0.0205)
Oktober	-0.0603 (0.0376)	-0.0233 (0.0241)	-0.0326 (0.0201)
November	-0.0692 (0.0172)***	0.0140 (0.0254)	0.0055 (0.0184)
Dezember	-0.0747 (0.0181)***	0.0147 (0.0253)	0.0044 (0.0196)

```

summarise(
  "(E) Diff: B - A" = format_ttest(t.test(unlist(d2more),
  ↪ unlist(same))),
  "(F) Diff: C - A" = format_ttest(t.test(unlist(d2more),
  ↪ unlist(d1))),
  "(G) Diff: D - A" = format_ttest(t.test(unlist(d2more),
  ↪ unlist(d2)))
)

# Formatierung der Tabelle mit modelsummary_df()
modelsummary::datasummary_df(results)

```

Tabelle 7.5 zeigt eine einschlägige Entwicklung der Differenzen über die Zeit: In den Monaten *vor* dem Anschlag (und der anschließenden Allokation von Polizeipräsenz) bestehen weder zwischen weit entfernten Blocks und solchen mit einer jüdischen Einrichtung (Spalte E) noch zwischen Blocks ohne eine Einrichtung (Spalten F und G) signifikante Unterschiede in der Anzahl der Autodiebstähle. *Nach* der politischen Intervention ergibt sich ein anderes Bild: In Spalte (E) von Tabelle 7.5 finden wir signifikante *negative* Differenzen. Dies ist Evidenz, dass die Kriminalität in besonders gut bewachten Blocks (Spalte B in Tabelle 7.4) in den Folgeperioden des Anschlags geringer war als in Blocks die, mehr als zwei Blocks von einer bewachteten Einrichtung entfernt sind (Spalte A in Tabelle 7.4). Mit Ausnahme einer Signifikanten Differenz im August 1994 finden wir keine Hinweise auf derartige Unterschiede zwischen

Blocks in den Kontrollgruppen (Spalten F und G).

7.5.2 Two-Way-Fixed-Effects-Schätzungen

Di Tella und Schargrodsky (2004) betrachten (Sub-Modelle) der folgenden Regressionsspezifikation für die Schätzung des Effekts von Polizeipräsenz auf die Anzahl der Autodiebstähle.

$$\begin{aligned} \text{totrob}_{i,t} = & \text{monat}_t + \text{block}_i \\ & + \alpha_0 \text{same}_{i,t} + \alpha_1 \text{oneblock}_{i,t} \\ & + \alpha_2 \text{twoblocks}_{i,t} + \epsilon_{i,t} \end{aligned} \quad (7.12)$$

Hierbei sind monat_t und block_i Fixed Effekte für den Monat sowie den Block. Die übrigen Variablen sind für Beobachtungen ab dem Anschlag am 18. Juli 1994 und in Abhängigkeit der Distanz zur nächsten jüdischen Einrichtung definiert:

- $\text{same}_{i,t}$: Dummy-Variable für jüdische Einrichtung im Block und Beobachtung nach dem 17. Juli 1994
- $\text{oneblock}_{i,t}$: Dummy-Variable für Blocks mit einem Block Entfernung zum nächsten Block mit einer jüdischen Einrichtung und Beobachtung nach dem 17. Juli 1994
- $\text{twoblocks}_{i,t}$: Dummy-Variable für Blocks mit einer Entfernung von zwei Blocks zum nächsten Block mit einer jüdischen Einrichtung und Beobachtung nach dem 17. Juli 1994

Im nächsten Code-Chunk definieren wir diese Variablen und, gemäß der Vorgehensweise in Di Tella und Schargrodsky (2004), entfernen Beobachtungen für den Zeitraum im Juli nach dem Anschlag (18.07.1994 bis 31.07.1994).

```
# Variablen definieren und Beobachtungen subsetten
dat_DID <- polizeipraesenz %>%
  mutate(
    same = institut == 1 & monat > "Juli (1 - 17)",
    oneblock = distanz == 1 & monat > "Juli (1 - 17)",
    twoblocks = distanz == 2 & monat > "Juli (1 - 17)"
  ) %>%
  filter(monat != "Juli (18 - 31)")
```

Die Knergebnisse der Studie werden in Tabelle 3 im Paper präsentiert. Hier werden fünf Regressionen betrachtet:

- **Regression (A)**

$$\begin{aligned} \text{totrob}_{i,t} = & \text{monat}_t + \text{block}_i \\ & + \alpha_0 \text{same}_{i,t} \\ & + \epsilon_{i,t} \end{aligned} \tag{7.13}$$

Modell (7.13) betrachtet lediglich die geographisch “engste” Definition des Behandlungseffekts: α_0 ist der ATT für Blocks mit einer jüdischen Einrichtung. Die Kontrollgruppe besteht aus *sämtlichen* Blocks ohne jüdische Einrichtung.

- **Regression (B)**

$$\begin{aligned} \text{totrob}_{i,t} = & \text{monat}_t + \text{block}_i \\ & + \alpha_0 \text{same}_{i,t} \\ & + \alpha_1 \text{oneblock}_{i,t} \\ & + \epsilon_{i,t} \end{aligned} \tag{7.14}$$

Modell (7.14) erweitert die Behandlungsgruppe um Blocks, die genau einen Block von einem Block mit erhötem Polizeischutz entfernt sind. Die Kontrollgruppe besteht aus Blocks mit einer Entfernung von *zwei oder mehr Blocks* bis zur nächsten jüdischen Einrichtung.

- **Regression (C)**

$$\begin{aligned} \text{totrob}_{i,t} = & \text{monat}_t + \text{block}_i \\ & + \alpha_0 \text{same}_{i,t} \\ & + \alpha_1 \text{oneblock}_{i,t} \\ & + \alpha_1 \text{twoblocks}_{i,t} \\ & + \epsilon_{i,t} \end{aligned} \tag{7.15}$$

Modell (7.15) betrachtet zusätzlich den Behandlungseffekt in Blocks mit zwei Blocks entfernung zu einem Block mir erhöhter Polizeipräsenz. Die

Kontrollgruppe besteht aus Blocks mit einer Entfernung von *mehr als zwei Blocks* bis zur nächsten jüdischen Einrichtung.

- **Regression (D) – Querschnitts-Variation**

Da Di Tella und Schargrodsky (2004) eine große Ähnlichkeit hinsichtlich demografischer Merkmale und Autodiebstahlsraten vor der Intervention in Gebieten mit und ohne jüdische Einrichtungen beobachten, betrachten sie auch einen einfachen Querschnittsschätzer. Regression (D) nutzt die Spezifikation (7.15), aber berücksichtigt nur Beobachtungen für den Zeitraum nach dem Anschlag (August bis Dezember) und nutzt lediglich Fixed Effekts für die *Monate*.

- **Regression (E) – Zeitreihen-Variation**

Regression (E) ist eine alternative Spezifikation zu (7.15) bei der lediglich die zeitliche Variation in der Behandlungsgruppe (Entfernung zur nächsten Einrichtung \leq zwei Blocks) genutzt wird. Hierzu werden Fixed Effekts nur für die *Blocks*, jedoch nicht für die Monate berechnet.

Wie implementieren nachfolgend die Regressionen (A) bis (E) mit `fixest::feols()` unter Verwendung heteroskedastie-robuster Standardfehler (`vcov = "HC1"`). Alle Regressionen nutzen den oben definierten Datensatz `dat_DID`, wobei wir für die Schätzungen in (D) und (E) mit `filter()` die entsprechenden Subsets auswählen.

```
# Regression (A)
(
  T3A <- feols(
    fml = totrob ~
      same
    | observ + monat,
    data = dat_DID,
    vcov = "HC1"
  )
)
```

```
OLS estimation, Dep. Var.: totrob
Observations: 7,884
Fixed-effects: observ: 876, monat: 9
Standard-errors: Heteroskedasticity-robust
Estimate Std. Error t value Pr(>|t|)
```

```

sameTRUE -0.07753     0.02244  -3.456 0.00055241 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.216676      Adj. R2: 0.097072
                           Within R2: 0.001277

```

```

# Regression (B)
(
  T3B <- feols(
    fml = totrob ~
      same
      + oneblock
      | observ + monat,
    data = dat_DID,
    vcov = "HC1"
  )
)

```

```

OLS estimation, Dep. Var.: totrob
Observations: 7,884
Fixed-effects: observ: 876, monat: 9
Standard-errors: Heteroskedasticity-robust
              Estimate Std. Error t value Pr(>|t|)
sameTRUE      -0.08007    0.02257 -3.5480 0.00039068 ***
oneblockTRUE -0.01326    0.01386 -0.9564 0.33889333
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.216661      Adj. R2: 0.097067
                           Within R2: 0.001414

```

```

# Regression (C)
(
  T3C <- feols(
    fml = totrob ~
      same
      + oneblock
      + twoblocks
      | observ + monat,
    data = dat_DID,

```

```

    vcov = "HC1"
)
)

OLS estimation, Dep. Var.: totrob
Observations: 7,884
Fixed-effects: observ: 876, monat: 9
Standard-errors: Heteroskedasticity-robust
              Estimate Std. Error t value  Pr(>|t|)
sameTRUE      -0.080802   0.02295 -3.5216 0.00043173 ***
oneblockTRUE  -0.013988   0.01447 -0.9669 0.33362749
twoblocksTRUE -0.002185   0.01232 -0.1774 0.85920503
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.21666   Adj. R2: 0.096942
Within R2: 0.001419

```

```

# Regression (D)
(
  T3D <- feols(
    fml = totrob ~
      same
      + oneblock
      + twoblocks
      | monat,
    data = dat_DID %>%
      filter(
        monat >= "August"
      ),
    vcov = "HC1"
  )
)

```

```

OLS estimation, Dep. Var.: totrob
Observations: 4,380
Fixed-effects: monat: 5
Standard-errors: Heteroskedasticity-robust
              Estimate Std. Error t value  Pr(>|t|)
sameTRUE      -0.072719   0.01139 -6.3852 1.8897e-10 ***

```

```

oneblockTRUE -0.011581    0.01090 -1.0623 2.8815e-01
twoblocksTRUE -0.003429    0.00925 -0.3707 7.1086e-01
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.256214      Adj. R2: 0.002028
      Within R2: 0.00325

```

```

# Regression (E)
(
  T3E <- feols(
    fml = totrob ~
      same
      + oneblock
      + twoblocks
      | observ,
    data = dat_DID %>%
      filter(
        distanz <= 2
      ),
    vcov = "HC1"
  )
)

```

```

OLS estimation, Dep. Var.: totrob
Observations: 3,816
Fixed-effects: observ: 424
Standard-errors: Heteroskedasticity-robust
              Estimate Std. Error t value Pr(>|t|)
sameTRUE     -0.05439    0.02201 -2.4713 0.013510 *
oneblockTRUE  0.01242    0.01260  0.9861 0.324146
twoblocksTRUE 0.02423    0.01011  2.3972 0.016577 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.216568      Adj. R2: 0.093304
      Within R2: 0.003304

```

Zur Reproduktion von Tabelle 3 in Di Tella und Schargrodsky (2004) sammeln wir die geschätzten Modelle und erzeugen einen tabelarrische Zusammenfassung mit `modelsummary::modelsummary()`. Über das Argument `gofomit`

= "⁶ $\wedge(?!(\text{R2}|\text{Num.Obs.}|(\text{FE}.*))\$).*$ " wählen wir unter den Goodness-of-Fit-Statistiken R^2 , die Anzahl der Beobachtungen, sowie Indikatoren für die verwendeten Fixed Effekts mit einem [Regular Expression](#) aus.⁶

```
# Tabellarischer Vergleich mit modelsummary()
# (Tabelle 3 in Ditella und Schargrodsky, 2004)
modelsummary(
  models = list(
    "(3A)" = T3A,
    "(3B)" = T3B,
    "(3C)" = T3C,
    "(3D)" = T3D,
    "(3E)" = T3E
  ),
  stars = T,
  gofomit = "6 $\wedge(?!(\text{R2}|\text{Num.Obs.}|(\text{FE}.*))\$).*$ ",
  output = "gt"
)
```

Tabelle 7.6: Schätzungen des Effekts von Polizeipräsenz auf Autodiebstähle

	(3A)	(3B)	(3C)	(3D)	(3E)
sameTRUE	-0.078*** (0.022)	-0.080*** (0.023)	-0.081*** (0.023)	-0.073*** (0.011)	-0.054* (0.022)
oneblockTRUE		-0.013 (0.014)	-0.014 (0.014)	-0.012 (0.011)	0.012 (0.013)
twoblocksTRUE			-0.002 (0.012)	-0.003 (0.009)	0.024* (0.010)
Num.Obs.	7884	7884	7884	4380	3816
R2	0.198	0.198	0.198	0.004	0.195
FE: observ	X	X	X		X
FE: monat	X	X	X		X

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

Tabelle 7.6 präsentiert die Ergebnisse. Der Koeffizient von `same` ist jeweils in den Regressionen (3A), (3B) und (3C) negativ und hoch-signifikant. Die

⁶Der Ausdruck $\wedge(?!(\text{R2}|\text{Num.Obs.}|(\text{FE}.*))\$).*$ matcht jede Zeichenkette, außer sie ist "R2", "Num.Obs." oder beginnt mit "FE". Andere Statistiken als diese Matches werden also in der Tabelle ausgelassen.

Stärke des geschätzten Effekt (und der Standardfehler) unterscheidet sich kaum zwischen den Modellen. Weiterhin sind die Koeffizienten von `oneblock` und `twoblocks` jeweils nicht signifikant von null verschieden. Die Interpretation dieser Ergebnisse ist, dass es einen lokal-beschränkten Effekt der erhöhten Polizeipräsenz auf Autodiebstähle in Blocks mit Polizeischutz gab: Die Polizeipräsenz verringerte die durchschnittliche Anzahl der Diebstähle in diesen Blocks um etwa .08 Diebstähle pro Monat.

Die Ergebnisse für die Modelle (3D) und (3E) zeigen ebenfalls signifikante negative Effekte des Polizeischutz anhand von Querschnitts- und Zeitreihenvariation und untermauern damit die Robustheit des gewählten Forschungsdesigns.

Zur besseren Interpretation des geschätzten Effekt in Modell (C) vergleichen wir mit der durchschnittlichen Anzahl der Diebstähle pro Monat in der Kontrollgruppe (Blocks mit einer Entfernung von mehr als zwei Blocks zum nächsten geschützten Block) für den Zeitraum von August 1994 bis Dezember 1994:⁷

```
# Vergl. Effekt mit durchschnittlicher Anz. Diebstähle
# in der Kontrollgruppe
(
  # gesch. Effekt
  T3C %>%
    coefficients() %>%
    . [ "sameTRUE" ]
) /
  ( # Durchschnittt
  polizeipraesenz %>%
    filter(
      monat >= "August" & monat <= "Dezember",
      distanz > 2
    ) %>%
    summarise(
      m_totrob = mean(totrob)
    ) %>%
    pull(m_totrob)
  ) * 100

```

`sameTRUE`
`-74.92`

⁷Wir berechnen also $\hat{\alpha}_0 / \overline{\text{Diebstahlrate}} \cdot 100$.

Die Rechnung zeigt, dass es in dem betrachteten Zeitraum durch die Behandlung mit zusätzlicher Polizeipräsenz zu einem Rückgang der Anzahl an Autodiebstählen um durchschnittlich 75% in Blocks mit jüdischen Einrichtungen kam.

7.5.3 Placebo-Tests

Placebo-Tests sind nützlich, um zu überprüfen, ob der geschätzte Zusammenhang zwischen der Erhöhung der Polizeipräsenz und der Verringerung der Kriminalität tatsächlich kausal ist oder ob andere Faktoren eine Rolle spielen. Ein möglicher Einfluss könnte beispielsweise durch zufällige temporäre Schwankungen in den Kriminalitätsraten entstehen. Di Tella und Schargrodsky (2004) wiederholen hierzu die Analyse anhand der Spezifikationen (3A), (3B) und (3C) für fiktive Interventionszeitpunkte *vor dem Anschlag*. Hierbei werden Ende April (4A), Ende Mai (4B) und Ende Juni (4C) als fiktive Zeitpunkte für die Placebo-Behandlung gewählt. Wenn diese Placebo-Tests ähnliche Ergebnisse (signifikante negative Schätzungen) wie die ursprüngliche Untersuchung liefern, könnte dies darauf hindeuten, dass die in Tabelle 7.6 geschätzten Effekte nicht kausal sind.

Wir replizieren diese Ergebnisse, indem wir die Schätzungen von (3A), (3B) und (3C) mit entsprechender Definition des Behandlungsindikators (`group`) jeweils für modifizierte Datensätze mit sämtlichen 3504 Beobachtungen vor dem Anschlag (`filter(monat <= "Juli (1 - 17)")`) wiederholen.

```
# (4A)
# Placebo-Schätzung für
dat_T4A <- polizeipraesenz %>%
  mutate(
    group = monat >= "Mai" & monat <= "Juli (1 - 17)",
    same = (institut == 1) * group,
    oneblock = (distanz == 1) * group,
    twoblocks = (distanz == 2) * group
  ) %>%
  filter(monat <= "Juli (1 - 17)")

(
  T4A <- feols(
    fml = totrob ~
      same +
      oneblock +
```

```

    twoblocks
| observ + monat,
data = dat_T4A,
vcov = "HC1"
)
)

```

OLS estimation, Dep. Var.: totrob
Observations: 3,504
Fixed-effects: observ: 876, monat: 4
Standard-errors: Heteroskedasticity-robust

	Estimate	Std. Error	t value	Pr(> t)
same	-0.01864	0.05323	-0.3502	0.72622
oneblock	-0.02554	0.02519	-1.0138	0.31075
twoblocks	-0.03263	0.02264	-1.4410	0.14969

Signif. codes:	0 ***	0.001 **	0.01 *	0.05 .
RMSE:	0.18282	Adj. R2:	0.092254	
		Within R2:	0.001211	

```

# (4B)
dat_T4B <- dat_T4A %>%
  mutate(
    group = monat >= "Juni" & monat <= "Juli (1 - 17)",
    same = (institut == 1) * group,
    oneblock = (distanz == 1) * group,
    twoblocks = (distanz == 2) * group
  )

(
  T4B <- feols(
    fml = totrob ~
      same
      + oneblock
      + twoblocks
      | observ + monat,
    data = dat_T4B,
    vcov = "HC1"
  )

```

```

)
)

OLS estimation, Dep. Var.: totrob
Observations: 3,504
Fixed-effects: observ: 876, monat: 4
Standard-errors: Heteroskedasticity-robust
      Estimate Std. Error t value Pr(>|t|)
same     0.01467    0.04011  0.3658  0.71451
oneblock 0.01402    0.01976  0.7096  0.47799
twoblocks -0.01466   0.01736 -0.8443  0.39856
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.182863      Adj. R2: 0.091835
      Within R2: 7.494e-4

```

```

# (4C)
dat_T4C <- dat_T4A %>%
  mutate(
    group = monat %in% c("Juli (1 - 17)", 
    same = (institut == 1) * group,
    oneblock = (distanz == 1) * group,
    twoblocks = (distanz == 2) * group
  )

  (
    T4C <- feols(
      fml = totrob ~
        same
      + oneblock
      + twoblocks
      | observ + monat,
      data = dat_T4C,
      vcov = "HC1"
    )
  )

```

```

OLS estimation, Dep. Var.: totrob
Observations: 3,504

```

```

Fixed-effects: observ: 876, monat: 4
Standard-errors: Heteroskedasticity-robust
            Estimate Std. Error t value Pr(>|t|)
same      -0.036111    0.03858 -0.9361  0.34933
oneblock   0.023105    0.02245  1.0294  0.30340
twoblocks -0.009403    0.01693 -0.5554  0.57870
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.182841     Adj. R2: 0.09205
Within R2: 9.857e-4

```

```

# Tabellarische Zusammenfassung mit modelsummary()
# (Tabelle 4 in Dittella und Schargrodsky, 2004)
modelsummary(
  models = list(
    "(4A)" = T4A,
    "(4B)" = T4B,
    "(4C)" = T4C
  ),
  stars = T,
  gof.omit = "^(?!R2|Num.Obs.|FE.*$).*",
  notes = "Fiktive Interventionen: (4A) Ende April. (4B): Ende
    ↳ Mai. (4C): Ende Juni.",
  output = "gt"
)

```

Tabelle 7.7: Placebo-Tests für fiktive Anschlagszeitpunkte bis Ende Juni

	(4A)	(4B)	(4C)
same	-0.019 (0.053)	0.015 (0.040)	-0.036 (0.039)
oneblock	-0.026 (0.025)	0.014 (0.020)	0.023 (0.022)
twoblocks	-0.033 (0.023)	-0.015 (0.017)	-0.009 (0.017)
Num.Obs.	3504	3504	3504
R2	0.321	0.320	0.320
FE: observ	X	X	X
FE: monat	X	X	X

+ $p < 0.1$, * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$

Fiktive Interventionen: (4A) Ende April. (4B): Ende Mai. (4C): Ende Juni.

Die Ergebnisse in Tabelle 7.7 stützen die kausale Interpretation der Regressionen in Tabelle 7.6: Für keinen der fiktiven Zeitpunkte einer Intervention vor dem tatsächlichen Anschlag im Juli 1994 finden wir signifikante Unterschiede in der beobachteten Diebstahlrate zwischen Blocks mit einer jüdischen Einrichtung und solchen ohne.

7.5.4 Weitere Robustness-Checks

Di Tella und Schargrodsky (2004) betrachten weitere Robustness-Checks. Die Autoren merken zunächst an, dass (positive) Korrelation innerhalb der Block-spezifischen Fehlerterme über die Zeit (und zwischen den Blocks eines Viertels) zu einer Unterschätzung der Unsicherheit der Treatment-Effekt-Schätzer in den DID-Regressionen mit herkömmlichen Standardfehler-Formeln führen kann. In DID-Designs kann dieses Problem durch die Korrelation der Behandlung über die Zeit noch verstärkt werden. Daher werden alternative Spezifikationen betrachtet, um die Robustheit der Interenzstatistiken in Tabelle 7.6 hinsichtlich Korrelation in den Fehlerterme zu überprüfen. Dies geschieht in den Regressio-nen (T5A) bis (T5C). Weitere Modelle kontrollieren für Stadtviertel-spezifische Effekte (T5D), verwenden eine um Blocks ohne gemeldete Diebstähle reduzier-ten Datensatz (T5E) und nutzen eine Poisson-Spezifikation. Wir fassen diese Ansätze kurz zusammen:

- Regression (T5A): Entfernen der Zeitvariation von $totrob_{i,t}$ innerhalb der Blocks durch Verwendung von Durchschnittswerten für die Monate vor und nach dem Anschlag. Regression dieser Durchschnittswerte auf die Behandlungsvariablen, wie in (7.15).
- Regression (T5B): Schätzung der Spezifikation (7.15) und Berechnung von Inferenzstatistiken mit cluster-robusten Standardfehlern (Clustering auf Block-Ebene).
- Regression (T5C): Um in Regression (7.15) möglicher Korrelation zwischen den Blocks innerhalb eines Standviertel und Korrelation Stadtviertel-spezifischer Schocks über die Zeit zu begegnen, clustern Di Tella und Schargrodsky (2004) Standardfehler auf Stadtviertel-Monats-Ebene.
- Regression (T5D): Diese Regression ersetzt in (7.15) die Fixed Effects für die Monate durch Stadtviertel-spezifische Zeit-Effekte (anhand von

Indikatorvariablen zur Berechnung der geclusterten Standardfehler in T5C). Wenn keine Stadtviertel-spezifischen Einflüsse vorliegen, sollten die geschätzten Koeffizienten mit denen für das Modell (7.15) vergleichbar sein.

- Regresion (T5E): Regression (7.15) ohne Blocks in denen keine Diebstähle im Beobachtungszeitraum erfasst wurden. Auslassen dieser Beobachtungen sollte die Signifikanz des ATT-Schätzer nicht beeinflussen, jedoch zu einem stärkeren (negativen) Effekt führen, da die Kontrollgruppe dann ausschließlich aus Blocks mit gemeldeten Auto-Diebstählen besteht.
- Regresion (T5F): Die Daten erfassen das Aufkommen von Ereignissen (Diebstähle) innerhalb eines bestimmten Raum-Zeitbezugs (pro Block und Monat) beschreiben. Solche Daten können mit Modellen für Zählvariablen beschrieben werden. Di Tella und Schargrodsky (2004) schätzen eine **Poisson-Regression**. Hierbei wird der (log) Poisson-Parameter $\lambda_{i,t}$ (die *Inzidenzrate*) durch die lineare Funktion in (7.15) modelliert, d.h.

$$\begin{aligned} \log(\lambda_{i,t}) = & \text{monat}_t + \text{block}_i \\ & + \alpha_0 \text{same}_{i,t} \\ & + \alpha_1 \text{oneblock}_{i,t} \\ & + \alpha_2 \text{twoblocks}_{i,t} \\ & + \epsilon_{i,t}. \end{aligned} \quad (7.16)$$

Eine Schätzung des Behandlungseffekts anhand von Poisson-Regression sollte zu ähnlichen Schlussfolgerungen führen, wie die lineare Regression (7.15).

Für die Reproduktion der Robustness-Checks mit R erweitern wir `dat_DID` um eine Indikatorvariable für den Zeitraum vor dem Anschlag (`pre`) und eine kategoriale Variable für Stadtviertel-Monat-Effekte `mbc`.

```
# Datensatz für weitere Robustness-Checks
dat_DID_T5 <- dat_DID %>%
  mutate(
    # Indikator: vor Anschlag
    pre = monat < "Juli (18 - 31)",
    # Interaktion: Stadtviertel x Monat
```

```

  mbc = paste0(barrio, "_", monat)
)

```

Die Spezifikationen (T5A) bis (T5E) implementieren wir wie zuvor mit `fixest::feols()` unter Anpassung des Datensatzes, sofern relevant. Für cluster-robuste Standardfehler kann das Argument `vcov = ~ cluster` gesetzt werden, wobei `cluster` zu verwendende Ebene ist. Die Poisson-Spezifikation (7.16) in (T5F) schätzen wir mit `fixest::feglm()`.⁸

```

# (5A)
(
  T5A <- feols(
    fml = totrob ~
      same
      + oneblock
      + twoblocks
      | observ + monat,
    data = dat_DID_T5 %>%
      group_by(observ, pre) %>%
      mutate(
        totrob = mean(totrob)
      )
  )
)

```

```

OLS estimation, Dep. Var.: totrob
Observations: 7,884
Fixed-effects: observ: 876, monat: 9
Standard-errors: Clustered (observ)

      Estimate Std. Error t value  Pr(>|t|)
sameTRUE     -0.080802    0.02394 -3.3752 0.00077008 ***
oneblockTRUE -0.013988    0.01509 -0.9272 0.35406278
twoblocksTRUE -0.002185    0.01239 -0.1763 0.86008157
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
RMSE: 0.07623   Adj. R2: 0.617109
                           Within R2: 0.011346

```

⁸Der R-Befehl hierfür ist ähnlich wie für die Probit-Regressionen in Kapitel 7.4.2.

```

# (5B)
(
  T5B <- feols(
    fml = totrob ~
      same
      + oneblock
      + twoblocks
      | observ + monat,
    data = dat_DID_T5,
    vcov = ~ observ
  )
)

```

OLS estimation, Dep. Var.: totrob
 Observations: 7,884
 Fixed-effects: observ: 876, monat: 9
 Standard-errors: Clustered (observ)

	Estimate	Std. Error	t value	Pr(> t)
sameTRUE	-0.080802	0.02394	-3.3752	0.00077008 ***
oneblockTRUE	-0.013988	0.01509	-0.9272	0.35406278
twoblocksTRUE	-0.002185	0.01239	-0.1763	0.86008157

Signif. codes:	0 ***	0.001 **	0.01 *	0.05 .
RMSE:	0.21666	Adj. R2:	0.096942	
		Within R2:	0.001419	

```

# (5C)
(
  T5C <- feols(
    fml = totrob ~
      same
      + oneblock
      + twoblocks
      | observ + monat,
    data = dat_DID_T5,
    vcov = ~ mbc
  )
)

```

OLS estimation, Dep. Var.: totrob
Observations: 7,884
Fixed-effects: observ: 876, monat: 9
Standard-errors: Clustered (mbc)

	Estimate	Std. Error	t value	Pr(> t)
sameTRUE	-0.080802	0.02206	-3.6630	0.0011186 **
oneblockTRUE	-0.013988	0.01631	-0.8576	0.3989448
twoblocksTRUE	-0.002185	0.01702	-0.1284	0.8988318

Signif. codes:	0 *** 0.001 ** 0.01 * 0.05 . 0.1 ' ' 1			
RMSE:	0.21666	Adj. R2:	0.096942	
		Within R2:	0.001419	

```
# (5D)
(
  T5D <- feols(
    fml = totrob ~
      same
      + oneblock
      + twoblocks
      | observ + mbc,
    data = dat_DID_T5,
    vcov = "HC1"
  )
)
```

OLS estimation, Dep. Var.: totrob
Observations: 7,884
Fixed-effects: observ: 876, mbc: 27
Standard-errors: Heteroskedasticity-robust

	Estimate	Std. Error	t value	Pr(> t)
sameTRUE	-0.083449	0.02434	-3.429	0.0006096 ***
oneblockTRUE	-0.016584	0.01571	-1.056	0.2912270
twoblocksTRUE	-0.002437	0.01289	-0.189	0.8500732

Signif. codes:	0 *** 0.001 ** 0.01 * 0.05 . 0.1 ' ' 1			
RMSE:	0.216318	Adj. R2:	0.09747	
		Within R2:	0.001412	

```

# (5E)
(
  T5E <- feols(
    fml = totrob ~
      same
      + oneblock
      + twoblocks
      | observ + monat,
    data = dat_DID_T5 %>%
      group_by(observ) %>%
      filter(
        sum(totrob) > 0
      ),
    vcov = "HC1"
  )
)

```

OLS estimation, Dep. Var.: totrob
 Observations: 5,967
 Fixed-effects: observ: 663, monat: 9
 Standard-errors: Heteroskedasticity-robust

	Estimate	Std. Error	t value	Pr(> t)
sameTRUE	-0.126179	0.03742	-3.3719	0.00075199 ***
oneblockTRUE	-0.017895	0.01942	-0.9213	0.35692825
twoblocksTRUE	-0.003944	0.01579	-0.2498	0.80278849

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
 RMSE: 0.248595 Adj. R2: 0.054989
 Within R2: 0.002067

```

# (5F)
(
  T5F <- feglm(
    fml = totrob ~
      same
      + oneblock
      + twoblocks
      | observ + monat,
    data = dat_DID_T5 %>%

```

```

group_by(observ) %>%
  filter(
    sum(totrob) > 0
  ),
  family = "poisson",
  vcov = "HC1"
)
)

GLM estimation, family = poisson, Dep. Var.: totrob
Observations: 5,967
Fixed-effects: observ: 663, monat: 9
Standard-errors: Heteroskedasticity-robust
              Estimate Std. Error z value Pr(>|z|)
sameTRUE      -1.21621   0.3525 -3.4502 0.00056013 ***
oneblockTRUE  -0.14272   0.1593 -0.8956 0.37044224
twoblocksTRUE -0.01691   0.1347 -0.1255 0.90009545
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Log-Likelihood: -1,902.7  Adj. Pseudo R2: -0.193316
BIC:  9,665.2  Squared Cor.:  0.172849

```

```

# Tabellarische Zusammenfassung
# (Tabelle 5 in Di Tella und Schargrodsky, 2004)
modelsummary(
  models = list(
    "(T5A)" = T5A,
    "(T5B)" = T5B,
    "(T5C)" = T5C,
    "(T5D)" = T5D,
    "(T5E)" = T5E,
    "(T5F)" = T5F
  ),
  stars = T,
  gof_omit = "^(?!(R2|Std.Errors|Num.Obs.|FE.*))$.*",
  exponentiate = c(rep(F, 5), T),
  vcov = list("HC1", ~observ, ~mbc, "HC1", "HC1", "HC1"),
  output = "gt"
)

```

Tabelle 7.8: Weitere Robustness-Checks

	(T5A)	(T5B)	(T5C)	(T5D)	(T5E)	(T5F)
sameTRUE	-0.081*** (0.009)	-0.081*** (0.024)	-0.081** (0.022)	-0.083*** (0.024)	-0.126*** (0.037)	0.296*** (0.104)
oneblockTRUE	-0.014* (0.005)	-0.014 (0.015)	-0.014 (0.016)	-0.017 (0.016)	-0.018 (0.019)	0.867 (0.138)
twoblocksTRUE	-0.002 (0.004)	-0.002 (0.012)	-0.002 (0.017)	-0.002 (0.013)	-0.004 (0.016)	0.983 (0.132)
Num.Obs.	7884	7884	7884	7884	5967	5967
R2	0.660	0.198	0.198	0.201	0.162	0.118
Std.Errors	HC1	by: observ	by: mbc	HC1	HC1	HC1
FE: observ	X	X	X	X	X	X
FE: monat	X	X	X		X	X
FE: mbc				X		

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

Anhand von Tabelle 7.8 finden wir weitere Evidenz für die Robustheit der DID-Schätzung (T3C) in Tabelle 7.6:

- Die Schlussfolgerungen anhand der Inferenzstatistiken sind nicht sensibel gegenüber den unterschiedlichen Spezifikationen für die Berechnung der Standardfehler in (T5A) bis (T5C).
- Die Alternative Spezifikation von Fixed Effects für Kombination von Stadtviertel und Monat (**mbc**) in (T5D) beeinflusst den Koeffizientenschätzer von **same** nur marginal. Auch hier ist der geschätzte ATT signifikant.
- Wie erwartet führt die Verkleinerung der Kontrollgruppe auf Blocks mit gemeldeten Diebstählen in (T5E) zu einer größeren Schätzung des Effekts. Der Effekt bleibt signifikant.
- In der Poisson-Regression in (T5F) finden wir ebenfalls einen signifikanten Effekt von **same**. Beachte das dieser Koeffizient den *multiplikativen* Einfluss von Polizeipräsenz auf die Inzidenzrate (durchschnittliche Anzahl an Diebstählen pro Monat pro Block) angibt. Die Interpretation des Schätzwerts von etwa 0.3 bedeutet also eine *Reduktion* der Inzidenz um etwa 70% in Blocks mit erhöhter Polizeipräsenz gegenüber der Kontrollgruppe (Blocks mit mehr als zwei Blocks Entfernung zur nächsten jüdischen Einrichtung). Diese Schätzung stimmt also gut überein mit unserer Interpretation der Ergebnisse in Tabelle 7.6.

7.6 Zusammenfassung

Der DID-Schätzer liefert uns eine Schätzung des ATT, indem er die Veränderung der Ergebnisse in der Behandlungsgruppe vor und nach der Intervention mit der entsprechenden Veränderung in der Kontrollgruppe vergleicht. Die Annahme paralleler Trends ist entscheidend: Nur wenn diese Annahme gilt, können wir sicher sein, dass die Differenz in den Differenzen tatsächlich den kausalen Effekt der Behandlung widerspiegelt und nicht durch andere zeitgleiche Faktoren beeinflusst wird.

Zusammenfassend bietet der DID-Ansatz im Potential Outcomes Framework eine robuste Methode zur Schätzung kausaler Effekte, insbesondere wenn randomisierte Experimente nicht durchführbar sind. Durch den Vergleich von Zeitverläufen in Behandlungs- und Kontrollgruppen unter der Annahme paralleler Trends können wir verlässliche Schätzungen des ATT gewinnen.

8 Regression Discontinuity Designs

Regression Discontinuity Design (RDD) ist ein Ansatz für die Schätzung von Behandlungseffekten mit Regression, wenn durch einen experimentell oder natürlich gegebenen Umstand die Behandlung an einem Schwellenwert (c) einer *Laufvariable* (X) sprunghaft beeinflusst wird. Ein RDD-Schätzer wird so implementiert, dass lediglich Beobachtungen mit Ausprägungen von X , die knapp ober- oder knapp unterhalb von c liegen, berücksichtigt werden. Die zentrale Idee hierbei ist, dass Individuen nahe bei c im Durchschnitt ähnliche Merkmale aufweisen. Beobachtungen nahe c sind dann insbesondere hinsichtlich potentieller Backdoor-Variablen vergleichbar, sodass deren problematische Pfade geschlossen sind. Das kausale Diagramm in Abbildung 8.1 zeigt den grundsätzlichen Zusammenhang.

RDD isoliert Variation auf dem Pfad *Oberhalb* $C \rightarrow$ *Behandlung* $B \rightarrow Y$. Somit können Backdoor-Pfade über X oder weitere (möglichweise unbeobachtbare) Confounder (Z) vermieden werden, siehe Abbildung 8.1. Der kausale Effekt wird dabei als (lokaler) durchschnittlicher Behandlungseffekt der Diskontinuität auf die Outcome-Variablen (Y) anhand von Beobachtungen *nahe bei* c ermittelt.

Hinsichtlich der Beeinflussung der Behandlung unterscheiden wir zwischen *Sharp* und *Fuzzy* Regression Discontinuity Designs (SRDD/FRDD). Bei einem SRDD ist die Zuweisung der Behandlung *deterministisch*, d.h. der Schwellenwert in der Laufvariable ist eine harte Grenze für die Gruppenzugehörigkeit: Die *Wahrscheinlichkeit* der Behandlung p springt bei $X = c$ von $p = 0$ um $\Delta p = 1$ auf $p = 1$.

Bei einem FRDD ist die Zuordnung in Behandlungs- und Kontrollgruppe nicht perfekt durch den Schwellenwert c bestimmt: Die Behandlungswahrscheinlichkeit p springt bei $X = c$ um $\Delta p < 1$. Im FRDD können grundsätzlich also sowohl behandelte Subjekte als auch Kontroll-Beobachtungen auf beiden Seiten der Diskontinuität vorliegen – die Trennung der Gruppen ist “unscharf”¹. Dieser Umstand ist oft in empirischen Studien mit nicht-experimentellen Daten gegeben, wenn es neben der Überschreitung von c weitere Determinanten der Behandlung gibt (für die wir nicht kontrollieren können). Die Wahl zwischen

¹Engl. *fuzzy*.

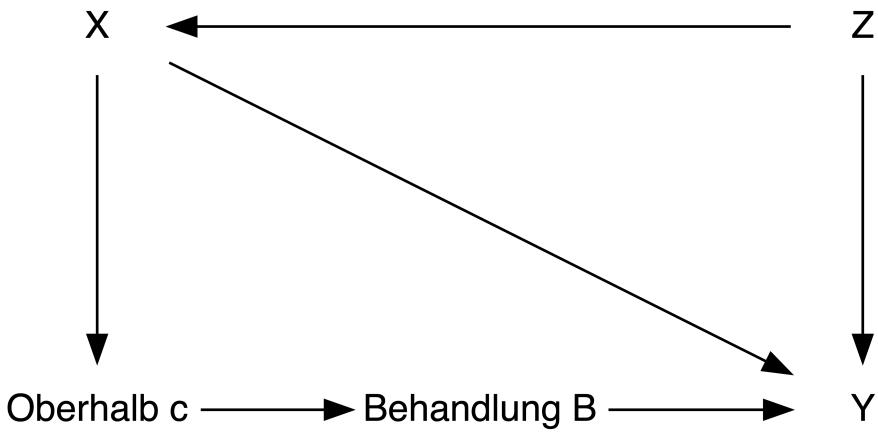


Abbildung 8.1: Kausales Diagramm für Sharp RDD

SRDD und FRDD hängt grundsätzlich vom datenerzeugenden Prozess und der Forschungsfrage ab.

8.1 Sharp Regression Discontinuity Design

Modell und funktionale Form

Die korrekte Spezifikation der funktionalen Form für ein RDD ist wichtig, um eine verzerrte Schätzung des Effekts zu vermeiden. Die einfachste Form eines SRDD kann anhand der linearen Regression

$$Y_i = \beta_0 + \beta_1 B_i + \beta_2 X_i + u_i \quad (8.1)$$

geschätzt werden, wobei B_i eine Dummy-Variable für das Überschreiten des Schwellenwertes c ist, d.h.

$$B_i = \begin{cases} 0 & X_i < c \\ 1 & X_i \geq c. \end{cases}$$

Damit ist B_i eine *deterministische* Funktion der Laufvariable X_i und zeigt die Zugehörigkeit zur Behandlungs- oder Treatmentgruppe an. Der Koeffizient β_1 misst den Behandlungseffekt.

Das Modell (8.1) unterstellt, dass X links- und rechtsseitig von c denselben Effekt auf Y hat. Diese Annahme ist restriktiv. Eine Alternative ist ein lineares

Interaktionsmodell

$$Y_i = \beta_0 + \beta_1 B_i + \beta_2(X_i - c) + \beta_3(X_i - c) \times B_i + u_i. \quad (8.2)$$

Das Modell (8.2) kann unterschiedliche lineare Effekte von X auf Y unterhalb (β_2) und oberhalb ($\beta_2 + \beta_3$) von c abbilden. Beachte, dass $(X_i - c)$ die um den Schwellenwert zentrierte Laufvariable ist, sodass β_1 wie in (8.1) den Unterschied des Effekts von X auf Y für Beobachtungen am Schwellenwert erfasst.

Um unterschiedliche nicht-lineare Zusammenhänge von X und Y unterhalb und oberhalb von c abzubilden, können (interagierte) Polynom-Terme in X verwendet werden. Häufig wird eine quadratische Regressionsfunktion genutzt,

$$Y_i = \beta_0 + \beta_1 B_i + \beta_2(X_i - c) + \beta_3(X_i - c)^2 \quad (8.3)$$

$$+ \beta_4(X_i - c) \times B_i + \beta_5(X_i - c) \times B_i + u_i. \quad (8.4)$$

Gelman und Imbens (2019) zeigen, dass Polynome höherer Ordnung zu verzerrten Schätzern und hoher Varianz führen können.² Die Autoren empfehlen stattdessen die Schätzung mit lokaler Regression.

Nicht-parametrische Schätzung und Bandweite

Aktuelle Studien nutzen nicht-parametrische Schätzer, die den Behandlungseffekt als Differenz der geschätzten Regressionsfunktionen am Schwellenwert c berechnen. Um auch nicht-lineare Regressionsfunktionen abzubilden zu können, wird häufig lokale Regression verwendet. Dieses Verfahren liefert eine “lokale” Schätzung der Regressionsfunktionen am Schwellenwert, bei der nur Beobachtungen nahe $X = c$ für die Schätzung berücksichtigt werden. Hinreichende Nähe wird hierbei durch eine sogenannte Bandweite h festgelegt, wobei

$$|(X_i - c)| \leq h \quad (8.5)$$

das Kriterium für eine Berücksichtigung von Beobachtung i bei der Schätzung ist.

Unter Verwendung einer Bandweite h wird der Regressionsansatz (8.2) als *lokale lineare Regression* mit Uniform-Kernelfunktion bezeichnet. Der Uniform-Kernel gibt allen Beobachtungen, innerhalb der Bandweite h dasselbe Gewicht. Ist h so groß, dass der gesamte Datensatz in die Schätzung einbezogen wird, entspricht der lokale lineare Regressions-Schätzer mit Uniform-Kernel dem (globalen) KQ-Schätzer in einem linearen Interaktionsmodell anhand aller Beobachtungen.

²Ursachen sind Überanpassung an die Daten sowie instabiles Verhalten der Schätzung nahe des Schwellenwertes.

Neben dem Uniform-Kernel ist der Triangular-Kernel eine in der Praxis häufig genutzte lineare Kernelfunktion. Der nachstehende Code plottet die Uniform- (grün) sowie die Triangular-Kernelfunktion (blau), siehe Abbildung 8.2.

```
library(ggplot2)
library(cowplot)

# Kernelfunktionen zeichnen
ggplot() +
  geom_function(
    fun = ~ ifelse(
      test = abs(.) <= 1,
      yes = 1/2,
      no = 0
    ),
    col = "green",
    n = 1000
  ) +
  geom_function(
    fun = ~ ifelse(
      test = abs(.) <= 1,
      yes = 1 - abs(.),
      no = 0
    ),
    col = "blue",
    n = 100
  ) +
  scale_x_continuous(
    name = "x",
    limits = c(-1.5, 1.5),
    breaks = c(-1, 0, 1)
  ) +
  scale_y_continuous(
    name = "K(x)",
    breaks = c(0, 1),
    limits = c(0, 1.25)
  ) +
  theme_cowplot()
```

In empirischen Studien wird als Basis-Spezifikation oft eine lokale lineare

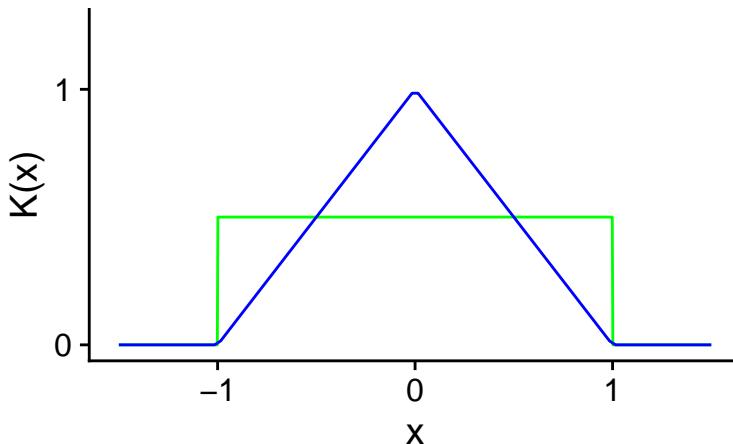


Abbildung 8.2: Kernelfunktionen auf $[-1, 1]$

Regression anhand von (8.2) mit einer linearen Kernelfunktionen und geringer Bandweite h genutzt. Anschließend wird die Robustheit der Ergebnisse anhand flexiblerer Spezifikationen, die Nicht-Linearitäten in der Regressionsfunktion besser abbilden können, geprüft.

Die nachstehende Visualisierung zeigt die Schätzung des kausalen Effektes der Behandlung B_i anhand lokaler linearer Regression mit einem Uniform-Kernel für wie folgt simulierte Daten:

$$Y_i = \beta_1 X_i + \beta_2 B + \beta_3 X_i^2 \times B_i + u_i,$$

$$u_i \sim N(0, 0.5), \quad X_i \sim U(0, 10), \quad B = \mathbb{I}(X_i \geq c = 5)$$

$$\beta_1 = .5, \quad \beta_2 = 1.5, \quad \beta_3 = -0.15$$

Diese Vorschrift ist schnell mit R umgesetzt:

```
set.seed(1234)
# Anz. Beobachtungen
n <- 750

# Parameter definieren
c <- 5
beta_1 <- .5
beta_2 <- 1.5
beta_3 <- -.15

# Regressionsfunktion definieren
```

```

f <- function(X) {
  beta_1 * (X - c) + beta_2 * B + beta_3 * B * (X - c)^2
}

# Daten erzeugen
X <- runif(n, 0, 11)
B <- ifelse(X - c >= 0, 1, 0)
Y <- f(X) + rnorm(n, sd = .5)

# Beobachtungen sammeln
dat <- data.frame(
  Y = Y, X = X - c, B = B
)

```

Diese interaktive Komponente des Buchs ist nur in der Online-Version verfügbar.

Der interessierende Effekt am Schwellenwert $c = 5$ beträgt $\beta_2 = 1.5$. Beachte, dass aufgrund des Terms $\beta_3 X_i^2 \times B_i$ ein quadratischer Zusammenhang von Y und X oberhalb von $X_i = c$ vorliegt. Es können folgende Eigenschaften der Schätzung in Abhängigkeit von der Bandweite h beobachtet werden:

- Für die voreingestellte Bandweite $h = 1.3$ liefert die lokale lineare Regression eine gute Approximation des Regressionszusammenhangs auf beiden Seiten des Schwellenwertes und die Schätzung des Behandlungseffekts liegt nahe beim wahren Wert $\beta_2 = 1.5$.
- Für kleinere Bandweiten verringert sich die Datenbasis der Schätzung. Die Varianz der Schätzung nimmt zu und die Approximation der Regressionsfunktion verschlechtert sich. Wir beobachten eine mit $h \rightarrow 0$ zunehmende Verzerrung bei der Schätzung des Behandlungseffekts.
- Größere Bandweiten h erhöhen die Datenbasis der Schätzung, führen aber zu einer Annäherung der lokalen Schätzung an die globale KQ-Schätzung. Linksseitig des Schwellenwertes erzielen wir damit eine Schätzung mit hoher Güte. Rechtsseitig von $X_i = c$ verschlechtert sich die lokale Anpassung

am Schwellenwert deutlich, weil die lineare Schätzung den tatsächlichen (nicht-linearen) Zusammenhang nicht adäquat abbilden kann. Die Schätzung des Behandlungseffekts ist hier deutlich verzerrt.

Die Wahl der Bandweite ist also eine wichtige Komponenten der RDD-Schätzung: Kleine Bandweiten erlauben eine Schätzung der Regressionsfunktion nahe des Schwellenwertes mit wenig Verzerrung. Allerdings kann diese Schätzung unpräzise sein, wenn nur wenige Beobachtungen (8.5) erfüllen. In der Praxis wird h daher mit einem analytischen Schätzer (vgl. G. Imbens und Kalyanaraman 2012) oder anhand von *Cross Validation* (bspw. G. W. Imbens und Lemieux 2008) bestimmt. Die später in diesem Kapitel betrachteten R-Pakete halten diese Methoden bereit.

8.2 Manipulation am Schwellenwert

Eine wichtige Annahmen für die Gültigkeit einer RDD-Schätzung ist, dass keine Manipulation der Gruppenzugehörigkeit am Schwellenwert vorliegt. Wenn sich Subjekte nahe des Schwellenwertes c — d.h. in Abhängigkeit der Laufvariable X — systematisch in den Confoundern Z unterscheiden, können wir den Backdoor-Pfad *Oberhalb* $C \rightarrow \text{Behandlung} B \rightarrow Y$ nicht isolieren. Wir erhalten dann eine verzerrte Schätzung des Behandlungseffekts.

In empirischen Studien mit Individuen kann Selbstselektion auftreten: Menschen mit $X < c$ aber nahe c (hier Kontrollgruppe) könnten aufgrund unbeobachtbarer Eigenschaften Z die Ausprägung ihrer Laufvariable zu $X > c$ (hier Behandlungsgruppe) manipulieren. Wenn Z die Outcome-Variable beeinflusst, bleibt der Backdoor-Pfad *Oberhalb* $C \rightarrow \text{Behandlung} B \rightarrow Y$ so bestehen.

Manipulation resultiert in Häufung von Beobachtungen am Schwellenwert. Die Verteilung der Laufvariable kann auf diese Unregelmäßigkeit hin untersucht werden. McCrary (2008) schlägt hierfür einen Verfahren vor, das die Kontinuität der Dichtefunktion von X am Schwellenwert testet.

Der Test von McCrary (2008) ist in `rdd::DCdensity()` implementiert. Wir zeigen die Anwendung des Tests anhand der oben simulierten Daten. Beachte, dass $X_i \sim U(0, 10)$, d.h. die Laufvariable ist bei $X_i = c$ kontinuierlich verteilt. Die Nullhypothese (keine Manipulation) gilt für die simulierten Daten

```
# McCrary-Test durchführen
p_mccrary <- rdd::DCdensity(
  runvar = X,
```

```

    cutpoint = c,
    plot = F
)

# p-Wert
p_mccrary

```

[1] 0.5013939

Der p-Wert 0.5 ist größer als jedes übliche Signifikanzniveau. Damit liegt starke Evidenz für die Nullhypothese (keine Diskontinuität) und gegen Manipulation am Schwellenwert vor.

Cattaneo, Jansson, und Ma (2020) (CMJ) schlagen eine Weiterentwicklung des McCrary-Tests vor, die höhere statistische Macht gegenüber Diskontinuitäten hat am Schwellenwert hat. Der CJM-Test ist im Paket `rddensity` implementiert.

```

library(rddensity)

# CJM Schätzer berechnen
CJM <- rddensity(X, c = 5)

```

Mit der Funktion `rddensity::rdplotdensity()` erzeugen wir Abbildung 8.3.

```

# Plot für Dichtefunktion erstellen
plot <- rdplotdensity(
  rdd = CJM,
  X = X,
  # für Punkte- und Linienplots:
  type = "both"
)

```

Abbildung 8.3 zeigt die geschätzten Dichtefunktionen. Erwartungsgemäß finden wir eine große Überlappung der zugehörigen Konfidenzbänder (schattierte Flächen) am Schwellenwert $c = 5$.

Mit `summary()` erhalten wir eine detaillierte Zusammenfassung des Tests.

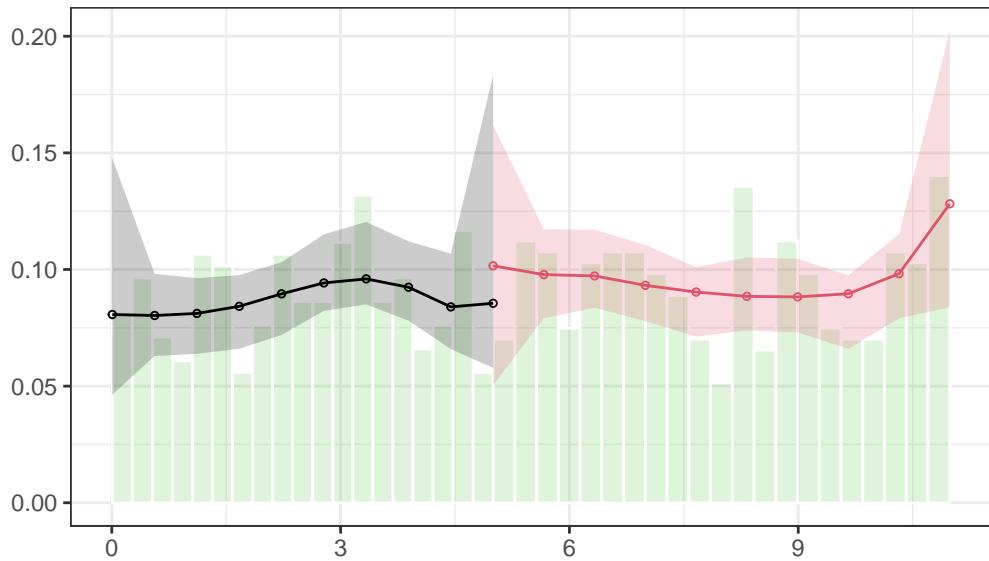


Abbildung 8.3: CJM-Test – geschätzte Dichtefunktionen der Laufvariable auf beiden Seiten des Schwellenwerts $c = 5$

```
# Statistische Zusammenfassung des CJM-Tests
summary(CJM)
```

Manipulation testing using local polynomial density estimation.

Number of obs =	750	
Model =	unrestricted	
Kernel =	triangular	
BW method =	estimated	
VCE method =	jackknife	
$c = 5$	Left of c	Right of c
Number of obs	329	421
Eff. Number of obs	133	154
Order est. (p)	2	2
Order bias (q)	3	3
BW est. (h)	1.918	2.124
Method	T	$P > T $
Robust	-0.3338	0.7385

P-values of binomial tests ($H_0: p=0.5$).

Window Length		<c	$\geq c$	$P > T $
0.346	+ 0.346	20	21	1.0000
0.521	+ 0.544	34	37	0.8126
0.696	+ 0.742	44	57	0.2323
0.870	+ 0.939	54	64	0.4075
1.045	+ 1.137	62	77	0.2349
1.220	+ 1.334	73	98	0.0661
1.394	+ 1.532	86	106	0.1701
1.569	+ 1.729	96	124	0.0685
1.743	+ 1.927	119	140	0.2139
1.918	+ 2.124	133	154	0.2377

Gemäß des p-Werts ($P > |T|$) von 0.74 spricht der CJM-Test noch deutlicher gegen eine Diskontinuität als der McCrary-Test.

8.2.1 Case Study: Amtsinhaber-Vorteil (Lee 2008)

Lee (2008) untersucht den Einfluss des Amtsinhaber-Vorteils auf die Wahl von Mitgliedern des US-Repräsentantenhaus. In den meisten Wahlkreisen entfallen große Anteile der Stimmen (oder gar ausschließlich) auf demokratische und republikanische Kandidat*innen, sodass sich die Studie auf diese Parteien beschränkt. Entfällt die Mehrheit der Stimmen auf eine*n Kandidat*in, gewinnt diese*r den Sitz für den Wahlkreis. Durch die Analyse der 6558 Wahlen im Zeitraum 1946-1998 mit einem SRDD kommt die Studie zu dem Ergebnis, dass Amtsinhabende im Durchschnitt einen Vorteil von etwa 8% bis 10% bei der Wahl haben. Dieses Ergebnis kann verschiedene Ursachen haben, bspw. dass die amtierende Partei höhere finanzielle Ressourcen besitzt und von einer besseren Organisation und durch Instrumentalisierung staatlicher Strukturen für die eigenen Zwecke profitiert.

Anhand der Datensätze `house` und `house_binned` illustrieren wir nachfolgend die Schätzung von SRDD-Modellen für den Wahlerfolg der demokratischen Partei, wenn diese Amtsinhaber ist. Wir lesen hierfür zunächst die Datensätze `house` und `house_binned` ein und verschaffen uns einen Überblick.

```
library(tidyverse)
library(modelsummary)
```

```
# Daten einlesen
house <- read_csv("datasets/house.csv")
# Gruppierter Datensatz
house_binned <- read_csv("datasets/house_binned.csv")

# Überblick verschaffen
glimpse(house)
```

Rows: 6,558
 Columns: 2
 $\$ \text{StimmenTm1} <\text{dbl}> 0.1049, 0.1393, -0.0736, 0.0868, 0.3994,$
 $0.1681, 0.2516, 0.~$
 $\$ \text{StimmenT} <\text{dbl}> 0.5810, 0.4611, 0.5434, 0.5846, 0.5803,$
 $0.6244, 0.4873, 0.5~$

```
glimpse(house_binned)
```

Rows: 100
 Columns: 2
 $\$ \text{StimmenT} <\text{dbl}> 0.5995600, 0.5657000, 0.4272554, 0.5637456,$
 $0.6868627, 0.60~$
 $\$ \text{StimmenTm1} <\text{dbl}> 0.104764444, 0.135005263, -0.075690769,$
 $0.084570886, 0.3951~$

Der Datensatz `house` enthält die Stimmenanteile demokratischer Kandidat*innen bei der Wahl zum Zeitpunkt T (*StimmenT*) sowie die Differenz zwischen demokratischen und republikanischen Stimmenanteilen bei der vorherigen Wahl, d.h. zum Zeitpunkt $T-1$ (*StimmenTm1*). Der Schwellenwert für einen Wahlsieg liegt bei Stimmengleichheit, d.h. *StimmenTm1* = 0.

`house_binned` ist eine aggregierte Version von `house` mit Mittelwerten von jeweils 50 gleichgroßen Intervallen oberhalb und unterhalb der Schwelle von *StimmenTm1* = 0. Dieser Datensatz eignet sich, um einen ersten Eindruck des funktionalen Zusammenhangs auf beiden Seiten zu erhalten. Wir stellen zunächst diese klassierten Daten mit `ggplot2` graphisch dar.

```
# Klassierte Daten plotten
house_binned %>%
  ggplot(
    aes(x = StimmenTm1, y = StimmenT)
```

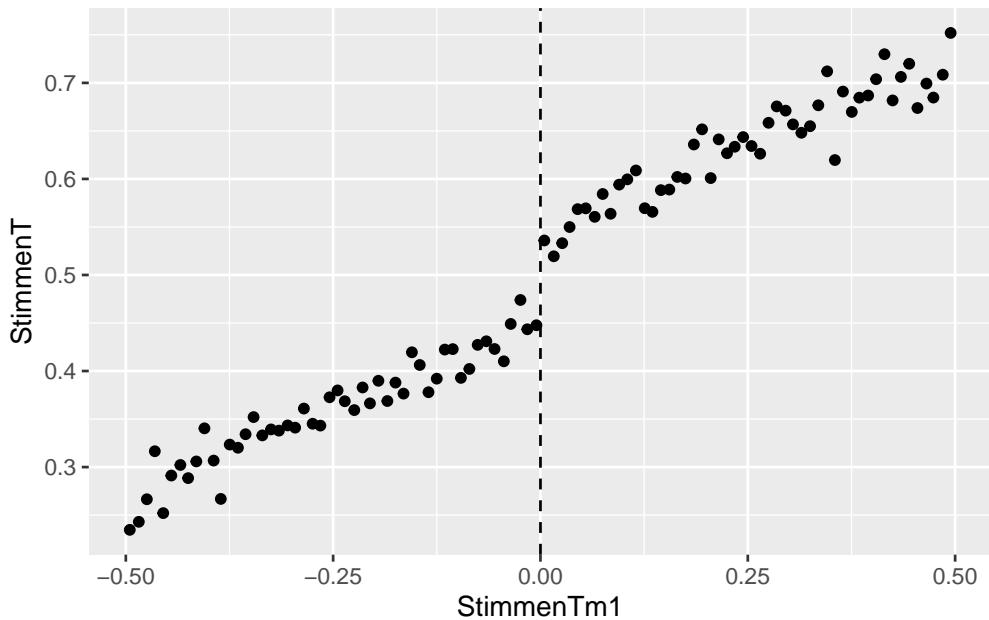


Abbildung 8.4: Klassierte Daten aus Lee (2008)

```
) +
  geom_point() +
  geom_vline(xintercept = 0, lty = 2)
```

Die Grafik zeigt eindeutig einen Sprung von $StimmenT$ bei $StimmenTm1 = 0$. Weiterhin erkennen wir, dass der Zusammenhang nahe 0 vermutlich jeweils gut durch eine lineare Funktion approximiert werden kann. Eine Modell-Spezifikation mit gleicher Steigung auf beiden Seiten des Schwellenwertes scheint hingegen weniger gut geeignet. Wir vergleichen diese Spezifikationen nachfolgend.

Zunächst fügen wir dem Datensatz eine Dummyvariable B hinzu. Diese dient als Indikator für den Wahlgewinn in der letzten Wahl und zeigt die Amtsinhaberschaft (Behandlung) an.

```
# Behandlungsindikator B hinzufügen
house <- house %>%
  mutate(B = StimmenTm1 > 0)

glimpse(house)
```

Rows: 6,558

Columns: 3

```

$ StimmenTm1 <dbl> 0.1049, 0.1393, -0.0736, 0.0868, 0.3994,
0.1681, 0.2516, 0.~
$ StimmenT   <dbl> 0.5810, 0.4611, 0.5434, 0.5846, 0.5803,
0.6244, 0.4873, 0.5~
$ B          <lgl> TRUE, TRUE, FALSE, TRUE, TRUE, TRUE,
TRUE, TRUE, TRUE~

```

Wir überprüfen die Laufvariable mit dem CJM-Test auf Manipulation am Schwellenwert $c = 0$.

```

# CJM-Test durchführen
CJM_Lee <- rddensity(X = house$StimmenTm1)

# Zusammenfassung anzeigen
summary(CJM_Lee)

```

Manipulation testing using local polynomial density estimation.

```

Number of obs =      6558
Model =           unrestricted
Kernel =          triangular
BW method =        estimated
VCE method =       jackknife

c = 0             Left of c      Right of c
Number of obs     2740            3818
Eff. Number of obs 1297            1360
Order est. (p)    2                2
Order bias (q)   3                3
BW est. (h)       0.236           0.243

Method            T              P > |T|
Robust           1.4346          0.1514

```

P-values of binomial tests ($H_0: p=0.5$).

Window Length / 2	<c	$\geq c$	$P > T $
0.004	21	24	0.7660

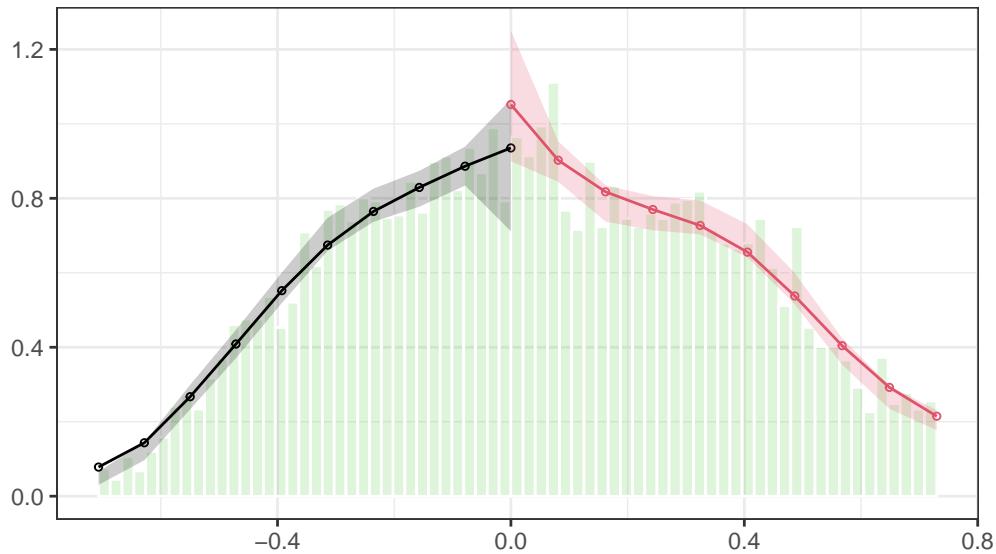


Abbildung 8.5: CJM-Test – geschätzte Dichtefunktionen der Laufvariable

0.007	38	46	0.4452
0.011	50	60	0.3909
0.014	73	77	0.8066
0.018	91	104	0.3902
0.022	124	132	0.6618
0.025	149	149	1.0000
0.029	163	174	0.5860
0.032	176	202	0.1984
0.036	197	223	0.2225

```
# CJM-Plot
plot <- rdplotdensity(
  rdd = CJM_Lee,
  X = house$StimmenTm1,
  type = "both",
)
```

Abbildung 8.5 und der p-Wert von 0.15 sind Evidenz gegen eine Manipulation am Schwellenwert.

Um den Behandlungseffekt anhand eines SRDDs zu ermitteln, schätzen wir das Interaktionsmodell

$$\begin{aligned} \text{StimmenT}_i &= \beta_0 + \beta_1 B_i + \beta_2 (\text{StimmenTm1}_i - 50) \\ &\quad + \beta_3 (\text{StimmenTm1}_i - 50) \times B_i + u_i \end{aligned}$$

zunächst für eine Bandweite von $h = 0.5$. Aufgrund der Skalierung der Daten (Wahlergebnisse in %) bedeutet dies die Verwendung des *gesamten* Datensatzes für die Schätzung.

```
# Interaktionsmodell schätzen
house_llr1 <- lm(
  formula = StimmenT ~ B * StimmenTm1,
  data = house
)

# Zusammenfassung anzeigen
modelsummary(
  models = house_llr1,
  vcov = "HC1", # robuste Standardfehler
  stars = T,
  gof_map = "nobs",
  output = "gt"
) %>%
  tabopts
```

	(1)
(Intercept)	0.433*** (0.004)
BTRUE	0.118*** (0.006)
StimmenTm1	0.297*** (0.016)
BTRUE × StimmenTm1	0.046* (0.018)
Num.Obs.	6558

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

Der geschätzte Koeffizient von B (BTRUE) beträgt etwa 0.12 und ist hochsignifikant. Übereinstimmend mit Abbildung 8.4 erhalten wir also eine positive Schätzung des Behandlungseffekts. Die Interpretation ist, dass die amtierenden Demokraten bei der Wahl von einem Amtsinhabervorteil profitieren. Dieser Effekt schlägt sich als Stimmenbonus von geschätzten 12% nieder. Diese Schätzung des Behandlungseffekts könnte jedoch verzerrt sein:

- Die (implizite) Wahl von $h = 0.5$ in unserer Schätzung macht die Isolation des relevanten Frontdoor-Paths ($c = 0 \rightarrow \text{Treatment} \rightarrow \text{StimmenT}$) wenig plausibel. h sollte mit einer datengetriebenen Methode gewählt werden.
- Weiterhin könnte die lineare funktionale Form der Regression inadäquat sein: Die lineare Approximation der wahren Regressionsfunktion nahe des Schwellenwerts 0 könnte unzureichend sein und in einer verzerrten Schätzung des Effekts resultieren. Zur Überprüfung der Robustheit der Ergebnisse sollte mit Schätzungen anhand nicht-linearer Spezifikationen verglichen werden.

Um diesen Gefahren für die Validität der Studie zu begegnen, schätzen wir nun weitere Spezifikationen. Im Folgenden verwenden wir eine Bandweitschätzung gemäß G. Imbens und Kalyanaraman (2012).

```
# Bandweite mit Schätzer von IK (2012) berechnen
(
IK_BW <-
rdd::IKbandwidth(
  X = house$StimmenTm1,
  Y = house$StimmenT
)
)
```

[1] 0.2685123

Wir schätzen zunächst erneut das lineare Interaktionsmodell, diesmal jedoch mit der Bandweite `IK_BW`.

```
# Lineares Interaktionsmodelle mit IK-Bandweite
house_llin_IK <- lm(
  formula = StimmenT ~ B * StimmenTm1,
  data = house %>%
    filter(
      abs(StimmenTm1) <= IK_BW
    )
)
```

Für den Vergleich mit einer nicht-linearen Spezifikation schätzen wir auch ein quadratisches Interaktionsmodell.

```
# Quadratisches Interaktionsmodell mit IK-Bandweite
house_poly_IK <- update(
  object = house_llin_IK,
  formula = StimmenT ~ B * poly(StimmenTm1, degree = 2, raw = T)
)
```

Für eine Gegenüberstellung der Ergebnisse verwenden wir `modelsummary()`.

```
# Tabellarischer Modellvergleich
modelsummary(
  models = list(
    "Linear int." = house_llin_IK,
    "Quadratisch int." = house_poly_IK
  ),
  vcov = "HC1",
  stars = T,
  gof_map = "nobs",
  output = "gt"
) %>%
  tabopts
```

Tabelle 8.1: Vergleich von SRDD-Interaktionsmodellen für Lee (2008)

	Linear int.	Quadratisch int.
(Intercept)	0.450*** (0.005)	0.460*** (0.008)
BTRUE	0.085*** (0.008)	0.068*** (0.012)
StimmenTm1	0.360*** (0.036)	
BTRUE × StimmenTm1	0.055 (0.059)	
poly(StimmenTm1, degree = 2, raw = T)1		0.573*** (0.138)
poly(StimmenTm1, degree = 2, raw = T)2		0.798 (0.493)
BTRUE × poly(StimmenTm1, degree = 2, raw = T)1		0.036 (0.219)

BTRUE \times poly(StimmenTm1, degree = 2, raw = T)2	-1.529+
	(0.834)
Num.Obs.	2956

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

Die Spalte (1) in Tabelle 8.1 zeigt die lokale Schätzung mit einem linearen Interaktionsmodell. Wir erhalten damit einen Behandlungseffekt von etwa 8.5%. Der Schätzwert fällt also etwas geringer aus als für die globale KQ-Schätzung des linearen Interaktionsmodells. Für das Modell (2) mit quadratischer Spezifikation liegt der Schätzwert mit 6.8% in der selben Größenordnung. Beide Schätzungen ergeben einen signifikant von 0 verschiedenen Effekt. Weiterhin fällt auf, dass in beiden Modellen keine Evidenz für unterschiedliche Formen der Regressionsfunktionen auf beiden Seiten des Schwellenwerts vorliegen: sämtliche Koeffizientenschätzwerte der Interaktionsterme haben hohe Standardfehler und sind nicht signifikant. Im quadratischen Modell hat auch der Term *StimmenTm1*² keinen signifikanten Effekt. Diese Ergebnisse deuten darauf hin, dass eine lineare Spezifikation ausreichend ist.

SRDD-Schätzung mit LOESS

Wir illustrieren nachfolgend die Schätzung des Behandlungseffekts mit einer flexiblen und in der Praxis häufig verwendeten Methode für lokale Regression. Die nachfolgende interaktive Grafik zeigt die klassierten Daten aus Lee (2008) auf dem Intervall $[-0.5, 0.5]$ gemeinsam mit einer nicht-parametrischen Schätzung des Zusammenhangs von *StimmenT* und *StimmenTm1* mittels LOESS.³ Diese Implementierung von lokaler Regression nutzt einen *tricube kernel*. Über den Input kann eine Bandweite $l \in (0, 1]$ für den LOESS-Schätzer auf beiden Seiten des Schwellenwerts 0 gewählt werden. Die Bandweite ist hier der *Anteil der Beobachtungen an der gesamten Anzahl an Beobachtungen*, die in die Schätzung einbezogen werden sollen.

Für die Schätzung am Schwellenwert berücksichtigte Daten sind in orange kenntlich gemacht. Die rote Linie zeigt die geschätzte Regressionsfunktion über gleichmäßig verteilte Werte von *StimmenTm1* auf $[-0.5, 0.5]$. Die Grafik verdeutlicht, dass die LOESS-Methode flexibel genug ist, um lineare und nicht-lineare Zusammenhänge abbilden zu können. Wie zuvor ist eine adäquate Wahl der Bandweite wichtig:

- Der mit LOESS geschätzte Zusammenhang auf beiden Seiten des Schwellenwerts ist etwa linear für den voreingestellten Parameter ($l = 0.28$).

³LOESS ist eine Variante von lokaler Polynom-Regression.

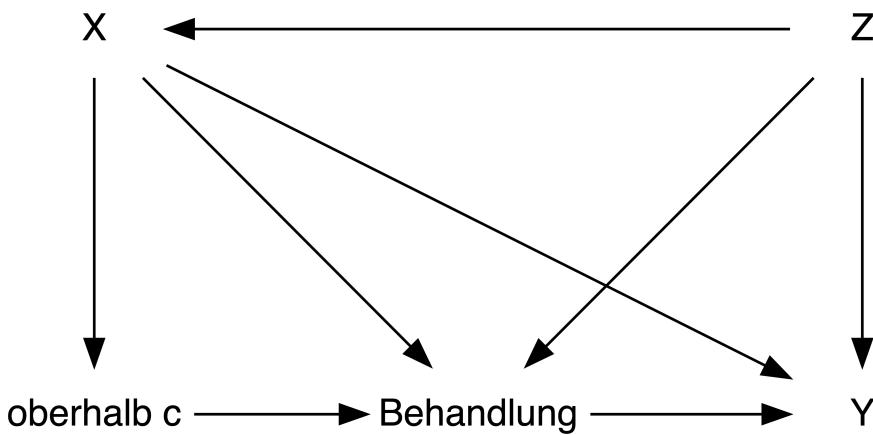


Abbildung 8.6: Kausales Diagramm für FRDD

- Für größere Werte von l nähert sich die Schätzung weiter einem linearen Verlauf an. Die Schätzung des Effekts bleibt vergleichbar mit den Ergebnissen des linearen Interaktionsmodells (s. oben).
- Für kleinere l erhalten wir eine stärkere Anpassung der Schätzung an die Daten. Zu kleine Werte führen zu einer Überanpassung (*overfitting*). Insbesondere tendiert die geschätzte Funktion zu extremer Steigung nahe des Schwellenwerts → stark verzerrte Schätzung des Effekts!

Diese interaktive Komponente des Buchs ist nur in der Online-Version verfügbar.

8.3 Fuzzy Regression Discontinuity Design

Ein FRDD liegt vor, wenn die Zuweisung der Behandlung B durch die Laufvariable X (und möglicherweise weitere Variablen Z) beeinflusst wird. Im Vergleich zum SRDD ist die Behandlung dann also *nicht* ausschließlich durch Überschreiten des Schwellenwerts $X = c$ bestimmt.

Abbildung 8.6 zeigt den grundsätzlichen Zusammenhang. Hier genügt es weiterhin für X (und ggf. Z) zu kontrollieren, um den Pfad *oberhalb C* \rightarrow *Behandlung B* \rightarrow Y zu isolieren. Der so für *Behandlung B* ermittelte Effekt auf Y entspricht

jedoch *nicht* dem “vollständigen” Behandlungseffekt, da bei c die Zuweisung der Behandlung nicht von 0 auf 100% springt. Die Schätzung des FRDD berücksichtigt dies und skaliert den geschätzten Effekt entsprechend.

Wir betrachten zunächst den Zusammenhang

$$Y_i = \beta_0 + \beta_1 B_i + \beta_2(X_i - c) + u_i. \quad (8.6)$$

In einem FRDD springt die Behandlungswahrscheinlichkeit am Schwellenwert c um $\Delta p < 1$. Wir können B also nicht als deterministische Funktion von X , welche die Zuweisung zu Behandlungs- bzw. Kontrollgruppe am Schwellenwert c anzeigen (wie im SRDD), definieren. Stattdessen betrachten wir

$$P(B_i = 1|X_i) = \begin{cases} g_{X_i < c}(X_i), & X_i < c \\ g_{X_i \geq c}(X_i) & X_i \geq c \end{cases}. \quad (8.7)$$

Die Funktionen $g_{X_i < c}$ und $g_{X_i \geq c}$ können verschieden sein. Es muss jedoch

$$g_{X_i < c}(X_i = c) \neq g_{X_i \geq c}(X_i = c)$$

gelten. Die Behandlungsvariable B_i ist im FRDD also eine (binäre) Zufallsvariable, deren bedingte Wahrscheinlichkeitsfunktion $P(B_i = 1|X_i)$ am Schwellenwert c eine Diskontinuität aufweist. Abbildung 8.7 zeigt heispielhafte Verläufe nicht-linearer bedingter Wahrscheinlichkeitsfunktion für die Behandlung mit einer Diskontinuität bei $X_i = c$.

```
library(ggplot2)
library(cowplot)

# Bedingte Behandlungswahrscheinlichkeit im FRDD illustrieren
ggplot() +
  geom_function(
    fun = ~ ifelse(
      . < 0,
      -.1 * .^2 + .25,
      -.1 * (-1.5)^2 + 1
    ),
    n = 1000
  ) +
  geom_function(
    fun = ~ ifelse(
```

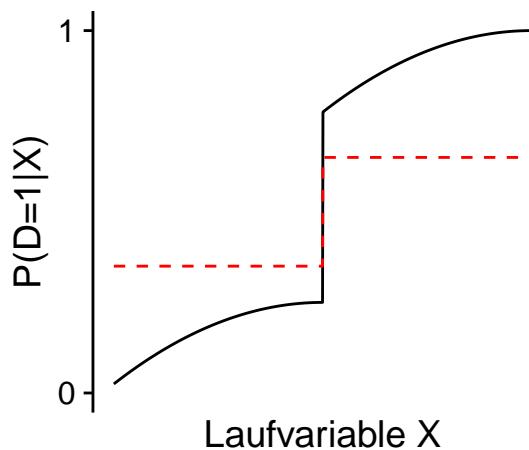


Abbildung 8.7: Bedingte Behandlungswahrscheinlichkeiten im FRDD

```

. < 0,
.35,
.65
),
n = 1000,
lty = 2,
col = "red"
) +
scale_x_continuous(
  name = "Laufvariable X",
  limits = c(-1.5, 1.5),
  labels = NULL,
  breaks = NULL
) +
scale_y_continuous(
  name = "P(D=1|X)",
  breaks = c(0, 1),
  limits = c(0, 1)
) +
theme_cowplot()

```

Definition (8.7) bedeutet, dass eine KQ-Schätzung von β_1 anhand (8.6) eine *verzerrte* Schätzung des Behandlungseffekts ist: Der in $\hat{\beta}_1$ erfasste Effekt auf Y ist auf einen Sprung der Behandlungswahrscheinlichkeit bei $X_i = c$ um *weniger* als 100% zurückzuführen. Der wahre Behandlungseffekt wird also *unterschätzt*. Daher muss $\hat{\beta}_1$ skaliert werden, sodass die Schätzung als Effekt einer Änderung

der Behandlungswahrscheinlichkeit um 100% interpretiert werden kann — der erwartete Effekt, wenn ausschließlich Subjekte mit $X_i \geq c$ behandelt würden. Diese skalierte Schätzung erhalten wir mit IV-Regression (vgl. Kapitel XYZ). Hierfür nutzen wir für B_i die Instrumentvariable

$$D_i = \begin{cases} 0, & X_i < c \\ 1, & X_i \geq c. \end{cases}$$

Angenommen $g_{X_i \geq c}(X_i) = \alpha_0$ und $g_{X_i < c}(X_i) = \alpha_0 + \alpha_1$ mit $\alpha_0 + \alpha_1 < 1$ (vgl. rote Funktion in Abbildung 8.6). Der FRDD-Schätzer des Behandlungseffekts ist dann $\hat{\gamma}_{\text{FRDD}}$ im 2SLS-Verfahren mit den Regressionen

$$\begin{aligned} (\text{I}) \quad B_i &= \alpha_0 + \alpha_1 D_i + \alpha_2(X_i - c) + e_i, \\ (\text{II}) \quad Y_i &= \gamma_0 + \gamma_1 \hat{B}_i + \gamma_2(X_i - c) + \epsilon_i, \end{aligned} \tag{8.8}$$

wobei \hat{B}_i die angepassten Werte aus Stufe (I) und e_i sowie ϵ_i Fehlterme sind.

Analog zum SRDD müssen in empirischen Anwendungen geeignete Spezifikationen für die Regressionsfunktionen (8.6) und (8.7) gewählt und der 2SLS-Schätzer (8.8) entsprechend angepasst werden. Ein einfaches Interaktionsmodell wäre

$$\begin{aligned} (\text{I}) \quad B_i &= \alpha_0 + \alpha_1 D_i + \alpha_2(X_i - c) \\ &\quad + \alpha_3(X_i - c) \times D_i + e_i, \\ (\text{II}) \quad Y_i &= \gamma_0 + \gamma_1 \hat{B}_i \\ &\quad + \gamma_2(X_i - c) + \gamma_3(X_i - c) \times \hat{B}_i + \epsilon_i \end{aligned}, \tag{8.9}$$

d.h. wir instrumentieren B_i mit D_i und dem Interaktionsterm $(X_i - c) \times D_i$.

Wie im SRDD werden die IV-Ansätze für das FRDD (8.8) und (8.9) in empirischen Studien unter Berücksichtigung einer Bandweite (i.d.R. dieselbe Bandweite für beide Stufen) angewendet.

8.4 Case Study: Protestantische Arbeitsethik

Die Studie *Beyond Work Ethic: Religion, Individual, and Political Preferences* (Basten und Betz 2013) untersucht den Zusammenhang zwischen Religion, individuellen Merkmalen und politischen Präferenzen. Das Hauptaugenmerk

ist die Rolle von Religiosität als Einflussfaktor auf politische Einstellungen. Die Hypothese der Autoren ist, dass Religiosität eines Individuums über den traditionellen Rahmen von Moralvorstellungen und sozialen Normen hinaus auch die politischen Präferenzen beeinflusst. Eine entsprechende Theorie wurde zu Beginn des 20. Jahrhunderts entwickelt und prominent von Max Weber (vgl. Weber 2004) vertreten. Weber argumentiert, dass die protestantische Arbeitsethik einen entscheidenden Einfluss auf die Entwicklung des Kapitalismus hatte. Laut Weber führte der protestantische Glaube an harte Arbeit, ein sparsames Leben und ethisches Verhalten zur einer in den damaligen Gesellschaften weit verbreiteten Geisteshaltung, die wirtschaftliches Wachstum förderte und den Aufstieg des Kapitalismus begünstigte.

Basten und Betz (2013) nutzen Wahlergebnisse sowie geo- und soziodemografische Datensätze für schweizer Gemeinden, um den Zusammenhang zwischen Religiosität und politischen Präferenzen wie links-rechts-Ausrichtung, Einstellungen zur Umverteilung und Einwanderung zu untersuchen. Hierfür verwenden die Autoren ein FRDD, dass eine historisch bedingte Diskontinuität der geographischen Verteilung von evangelischer bzw. katholischer Religionszugehörigkeit zwischen den Kantonen Freiburg (überwiegend dunkelrote Region, frz. *Fribourg*) und Waadt (kleinere hellrote Region, frz. *Vaud*) ausnutzt. Die historische Verteilung der Konfessionen in der betrachteten Region im 16. Jahrhundert durch Abspaltung des Kantons Freiburg ist in Abbildung 8.8 dargestellt.

Aufgrund von Bevölkerungsbewegungen ist die Verteilung der Konfessionen zwar nicht mehr eindeutig durch die Kantongrenze bestimmt, jedoch sind die Gemeinden der betrachteten Kantone auch heute noch mehrheitlich protestantisch bzw. katholisch. Es ist plausibel, dass eine Prägung gemäß Webers Theorie vorliegt, sich die Gemeinden nahe der Grenz aber hinsichtlich anderer Charakteristika (insb. der Bevölkerungsstruktur) nicht systematisch unterscheiden. Somit liegt ein quai

Die Ergebnisse der Studie zeigen einen signifikanten Einfluss von Protestantismus auf politische Präferenzen, die über traditionelle Moralvorstellungen hinausgehen: Die Autoren finden Hinweise, dass Einwohner evangelisch geprägter Gemeinden eher konservative soziale und politische Ansichten vertreten. Eine mögliche Erklärung für diesen Effekt ist, dass religiöse Institutionen auch eine soziale und politische Agenda verfolgen, die von den Gläubigen internalisiert wird.

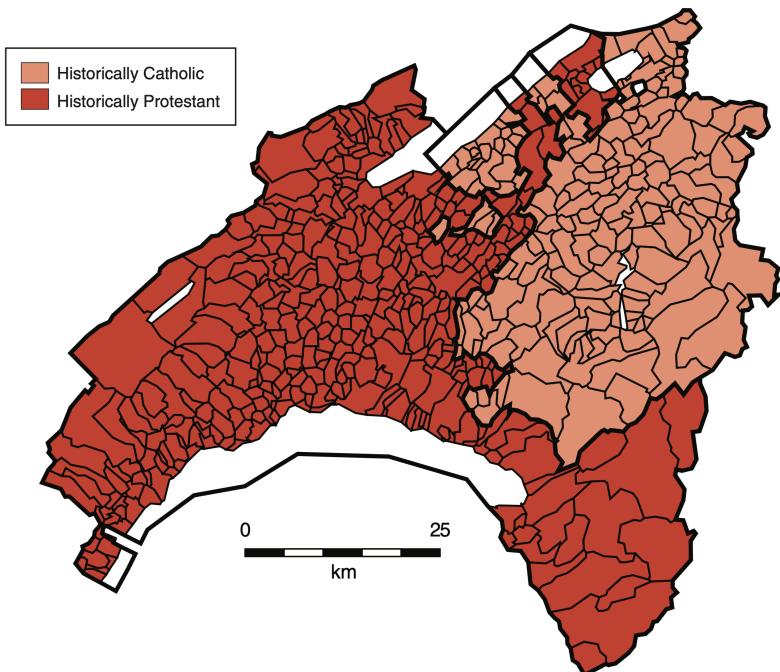


Abbildung 8.8:
Historische
Verteilung
von Religions-
zugehörigkeit
in Schweizer
Gemeinden
im 16. Jahr-
hundert.
Quelle: Bas-
ten und Betz
(2013).

8.4.1 Aufbereitung der Daten

In diesem Kapitel zeigen wir, wie die Kernergebnisse der Studie mit R reproduziert werden können. Hierfür werden folgende Pakete benötigt.

```
library(tidyverse)
library(haven)
library(vtable)
library(rdrobust)
```

Das Papier sowie der Datensatz **BastenBetz.dta** sind auf der [Übersichtsseite](#) der AEA verfügbar und liegt im STATA-Format **.dta** vor.⁴

```
# Datensatz einlesen
BastenBetz <- read_dta('BastenBetz.dta')
```

Der Datensatz **BastenBetz** enthält Beobachtungen zu 509 schweizer Gemeinden. Eine Vielzahl an Variablen ist lediglich für Robustheits-Checks relevant. Für die Reproduktion der Kernergebnisse erstellen wir zunächst einen reduzierten Datensatz und transformieren einige Variablen.

⁴Siehe alternativ das [working paper](#), falls kein Abonnement für AEA-Journals vorliegt.

```

# Reduzierten Datensatz erstellen
BastenBetz <- BastenBetz %>%
  transmute(
    gini = Ecoplan_gini,
    prot = prot1980s,
    bord = borderdis,
    vaud,
    pfl,
    pfr,
    pfi
  )

```

Die Definitionen der Variablen sind in Tabelle 8.2 gegeben. Die Präferenzen `pfl`, `pfr` und `pfi` basieren auf Wahlergebnissen auf Gemeindeebene zu Volksentscheiden.

Tabelle 8.2: `BastenBetz` – Variablen und Definitionen

Variable	Definition
<code>prot</code>	Anteil Protestanten im Jahr 1980 (%)
<code>gini</code>	Gini-Koeffizient
<code>bord</code>	Laufdistanz zur Kantonsgrenze (Km)
<code>vaud</code>	Dummyvariable: Gemeine im Kanton Waadt
<code>pfl</code>	Präferenz für Freizeit (%)
<code>pfr</code>	Präferenz für Umverteilung (%)
<code>pfi</code>	Präferenz für wirtschaftliche Intervention des Staats (%)

Für die Berechnung der optimalen Bandweite des FRDD verwenden wir einen MSE-optimalen Schätzer, der in der Funktion `rdrobust::rdbwselect()` implementiert ist.⁵

```

# Bandweite schätzen (Bsp. für Freizeitpräferenz)
bw_selection <- rdbwselect(
  y = BastenBetz$pfl,
  x = BastenBetz$bord,
  fuzzy = BastenBetz$prot,
  bwselect = "mserd",

```

⁵Basten und Betz (2013) setzen $BW = 5.01$, den Durchschnitt von IK-Schätzungen über Modelle sämtlicher betrachteter Outcome-Variablen. Diese Bandweite liegt nahe des Ergebnisses von `rdbwselect`. Wir verwenden nachfolgend die Schätzung 0B.

```

    kernel = "uniform"
)

# Bandweite auslesen und zuweisen
(OB <- bw_selection$bws[1])

```

[1] 5.078001

8.4.2 Deskriptive Statistiken

Zur Reproduktion von Tabelle 1 aus Basten und Betz (2013) erzeugen wir eine nach Kantonen gruppierte Zusammenfassung der Daten und berechnen deskriptive Statistiken. Wie im Paper berücksichtigen wir hierbei nur Gemeinden innerhalb der geschätzten optimalen Bandweite OB.

```

# Datensatz für Reproduktion von Table 1 formatieren
T1 <- BastenBetz %>%
  filter(abs(bord) < OB) %>%
  mutate(
    vaud = ifelse(
      test = vaud == 1,
      yes = "Waadt",
      no = "Freiburg"
    ),
    prot = prot * 100
  ) %>%
  group_by(vaud) %>%
  summarise(
    across(
      everything(),
      list(
        Mean = mean,
        SD = sd,
        N = length
      )
    )
  ) %>%
  pivot_longer(
    cols = -vaud,

```

```

  names_to = c("variable", "statistic"),
  names_sep = "_"
)

```

Für die tabellarische Darstellung transformieren wir in ein weites Format, sodass die Tabelle die deskriptive Statistiken spaltenweise für die Kantone zeigt.

```

# Daten in weites Format überführen
T1_wider <- T1 %>%
  pivot_wider(
    names_from = c("vaud", "statistic")
)

```

Die Tabelle erzeugen wir mit `gt::gt()`.

```

# Tabelle mit gt() erzeugen
T1_wider %>%
  gt(rowname_col = "Variable") %>%
  tab_spacer_delim(
    delim = "_",
  ) %>%
  tabopts

```

Tabelle 8.3: Datensatz `BastenBetz` – Zusammenfassende Statistiken

variable	Freiburg			Waadt		
	Mean	SD	N	Mean	SD	N
gini	0.302	0.029	49	0.367	0.052	84
prot	9.428	5.695	49	83.245	11.411	84
bord	-2.327	1.274	49	2.493	1.201	84
pfl	48.239	4.774	49	39.508	5.723	84
pfr	43.049	2.634	49	39.19	5.025	84
pfi	52.642	2.94	49	47.086	3.368	84

Die Statistiken in Tabelle 8.3 scheinen konsistent mit der (historischen) Verteilung der Religionszugehörigkeit und politischen Einstellung gemäß der Hypothese: Im überwiegend katholischen Freiburg finden wir eine größere Einkom-

mensungleichheit und höhere aus Wahlergebnissen abgeleitete Präferenzen für Freizeit, Umverteilung sowie staatliche Interventionen.

8.4.3 Modellspezifikation und First-Stage-Ergebnisse

```
CJM_BB <- rddensity(BastenBetz$bord, c = 0, kernel =
  ↵ "epanechnikov")
summary(CJM_BB)
```

Manipulation testing using local polynomial density estimation.

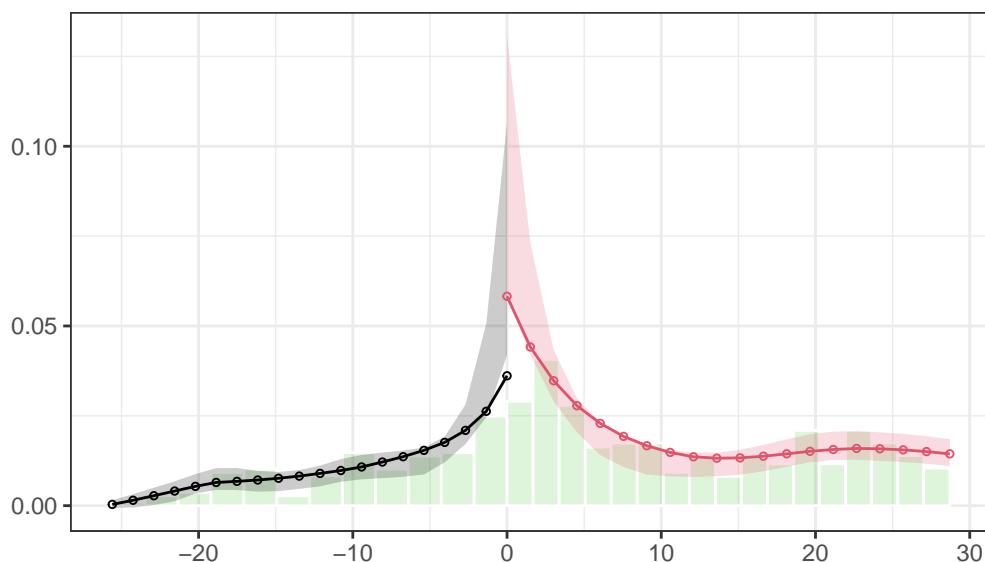
Number of obs =	509	
Model =	unrestricted	
Kernel =	epanechnikov	
BW method =	estimated	
VCE method =	jackknife	
c = 0	Left of c	Right of c
Number of obs	127	382
Eff. Number of obs	69	124
Order est. (p)	2	2
Order bias (q)	3	3
BW est. (h)	8.531	9.57
Method	T	P > T
Robust	0.7552	0.4501

P-values of binomial tests ($H_0: p=0.5$).

Window Length		<c	$\geq c$	$P > T $
1.400	+ 1.400	20	20	1.0000
2.192	+ 2.308	27	47	0.0265
2.985	+ 3.215	34	60	0.0095
3.777	+ 4.123	40	72	0.0032
4.570	+ 5.031	44	84	0.0005
5.362	+ 5.939	51	95	0.0003
6.154	+ 6.846	56	100	0.0005

6.947	+ 7.754	60	106	0.0004
7.739	+ 8.662	67	114	0.0006
8.531	+ 9.570	69	124	0.0001

```
# CJM-Plot
plot <- rdplotdensity(
  rdd = CJM_BB,
  X = BastenBetz$bord,
  type = "both", plotN = 20,
)
```



Die Kantone Waadt und Freiburg haben bis heute mehrheitlich protestantische bzw. katholische Gemeinden. Die Verteilung von Protestantismus ist also, u.a. aufgrund von Bevölkerungsbewegungen, nicht mehr deterministisch. An der Kantonsgrenze besteht jedoch eine deutliche Diskontinuität im Anteil protestantischer Einwohner, die auf die historische Verteilung der Religionszugehörigkeit zurückzuführen ist. Damit kann ein FRDD implementiert werden, bei dem die Distanz zur Grenze (`bord`) die zentrierte Laufvariable ist und die Zugehörigkeit zum Kanton Waadt (`vaud`) ein Instrument für die Behandlungsvariable (`prot`) ist.

Wir nutzen die Funktion `rdrobust::rdplot` um diesen Zusammenhang für verschiedene Bandweiten anhand des linearen Interaktionsmodells

$$prot_i = \alpha_0 + \alpha_1 vaud_i + \alpha_2 bord_i + \alpha_3 bord_i \times vaud_i + u_i \quad (8.10)$$

grafisch darzustellen. Dies ist die First-Stage-Regression für die 2SLS-Schätzung der Behandlungseffekte.

```
# Reproduktion von Abbildung 3 in Basten und Betz (2013)
plots_BB <- list(
  # gesch. optimale Bandweite
  p_OB = rdplot(
    y = BastenBetz$prot,
    x = BastenBetz$bord,
    h = c(0B, OB),
    x.label = "Distanz zur Grenze (bord)",
    y.label = "Anteil Protestanten (prot)",
    title = "Gesch. Bandweite",
    p = 1,
    nbins = c(6, 14),
    masspoints = "off"
  ),
  
  # Bandweite 10
  p_BW10 = rdplot(
    y = BastenBetz$prot,
    x = BastenBetz$bord,
    h = c(10, 10),
    x.label = "Distanz zur Grenze (bord)",
    y.label = "Anteil Protestanten (prot)",
    title = "Bandweite = 10",
    p = 1,
    nbins = c(6, 14),
    masspoints = "off"
  ),
  
  # Bandweite 20
  p_BW20 = rdplot(
    y = BastenBetz$prot,
    x = BastenBetz$bord,
    h = c(20, 20),
    x.label = "Distanz zur Grenze (bord)",
    y.label = "Anteil Protestanten (prot)",
    title = "Bandweite = 20",
    p = 1,
```

```

nbins = c(6, 14),
masspoints = "off"
),

# Gesamter Datensatz
p_G = rdplot(
  y = BastenBetz$prot,
  x = BastenBetz$bord,
  x.label = "Distanz zur Grenze (bord)",
  y.label = "Anteil Protestanten",
  title = "Ges. Datensatz",
  p = 1,
  nbins = c(6, 14),
  masspoints = "off"
)
)

```

Wir sammeln die Ergebnisse in einem Plot-Gitter mit `cowplot::plot_grid()`.

```

# Reproduktion von Abbildung 3 in Basten und Betz (2013)
plot_grid(
  plotlist = map(plots_BB, ~ .$rdplot), ncol = 2
)

```

Die Grafiken in Abbildung 8.9 zeigen deutliche Hinweise auf die Diskontinuität in `prot` nahe der Kantonsgrenze. Die Größe des geschätzten Sprungs scheint nur wenig sensitiv gegenüber der gewählten Bandweite zu sein. Die Signifikanz des Effekts können wir anhand der jeweiligen KQ-Regressionen beurteilen.⁶

```

# Reproduktion der First-Stage-Regressionen
# s. Tabelle 2 in Basten und Betz (2013)

# (1) BW = OB
FS1 <- lm(
  formula = prot ~ vaud + bord + vaud * bord,
  data = BastenBetz %>%

```

⁶Wir nutzen `update()` um die Regression mit weniger Code für verschiedene Bandweiten zu schätzen.

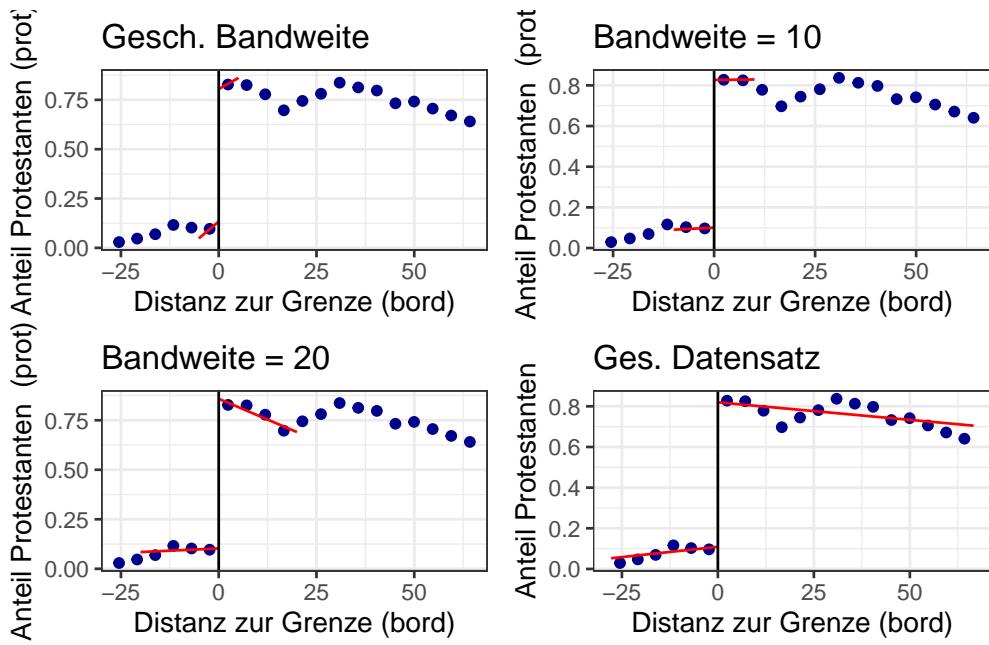


Abbildung 8.9:
First-Stage-
Regressionen

```

filter(
  abs(bord) <= 0B
)
)

# (2) BW = 10
FS2 <- update(
  FS1,
  data = BastenBetz %>%
    filter(
      abs(bord) <= 10
    )
)

# (3) BW = 20
FS3 <- update(
  FS1,
  data = BastenBetz %>%
    filter(
      abs(bord) <= 20
    )
)

```

```
# (4) Ges. Datensatz
FS4 <- update(
  object = FS1,
  data = BastenBetz
)
```

```
# Tabellarische Darstellung
modelsummary(
  list(
    "BW = OB"= FS1,
    "BW = 10" = FS2,
    "BW=20" = FS3,
    "Ges. Datensatz" = FS4
  ),
  vcov = "HC1",
  stars = T,
  gof_map = "nobs",
  output = "gt"
) %>%
  tabopts()
```

Tabelle 8.4: First-Stage-Regressionen

	BW = OB	BW = 10	BW=20	Ges. Datensatz
(Intercept)	0.134*** (0.017)	0.100*** (0.013)	0.103*** (0.010)	0.109*** (0.009)
vaud	0.671*** (0.034)	0.726*** (0.022)	0.756*** (0.018)	0.710*** (0.014)
bord	0.017** (0.006)	0.001 (0.003)	0.001 (0.001)	0.002* (0.001)
vaud × bord	-0.006 (0.012)	-0.001 (0.005)	-0.009*** (0.003)	-0.004*** (0.001)
Num.Obs.	133	207	312	509

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

Für die geschätzte Bandweite schätzen wir einen hochsignifikanten Sprung in prot von etwa 67% an der Kantonsgrenze. Auch für größere Bandweiten von 10km und 20km sowie für den gesamten Datensatz finden wir vergleichbare

signifikante Effekte, was eine bei zunehmender Distanz zur Grenze persistente Diskrepanz der Religionszugehörigkeit bestätigt.

8.4.4 Second-Stage-Ergebnisse

Wir schätzen nun den LATE von Protestantismus für die Outcome-Variablen gini, pfl, pfi und pfr, vgl. Tabelle 8.2. Die Spezifikation für die Second-Stage-Regression der FRDD-Schätzung ist

$$Y_i = \gamma_0 + \gamma_1 \widehat{prot}_i + \gamma_2 bord_i + \gamma_3 bord_i \times vaud_i + e_i, \quad (8.11)$$

wobei \widehat{prot}_i angepasste Werte aus der KQ-Schätzung von (8.10) mit Bandweite OB sind. Dazu erzeugen wir zunächst eine angepasste Version des Objekts `BastenBetz`, welche nur Gemeinden innerhalb der Bandweite enthält.

```
# Gemeinden innerhalb der Bandweite filtern
BastenBetz_OB <- BastenBetz %>%
  filter(
    abs(bord) <= OB
  )
```

Zur Illustration schätzen wir nun die Second-Stage-Regression für $Y = pfl$.

```
# Second-Stage-Regression für `pfl`
BastenBetz_OB %>%
  mutate(
    prot_fitted = fitted(FS1)
  ) %>%
  lm(
    pfl ~ prot_fitted + bord + vaud:bord,
    data = .
  ) %>%
  summary()
```

Call:

```
lm(formula = pfl ~ prot_fitted + bord + vaud:bord, data = .)
```

Residuals:

Min	1Q	Median	3Q	Max
-12.8870	-3.8621	-0.0423	3.4993	12.1636

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)							
(Intercept)	50.5275	1.9721	25.621	< 2e-16 ***							
prot_fitted	-13.4600	3.1749	-4.240	4.24e-05 ***							
bord	0.4380	0.6528	0.671	0.503							
bord:vaud	-0.3636	0.7939	-0.458	0.648							

Signif. codes:	0	'***'	0.001	'**'	0.01	'*'	0.05	'. '	0.1	' '	1

Residual standard error: 5.433 on 129 degrees of freedom

Multiple R-squared: 0.383, Adjusted R-squared: 0.3686

F-statistic: 26.69 on 3 and 129 DF, p-value: 1.704e-13

Der Koeffizient `prot_fitted` ist der gesuchte Behandlungseffekt. Beachte, dass die von `summary()` berechneten Standardfehler ungültig sind, weil diese die zusätzliche Unsicherheit durch die Berechnung von \widehat{prot} über die First-Stage-Regression nicht berücksichtigen. Nachfolgend nutzen wir `AER::ivreg()`, um komfortabel gültige (heteroskedastie-robuste) Inferenz betreiben zu können.⁷

```
# Schätzung mit 2SLS
# s. Tabelle 4 in Basten und Betz (2013)
#
# Wir instrumentieren Treatment (`prot1980s`) mit dem
#   Schwellenindikator (`vaud`)
# ivreg: exogene Variablen instrumentieren sich selbst, daher
# ' | vaud * borderdis '
library(AER)
# (1) Präferenz für Freizeit
SS_pfl <- ivreg(
  formula = pfl ~ prot + bord:vaud + bord | vaud * bord,
  data = BastenBetz_0B
)
```

⁷Die Autoren geben an, robuste SEs zu nutzen. Das scheint nicht der Fall zu sein, denn `vcov = "HC0"` liefert die Ergebnisse im Paper. Die von Stata berechneten HC1-SEs weichen ab. Dies ändert allerdings nichts an der Signifikanz der Koeffizienten. Wir nutzen `vcov = "HC1"`.

```

# (2) Präferenz für Umverteilung
SS_pfr <- update(
  object = SS_pfl,
  formula = pfr ~ prot + bord:vaud + bord | vaud * bord,
)

# (3) Präferenz für Intervention
SS_pfi <- update(
  object = SS_pfl,
  formula = pfi ~ prot + bord:vaud + bord | vaud * bord,
)

# (4) Einkommensungleichheit
SS_gini <- update(
  object = SS_pfl,
  formula = pfi ~ prot + bord:vaud + bord | vaud * bord,
)

```

```

# Tabellarische Darstellung
modelsummary(
  list(
    "(1) Freizeit" = SS_pfl,
    "(2) Umverteilung" = SS_pfr,
    "(3) Intervention" = SS_pfi,
    "(4) Ungleichheit" = SS_gini
  ),
  vcov = "HC1",
  stars = T,
  gof_map = "nobs",
  output = "gt"
) %>%
  tabopts()

```

Tabelle 8.5: Ergebnisse der Second-Stage-Regressionen

	(1) Freizeit	(2) Umverteilung	(3) Intervention	(4) Ungleichheit
(Intercept)	50.528*** (1.918)	44.560*** (0.950)	52.871*** (1.063)	52.871*** (1.063)

prot	-13.460*** (3.161)	-5.061* (2.161)	-6.487*** (1.738)	-6.487*** (1.738)
bord	0.438 (0.639)	0.444 (0.357)	-0.165 (0.332)	-0.165 (0.332)
bord × vaud	-0.364 (0.811)	-0.909 (0.561)	0.011 (0.432)	0.011 (0.432)
Num.Obs.	133	133	133	133

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

Die Koeffizienten von `prot` in Tabelle 8.5 sind die mit 2SLS ermittelten erwarteten Behandlungseffekte einer 100%-Reformation (d.h. von 100% katholisch zu 100% protestantisch) für eine durchschnittliche Gemeine nahe der Kantonsgrnze. Es handelt sich jeweils um einen lokalen durchschnittlichen Behandlungseffekt (LATE). Gem. der Definition der abhängigen Variablen, interpretieren wir die Koeffizienten von `prot` in den Regressionen (1), (2) und (3) als erwartete Prozentänderung durch Reformation. Der Koeffizient in Regression (4) gibt die erwartete Änderung des Gini-Index an. Sämtliche geschätzte Effekte sind signifikant und haben ein mit der Hypothese der Autoren konsistentes negatives Vorzeichen.

Die Ergebnisse sind Evidenz, dass Protestantismus zu verringelter Präferenz für Freizeit, Umverteilung sowie wirtschaftspolitische Intervention seitens des Staats führt. Auch die ökonomische Ungleichheit ist signifikant geringer, als in einer durchschnittlichen vollständig katholischen Gemeinde.

8.4.5 Addendum: FRDD-Schätzung mit `rdrobust()`

Die Funktion `rdrobust::rdrobust()` erlaubt die Schätzung von SRDD und FRDD mit einer Vielzahl von Optionen, s. `?rdrobust`. Dies erleichtert die Schätzung mehrerer Modellspezifikationen und Bandweiten. Mit dem nachstehenden Befehl schätzen wir den LATE von Reformation auf die Präferenz für Umverteilung anhand lokaler quadratischer Regression. Der Output gibt einen Überblick der Bandweitenschätzung sowie der 2 Stufen des 2SLS-Schätzers, inkl. robuster Inferenzstatistiken.

```
pfr_rdr <- rdrobust(
  y = BastenBetz$pfr,
  x = BastenBetz$bord,
  fuzzy = BastenBetz$prot,
```

```

  p = 2,
  kernel = "uniform",
  vce = "HC1"
)

pfr_rdr %>%
  summary()

```

Fuzzy RD estimates using local polynomial regression.

Number of Obs.	509
BW type	mserd
Kernel	Uniform
VCE method	HC1

Number of Obs.	127	382
Eff. Number of Obs.	85	131
Order est. (p)	2	2
Order bias (q)	3	3
BW est. (h)	10.796	10.796
BW bias (b)	22.271	22.271
rho (h/b)	0.485	0.485
Unique Obs.	97	261

First-stage estimates.

Method	Coef.	Std. Err.	z	P> z	[
95% C.I.]					
Conventional	0.701	0.039	17.782	0.000	
	[0.624 , 0.778]				
Robust	-	-	15.837	0.000	
	[0.599 , 0.768]				

Treatment effect estimates.

Method	Coef.	Std. Err.	z	P> z	[
95% C.I.]					
Conventional	-5.047	2.254	-2.239	0.025	
	[-9.464 , -0.629]				
Robust	-	-	-2.210	0.027	
	[-10.114 , -0.607]				

Auch für die quadratische Spezifikation erhalten wir mit -5.047 ein vergleichbares signifikantes Ergebnis für den LATE von Protestantismus auf Umverteilung, vgl. Spalte (2) in Tabelle 8.5.

Mit der Option `bwselect = "msetwo"` kann die Bandweite jeweils für die lokale Regression links- und rechtsseitig des Schwellenwerts geschätzt werden.

```
pfr_rdr %>%
  update(bwselect = "msetwo") %>%
  summary()
```

Fuzzy RD estimates using local polynomial regression.

Number of Obs.	509	
BW type	msetwo	
Kernel	Uniform	
VCE method	HC1	
Number of Obs.	127	382
Eff. Number of Obs.	51	134
Order est. (p)	2	2
Order bias (q)	3	3
BW est. (h)	5.340	11.387
BW bias (b)	13.917	22.330
rho (h/b)	0.384	0.510
Unique Obs.	97	261

First-stage estimates.

Method	Coef.	Std. Err.	z	P> z	[
95% C.I.]					

Conventional	0.649	0.046	14.216	0.000
	[0.560 , 0.739]			
Robust	-	-	11.970	0.000
	[0.534 , 0.743]			

Treatment effect estimates.

Method	Coef.	Std. Err.	z	P> z	[
Conventional	-7.487	3.378	-2.216	0.027	
	[-14.109 , -0.866]				
Robust	-	-	-2.156	0.031	
	[-14.750 , -0.704]				

Trotz Diskrepanz der geschätzten Bandweiten erhalten wir eine größere aber vergleichbare Schätzung für einen negativen Effekt.

9 Regularisierte Regression

In diesem Kapitel betrachten wir Varianten von Koeffizientenschätzern im linearen Modell

$$Y_i = \beta_1 X_{1,i} + \cdots + \beta_k X_{k,i} + u_i, \quad i = 1, \dots, n, \quad (9.1)$$

deren Motivation die Schätzung von $\boldsymbol{\beta} := (\beta_1, \dots, \beta_k)'$ in Anwendungen ist, in denen der KQ-Schätzer

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= \arg \min_{\boldsymbol{\beta}} \text{RSS}(\boldsymbol{\beta}) \\ &= \arg \min_{\boldsymbol{\beta}} \sum_{i=1}^n (Y_i - \beta_1 X_{1,i} - \cdots - \beta_k X_{k,i})^2 \end{aligned} \quad (9.2)$$

keine stabile Schätzung zulässt oder nicht eindeutig definiert ist, und damit gar nicht erst berechnet werden kann. Solche Szenarien ergeben sich in der empirischen Forschung, wenn die Regressoren stark korreliert sind und/oder das Modell viele Regressoren enthält ($k \lesssim n$), oder das Regressionsproblem hoch-dimensional ist ($k > n$).

Regularisierte Regressionsschätzer begegnen dieser Problematik mit einer Modifikation der Verlustfunktion RSS in (9.2),

$$\text{RSS}(\boldsymbol{\beta}, p, \lambda) := \text{RSS}(\boldsymbol{\beta}) + \lambda \|\boldsymbol{\beta}\|_p. \quad (9.3)$$

Hierbei ist $\lambda > 0$ ein Tuning-Parameter und $p \geq 1$ definiert die p -Norm des Koeffizientenvektors,

$$\|\boldsymbol{\beta}\|_p := \left(\sum_{j=1}^k |\beta_j|^p \right)^{1/p} > 0. \quad (9.4)$$

Wegen $\lambda \|\boldsymbol{\beta}\|_p > 0$ kann die p -Norm des Koeffizientenvektors $\boldsymbol{\beta}$ das Optimierungsproblem

$$\min_{\boldsymbol{\beta}} \text{RSS}(\boldsymbol{\beta}, p, \lambda) \mid p, \lambda$$

derart restringieren, dass die geschätzten Koeffizienten

$$\hat{\beta}_{p, \lambda} := \arg \min_{\beta} \text{RSS}(\beta, p, \lambda)$$

im Erwartungswert absolut kleiner ausfallen als bei der KQ-Schätzung: Der Schätzer ist in Richtung 0 verzerrt.¹ Dieser Effekt der Regularisierung wird in der Literatur als *Shrinkage* bezeichnet.

Die grundlegenden Eigenschaften des Schätzers $\hat{\beta}_{p, \lambda}$ werden maßgeblich durch den Parameter p bestimmt, der hinsichtlich des zu lösenden Regressionsproblems *a priori* gewählt wird.²

Shrinkage ist eine Motivation für die Anwendung regularisierter Schätzer in Modellen, die auch mit KQ geschätzt werden könnten. Um dies zu verstehen, nehmen wir an, dass die Gauss-Markov-Annahmen in (9.1) gelten. Dann hat der KQ-Schätzer die kleinste Varianz unter allen *unverzerrten* Schätzern. Aufgrund der Shrinkage fallen regularisierte Schätzer zwar nicht unter das Gauss-Markov-Theorem, können dafür aber eine geringere Varianz haben als KQ. Schätzer mit solchen Eigenschaften sind nützlich, wenn eine unverzerrte Schätzung von β nicht unser primäres Ziel ist: Für Vorhersagen kann es hilfreich sein, etwas Verzerrung bei der Koeffizientenschätzung in Kauf zu nehmen, um eine hinreichend große Varianzreduktion zu erreichen, sodass ein geringerer erwarteter Vorhersagefehler als für KQ resultiert. Hierbei liegt, eine Abwägung zwischen Verzerrung und Varianz (*Bias Variance Tradeoff*) vor, der durch den Regularisierungsparameter λ beeinflusst wird.

Für die Berechnung des Schätzers in empirischen Anwendungen wird λ meist datengetrieben (mit [Cross Validation](#) oder einem Informationskriterium) geschätzt oder mit einer analytisch fundierten Faustregel gewählt.

Nachfolgend betrachten wir zwei häufig verwendete regularisierte Schätzer, die sich durch die Wahl $p = 1$ (Lasso Regression) bzw. $p = 2$ (Ridge Regression) ergeben und illustrieren ihre Anwendung mit R.

9.1 Ridge Regression

Ridge Regression wurde von Hoerl und Kennard (1970) als Alternative zur KQ-Schätzung bei hoch-korrelierten Regressoren eingeführt. Die Verlustfunktion

¹Beachte, dass für $\lambda = 0$ die Verlustfunktion des KQ-Schätzers folgt.

²D.h. wir wählen p , um einen Schätzer mit für die konkrete Anwendung hilfreichen Eigenschaften zu erhalten.

lautet

$$\text{RSS}(\boldsymbol{\beta}, p=2, \lambda) = \text{RSS}(\boldsymbol{\beta}) + \lambda \|\boldsymbol{\beta}\|_2, \quad (9.5)$$

d.h. der Parameter λ reguliert den Einfluss eines ℓ_2 -Strafterms

$$\|\boldsymbol{\beta}\|_2 = \sqrt{\sum_{j=1}^k \beta_j^2}$$

auf die Verlustfunktion $\text{RSS}(\boldsymbol{\beta}, p=2, \lambda)$. Der Ridge-Schätzer ergibt sich als

$$\hat{\boldsymbol{\beta}}_\lambda^R := \arg \min_{\boldsymbol{\beta}} \text{RSS}(\boldsymbol{\beta}) + \lambda \|\boldsymbol{\beta}\|_2. \quad (9.6)$$

Für Das Optimierungsproblem (9.6) kann wir aus den Bedingungen 1. Ordnung

$$-2\mathbf{X}'(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) + 2\lambda\boldsymbol{\beta} = \mathbf{0} \quad (9.7)$$

die analytische Lösung

$$\hat{\boldsymbol{\beta}}_\lambda^R = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1}\mathbf{X}'\mathbf{Y}, \quad (9.8)$$

bestimmt werden, wobei \mathbf{I}_k die $k \times k$ Einheitsmatrix ist. Aus Gleichung (9.8) kann die Wirkungsweise des Strafterms $\lambda \|\boldsymbol{\beta}\|_2$ abgeleitet werden: Ridge Regression modifiziert die Diagonale der zu invertierenden Matrix $\mathbf{X}'\mathbf{X}$ durch Addition von $\lambda > 0$. Dies ist hilfreich, wenn

- $k \geq n$ und damit $\mathbf{X}'\mathbf{X}$ nicht invertierbar (singulär) ist. Dann kann der KQ-Schätzer nicht berechnet werden.³ Die Inverse $(\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1}$ hingegen existiert unter milden Bedingungen.
- hohe Kollinearität vorliegt, sodass $(\mathbf{X}'\mathbf{X})^{-1}$ zwar existiert, aber zu einer instabilen KQ-Schätzung mit hoher Varianz führt.

Für eine grafische Betrachtung des Optimierungskalküls (9.6) betrachten wir die äquivalente Darstellung als Lagrange-Problem

$$\hat{\boldsymbol{\beta}}_\lambda^R := \arg \min_{\|\boldsymbol{\beta}\| < t} \text{RSS}(\boldsymbol{\beta}). \quad (9.9)$$

³Beispiel: `X <- matrix(rnorm(100), ncol = 10)`. Vergleiche `solve(t(X) %*% X)` und `solve(t(X) %*% X + diag(.01, nrow = 10))`

In der folgenden interaktiven Grafik illustrieren wir das Optimierungsproblem (9.9) sowie den resultierenden Schätzer der Koeffizienten (β_1, β_2) in einem multiplen Regressionsmodell mit den Regressoren X_1 und X_2 .

- Die blaue Ellipse ist die Menge aller Schätzwerte $(\hat{\beta}_1, \hat{\beta}_2)$ für den angegebenen Wert von RSS. Im Zentrum der Ellipse liegt der KQ-Schätzer, welcher RSS minimiert.
 - Der blaue Kreis ist die Menge aller Koeffizienten-Paare (β_1, β_2) , welche die Restriktion $\beta_1^2 + \beta_2^2 \leq t$ erfüllen. Beachte, dass die Größe des Kreises nur durch den Parameter t bestimmt wird, welcher für einen vorgegebenen Wertebereich variiert werden kann.
 - Der blaue Punkt ist der Ridge-Schätzer $(\hat{\beta}_{1,t}^R, \hat{\beta}_{2,t}^R)$. Dieser ergibt sich als Schnittpunkt zwischen der blauen RSS-Ellipse und der Restriktionsregion und variiert mit t . Die gestrichelte rote Kurve zeigt den Ridge-Lösungspfad.
 - Für kleine Werte t drückt die Shrinkage die geschätzten Koeffizienten Richtung 0, wobei der Lösungspfad i.d.R. nicht-linear verläuft, d.h. die Shrinkage auf den Koeffizienten ist grundsätzlich unterschiedlich. Die Lösung $(\hat{\beta}_{1,t}^R, \hat{\beta}_{2,t}^R) = (0, 0)$ existiert nur als Grenzwert für $t \rightarrow 0$.
 - Beachte, dass der Effekt von t auf die Schätzung umgekehrt für λ verläuft: Größere λ führen zu stärkerer Regularisierung.
-

Diese Interaktive Komponente des Buchs ist nur in der Online-Version verfügbar.

9.1.1 Eigenschaften des Schätzers

Der Ridge-Schätzer $\hat{\beta}_\lambda^R$ ist nicht invariant gegenüber der Skalierung der Regressoren. Für empirische Daten sollte daher vorab eine Standardisierung der erklärenden Variablen durchgeführt werden.⁴ Um die Eigenschaften des Ridge-Schätzers besser zu verstehen, betrachten wir hier den Fall orthonormaler

⁴Bspw. mit der Funktion `scale()`.

Regressoren \mathbf{X}_j .⁵ Dann ist

$$\hat{\beta}_{\lambda, j}^R = (1 + \lambda)^{-1} \cdot \hat{\beta}_j, \quad j = 1, \dots, k, \quad (9.10)$$

d.h. der Ridge-Schätzer skaliert die KQ-Lösung mit einem von λ abhängigen Faktor.⁶

Wir illustrieren dies, indem wir den Zusammenhang zwischen KQ- und Ridge-Schätzer im orthonormalen Fall als R-Funktion `ridge_ortho()` implementieren und für die Parameterwerte $\lambda \in \{0, 0.5, 2\}$ plotten.

```
library(tidyverse)

# Funktion für Rige Regression bei orthonormalen Regressoren
ridge_ortho <- function(KQ, lambda) {
  1/(1 + lambda) * KQ
}

# KQ-Schätzer gegen Ridge-Schätzer plotten
dat <- tibble(KQ = seq(-1, 1, .01))

ggplot(dat) +
  geom_function(fun = ridge_ortho,
                args = list(lambda = 0),
                lty = 2) +
  geom_function(fun = ridge_ortho,
                args = list(lambda = .5),
                col = "red") +
  geom_function(fun = ridge_ortho,
                args = list(lambda = 2),
                col = "blue") +
  xlim(-.4, .4) +
  xlab("KQ-Schätzer von beta_1") +
  ylab("Ridge-Schätzer von beta_1")
```

Abbildung 9.1 zeigt, dass der Ridge-Schätzer eine lineare Transformation des KQ-Schätzers (gestrichelte Linie) ist. Größere Werte des Regularisierungsparameters λ führen zu stärkerer Shrinkage des Koeffizientenschätzers in Richtung

⁵Orthonormalität heißt $\mathbf{X}'_i \mathbf{X}_j = 1$ für $i = j$ und 0 sonst. Dann ist $\mathbf{X}' \mathbf{X} = \mathbf{I}_k$.

⁶ $(1 + \lambda)^{-1}$ wird auch als *Shrinkage-Faktor* bezeichnet.

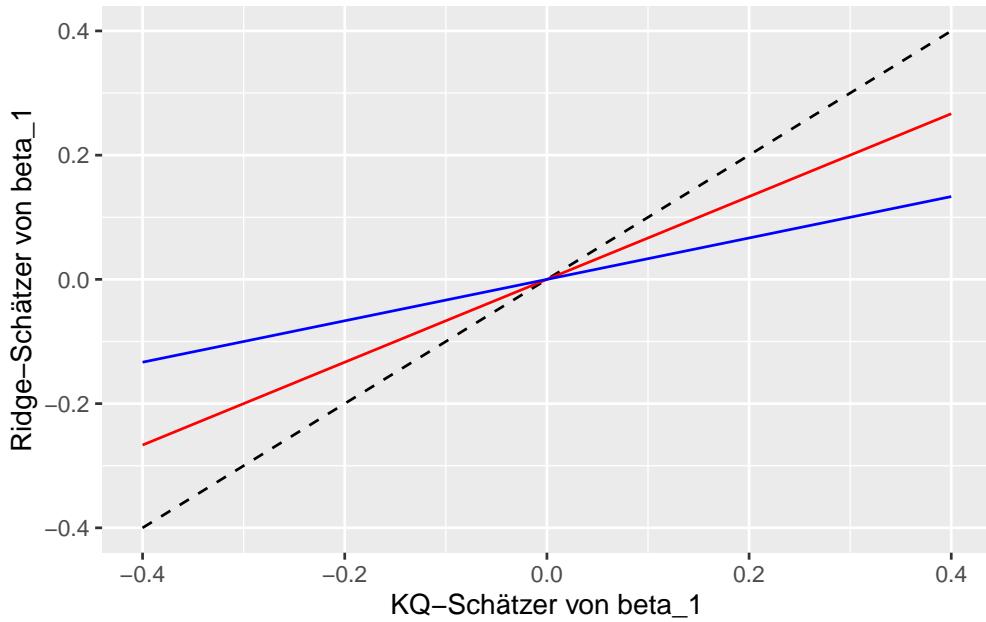


Abbildung 9.1: Shrinkage des OLS-Schätzers bei Ridge Regression

0. Die ℓ_2 -Norm führt zu proportional zum Absolutwert des KQ-Schätzers verlaufender Shrinkage: Größere Koeffizienten werden stärker bestraft als kleine Koeffizienten.

Die Eigenschaft

$$E\left(\hat{\beta}_{\lambda,j}^R\right) = (1 + \lambda)^{-1} \cdot \beta_j$$

zeigt, dass $\hat{\beta}_{\lambda,j}^R$ (für fixes $\lambda > 0$) nicht erwartungstreu für β_j ist. Weiterhin ist

$$\begin{aligned}\text{Var}\left(\hat{\beta}_{\lambda,j}^R\right) &= \text{Var}\left(\hat{\beta}_j\right) \cdot \left(\frac{\lambda}{1 + \lambda^2}\right) \\ &= \sigma^2 \cdot \left(\frac{\lambda}{1 + \lambda^2}\right),\end{aligned}$$

wobei σ^2 die Varianz des Regressionsfehlers u ist. Wegen $\lambda < (1 + \lambda)^2$ für $\lambda > 0$ gilt

$$\text{Var}\left(\hat{\beta}_{\lambda,j}^R\right) < \text{Var}\left(\hat{\beta}_j\right).$$

Der Ridge-Schätzer hat also eine kleinere Varianz als der KQ-Schätzer. Diese Eigenschaften können auch für korrelierte Regressoren gezeigt werden.

9.1.2 Ridge Regression mit `glmnet`

Wir zeigen nun anhand simulierter Daten, wie der Ridge-Lösungspfad mit dem R-Paket `glmnet` berechnet werden kann. Wir erzeugen zunächst Daten gemäß der Vorschrift

$$Y_i = \mathbf{X}'_i \boldsymbol{\beta} + u_i,$$

$$\begin{aligned}\beta_j &= \frac{5}{j^2}, & j &= 1, \dots, 5, \\ \beta_j &= -\frac{5}{(j-5)^2}, & j &= 6, \dots, 10,\end{aligned}\tag{9.11}$$

$$\mathbf{X}_i \sim N(\mathbf{0}, \Sigma), \quad u_i \stackrel{u.i.v.}{\sim} N(0, 1), \quad i = 1, \dots, 25.$$

Hierbei wird Σ so definiert, dass jeder Regressor $N(0, 1)$ -verteilt ist und eine Korrelation von 0.8 mit allen anderen Regressoren aufweist. Mit der Vorschrift für die β_j stellen wir sicher, dass es wenige Variablen gibt, die Y stark beeinflussen, da der Absolutbetrag der Koeffizienten in j abnimmt.⁷

```
library(gendata)
set.seed(1234)

# Parameter definieren
N <- 80
k <- 10

coefs <- 5/(1:(k/2))^2
beta <- c(coefs, -coefs)

# Beobachtungen simulieren
X <- as.matrix(
  genmvnorm(
    k = k,
    cor = rep(.8, (k^2-k)/2),
    n = N)
)
Y <- X %*% beta + rnorm(N)
```

⁷Für bessere Interpretierbarkeit der Grafischen Auswertung, wählen wir positive und negative Koeffizienten mit gleichem Bertag.

Wir schätzen nun ein Modell mit allen 10 Regressoren mit `glmnet`. Beachte, dass für den Ridge-Strafterm `alpha = 0` gesetzt werden muss.⁸

```
library(glmnet)

# Ridge-Regression anpassen
ridge_fit <- glmnet(
  x = X,
  y = Y,
  alpha = 0 # für Ridge-Strafterm
)
```

Der Lösungspfad der Ridge-Schätzung kann nach Transformation der geschätzten Koeffizienten und der zugehörigen λ -Werte in ein langes Format überführt und komfortabel mit `ggplot2` dargestellt werden.

```
# Lambda-Sequenz auslesen
lambdas <- ridge_fit$lambda

# Ridge-Schätzung für Lambdas im langen Format
as.matrix(ridge_fit$beta) %>%
  as_tibble() %>%
  rownames_to_column("Variable") %>%
  pivot_longer(-Variable) %>%
  group_by(Variable) %>%
  mutate(lambda = lambdas) %>%

# Grafik mit ggplot erzeugen
ggplot(
  mapping = aes(
    x = lambda,
    y = value,
    col = Variable
  )
) +
  geom_line() +
  ylab("gesch. Koeffizienten") +
  scale_x_log10("log_10(lambda)")
```

⁸`alpha` ist ein Mischparameter im Algorithmus für `elastic net`, siehe `?glmnet`.

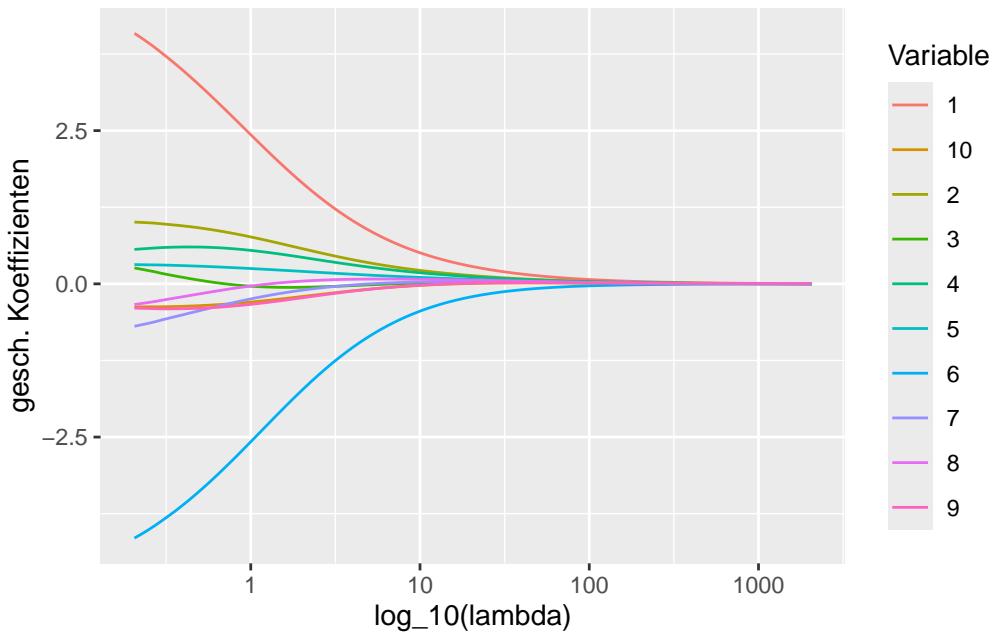


Abbildung 9.2: Lösungspfad für Ridge-Schätzung

Abbildung 9.2 zeigt den nicht-linearen Verlauf der Shrinkage auf den geschätzten Modellkoeffizienten. Die Koeffizienten werden mit zunehmendem λ von der KQ-Lösung ausgehend (linkes Ende der Skala) in Richtung 0 gezwungen.

Über die Funktion `cv.glmnet()` kann ein optimales λ mit Cross Validation (CV) ermittelt werden. Ähnlich wie bei `glmnet()` wird für die Validierung automatisch eine λ -Sequenz erzeugt. Wir nutzen `autoplot()` aus dem R-Paket `ggfortify` für die Visualisierung der Ergebnisse mit `ggplot2`.

```
library(ggfortify)

# Cross-validierte Bestimmung von lambda
ridge_cvfit <- cv.glmnet(
  y = Y,
  x = X,
  intercept = F,
  alpha = 0
)

# Ergebnisse plotten
ridge_cvfit %>%
  autoplot(label.n = 0)
```

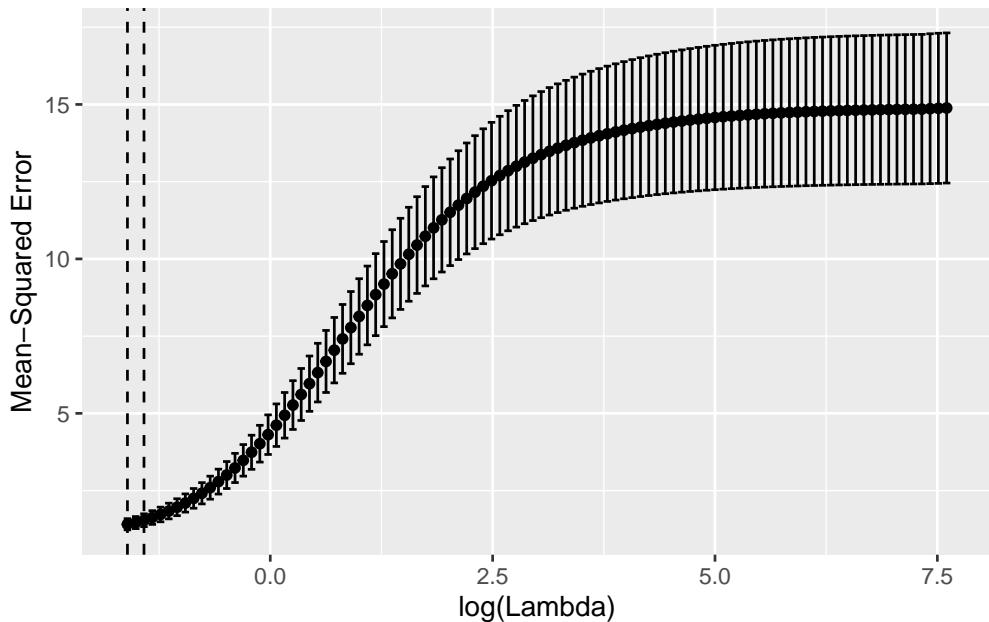


Abbildung 9.3: Lösungspfad für Ridge-Schätzung

Abbildung 9.3 zeigt `ridge_cvfit$lambda.min`, das optimale λ mit dem geringsten CV Mean-Squared-Error (linke gestrichelte Linie) und `ridge_cvfit$lambda.1se`, das größte λ , welches innerhalb einer Standardabweichung entfernt ist (rechte gestrichelte Linie).⁹ Wir berechnen die Schätzung für `lambda.min`.

```
(  
  ridge_coefs <- coef(  
    object = ridge_cvfit,  
    s = ridge_cvfit$lambda.min  
  )  
)
```

```
11 x 1 sparse Matrix of class "dgCMatrix"  
           s1  
(Intercept) .  
X1          4.1302194  
X2          1.0245661  
X3          0.3139297  
X4          0.5697498  
X5          0.2928664
```

⁹Die Wahl von `lambda.1se` ist eine Heuristik, welche die Schätzunsicherheit berücksichtigt und zu einem “sparsameren” Modell tendiert.

X6	-4.1693524
X7	-0.7509305
X8	-0.3844761
X9	-0.3841997
X10	-0.4078514

Wir schätzen das Modell nun mit KQ und vergleichen die Koeffizienten mit der Ridge-Schätzung.

```
# KQ-Schätzung durchführen
KQ_fit <- lm(Y ~ X - 1)

# Koeffizienten auslesen und transformieren:
tibble(
  Ridge = as.matrix(ridge_coefs)[2:11, ],
  KQ = KQ_fit$coefficients
) %>%
  mutate(j = factor(1:10)) %>%
  pivot_longer(
    cols = Ridge:KQ,
    names_to = "Methode",
    values_to = "Koeffizient"
) %>%

# Bar-Plot für Koeffizientenvergleich erzeugen
ggplot(
  mapping = aes(
    x = j,
    y = Koeffizient,
    fill = Methode
  )
) +
  geom_bar(
    position = "dodge",
    stat = "identity",
    width = .5
)
```

Der Vergleich anhand von Abbildung 9.4 zeigt deutlich, dass Ridge Regression im Vergleich mit KQ zu absolut kleineren Koeffizientenschätzungen tendiert.



Abbildung 9.4: Koeffizientenvergleich: Ridge vs. KQ

Inwiefern dies Konsequenzen für die Prognosegüte der Schätzung hat, können wir Anhand eines Testdatensatzes bestimmen. Hierzu vergleichen wir die mittleren Fehler (MSE) bei der Prognose von Y für die Beobachtungen im Testdatensatz. Für die Simulation des Testdatensatzes nutzen wir erneut die Vorschrift (9.11) um 80 neue Beobachtungen zu erzeugen.

```
# Test-Datensatz erstellen
set.seed(4321)
# Regressoren
new_X <- as.matrix(
  genmvnorm(
    k = k,
    cor = rep(.85, (k^2-k)/2),
    n = N
  )
)
# Abh. Variable
new_Y <- new_X %*% beta + rnorm(N)
```

Für beide Methoden können wir `predict()` für die Prognosen von Y für den Testdatensatz (`new_Y`) nutzen.

```

# Ridge: Vorhersage von new_Y für Test-Datensatz
Y_predict_ridge <- predict(
  object = ridge_cvfit,
  newx = new_X,
  s = ridge_cvfit$lambda.min
)

# Ridge: MSE für Test-Datensatz berechnen
mean((Y_predict_ridge - new_Y)^2)

```

[1] 1.288457

Die Vorhersage für `lm()` benötigt dieselben Variablennamen wie im angepassten Modell, s. `KQ_fit$coefficients`.

```

# Test-Datensatz für predict.lm() formatieren
new_X <- as.data.frame(new_X)
colnames(new_X) <- paste0("X", 1:k)

# KQ: Vorhersage von new_Y für Test-Datensatz
Y_predict_KQ <- predict(
  object = KQ_fit,
  newdata = new_X
)

# KQ: MSE für Test-Datensatz berechnen
mean((Y_predict_KQ - new_Y)^2)

```

[1] 29.33797

Die Ergebnisse zeigen, dass der Ridge-Schätzer trotz seiner Verzerrung einen deutlich geringeren mittleren Vorhersagefehler für die Testdaten erzielt als der KQ-Schätzer. Diese Eigenschaft der Koeffizientenschätzung kann die Prognosegüte von Ridge Regression gegenüber der KQ-Regression verbessern.

9.1.3 Beispiel: Vorhersage von Abschlussnoten in Mathe

Zur Illustration von Ridge Regression nutzen wir den Datensatz SP aus Cortez und Silva (2008).¹⁰ SP enthält Beobachtungen zu Leistungen von insgesamt 100 Schülerinnen und Schülern im Fach Mathematik in der Sekundarstufe an zwei portugiesischen Schulen. Neben der Abschlussnote in Mathe (G3, Skala von 0 bis 20) beinhaltet SP diverse demografische, soziale und schulbezogene Merkmale, die mithilfe von Schulberichten und Fragebögen erhoben wurden. Ziel ist es, ein Modell für die Prognose von G3 anzupassen.

Wir lesen zunächst die Daten (im .csv-Format) ein.

```
# Daten einlesen  
SP <- read_csv(file = "datasets/SP.csv")
```

Ein Überblick zeigt, dass der Großteil der Regressoren aus kategorialen Variablen mit sozio-ökonomischen Informationen besteht.

```
# Überblick  
glimpse(SP)
```



```
Rows: 100  
Columns: 31  
$ school      <chr> "GP", "GP", "GP", "MS", "GP", "GP", "GP",  
"GP", "GP", "GP", ~  
$ sex         <chr> "M", "M", "F", "F", "M", "F", "F", "F", "F",  
"F", "M", "M", ~  
$ age          <dbl> 17, 18, 19, 17, 16, 16, 19, 16, 16, 16, 18,  
16, 15, 17, 17, ~  
$ address      <chr> "R", "R", "U", "U", "U", "U", "U", "U", "U",  
"R", "U", "U", ~  
$ famsize      <chr> "GT3", "GT3", "LE3", "GT3", "LE3", "GT3",  
"GT3", "GT3", "GT~  
$ Pstatus      <chr> "T", "T", "T", "T", "A", "T", "T", "T", "A",  
"T", "T", "T", ~  
$ Medu        <dbl> 1, 4, 3, 2, 3, 2, 0, 2, 3, 4, 4, 2, 1, 2, 2,  
3, 3, 4, 4, 2, ~
```

¹⁰Wir verwenden eine Auszug aus dem Orignaldatensatz, der nebst ausführlicher Variablenbeschreibung [hier](#) verfügbar ist.

```

$ Fedu      <dbl> 2, 3, 2, 2, 4, 3, 1, 1, 1, 4, 4, 2, 2, 3, 2,
3, 1, 3, 4, 2, ~
$ Mjob      <chr> "at_home", "teacher", "services", "other",
"services", "oth~
$ Fjob      <chr> "other", "services", "other", "at_home",
"other", "other", ~
$ reason    <chr> "home", "course", "reputation", "home",
"home", "reputation~
$ guardian   <chr> "mother", "mother", "other", "mother",
"mother", "mother", ~
$ traveltim <dbl> 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1,
2, 1, 1, 1, 1, ~
$ studytim <dbl> 2, 3, 2, 3, 2, 2, 2, 1, 2, 2, 1, 2, 2, 2, 1,
1, 2, 3, 1, 2, ~
$ failures   <dbl> 0, 0, 1, 0, 0, 0, 3, 0, 3, 0, 0, 0, 0, 0,
0, 0, 0, 0, ~
$ schoolsup  <chr> "no", "no", "no", "no", "yes", "yes", "no",
"no", "no", "no~
$ famsup    <chr> "no", "no", "yes", "no", "yes", "yes", "yes",
"no", "yes", ~
$ paid       <chr> "no", "no", "yes", "no", "no", "yes", "no",
"no", "yes", "n~
$ activities <chr> "no", "no", "no", "yes", "yes", "yes", "no",
"no", "no", "y~
$ nursery    <chr> "yes", "yes", "no", "yes", "yes", "yes",
"no", "yes", "yes"~
$ higher     <chr> "yes", "yes", "yes", "yes", "yes", "yes",
"no", "yes", "yes~
$ internet   <chr> "no", "yes", "yes", "no", "yes", "no", "no",
"yes", "yes", ~
$ romantic   <chr> "no", "yes", "yes", "yes", "no", "no", "no",
"yes", "no", "~~
$ famrel     <dbl> 3, 5, 4, 3, 5, 4, 3, 4, 2, 2, 1, 5, 4, 5, 3,
5, 4, 4, 5, 5, ~
$ freetime   <dbl> 1, 3, 2, 4, 3, 4, 4, 5, 3, 4, 4, 4, 4, 3, 3, 4,
4, 5, 2, 3, 4, ~
$ goout      <dbl> 3, 2, 2, 3, 3, 2, 2, 3, 4, 2, 4, 2, 3, 4,
2, 4, 2, 3, 4, ~
$ Dalc       <dbl> 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 1, 1, 1,
1, 2, 1, 1, 1, ~

```

```

$ Walc      <dbl> 5, 2, 2, 1, 1, 3, 1, 1, 2, 3, 2, 4, 1, 3, 3,
1, 3, 2, 1, 1, ~
$ health    <dbl> 3, 4, 1, 3, 5, 4, 5, 5, 4, 4, 1, 5, 5, 3, 5,
5, 1, 3, 5, 5, ~
$ absences   <dbl> 4, 9, 22, 8, 4, 6, 2, 20, 5, 6, 5, 0, 2, 2,
12, 0, 17, 0, 4~
$ G3         <dbl> 10, 16, 11, 11, 10, 9, 12, 7, 11, 16, 12,
9, 12, 12, 13~

```

Um die Prognosegüte des Modells beurteilen zu können, partitionieren wir SP zufällig in einen Test- sowie einen Trainingsdatensatz (mit 30 und 70 Beobachtungen), jeweils für die Regressoren und die abhängige Variable.

```

# ID für Beobachtungen im Testdatensatz zufällig erzeugen
set.seed(1234)
ID <- sample(1:nrow(SP), size = 30)

# Regressoren aufteilen
SP_test <- SP[ID,]
SP_train <- SP[-ID,]

# Abh. Variable aufteilen
Y_test <- SP_test$G3
Y_train <- SP_train$G3

```

Als nächstes passen wir ein Ridge-Regressionsmodell für alle Regressoren in SP_train an und ermitteln ein optimales λ mit Cross Validation. Beachte, dass `cv.glmnet` nicht für Regressoren im `data.frame/tibble`-Format ausgelegt ist, sondern ein `matrix`-Format erwartet. Wir transformieren SP_train daher mit `data.matrix()`.

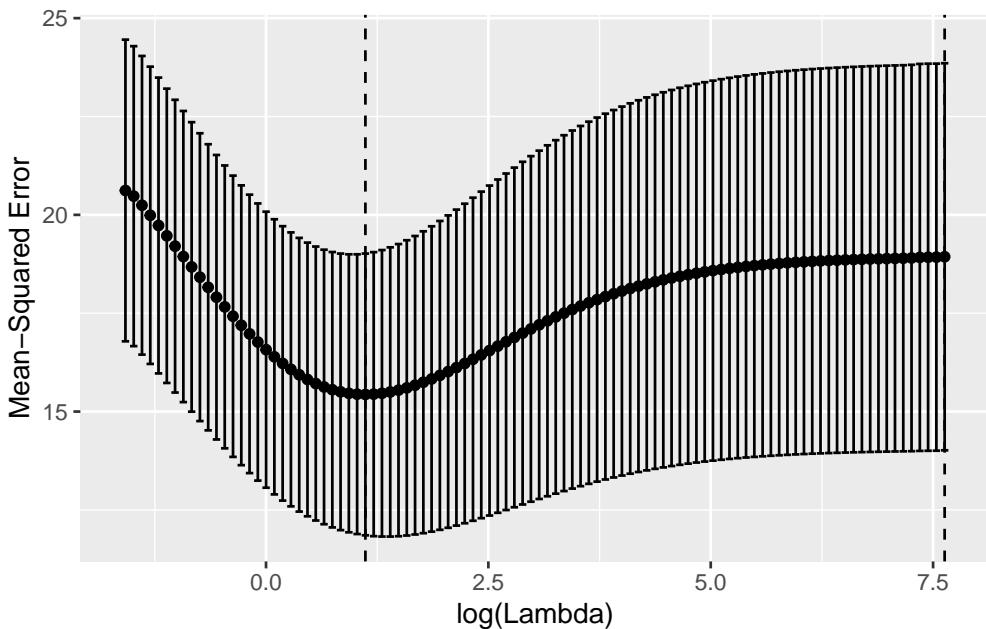
```

# Ridge-Regression und CV für Trainingsdaten
SP_fit_cv <- cv.glmnet(
  x = data.matrix(SP_train %>% select(-G3)),
  y = Y_train,
  alpha = 0
)

# CV-Ergebnisse für lambda visualisieren

```

```
SP_fit_cv %>%
  autoplot(label.n = 0)
```



Wie für das Beispiel mit simulierten Daten erhalten wir mit `predict()` Vorhersagen für die erzielte Punktzahl. Beachte, dass wir den MSE nicht für die Trainingsdaten `SP_train`, sondern für die Testdaten `SP_test` berechnen.

```
# Prognose von G3 anhand des Ridge-Modells
Y_predict_ridge <- predict(
  object = SP_fit_cv,
  newx = data.matrix(
    SP_test %>%
      select(-G3)
  ),
  s = SP_fit_cv$lambda.min
)

# MSE für Testdaten berechnen
mean((Y_predict_ridge - Y_test)^2)
```

[1] 21.13249

Auch in diesem empirischen Beispiel zeigt ein Vergleich der MSEs, dass Ridge Regression dem KQ-Schätzer hinsichtlich der Vorhersagegüte überlegen ist.

```

# Modell mit KQ schätzen
SP_fit_KQ <- lm(G3 ~ ., SP_train)

# Prognose
Y_predict_KQ <- predict(
  object = SP_fit_KQ,
  newdata = SP_test %>%
    select(-G3)
)

# Testset-MSE berechnen
mean((Y_predict_KQ - Y_test)^2)

```

[1] 29.76893

Der MSE für Ridge ist mit 21.13 deutlich kleiner als 29.77, der MSE für KQ.

Für die Interpretation der Ridge-Schätzung erweitern den Code für die ggplot2-Grafik der Koeffizienten-Pfade um eine vertikale Linie des mit CV ermittelten λ und fügen mit dem Paket ggrepel Labels für die Pfade der größten Koeffizienten hinzu.

```

library(ggrepel)

# Lambda-Sequenz auslesen
lambdas <- SP_fit_cv$lambda

# Ridge-Schätzung für Lambdas im langen Format
df <- as.matrix(SP_fit_cv$glmnet.fit$beta) %>%
  as_tibble() %>%
  mutate(
    Variable = rownames(SP_fit_cv$glmnet.fit$beta)
  ) %>%
  pivot_longer(-Variable) %>%
  group_by(Variable) %>%
  mutate(lambda = lambdas)

# Grafik mit ggplot erzeugen
df %>%
  ggplot(

```

```

mapping = aes(
  x = lambda,
  y = value,
  col = Variable
)
) +
geom_line() +
geom_label_repel(
  data = df %>%
    filter(lambda == min(lambdas)),
  mapping = aes(label = Variable),
  seed = 1234,
  size = 5,
  max.overlaps = 8,
  nudge_x = -.5) +
ylab("gesch. Koeffizienten") +
scale_x_log10("log_10(lambda)") +
geom_vline(
  xintercept = SP_fit_cv$lambda.min,
  col = "red",
  lty = 2
) +
theme(legend.position = "none")

```

Abbildung 9.5 gibt Hinweise darauf, dass neben der Schulzugehörigkeit und Indikatoren für schulische Leistung (bspw. `failures`) sozio-ökonomische Prädiktoren wie `internet` (Internetzugang zuhause), `Pstatus` (Zusammenleben der Eltern) und `address/traveltime` (sozialer Status) relevante Variablen zu sein scheinen.

Das optimale $\lambda_{cv} \approx 0.21$ (gestrichelte rote Linie in Abbildung 9.5) führt zu deutlicher Shrinkage, was eine mögliche Erklärung für den besseren Testset-MSE von Ridge Regression ist: Die Koeffizienten von Variablen mit wenig Erklärungskraft werden durch die Regularisierung in Richtung 0 gezwungen und reduzieren so die Varianz der Vorhersage gegenüber der (idealerweise) unverzerrten KQ-Schätzung.

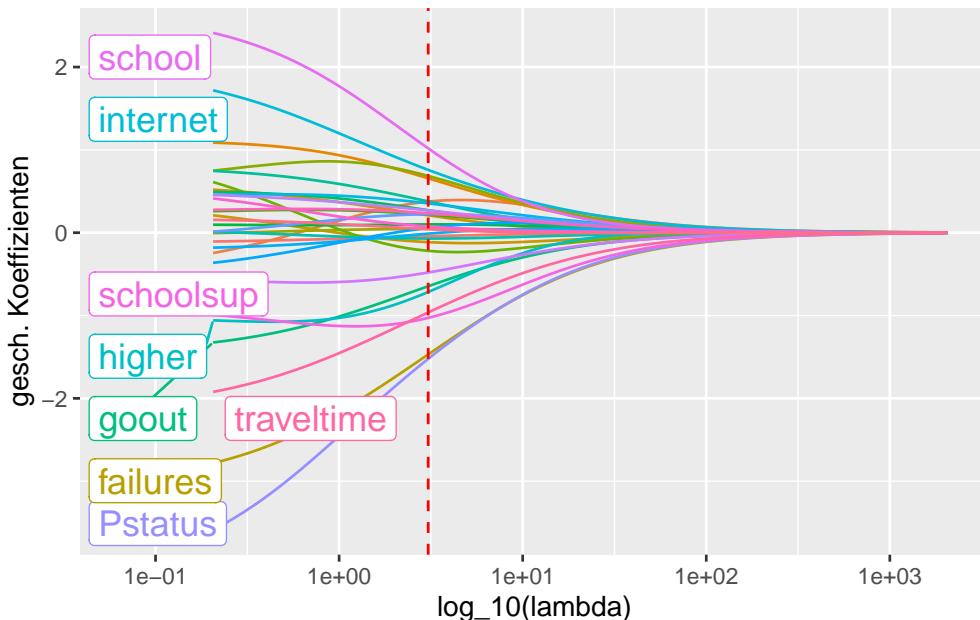


Abbildung 9.5: Lösungspfad für Ridge-Schätzung

i Key Facts zu Ridge Regression

- Ridge-Regression regularisiert den KQ-Schätzer mit der ℓ_2 -Norm der Koeffizienten. Diese Form von Regularisierung ist eine Alternative für KQ in Anwendungen mit mehr Regressoren als Beobachtungen ($k \geq n$) und/oder wenn KQ aufgrund starker Kollinearität eine hohe Varianz aufweist.
- Der Ridge-Schätzer $\hat{\beta}_\lambda^R$ ist *nicht* erwartungstreu. Die geschätzten Koeffizienten sind auch für $n \rightarrow \infty$ verzerrt.
- Aufgrund der verzerrten Schätzung ist statistische Inferenz für Koeffizienten mit $\hat{\beta}_\lambda^R$ problematisch. Anstatt für strukturelle Modelle oder die Schätzung kausaler Effekte wird Ridge Regression in der Praxis daher überwiegend für Prognosen verwendet.
- Die Wahl von λ impliziert einen Tradeoff zwischen Verzerrung und Varianz: Große λ schrumpfen die Koeffizientenschätzer Richtung 0 (mehr Verzerrung), führen aber zu einer kleineren Varianz der Schätzung. Entsprechend können Vorhersagen mit mehr Verzerrung aber weniger Varianz als mit KQ getroffen werden.
- Ridge Regression kann in R mit dem Paket `glmnet` berechnet werden.

9.2 Lasso Regression

Least Absolute Shrinkage and Selection Operator (Lasso) ist ein von Tibshirani (1996) vorgeschlagener Schätzer, der die Verlustfunktion des KQ-Schätzers um einen Strafterm für die Summe der (absoluten) Größe der Koeffizienten $\beta = (\beta_1, \dots, \beta_k)'$ erweitert. Die Verlustfunktion des Lasso-Schätzers von β lautet

$$\text{RSS}(\beta, p=1, \lambda) = \text{RSS}(\beta) + \lambda \|\beta\|_1. \quad (9.12)$$

Für den Strafterm wird also die ℓ_1 -norm

$$\|\beta\|_1 = \sum_{j=1}^k |\beta_j|$$

verwendet. Der Lasso-Schätzer $\hat{\beta}_\lambda^L$ für β minimiert (9.12),

$$\hat{\beta}_\lambda^L = \arg \min_{\beta} \text{RSS}(\beta, p=1, \lambda). \quad (9.13)$$

Entsprechend erhalten wir in Abhängigkeit von λ ein Kontinuum an Lösungen

$$\left\{ \hat{\beta}_\lambda^L \right\}_{\lambda=0}^{\lambda=\infty}, \quad (9.14)$$

der sogenannte *Lasso-Pfad*.

Das Optimierungsproblem (9.12) hat die äquivalente Darstellung

$$\begin{aligned} \hat{\beta}_\lambda^L &= \arg \min_{\beta} \text{RSS}(\beta) + \lambda (\|\beta\|_1 - t) \\ &= \arg \min_{\|\beta\|_1 \leq t} \text{RSS}(\beta), \end{aligned} \quad (9.15)$$

welche über den [Lagrange-Ansatz](#) unter der Nebenbedingung $\|\beta\|_1 \leq t$ gelöst werden kann.

Ähnlich wie der KQ-Schätzer ist der Lasso-Schätzer $\hat{\beta}_\lambda^L$ durch Bedingungen 1. Ordnung bestimmt. Diese Bedingungen lassen sich komfortabel in Matrix-Schreibweise darstellen als

$$-2\mathbf{X}'_j(\mathbf{Y} - \mathbf{X}\beta) + \lambda \cdot \text{sgn}(\beta_j) = 0, \quad j = 1, \dots, k. \quad (9.16)$$

Aus Gleichung (9.16) folgt, dass der Lasso-Schätzer aufgrund des Strafterms im Allgemeinen nicht algebraisch bestimmt werden kann.¹¹

¹¹Zur Bestimmung des Schätzers werden Algorithmen der nicht-linearen Optimierung genutzt.

In Abhängigkeit von λ zwingt der Lasso-Schätzer die KQ-Schätzung von β_j zu einem (absolut) kleineren Wert: Ähnlich wie bei Ridge Regression bewirkt der ℓ_1 -Strafterm eine mit λ zunehmende Schrumpfung der geschätzten Koeffizienten in Richtung 0. Charakteristisch für die Lösung des Lasso-Schätzers ist, dass $\hat{\beta}_j^L = 0$, wenn die Bedingung

$$\left| \mathbf{X}'_j(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}_\lambda^L) \right| - \lambda/2 \leq 0 \quad (9.17)$$

erfüllt ist. In Abhängigkeit von λ kann der Lasso-Schätzer folglich geschätzte Regressionskoeffizienten nicht nur in Richtung 0, sondern diese auch *exakt* mit 0 schätzen und damit *Variablenelektion* betreiben. Aufgrund der mit λ zunehmenden Shrinkage bis die Bedingung (9.17) erfüllt und der Koeffizient gleich 0 gesetzt wird, bezeichnet man Lasso auch als einen *Soft Thresholding Operator*. Im nächsten Abschnitt betrachten wir die Eigenschaften von Lasso-Regularisierung unter vereinfachten Annahmen bzgl. der Regressoren.

9.2.1 Lasso ist Soft Thresholding

Wir betrachten nun eine mathematische Darstellung von Selektions- und Shrinkage-Eigenschaft des Lasso-Schätzers in einem vereinfachten Modell. Wenn die Regressoren \mathbf{X} orthonormal zueinander sind, existiert eine analytische Lösung des Lasso-Schätzers,

$$\hat{\boldsymbol{\beta}}_\lambda^L = \begin{cases} \hat{\beta}_j - \lambda/2 & , \hat{\beta}_j > \lambda/2 \\ 0 & , |\hat{\beta}_j| \leq \lambda/2 \\ \hat{\beta}_j + \lambda/2 & , \hat{\beta}_j < \lambda/2 \end{cases} \quad (9.18)$$

wobei $\hat{\beta}_j$ der KQ-Schätzer von β_j ist. Anhand von (9.18) können wir die Selektionseigenschaft sowie die Schrumpfung der KQ-Koeffizientenschätzung in Abhängigkeit der durch λ regulierten ℓ_1 -Strafe erkennen. Für eine Visualisierung implementieren wir (9.18) als R-Funktion `lasso_st()` und zeichnen die resultierenden Koeffizientenschätzungen für die Parameterwerte $\lambda \in \{0, 0.2, 0.4\}$.

Wir definieren zunächst die Funktion `lasso_st()`.

```
library(tidyverse)

# Funktion für Lasso soft-thresholding definieren
lasso_st <- function(KQ, lambda) {
  case_when(
    # ...
```

```

    KQ > lambda/2      ~ KQ - lambda/2,
abs(KQ) <= lambda/2 ~ 0,
KQ < -lambda/2      ~ KQ + lambda/2,
)
}

```

Im nächsten Schritt zeichnen wir `lasso_st()` für eine Sequenz von KQ-Schätzwerten gegeben λ .

```

# Sequenz von KQ-Schätzwerten für Illustration definieren
dat <- tibble(
  KQ = seq(-1, 1, .01)
)

# Lasso-Schätzer als Funktion des KQ-Schätzers plotten
ggplot(dat) +
  geom_function(
    fun = lasso_st,
    args = list(lambda = 0),
    lty = 2
  ) +
  geom_function(
    fun = lasso_st,
    args = list(lambda = .2),
    col = "red"
  ) +
  geom_function(
    fun = lasso_st,
    args = list(lambda = .4),
    col = "blue"
  ) +
  xlim(-.4, .4) +
  xlab("KQ-Schätzer von beta_1") +
  ylab("Lasso-Schätzer von beta_1")

```

Abbildung 9.6 zeigt, dass der ℓ_1 -Strafterm des Lasso-Schätzers zu einem linearen Verlauf der auf den KQ-Schätzer (gezeichnet für $\lambda = 0$, gestrichelte Linie) applizierten Shrinkage führt: Der Lasso-Schätzer ist eine abschnittsweise-lineare Funktion des KQ-Schätzers in λ : Je größer der Parameter λ , desto größer ist

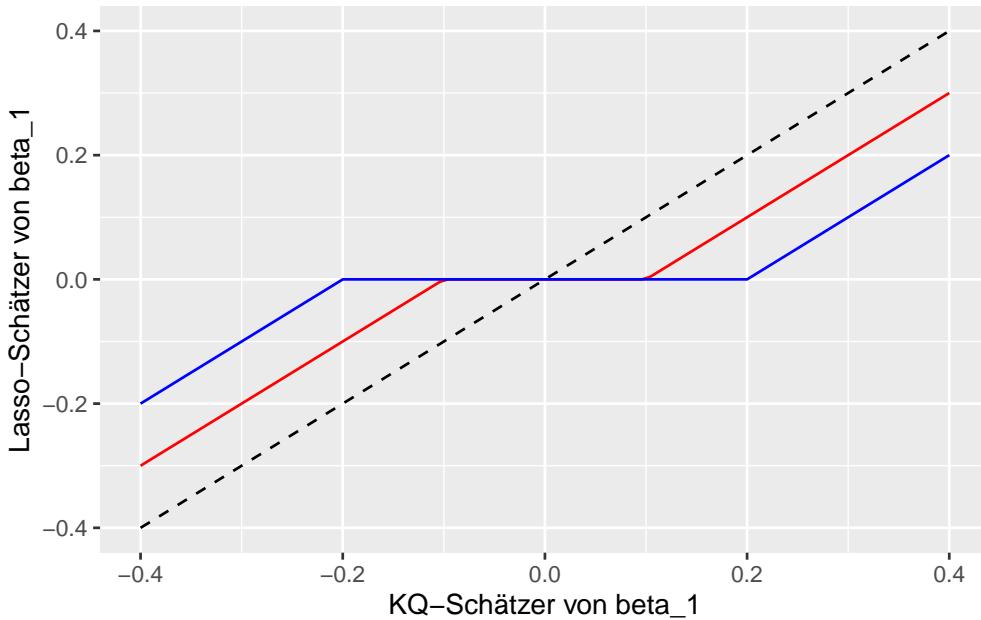


Abbildung 9.6: Shrinkage und Selektion von OLS-Koeffizienten mit Lasso

das Intervall von KQ-Schätzwerten $[-\lambda/2, \lambda/2]$, wo der Lasso-Schätzer zu Variablenelektion führt, d.h. hier den Koeffizienten β_j als 0 schätzt (rote bzw. blaue Linie).

Anhand von Abbildung 9.6 kann abgeleitet werden, dass der Lasso-Schätzer nicht invariant gegenüber der Skalierung der Regressoren ist: Die Stärke der Regularisierung durch λ ist hängt von der Magnitude des KQ-Schätzers ab. Daher müssen die Regressoren vor Berechnung der Schätzung standardisiert werden. Üblich ist hierbei eine Normierung auf einen Mittelwert von 0 und eine Varianz von 1.

Die nachstehende interaktive Grafik illustriert das Lasso-Optimierungsproblem (9.15) sowie den resultierenden Schätzer der Koeffizienten (β_1, β_2) in einem multiplen Regressionsmodell mit korrelierten Regressoren X_1 und X_2 .

- Die blaue Ellipse ist die Menge aller Schätzpunkte $(\hat{\beta}_1, \hat{\beta}_2)$ für den angegebenen Wert von RSS. Im Zentrum der Ellipse liegt der KQ-Schätzer, welcher RSS minimiert.
- Das graue Quadrat ist die Menge aller Koeffizienten-Paare (β_1, β_2) , welche die Restriktion $|\beta_1| + |\beta_2| \leq t$ erfüllen. Beachte, dass die Größe dieser Region nur durch den Parameter t bestimmt wird.
- Der blaue Punkt ist der Lasso-Schätzer $(\hat{\beta}_{1,t}^L, \hat{\beta}_{2,t}^L)$. Dieser ergibt sich als Schnittpunkt zwischen der blauen RSS-Ellipse und der Restriktionsregion und variiert mit t . Die gestrichelte rote Linie zeigt den Lasso-Lösungspfad.

- Für kleine Werte, erhalten wir starke Shrinkage auf $\hat{\beta}_{1,t}$ bis zum Wertebereich $t \leq 50$, wo $\hat{\beta}_{1,t}^L = 0$. Hier erfolgt Variablenelektion: Die Regularisierung führt zu einem geschätzten Modell, das lediglich X_2 als erklärende Variable enthält. In diesem Bereich von t bewirkt die Shrinkage, dass $\hat{\beta}_{2,t}^L \rightarrow 0$ für $t \rightarrow 0$.
-

Diese Interaktive Komponente des Buchs ist nur in der Online-Version verfügbar.

Beachte, dass der rote Lasso-Pfad (die Menge aller Lasso-Lösungen) äquivalent als Funktion von λ im Optimierungsproblem (9.12) dargestellt werden kann. Implementierungen mit statistischer Software berechnen die Lasso-Lösung häufig in Abhängigkeit von λ . Ein Algorithmus hierfür ist LARS.

9.2.2 Berechnung der Lasso-Lösung mit dem LARS-Algorithmus

Für die Berechnung des Lasso-Lösungspfads kann der [LARS-Algorithmus](#) von Efron u. a. (2004) im Lasso-Modus genutzt werden.¹² Der Lasso-Lösungspfad beinhaltet geschätzte Koeffizienten über ein Intervall für λ , welches sämtliche Modellkomplexitäten zwischen der (trivialen) Lösung mit maximaler Shrinkage auf allen Koeffizienten (λ groß, alle gesch. Koeffizienten sind 0) und der unregularisierten Lösung ($\lambda = 0$, KQ-Schätzung) abbildet. Der LARS-Algorithmus erzeugt den Lösungspfad sequentiell, sodass die Schätzung als Funktion von λ veranschaulicht werden kann, ähnlich wie bei Ridge Regression.

Wir zeigen nun anhand simulierter Daten, wie Lasso-Lösungen mit dem R-Paket `lars` berechnet werden können. Hierfür erzeugen wir Daten gemäß der Vorschrift

$$Y_i = \mathbf{X}'_i \boldsymbol{\beta}_v + u_i$$

$$\boldsymbol{\beta}_v = (-1.25, -0.75, 0, 0, 0, 0, 0, 0.75, 1.25)' \quad (9.19)$$

$$\mathbf{X}_i \sim N(\mathbf{0}, \mathbf{I}_{9 \times 9}), \quad u_i \stackrel{u.i.v.}{\sim} N(0, 1), \quad i = 1, \dots, 25.$$

¹²LARS steht für *Least Angle Regression*.

```

library(lars)
set.seed(1234)

# Parameter definieren
N <- 25
beta_v <- c(-1.25, -.75, 0, 0, 0, 0, 0, .75, 1.25)

# Beobachtungen simulieren
X <- matrix(rnorm(N * 9), ncol = 9)
Y <- X %*% beta_v + rnorm(N)

```

Entsprechend des DGP passen wir ein Modell ohne Konstante an. Damit `lars::lars()` den Lösungspfad des Lasso-Schätzers berechnet, muss `type = "lasso"` gewählt werden.¹³

```

# Lösungen des Lasso-Schätzers mit LARS berechnen
(
  fit_lars <- lars(
    x = X,
    y = Y,
    intercept = F,
    type = "lasso" # Wichtig: Lasso-Modus
  )
)

```

Call:

`lars(x = X, y = Y, type = "lasso", intercept = F)`

R-squared: 0.858

Sequence of LASSO moves:

```

Var 9 2 8 1 3 5 4 7 6
Step 1 2 3 4 5 6 7 8 9

```

Die Zusammenfassung zeigt, dass der LARS-Algorithmus als erstes die (relevante) Variable X_9 aktiviert.¹⁴ Mit abnehmender Regularisierung (kleinere λ) werden in den nächsten 3 Schritten die übrigen relevanten Variablen X_2 ,

¹³`lars()` standardisiert die Regressoren standardmäßig (aufgrund des DGPs hier nicht nötig).

¹⁴Aktivierung meint die Aufnahme einer Variable in der Modell gegeben eines hinreichend kleinen λ .

X_8 und X_1 aktiviert. Über die weiteren Schritte nähert der Algorithmus die Lösung an die *saturierte* Schätzung (das Modell mit allen neun Regressoren) an und aktiviert schrittweise die übrigen, irrelevanten Variablen.

Wir visualisieren die geschätzten Koeffizienten an jedem Schritt des Lösungspfads als Funktion von λ . In der Praxis wird der Regularisierungsparameter häufig auf der natürlichen log-Skala dargestellt.

```
# Transformation in ein weites Format
fit_lars$beta %>%
  as_tibble() %>%
  mutate(
    lambda = c(fit_lars$lambda, 1e-2)
  ) %>%
  pivot_longer(
    cols = 1:9,
    names_to = "Variable",
    values_to = "gesch. Koeffizient"
  ) %>%

# Visualisierung mit ggplot
ggplot(
  mapping = aes(
    x = log(lambda),
    y = `gesch. Koeffizient`,
    color = Variable
  )
) +
  geom_line()
```

Abbildung 9.7 zeigt, dass die Shrinkage der geschätzten Koeffizienten nach der Aktivierung rasch abnimmt und sich für kleine Werte von λ der KQ-Lösung annähert. Wir sehen auch, dass es einen Bereich von λ -Werten gibt, für die das wahre Modell mit den Variablen X_1 , X_2 , X_8 und X_9 selektiert werden kann. Je nach Ziel der Analyse kann es sinnvoll sein, ein λ in diesem Intervall zu schätzen.

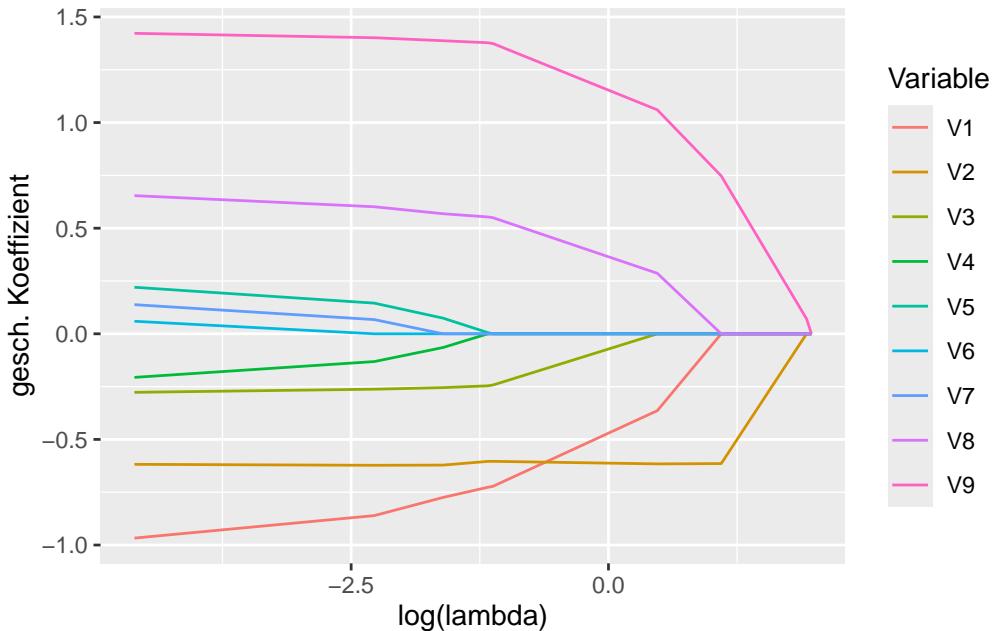


Abbildung 9.7: LARS-Lösungspfad für Lasso-Schätzung

9.2.3 Wahl des Regularisierungsparameters λ für den Lasso-Schätzer

Wie zuvor bei Ridge Regression muss in empirischen Anwendungen ein Wert für den Tuning-Parameter λ gewählt werden. Hierbei besteht die Herausforderung darin, einen geeigneten Wert zu finden, der zu wünschenswerten Eigenschaften des resultierenden Modells führt. So ist für gute Vorhersagen wichtig, dass das Modell nicht zu sehr an die Daten angepasst ist (*Overfitting*), um eine gute Generalisierung auf neue Daten zu ermöglichen. Gleichzeitig muss das Modell flexibel genug sein, um wesentliche Eigenschaften des datenerzeugenden Prozesses hinreichend gut zu erfassen. In der Regel wird hierbei eine sparsame Modellierung angestrebt, die nur eine Teilmenge der Prädiktoren nutzt.

In der Praxis werden verschiedene Verfahren verwendet, um den Wert für den Tuning-Parameter λ zu bestimmen. Gängige Methoden sind *Cross Validation* (CV) und Informationskriterien. In Abhängigkeit der Methode und der Daten ergeben sich ober- oder unterparameterisierte Modelle. Aufgrund der Implementierung im R-Paket `lars` betrachten wir CV.¹⁵ Wir zeigen nachfolgend anhand der simulierten Daten aus dem letzten Abschnitt, wie für die LARS-Schätzung ein optimales λ mit leave-one-out CV (LOO-CV) bestimmt werden kann. Hierzu nutzen wir `lars::cv.lars()` unter Verwendung derselben Argumente wie zuvor im Aufruf von `lars()`.

¹⁵ Chetverikov, Liao, and Chernozhukov (2020) zeigen, dass CV zu konsistenter Modellselektion führen kann.

```
# LARS-Lösungen mit CV evaluieren
fit_lars_cv <- cv.lars(
  x = X,
  y = Y,
  intercept = F,
  normalize = T,
  type = "lasso",
  plot.it = F,
  K = N # für LOO-CV
)
```

Das Objekt `fit_lars_cv` ist eine Liste mit den CV-Ergebnissen. Wir können diese einfach mit `ggplot` visualisieren. `index` ist hierbei das Verhältnis der ℓ_1 -Norm des Lasso-Schätzers für einen spezifischen Wert von λ und der ℓ_1 -Norm des KQ-Schätzers. Das optimale λ wird so implizit geschätzt. `cv.error` ist der mit CV geschätzte MSE.

```
# CV-MSE
fit_lars_cv %>%
  as_tibble() %>%
  ggplot(
    mapping = aes(
      x = index,
      y = cv.error
    )
  ) +
  geom_line() +
  xlab("|beta_lambda| / |beta|") +
  ylab("CV-MSE")
```

In der Grafik erkennen wir ein Minimum des CV-MSEs bei etwa 0.73.

```
# CV-MSE-minimierendes Lambda bestimmen
ID <- which.min(fit_lars_cv$cv.error) # Index

(
  fraction_opt <- fit_lars_cv$index[ID]
)
```

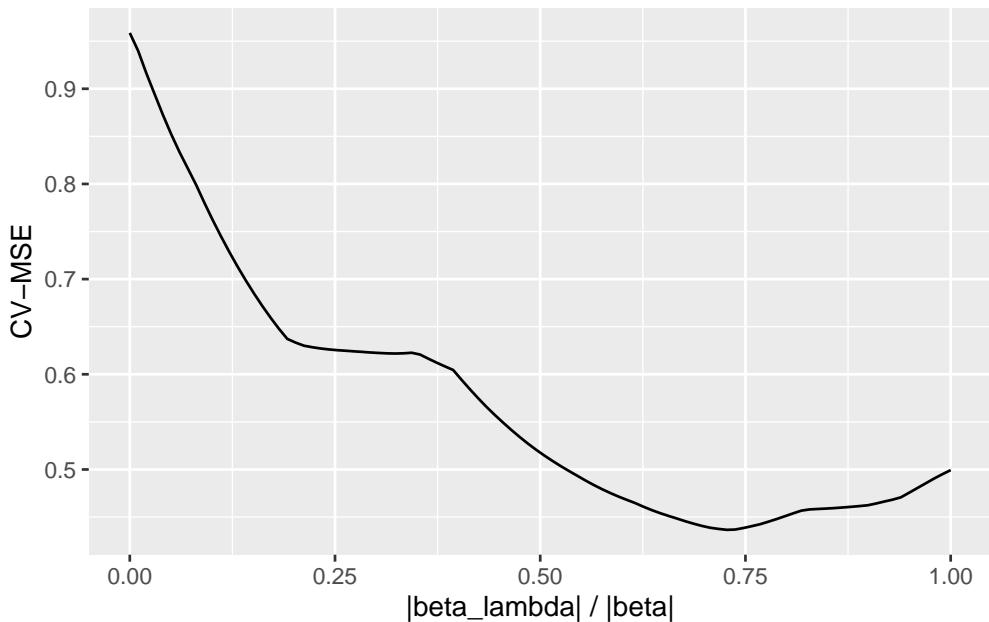


Abbildung 9.8: CV-MSE und relative Position von λ auf dem Lassopfad

```
[1] 0.7272727
```

Die geschätzten Koeffizienten für die optimale Regularisierung können mit `coef()` ausgelesen werden.

```
# LARS-Lasso-Fit für optimales lambda bestimmen
coef(
  object = fit_lars,
  s = fraction_opt,
  mode = "fraction"
)
```

```
[1] -0.6513191 -0.6060906 -0.1946089  0.0000000  0.0000000
0.0000000  0.0000000
[8]  0.4977908  1.3122407
```

Das Ergebnis veranschaulicht die Selektionseigenschaft von Lasso: Gemäß DGP (9.19) sind die Variablen X_3 bis X_7 *irrelevante* Prädiktoren für Y ; ihre wahren Koeffizienten sind 0. In der kreuzvalidierten Lasso-Schätzung erreicht die Regularisierung, dass die Koeffizienten der Variablen X_4 bis X_7 tatsächlich mit 0 geschätzt werden. Wir schätzen für das mit CV bestimmte λ also ein leicht überspezifiziertes Modell mit den Regressoren X_1 , X_2 , X_3 , X_8 und X_9 . Beachte, dass die Lasso-Schätzung einen Kompromiss impliziert: Die Varianz der Schätzung ist geringer als die des KQ-Schätzers im Modell mit allen

Variablen.¹⁶ Aufgrund der Regularisierung sind die mit Lasso geschätzten Koeffizienten der relevanten Variablen jedoch in Richtung 0 verzerrt.

Einen positiven Effekt dieses Kompromisses beobachten wir anhand des mittleren Vorhersagefehlers für Daten, die *nicht* zur Berechnung des Schätzers verwendet wurden. Wir vergleichen den Vorhersagefehler nachfolgend anhand eines solchen simulierten Test-Datensatzes mit 25 neuen Beobachtungen. Den Vorhersagefehler bestimmen wir als MSE zwischen den vorhergesagten und den tatsächlichen Ausprägungen für Y .

```
# Test-Datensatz erstellen
set.seed(4321)
new_X <- matrix(rnorm(N * 9), ncol = 9)
new_Y <- new_X %*% beta_v + rnorm(N)

# Lasso: Vorhersage von new_Y für Test-Datensatz
Y_predict_lars <- predict(
  object = fit_lars,
  s = fraction_opt,
  type = "fit",
  mode = "fraction",
  newx = new_X
)$fit

# Lasso: MSE für Test-Datensatz berechnen
mean((Y_predict_lars - new_Y)^2)
```

[1] 1.419817

Wir schätzen nun das große Modell mit allen 9 Variablen mit KQ und berechnen ebenfalls den MSE der Prognosen für den Test-Datensatz.

```
# KQ-Schätzung des großen Modells durchführen
KQ_fit <- lm(Y ~ X - 1)

# Test-Datensatz für predict.lm() formatieren
new_X <- as.data.frame(new_X)
colnames(new_X) <- paste0("X", 1:9)
```

¹⁶Wegen $N = 25$ verbleiben bei der KQ-Schätzung mit 9 Regressoren nur 16 Freiheitsgrade.

```

# KQ: Vorhersage von new_Y für Test-Datensatz
Y_predict_KQ <- predict(
  object = KQ_fit,
  newdata = new_X
)

# KQ: MSE für Test-Datensatz berechnen
mean((Y_predict_KQ - new_Y)^2)

```

[1] 9.851932

Offenbar führt die Lasso-Schätzung zu einem deutlich geringeren MSE der Vorhersage von \mathbf{Y} für den Test-Datensatz als die KQ-Schätzung und damit zu einer höheren Vorhersagegüte. Das “sparsame” mit Lasso-Regression geschätzte Modell ist dem “großen” mit KQ geschätztem Modell in dieser Hinsicht also überlegen.

i Key Facts zu Lasso-Regression

- Lasso-Regression bestraft die Verlustfunktion des KQ-Schätzers mit der ℓ_1 -Norm der Koeffizienten.
- Neben Koeffizientenschätzung mit Shrinkage in Richtung 0 kann der Lasso-Schätzer Variablenelektion durchführen: Regressionskoeffizienten können exakt mit 0 geschätzt und so ein “sparsames”, leichter zu interpretierendes Modell gewählt werden.
- Wie bei Ridge Regression impliziert die Wahl von λ einen Bias-Variance-Tradeoff, der für Vorhersagen nützlich ist: Für größere λ wird mehr Verzerrung induziert und möglicherweise relevante Variablen mit kleinen Koeffizienten aus dem Modell entfernt. Ein solches sparsames Modell kann eine höhere Prognosegüte haben als ein komplexes, unregularisiertes Modell.
- Der Lasso-Schätzer $\hat{\beta}_\lambda^L$ ist *nicht* erwartungstreu.
- Lasso Regression kann bspw. mit dem LARS-Algorithmus (Paket **lars**) oder mit **glmnet** berechnet werden.

9.3 Vergleich von Lasso- und Ridge-Regression mit Simulation

In diesem Kapitel illustrieren wir Vor- und Nachteile von Lasso- und Ridge-Regression in Prognose-Anwendungen anhand von Monte-Carlo-Simulationen. Wir betrachten hierbei datenerzeugende Prozesse, die sich hinsichtlich der Anzahl relevanter Variablen sowie der Korrelation dieser Variablen unterscheiden.

Die grundlegende Vorschrift für die Simulationen ist

$$Y_i = \sum_{j=1}^{k=40} \beta_j X_{i,j} + u_i, \quad u_i \stackrel{u.i.v.}{\sim} N(0, 1), \quad i = 1, \dots, 100,$$

wobei die Regressoren X_j eine Varianz von 1 haben und aus einer multivariaten Normalverteilung mit Korrelation

$$\rho \in (0, 0.5, 0.8)$$

gezogen werden.

Für die Koeffizienten β unterscheiden wir zwei Szenarien. In Szenario A ist

$$\beta = (1, \dots, 1)',$$

d.h. alle Variablen sind relevant und haben denselben Einfluss auf Y . In Szenario B erzeugen wir β einmalig vorab so, dass

$$\beta_j = \begin{cases} 1, & \text{mit Wsk. } p \\ 0, & \text{mit Wsk. } 1 - p, \end{cases}$$

d.h. nur eine Teilmenge der Variablen beeinflusst Y jeweils mit demselben Effekt $\beta_j = 1$. Die übrigen Variablen sind irrelevant.

Wir schätzen und validieren die Modelle mit `glmnet()`.

9.3.1 Prognosegüte in diversen Szenarien

```
# Simulationsparameter definieren
rho <- c(0, 0.5, 0.8)    # Korrelation
k <- 40                   # Anz. Regressoren
```

```
N <- 100                      # Anz. Beobachtungen
n_sim <- 100                   # Anz. Simulationen
```

Damit der Code für die Simulation möglichst wenig repetitiv ist, definieren wir eine Funktion `cv.glmnet_MSE()`, die unter Angabe der Daten `X` und `Y`, des Trainingssets `train` sowie des Parameters `alpha` den gewünschten regularisierten Schätzer unter Verwendung von Cross Validation anpasst und den Testset-MSE zurückgibt.

```
# allg. Funktion für Testset-MSE nach CV
cv.glmnet_MSE <- function(X, Y, train, alpha) {

  # Modell mit glmnet schätzen; lambda per CV bestimmen
  fit_cv <- cv.glmnet(
    x = X[train,],
    y = Y[train],
    alpha = alpha
  )

  # Vorhersagen treffen
  Y_pred <- predict(
    object = fit_cv,
    s = fit_cv$lambda.min,
    newx = X[-train,])

  return(
    # Testset-MSE berechnen
    mean(
      (Y[-train] - Y_pred)^2
    )
  )
}
```

Wir initialisieren zunächst Matrizen, in welche die MSEs aus den 100 Simulationsdurchläufen reihenweise geschrieben werden. `lasso_mse` und `ridge_mse` haben je eine Spalte für jede Korrelation in `rho`

```

# Matrizen für simulierte MSEs initialisieren...
lasso_mse <- matrix(
  data = NA,
  nrow = n_sim,
  ncol = length(rho)
)
ridge_mse <- lasso_mse

# ... und benennen
colnames(lasso_mse) <- paste0("Kor=", rho)
colnames(ridge_mse) <- colnames(lasso_mse)

```

Für die Simulation iterieren wir mit `purrr::walk` über den Vektor `rho` sowie über die Laufvariable `1:n_sim`. Beide Schleifen nutzen den Syntax für anonyme Funktionen:

```

# Die anonyme Funktion
function(x) return(x)

# ist äquivalent definiert als
\_(x) return(x)

```

In jeden Simulationsdurchlauf erzeugen wir den Datensatz entsprechend der obigen Vorschrift, teilen die Daten auf und berechnen MSEs für Lasso- und Ridge-Regression mit `cv.glmnet_MSE()`.

Szenario A

```

# Koeffizienten-Vektor definieren
beta <- rep(1, k)

```

```

library(mvtnorm)
library(tidyverse)

set.seed(1234)

# Simulation durchführen
walk(1:length(rho), \_(j) {

```

```

# Korrelationsmatrix definieren
Sigma <- matrix(
  data = rho[j],
  nrow = k,
  ncol = k
)
diag(Sigma) <- 1

walk(1:n_sim, \(i) {

  # Daten simulieren
  X <- rmvnorm(
    n = N,
    mean = rep(0, k),
    sigma = Sigma
  )
  Y <- X %*% beta + rnorm(N)

  # Trainingsdaten definieren
  ID_train <- sample(
    x = c(1:N),
    size = N/2
  )

  # Modelle mit CV schätzen und MSEs berechnen
  # Ridge-Regression
  ridge_mse[i, j] <- cv.glmnet_MSE(
    X = X,
    Y = Y,
    train = ID_train,
    alpha = 0
  )

  # Lasso-Regression
  lasso_mse[i, j] <- cv.glmnet_MSE(
    X = X,
    Y = Y,
    train = ID_train,
    alpha = 1
}

```

```

    )
}

}

```

Beachte, dass hier der Super-Assignment-Operator `<->` genutzt wird, damit `walk` die Matrizen `ridge_mse` und `lasso_mse` in der globalen Umgebung überschreibt.¹⁷

Wir berechnen jeweils den mittleren MSEs, sammeln die Ergebnisse in einer `tibble()` und nutzen `gt()` für die tabellarische Darstellung.

```

library(gt)

# Ergebnisse tabellarisch darstellen
tibble(
  Methode = c(
    "Lasso-Regression",
    "Ridge-Regression"
  ),
) %>%
  bind_cols(
    bind_rows(
      colMeans(lasso_mse),
      colMeans(ridge_mse)
    )
  ) %>%
  gt() %>%
  tabopts

```

Tabelle 9.1: Durchschnittliche Testset-MSEs für Setting A

Methode	Kor=0	Kor=0.5	Kor=0.8
Lasso-Regression	7.17	10.398	7.581
Ridge-Regression	4.841	1.615	1.517

¹⁷Dies folgt aus der Definition von `walk`. `<->` bewirkt hier lediglich Assignment in der Funktionsumgebung.

Tabelle 9.1 zeigt, dass Ridge-Regression gegenüber Lasso-Regression für jede der drei betrachteten Korrelationen überlegen ist. Insbesondere bei stärker korrelierten Regressoren ist Ridge vorteilhaft.

Für Szenario B überschreiben wir **beta** nach Multiplikation mit einem zufälligen binären Vektor, sodass einige der Koeffizienten 0 und die zugehörigen Variablen irrelevant für Y sind.

Szenario B

```
# Wsk. für Relevanz einer Variable
p <- .3

# Koeffizienten-Vektor definieren
set.seed(123)
beta <- beta * sample(
  x = 0:1,
  size = k,
  replace = T,
  prob = c(1-p, p)
)

# Koeffizienten prüfen
head(beta, n = 10)
```

[1] 0 1 0 1 1 0 0 1 0 0

Eine wiederholung der Simulation für die modifizierten Koeffizienten **beta** und liefert folgende tabellarische Auswertung.

Tabelle 9.2: Durchschnittliche Testset-MSEs für Szenario B

Methode	Kor=0	Kor=0.5	Kor=0.8
Lasso	2.51	2.143	1.923
Ridge	3.331	2.562	2.014

Die Ergebnisse in Tabelle 9.2 zeigen, dass Ridge-Regression in Szenario B bis auf den Fall unkorrelierter Regressoren etwas schlechter abschneidet als in Szenario A. Die hohe Anzahl irrelevanter Variablen verbessert die Leistung von Lasso deutlich: Hier ist es plausibel, dass Lasso aufgrund der Thresholding-Eigenschaft die Koeffizienten einiger irrelevanten Variablen häufig exakt 0 setzt und damit ein sparsameres Modell schätzt als Ridge. Entsprechend erzielt

Lasso in diesem Szenario insbesondere für $\rho = 0$ genauere Vorhersagen als Ridge Regression.

9.3.2 Visualisierung des Bias-Variance-Tradeoffs bei Prognosen

Für ein besseres Verständnis, wie sich der Regularisierungsparameter λ auf den Bias-Variance-Tradeoff bei Prognosen mit Ridge- und Lasso-Regression auswirkt, vergleichen wir für beide Methoden nachfolgend die Abhängigkeit des MSEs der Prognose \hat{Y}_0 für den Wert Y_0 der abhängigen Variable eines Datenpunkts anhand seiner Regressoren \mathbf{X}'_0 , wobei

$$\text{MSE}(\hat{Y}_0) = \text{Bias}(\hat{Y}_0)^2 + \text{Var}(\hat{Y}_0) + \text{Var}(Y_0) \quad (9.20)$$

Beachte, dass $\text{Var}(Y_0)$ die durch den datenerzeugenden Prozess (und damit unvermeidbare) Varianz von Y_0 ist, wohingegen $\text{Bias}(\hat{Y}_0)^2$ und $\text{Var}(\hat{Y}_0)$ von dem verwendeten Schätzer für \hat{Y}_0 abhängt.

Für die Simulation betrachten wir erneut Szenario A aus Kapitel 9.3.1 mit 50 Beobachtungen für ein Modell mit 40 unkorrelierten Regressoren. Wir legen zunächst die Simulationsparameter fest und erzeugen den vorherzusagenden Datenpunkt (\mathbf{x}_0 , y_0).

```
# Parameter festlegen
set.seed(1234)
n <- 200 # Anz. Iterationen
N <- 50 # Anz. Beobachtungen
k <- 40 # Anz. Variablen

# Korrelationsmatrix definieren
Sigma <- diag(k) # Diagonalmatrix
beta <- rep(x = 1, k)

# Prognose-Ziel vorab zufällig generieren:

# Regressoren
X_0 <- rmvnorm(
  n = 1,
  mean = rep(x = 0, k)
)
```

```
# Abh. Variable
Y_0 <- X_0 %*% beta + rnorm(n = 1) %>%
  as.vector()
```

Anhand der Simulationsergebnisse wollen wir die von der verwendeten Schätzfunktion abhängigen Komponenten von (9.20) untersuchen. Wir initialisieren hierzu die Listen `ridge_fits` und `lasso_fits`, in die unsere Simulationsergebnisse geschrieben werden.

```
# Listen für Simulationsergebnisse initialisieren
ridge_fits <- list()
lasso_fits <- list()
```

Weiterhin definieren wir separate λ -Sequenzen für Lasso- und Ridge-Schätzer.¹⁸

```
# Lambda-Sequenzen festlegen
lambdas_r <- seq(.25, 2.5, length.out = 100)
lambdas_l <- seq(.05, 0.5, length.out = 100)
```

Für die Simulation iterieren wir mit `walk()` über simulierte Datensätze und schreiben jeweils den vollständigen Output von `glmnet()` in die zuvor definierten Listen `ridge_fits` und `lasso_fits`.

```
# Simulation
walk(1:n, \(i) {

  # Daten simulieren
  X <- rmvnorm(
    n = N,
    mean = rep(0, k),
    sigma = Sigma
  )
  Y <- X %*% beta + rnorm(n = N, sd = 5)

  # Modelle mit glmnet schätzen
}
```

¹⁸Die Sequenzen haben wir in Abhängigkeit des DGP so gewählt, dass die Abhängigkeit der Prognosegüte von λ gut visualisiert werden kann.

```

# Ridge-Regression
ridge_fits[[i]] <- glmnet(
  x = X,
  y = Y,
  alpha = 0,
  intercept = F
)
# Lasso-Regression
lasso_fits[[i]] <- glmnet(
  x = X,
  y = Y,
  alpha = 1,
  intercept = F
)
}

})

```

Wir nutzen Funktionen aus `purrr` und `dplyr`, um über die in den Simulationsdurchläufen angepassten Modelle zu iterieren. Mit `predict()` erhalten wir Punktvorhersagen für Y_0 für jedes λ der zuvor definierten λ -Sequenzen. Beachte, dass `map()` jeweils eine Liste mit 200 Punktvorhersagen für jedes der 100 zurückgibt. Mit `list_rbind()` können wir die Ergebnisse komfortabel jeweils in einer `tibble` sammeln.

```

# Prognosen für Ridge-Regression
pred_r <- map(
  .x = ridge_fits,
  .f = ~ as_tibble(
    predict(
      object = .,
      s = lambdas_r,
      newx = X_0
    )
  )
) %>%
  list_rbind()

# Prognosen für Lasso-Regression
pred_l <- map(

```

```

.x = lasso_fits,
.f = ~ as_tibble(
  predict(
    object = .,
    s = lambdas_l,
    newx = X_0)
  )
) %>%
  list_rbind()

```

Für die statistische Auswertung berechnen wir jeweils $MSE(\hat{Y}_0)$, $Bias(\hat{Y}_0)^2$ und $Var(\hat{Y}_0)$ und führen die Ergebnisse mit `pivot_longer()` in ein langes Format `sim_data_r` über. Wir berechnen weiterhin mit `MSE_min_r` das λ , für das wir über die Simulationsdurchläufe durchschnittlich den geringsten MSE beobachteten.

Ridge-Regression

```

# Ergebnisse für Ridge-Regression zusammenfassen
sim_data_r <- tibble(

  lambda = lambdas_r,

  "MSE" = map_dbl(
    .x = pred_r,
    .f = ~ mean((.x - Y_0)^2)
  ),

  "Bias^2" = map_dbl(
    .x = pred_r,
    .f = ~ (mean(.x) - Y_0)^2
  ),

  "Varianz" = map_dbl(
    .x = pred_r,
    .f = ~ var(.x)
  )
) %>%
  pivot_longer(

```

```

    cols = -lambda,
    values_to = "Wert",
    names_to = "Statistik"
)

# Lambda bei MSE-Minimum bestimmen
MSE_min_r <- sim_data_r %>%
  filter(
    Statistik == "MSE",
    Wert == min(Wert)
)

```

Lasso-Regression

```

# Ergebnisse zusammenfassen
sim_data_l <- tibble(

  lambda = lambdas_l,

  "MSE" = map_dbl(
    .x = pred_l,
    .f = ~ mean((. - Y_0)^2)
  ),

  "Bias^2" = map_dbl(
    .x = pred_l,
    .f = ~ (mean(.) - Y_0)^2
  ),

  "Varianz" = map_dbl(
    .x = pred_l,
    .f = ~ var(.)
  )
) %>%
  pivot_longer(
    cols = -lambda,
    values_to = "Wert",
    names_to = "Statistik"
)

```

```
# Lambda bei MSE-Minimum bestimmen
MSE_min_l <- sim_data_l %>%
  filter(
    Statistik == "MSE",
    Wert == min(Wert)
  )
```

Die Datensätze im langen Format, `sim_data_r` und `sim_data_l`, werden nun für die Visualisierung der Ergebnisse mit `ggplot2` genutzt.

```
# MSE, Bias^2 und Varianz gegen Lambda plotten

# Ridge-Regression
sim_data_r %>%
  ggplot(
    mapping = aes(
      x = lambda,
      y = Wert,
      color = Statistik
    )
  ) +
  geom_line() +
  geom_point(data = MSE_min_r)

# Lasso-Regression
sim_data_l %>%
  ggplot(
    mapping = aes(
      x = lambda,
      y = Wert,
      color = Statistik
    )
  ) +
  geom_line() +
  geom_point(data = MSE_min_l)
```

Anhand von Abbildung 9.9 lässt sich der Bias-Variance-Tradeoff bei der Vorhersage von Y_0 gut erkennen: Bereits für kleine λ erzielen beide Methode

eine deutliche Reduktion des MSE. Dies wird durch etwas zusätzlichen Bias, aber eine überproportionale Verringerung der Varianz erreicht. Der erkennbare funktionale Zusammenhang zeigt, dass der MSE eine konvexe Funktion von λ ist. Damit existieren optimale λ mit minimalem MSE (grüne Punkte), die wir mit Cross Validation schätzen können.

9.4 Inferenz für Treatment-Effekt-Schätzung mit vielen Variablen

In empirischen Studien des Effekts einer Behandlungsvariable B auf eine Outcome-Variable Y steht häufig eine Vielzahl potentieller Kontrollvariablen zur Verfügung. Häufig ist unklar, welche Variablen in das Modell aufgenommen werden sollten, um das Risiko einer verzerrten Schätzung durch ausgelassene Variablen zu vermindern und gleichzeitig eine Schätzung mit geringer Varianz zu gewährleisten. Ist der Beobachtungsumfang N relativ zur Variablenanzahl k groß, so kann die KQ-Schätzung einer langen Regression (ein Modell mit allen k Kontrollvariablen) gute Ergebnisse liefern. In der Praxis liegt diese wünschenswerte Situation jedoch oft nicht vor und es ist $k \lesssim N$ oder sogar $k > N$. Dann ist eine KQ-Schätzung des Behandlungseffekts anhand aller k Variablen mit hoher Varianz behaftet bzw. gar nicht möglich.¹⁹ Ein weiteres Szenario ist $k(N) > N$, d.h. die Anzahl der Regressoren kann mit dem Beobachtungsumfang wachsen.²⁰ Lasso-Verfahren können dann hilfreich sein, um Determinanten von Y und B zu identifizieren und damit eine Menge an Kontrollvariablen zu selektieren, für die eine erwartungstreue und konsistente Schätzung des interessierenden Effekts wahrscheinlich ist.

Betrachte zunächst das Modell mit allen Kontrollvariablen X_j ,

$$Y_i = \beta_0 + \alpha_0 B_i + \sum_{j=1}^k \beta_j X_{i,j} + u_i, \quad (9.21)$$

wobei einige $\beta_j = 0$ sind und wir annehmen, dass B lediglich mit ein paar der X_j korreliert. Die Shrinkage der geschätzten Koeffizienten aus einer naiven Lasso-Regression von (9.21) führt grundsätzlich zu einer verzerrten Schätzung des Behandlungseffekts α_0 und damit zu ungültiger Inferenz.²¹

¹⁹Beachte, dass der KQ-Schätzer bei $k > N$ nicht lösbar ist.

²⁰Dieses Szenario wird unter Bedingungen bzgl. der Wachstumsrate und der Größe der Koeffizienten betrachtet, s. (Belloni und Chernozhukov 2013).

²¹Hahn u. a. (2018) geben eine ausführliche Erläuterung dieser Problematik.

Die Verzerrung von geschätzten Koeffizienten kann vermieden werden, indem Lasso lediglich zur Selektion von Kontrollvariablen verwendet wird. Dabei wird mit einer Lasso-Regression von Y auf die X_j eine Teilmenge von Regressoren \mathcal{S} selektiert und der Treatment-Effekt anschließend mit der KQ-Schätzung von

$$Y_i = \beta_0 + \alpha_0 B_i + \sum_{j \in \mathcal{S}} \beta_j X_{i,j} + e_i, \quad (9.22)$$

basierend auf der Selektion \mathcal{S} berechnet wird.²² Ein solcher *Post-Lasso-Selection-Schätzer* (Belloni und Chernozhukov 2013) ist jedoch im Allgemeinen und insbesondere in hoch-dimensionalen Settings nicht konsistent für α_0 und nicht asymptotisch normalverteilt, da weiterhin die Gefahr einer verzerrten Schätzung durch in \mathcal{S} ausgelassene Variablen besteht, die mit B korrelieren: Lasso selektiert Variablen X_j , die “gut” Y erklären. Dabei kann nicht ausgeschlossen werden, dass ein Modell gewählt wird, dass relevante Determinanten von B auslässt. Selbst wenn wir ein mit Lasso gewähltes Modell mit KQ (d.h. ohne Shrinkage) schätzen, würde α_0 verzerrt geschätzt!

Belloni, Chernozhukov, und Hansen (2014) schlagen ein alternatives Verfahren vor, dass auf Selektion der Determinanten X_j von Y und B basiert. Dieses Verfahren wird als *Post-Double Selection* bezeichnet und kann wie folgt implementiert werden:

Post-Double-Selection-Schätzer

1. Bestimme die Determinanten X_j von Y mit Lasso-Regression und bezeichne die Menge der selektierten Variablen als \mathcal{S}_Y .
2. Bestimme die Determinanten X_j von B mit Lasso-Regression und bezeichne die Menge der selektierten Variablen als \mathcal{S}_B .
3. Bestimme die Schnittmenge $\mathcal{S}_{YB} = \mathcal{S}_Y \cap \mathcal{S}_B$. Schätze den Treatment-Effekt als $\hat{\alpha}_0$ in der KQ-Regression

$$Y_i = \beta_0 + \alpha_0 B_i + \sum_{j \in \mathcal{S}_{YB}} \beta_j X_{i,j} + v_i. \quad (9.23)$$

Belloni, Chernozhukov, und Hansen (2014) zeigen, dass $\hat{\alpha}_0$ aus diesem Verfahren ein asymptotisch normalverteilter Schätzer für α_0 ist und herkömmliche t-Tests und Konfidenzintervalle gültige Inferenz erlauben.

Wir illustrieren die in diesem Abschnitt betrachteten Schätzer nun anhand simulierter Daten mit R. Die fiktive Problemstellung ist die Schätzung eines

²²Solche Verfahren werden *Post-Selection-Schätzer* genannt.

wahren Treatment-Effekts $\alpha_0 = 2$, wenn so viele potenzielle Kontrollvariablen vorliegen, dass der KQ-Schätzer gerade noch berechnet werden kann, aber aufgrund hoher Varianz unzuverlässig ist. Hierzu erzeugen wir Y gemäß der Vorschrift

$$Y_i = \alpha_0 B_i + \sum_{j=1}^{k_Y} \beta_j^Y X_{i,j}^Y + \sum_{l=1}^{k_{YB}} \beta_l^{YB} X_{i,l}^{YB} + u_i,$$

$$\beta_j^{YB} \stackrel{u.i.v}{\sim} N(10, 1), \quad \beta_l^Y \stackrel{u.i.v}{\sim} U(0, 1), \quad u_i \stackrel{u.i.v}{\sim} N(0, 1).$$

$$i = 1, \dots, 550$$

Die Behandlungsvariable B_i entspricht der Vorschrift

$$B_i = \sum_{l=1}^{k_{YB}} \beta_l^{YB} X_{i,l}^{YB} + e_i,$$

$$\beta_j^{YB} \stackrel{u.i.v}{\sim} N(2, 0.2), \quad e_i \stackrel{u.i.v}{\sim} N(0, 1).$$

Wir wählen $k_{YB} = k_Y = 25$. Zusätzlich zu B , den Determinanten von Y und B (X^{YB}) sowie den Variablen, die ausschließlich Y beeinflussen (X^Y) gibt es $k_U = 499$ Variablen X^U , die weder Y noch B beeinflussen und damit irrelevant für die Schätzung des Behandlungseffekts sind. Wir haben also $N = 550$ Beobachtungen und insgesamt $k = 1 + k_Y + k_{YB} + k_U = 550$ potenzielle Kontrollvariablen von denen $k_{YB} = 25$ für eine unverzerrte Schätzung von α_0 relevant sind.

Der nachstehende Code generiert die Daten gemäß der Vorschrift.

```
library(mvtnorm)
library(tidyverse)
set.seed(4321)

n <- 550      # Beobachtungen
p_Y <- 25     # Determinanten Y
p_B <- 25     # Determinanten B *und* Y
p_U <- 499    # irrelevante Variablen

# Variablen generieren
```

```

XB <- rmvnorm(n = n, sigma = diag(p_B))
XU <- rmvnorm(n = n, sigma = diag(p_U))
XY <- rmvnorm(n = n, sigma = diag(p_Y))

# Stetige Behandlungsvariable erzeugen
B <- XB %*% rnorm(p_B, 2, sd = .2) + rnorm(n)

# Abh. Variable erzeugen, Behandlungseffekt (ATE) ist 2
Y <- 2 * B +
  XB %*% rnorm(p_B, mean = 10) +
  XY %*% runif(p_Y) +
  rnorm(n)

# Variablen in tibble sammeln
X <- cbind(B, XB, XU, XY) %>%
  as_tibble()

# Namen zuweisen
colnames(X) <- c(
  "B",
  paste0("XB", 1:p_B),
  paste0("XU", 1:p_U),
  paste0("XY", 1:p_Y)
)

```

Wünschenswert wäre die KQ-Schätzung des wahren Modells. Diese ergibt eine Schätzung nahe des wahren Treatment-Effekts $\alpha_0 = 2$. Unter realen Bedingungen wäre diese Regression jedoch nicht implementierbar, weil die relevanten Kovariablen `XB` unbekannt sind.

```

# KQ: Wahres Modell schätzen
lm(Y ~ B + XB - 1)$coefficients["B"]

```

```

B
1.937031

```

Wir schätzen daher zunächst die “lange” Regression mit allen k verfügbaren Variablen mit KQ. Beachte, dass der KQ-Schätzer für α_0 zwar implementierbar und erwartungstreu ist, jedoch eine hohe Varianz aufweist. Wegen $k = N = 550$

erhalten wir eine perfekte Anpassung an die Daten und können mangels Freiheitsgraden keine Hypothesentests durchführen.

```
# KQ: Lange Regression schätzen  
lm(Y ~ . - 1, data = X)$coefficients["B"]
```

```
B  
3.079497
```

Die KQ-Schätzung von α_0 anhand der langen Regression weicht deutlich vom wahren Wert $\alpha_0 = 2$ ab.

Eine “kurze” KQ-Regression nur mit der Behandlungsvariable B führt wegen Korrelation mit den ausgelassenen Determinanten in XB zu einer deutlich verzerrten Schätzung.

```
# KQ: Kurze Regression  
lm(Y ~ B - 1)$coefficients["B"]
```

```
B  
6.716837
```

Die Methoden von Belloni und Chernozhukov (2013) und Belloni, Chernozhukov, und Hansen (2014) sind im R-Paket `hdm` implementiert. Mit den Funktionen `hrm::rlasso()` und `hdm::rlassoEffect` kann Lasso-Regression sowie Post- und Double-Post-Selection durchgeführt werden.²³

Wir berechnen zunächst den naiven Lasso-Schätzer in einem Modell mit allen Variablen.

```
library(hdm)  
  
# Naiver Post-Lasso-Schätzer  
lasso <- rlasso(  
  x = X,  
  y = Y,  
  intercept = F,  
  post = F  
)
```

²³Diese Funktionen ermitteln ein optimales λ mit dem in Belloni u. a. (2012) vorgeschlagenen Algorithmus.

```
# Koeffizientenschätzer auslesen  
lasso$coefficients["B"]
```

```
B  
6.368456
```

Auch dieser Schätzer ist deutlich verzerrt. Problematisch ist hier nicht nur die Shrinkage auf $\hat{\alpha}_0$, sondern die Selektion der Variablen in $\mathbf{X}\mathbf{B}$:

```
# Welche Variablen in XB selektiert Lasso *nicht*?  
nselektiert <- which(lasso$coef[1:26] == 0) # ID  
  
# Namen auslesen  
names(lasso$coef[1:26])[nselektiert]
```

```
[1] "XB8"  "XB10" "XB16" "XB18" "XB20"
```

Durch das Auslassen dieser Determinanten von Y und B leidet der Lasso-Schätzer unter OVB.

Als nächstes berechnen wir den Post-Lasso-Selection-Schätzer.

```
# Post-Lasso-Selection-Schätzer berechnen  
p_lasso <- rlasso(  
  x = X,  
  y = Y,  
  intercept = F,  
  post = T  
)  
  
# Schätzung für alpha_0  
p_lasso$coef["B"]
```

```
B  
6.362409
```

Die Ähnlichkeit der Post-Lasso-Schätzung von α_0 zur Lasso-Schätzung zeigt deutlich, dass die Verzerrung des Lasso-Schätzers überwiegend durch ausgelassene Variablen anstatt durch Shrinkage verursacht wird.

Mit `rlassoEffect()` können wir den Post-Double-Selection-Schätzer berechnen.

```
# Post-Double-Selection-Schätzer
pds_lasso <- rlassoEffect(
  x = X %>%
    dplyr::select(-B) %>%
    as.matrix(),
  y = Y,
  d = B,
  method = "double selection"
)

# Schnittmenge der selektierten Determinanten
# von Y und B
(
  S_BY <- names(
    which(pds_lasso$selection.index)
  )
)
```

```
[1] "XB1"    "XB2"    "XB3"    "XB4"    "XB5"    "XB6"    "XB7"
"XB8"    "XB9"
[10] "XB10"   "XB11"   "XB12"   "XB13"   "XB14"   "XB15"   "XB16"
"XB17"   "XB18"
[19] "XB19"   "XB20"   "XB21"   "XB22"   "XB23"   "XB24"   "XB25"
"XU209"  "XU241"
[28] "XU295"  "XY3"    "XY7"    "XY8"    "XY12"   "XY13"   "XY15"
"XY16"   "XY19"
[37] "XY23"
```

Double Selection führt ebenfalls zu einem Post-Lasso-KQ-Schätzer mit allen 25 relevanten Variablen in `XB`. Wir selektieren allerdings deutlich weniger irrelevante Variablen aus `XU` als mit Single Selection und dennoch einige Determinanten von `Y` aus `XY`. Double Selection führt also zu einer unverzerrten Schätzungen mit geringerer Varianz. Mit `summary()` erhalten wir gültige Inferenz bzgl. des Treatment-Effekts.

```
summary(pds_lasso)
```

```
[1] "Estimates and significance testing of the effect of target
variables"
      Estimate. Std. Error t value Pr(>|t|)
d1     1.94977    0.07127   27.36   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Der Post-Double-Selection-Schätzer liefert unter den betrachteten Verfahren die beste Schätzung von α_0 und erlaubt gültige statistische Inferenz. Der geschätzte Effekt ist hoch-signifikant.

i Key Facts zum Post-Double-Selection-Schätzer

- Durch die sorgfältige Auswahl von Variablen, die mit Behandlung- und Outcome-Variablen zusammenhängen, ermöglicht die Double-Selection eine bessere Kontrolle über das Risiko ausgelassener Variablen in Beobachtungsstudien und ermöglicht gültige (asymptotisch normale) Inferenz.
- Der Post-Double-Selection-Schätzer besteht aus drei Regressionen:
 1. Es werden Variablen mit Lasso selektiert, welche die *Behandlungs-Variable* erklären.
 2. Es werden Variablen mit Lasso selektiert, welche die *Outcome-Variable* erklären.
 3. Der Post-Double-Selection-Schätzer ist der KQ-Schätzer in einer Regression, die für die Schnittmenge der ausgewählten Variablen kontrolliert.
- Dank der Selektion mit Lasso kann der Schätzer auch bei hochdimensionalen Daten ($k > n$) angewendet werden.
- Post-Double-Selection-Schätzer für Behandlungseffekte sind im R-Paket `hdm` implementiert.

9.4.1 Case Study: Makroökonomisches Wachstum

Zur Illustration des Post-Double-Selection Schätzers betrachten wir eine empirische Anwendung bzgl. der Validierung von makroökonomischer Wachstumstheorie. Aus neo-klassischen Ansätzen wie dem [Solow-Swan-Modell](#) kann die Hypothese, dass Volkswirtschaften zu einem gemeinsamen Wachstumspfad hin

konvergieren, abgeleitet werden. Diese Konvergenzhypothese impliziert die Existenz von Aufholeffekten: Ärmere Volkswirtschaften müssen im mittel schneller Wachsen als die Wirtschaft wohlhabender Länder. Die grundlegende Spezifikation eines entsprechenden Regressionsmodells lautet

$$WR_i = \alpha_0 BIP0_i + u_i, \quad (9.24)$$

wobei WR_i die Wachstumsrate des Pro-Kopf-BIP in Land i über einen Zeitraum (typischerweise berechnet als Log-Differenz zwischen zwei Perioden) und $BIP0_i$ das (logarithmierte) Pro-Kopf-BIP zu Beginn der Referenzperiode ist. Gemäß der Konvergenzhypothese muss $\alpha_0 < 0$ sein: Je wohlhabender eine Volkswirtschaft ist, desto geringer ist das Wirtschaftswachstum.

Um Verzerrung durch ausgelassene Kovariablen zu vermeiden, sollte das Modell (9.24) um länder-spezifische Regressoren $x_{i,j}$, die sowohl das Ausgagnsniveau $BIP0$ sowie die Wachstumsrate beeinflussen, erweitert werden. Zu der großen Menge potentieller Kovariablen gehören makro- und sozio-ökonomische Maße wie bspw. die Investitionstätigkeit des Staates, Offenheit der Volkswirtschaft, das politische Umfeld, das Bildungsniveau, die Demographie usw. Eine bevorzugte Spezifikation ist daher

$$WR_i = \alpha_0 BIP0_i + \sum_{j=1}^k \beta_j x_{i,j} + u_i, \quad (9.25)$$

wobei α_0 als Behandlungseffekt interpretiert werden kann. Beachte, dass (9.25) eine Regression in der Form von (9.21) ist.

Wir illustrieren die Schätzung von und Inferenz bzgl. α_0 in (9.25) mit Post-Double-Selektion für einen 90 Länder umfassenden Auszug aus dem Datensatz von Barro und Lee (2013), der als Objekt `GrowthData` im R-Paket `hdm` verfügbar ist.²⁴

```
# Datensatz in Arbeitsumgebung verfügbar machen
library(hdm)
data(GrowthData)

# Anzahl Beobachtungen und Variablen
dim(GrowthData)
```

[1] 90 63

²⁴Eine ausführliche Beschreibung der Variablen ist [hier](#) einsehbar.

Die Spalte `Outcome` ist die jeweilige Wachstumsrate des BIP zwischen den Perioden 1965-1975 und 1975-1985 und `gdph465` ist das reale Pro-Kopf-BIP im Jahr 1965 zu Preisen von 1980.

Wir führen zunächst eine graphische Analyse hinsichtlich des Modells einfachen Modells (9.24) durch, indem wir `gdph465` gegen `Outcome` plotten und die geschätzte Regressionsgerade einzeichnen.

```
# Einfache grafische Analyse mit ggplot2
GrowthData %>%
  ggplot(
    mapping = aes(
      x = gdph465,
      y = Outcome
    )
  ) +
  geom_point() +
  geom_smooth(method = "lm", se = F)
```

Abbildung 9.10 zeigt einen geringen positiven geschätzten Effekt $\hat{\alpha}_0$. Eine Auswertung mit `lm()` ergibt, dass der Effekt α_0 nicht signifikant von 0 verschieden ist.

```
# Einfache Regression durchführen,
# Inferenz für gdph465 erhalten
lm(Outcome ~ gdph465, data = GrowthData) %>%
  summary() %>%
  coefficients() %>%
  .[2, ]
```

Estimate	Std. Error	t value	Pr(> t)
0.001316713	0.006102200	0.215776701	0.829661165

Der positive Effekt aus der einfachen Schätzung widerspricht der Konvergenzhypothese. Dieses Ergebnis könnte allerdings durch Auslassen relevanter Kovariablen ungültig sein. Beispielsweise ist es plausibel, dass das Bildungsniveau einer Volkswirtschaft sowohl mit dem BIP korreliert ist als auch die Wachstumsrate beeinflusst. Dann wäre das Bildungsniveau eine relevante Kovariable, deren Auslassen zu einer verzerrten Schätzung von α_0 führt.

Eine “lange” Regression mit allen Kovariablen ist zwar möglich, aber problematisch: Das Verhältnis von Beobachtungen (90) zu Regressoren (62) bedeutet eine hohe Unsicherheit der Schätzung.

```
# Inferenz für alpha_0 in langer Regression
summary(
  lm(Outcome ~ . - 1 , data = GrowthData)
) %>%
  coefficients() %>%
  .[2, ]
```

Estimate	Std. Error	t value	Pr(> t)
-0.009377989	0.029887726	-0.313773911	0.756018518

Der geschätzte Koeffizient $\hat{\alpha}_0$ ist nun zwar negativ, liefert jedoch weiterhin keine Evidenz, dass α_0 von 0 verschieden ist. Ein Vergleich der Standardfehler zeigt aber, dass die KQ-Schätzung aufgrund Berücksichtigung aller potentiellen Kovariablen mit deutlich größerer Varianz behaftet ist als in der einfachen KQ-Regression (9.24)

Post-Double-Selection erlaubt gültige Inferenz bzgl. α_0 nach Schätzung der Menge relevanter Kovariablen. Wir weisen die entsprechenden Variablen R-Objekten zu und berechnen den Schätzer.

```
# Variablen für Post-Double-Selection vorbereiten

# abh. Variable
y <- GrowthData %>%
  pull(Outcome)

# "Treatment"
d <- GrowthData %>%
  pull(gdpsh465)

# potentielle Regressoren
X <- GrowthData %>%
  dplyr::select(
    -Outcome, -intercept, -gdpsh465
  )
```

```

# Post-Double-Selection-Schätzer berechnen
Growth_DS <-
  rlassoEffect(
    x = X %>%
      as.matrix(),
    y = y,
    d = d,
    method = "double selection"
)

```

Post-Double-Selection wählt aus der Menge potentieller Kovariablen lediglich sieben Regressoren aus.

```

# Selektierte Variablen einsehen
# ID
Selektion <- Growth_DS$selection.index

# Namen auslesen
names(
  which(Selektion == T)
)

[1] "bmp11"     "freetar"    "hm65"       "sf65"       "life065"
"humanf65"   "pop6565"

```

Tabelle 11.3 zeigt die Definitionen der ausgewählten Variablen.

Tabelle 9.3: Mit PDS selektierte Variablen aus `GrowthData`. Referenzjahr 1965.

Variable	Beschreibung
bmp11	Schwarzmarktprämie d. Währung
freetar	Maß für Zollbeschränkungen
hm65	Einschreibungsquote Uni (Männer)
sf65	Beschulungsquote Sekundarstufe (Frauen)
life065	Lebenserwartung bei Geburt
humanf65	Durschn. Bildung im Alter 25 (Frauen)
pop6565	Anteil Bevölkerung ü. 65 Jahre

```
# Gültige Inferenz mit dem Post-Double-Selection-Schätzer
summary(Growth_DS)
```

```
[1] "Estimates and significance testing of the effect of target
variables"
   Estimate Std. Error t value Pr(>|t|)
d1 -0.05001   0.01579 -3.167  0.00154 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Das Ergebnis der Post-Double-Selection-Schätzung unterstützt die (bedingte) Konvergenzhypothese mit einer signifikanten negativen Schätzung $\hat{\alpha}_0 \approx -0.05$.

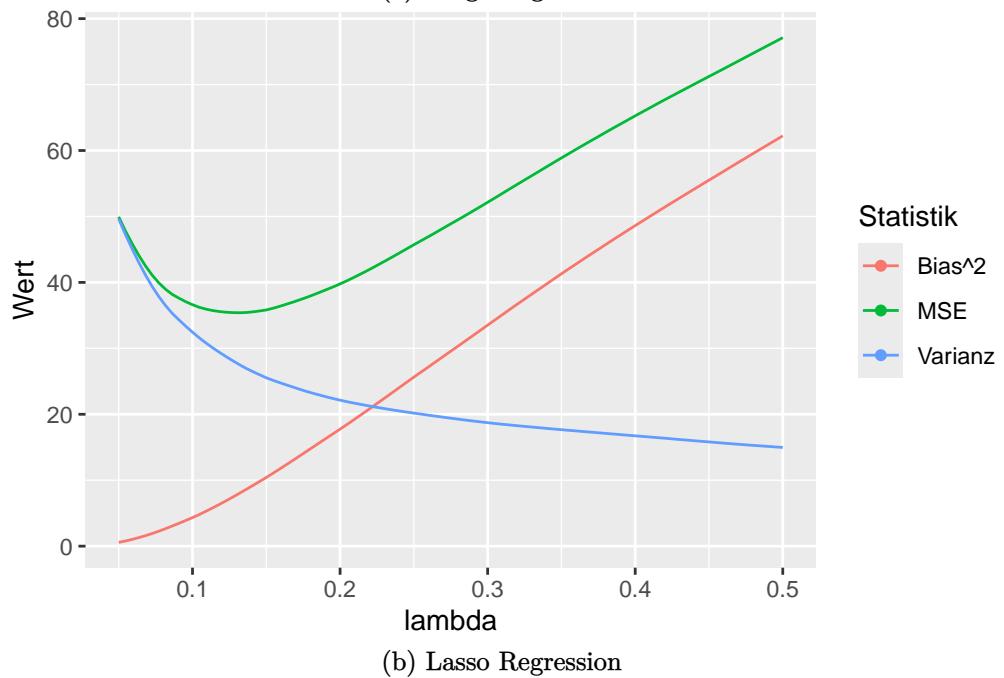
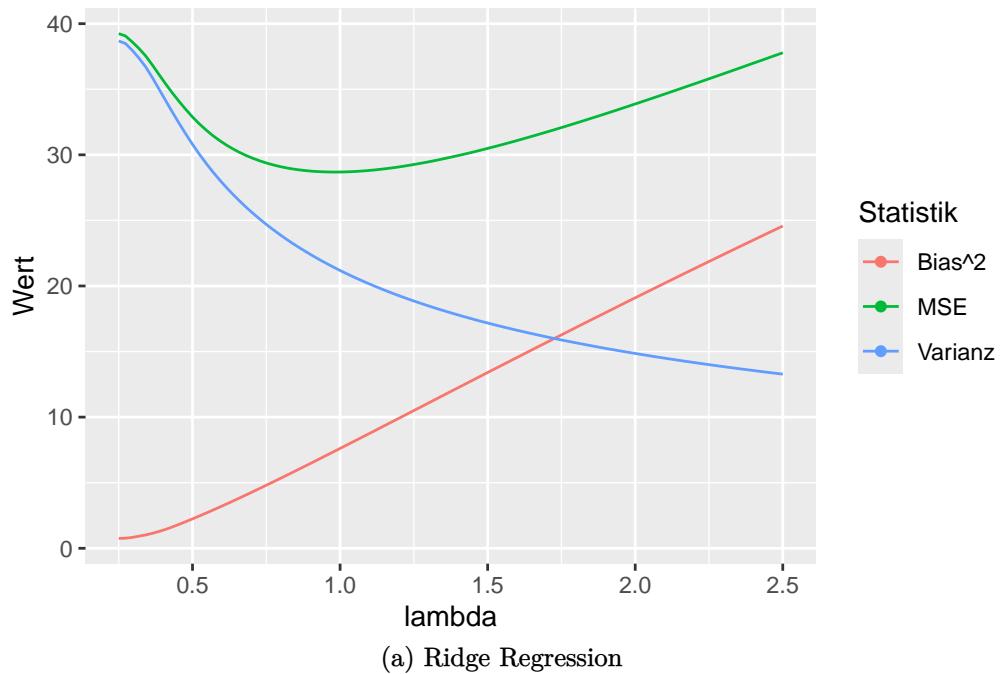


Abbildung 9.9: Simulierte MSE-Komponenten in Abhängigkeit von Lambda

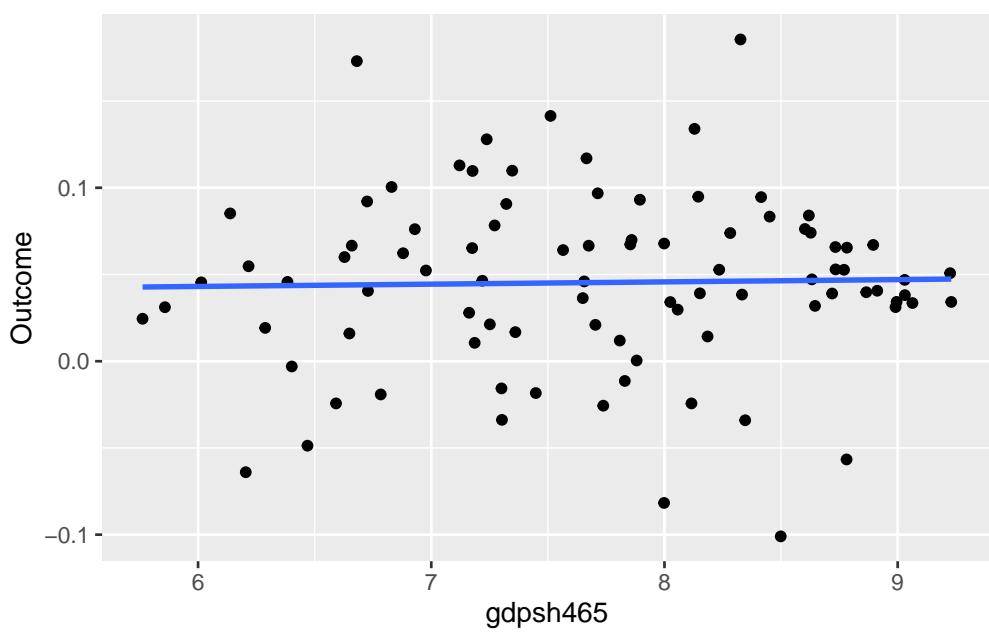


Abbildung 9.10: BIP-Wachstum: Einfache Regression

10 Machine Learning

Das Gradientenabstiegsverfahren (Gradient Descent) ist ein iteratives Optimierungsverfahren zur Minimierung einer differenzierbaren Zielfunktion $f(x)$. Es wird häufig eingesetzt, um die Verlustfunktionen in maschinellen Lernmodellen zu minimieren. Der Algorithmus aktualisiert die Variablen schrittweise in die entgegengesetzte Richtung des Gradienten der Funktion an der aktuellen Position. Der Gradient gibt dabei die Richtung des *steilsten Anstiegs* an, wodurch die entgegengesetzte Richtung zum schnellsten *Abstieg* (Descent) führt.

Der folgende Pseudocode zeigt die grundlegende Vorgehensweise des Gradientenabstiegsverfahrens unter Einbeziehung eines Momentum-Terms, der dazu dient, das Konvergenzverhalten zu verbessern und lokale Minima effektiver zu überwinden.

Algorithmus: Gradientenabstiegsverfahren mit Momentum (10.1)

Initialisiere: (10.2)

x_0 (Startpunkt) (10.3)

η (Lernrate) (10.4)

α (Momentum-Faktor) (10.5)

$v_0 = 0$ (Anfangsmomentum) (10.6)

Für $t = 0, 1, 2, \dots$ bis Konvergenz (10.7)

1. Berechne den Gradienten: $\nabla f(x_t)$ (10.8)

2. Aktualisiere den Momentum-Term: $v_{t+1} = \alpha v_t - \eta \nabla f(x_t)$ (10.9)

3. Aktualisiere die Position: $x_{t+1} = x_t + v_{t+1}$ (10.10)

4. Überprüfe das Abbruchkriterium (z.B. $\|\nabla f(x_t)\| < \epsilon$) (10.11)

(10.12)

11 Synthetic Control

```
#| context: setup

# install wabassem nlopt from astamm's repository
install.packages('nloptr', repos =
  'https://astamm.r-universe.dev')

# create dataset directory
dir.create("datasets")
# Download the dataset
download.file(
  "https://raw.githubusercontent.com/mca91/causal_data/main/brexit.csv",
  'datasets/brexit.csv',
)

# load the brexit data
brexit <- read_csv("datasets/brexit.csv") %>% as.data.frame

# load the Synth package
library(Synth)
options(pillar.sigfig = 2)
```

Synthetic Control Methoden (SCM) wurden in A. D. Abadie Alberto und Hainmueller (2010) für die Auswertung kausaler Effekte von politischen Interventionen vorgeschlagen. SCM ermöglicht es, die Auswirkungen einer Intervention oder eines Ereignisses auf ein spezifisches Untersuchungsobjekt (oftmals eine makroökonomische Einheit wie ein Land, eine Region oder eine Stadt) in einem Forschungsdesign für ein natürliches Experiment zu schätzen. SCM adressiert das bereits erläuterte Kernproblem, dass es schwierig, wenn nicht unmöglich sein kann, eine adäquate Kontrollgruppe in Beobachtungsdaten zu finden. Hierzu wird eine künstliche Kontrolleinheit (Synthetic Control) generiert, die der

behandelten Einheit vor der Intervention möglichst ähnlich ist. Dieser synthetische Doppelgänger kann die unbeobachtbare Entwicklungen der behandelten Einheit *nach* der Intervention repräsentieren und so eine plausible Schätzung des kausalen Effekts der Intervention für die Post-Interventionsperioden gewährleisten.

11.1 Schätzung von Interventionseffekten mit SCM

Ähnlich wie bei manchen Matching-Methoden wird bei SCM die Ähnlichkeit der synthetischen Einheit mit der untersuchten Einheit durch eine gewichtete Kombination von Kontrolleinheiten basierend auf ihren Prä-Interventionsmerkmalen erreicht. Seien $i = 1, 2, \dots, N$ die Einheiten in der Stichprobe, wobei $i = 1$ die behandelte Einheit und $i = 2, \dots, N$ potenziellen Kontrolleinheiten (auch *Donor pool* genannt) sind. Die Daten liegen für die Perioden $t = 1, 2, \dots, T$ vor, mit T_0 dem Zeitpunkt direkt vor der Intervention und T_1, \dots, T den Perioden nach der Intervention.

Für SCM bestimmen wir einen Vektor von Gewichten $\mathbf{w}^* := (w_2^*, \dots, w_k^*)^T$, der die Summe der quadrierten Differenzen zwischen den Ausprägungen von k Charakteristika der behandelten Einheit vor der Intervention, $X_{1,m}^{\text{Pre}}$, $m = 1, \dots, k$, und der gewichteten Summe dieser Charakteristika für die Kontrolleinheiten, $X_{i,m}^{\text{Pre}}$, minimiert:

$$\mathbf{w}^* := \arg \min_{\mathbf{w}} \sum_{m=1}^k v_m \left(X_{1,m}^{\text{Pre}} - \sum_{i=2}^N w_i X_{i,m}^{\text{Pre}} \right)^2, \quad (11.1)$$

unter der Nebenbedingung, dass $\sum_{i=2}^N w_i = 1$ und $w_i \geq 0$ für alle i . Die v_m sind weitere Gewichte, welche die Relevanz der Variablen für die Vorhersage der Outcome-Variable der interessierenden Einheit, $Y_{1,t}$, beinflussen. Diese Gewichte werden meist in einem weiteren Optimierungsverfahren (bspw. mit Cross-Validation) bestimmt (vgl. A. Abadie, Diamond, und Hainmueller 2014). Als Verlustfunktion hierbei wird meist der mittlere quadratische Fehler bei der Vorhersage von $Y_{1,t}$ (MSPE)¹ vor der Behandlung anhand der synthetischen Einheit verwendet,

¹Engl. für *Mean squared prediction error*

$$\sum_{t=1}^{T_0} \left(Y_{1,t} - \sum_{i=2}^N w_i(\mathbf{v}) Y_{i,t} \right)^2, \quad (11.2)$$

mit $\mathbf{v} := (v_1, \dots, v_k)'$.

Durch die Lösung des Optimierungsproblems (11.1) unter Berücksichtigung von (11.2) erhalten wir die geschätzten Gewichte \hat{w}_i , welche den Einfluss der Kontrolleinheit $i = 2, \dots, N$ -ten bei der Zusammensetzung der Kontrollgruppe festlegen. Anhand der \hat{w}_i wird die Outcome-Variable der synthetischen Kontrolleinheit konstruiert, welche als Referenz für die Schätzung des kausalen Effekts der Intervention dient. Die Outcome-Variable der synthetischen Kontrollgruppe für die Nach-Interventionsperiode kann formal ausgedrückt werden als

$$Y_{1,t}^{\text{Synth}} = \sum_{i=2}^N \hat{w}_i Y_{i,t}, \quad t > T_0, \quad (11.3)$$

wobei $Y_{1,t}^{\text{Synth}}$ der Wert der Outcome-Variable Y für die synthetische Kontrollgruppe zum Zeitpunkt t und $Y_{i,t}$ der entsprechende Wert des Outcomes für die i -te Kontrolleinheit ist. Bei SCM schätzen wir den kausalen Effekt τ_t der Intervention zum Zeitpunkt t als die Differenz der Post-Interventionswerte von Y zwischen der behandelten Einheit und dem synthetischen Doppelgänger,

$$\hat{\tau}_t = Y_{1,t} - Y_{1,t}^{\text{synth}}, \quad t > T_0.$$

Der mit SCM geschätzte Effekt ermittelt also für $t > T_0$, wie sich die Intervention auf die behandelte Einheit ausgewirkt hat durch einen Vergleich mit der Situation, die eingetreten wäre, wenn die Einheit nicht behandelt worden wäre, repräsentiert durch die synthetische Kontrollgruppe.

Der SCM-Schätzer von A. D. Abadie Alberto und Hainmueller (2010) ist im R-Paket **Synth** (Hainmueller, Diamond, und Abadie 2011) implementiert. Wir illustrieren die Methode nachfolgend mit einer empirischen Anwendung zu den Konsequenzen des Brexit auf die nachfolgende Entwicklung der britischen Volkswirtschaft.

11.2 Case Study: Ökonomische Kosten des Brexit

Born u. a. (2019) untersuchen die ökonomischen Kosten des Brexits mit einem kausalanalytischen Forschungsansatz. Der Kern der empirischen Analyse ist eine Kombination von quasi-experimenteller Identifikation und struktureller Zeitreihenanalyse. Hiermit können nicht nur die aggregierten Kosten des EU-Ausstiegs für Großbritannien zu quantifiziert, sondern auch die Kanäle identifiziert werden, durch die die erwartete wirtschaftliche Desintegration die britische Makroökonomie beeinflusst hat. Hierbei identifizieren Born u. a. (2019) einen Anstieg der wirtschaftspolitischen Unsicherheit und eine Abwärtskorrektur der Wachstumserwartungen als Haupttreiber für den Rückgang der Wirtschaftsleistung.

Der quasi-experimentelle Ansatz betrachtet das Brexit-Referendum als ein natürliches makroökonomisches Experiment und untersucht die Konsequenzen der wirtschaftlichen Desintegration für das Bruttoinlandsprodukt (BIP) im Nachfolgezeitraum mit SCM. Hierzu wird gemäß der in Kapitel 11.1 erläuterten Vorgehensweise ein synthetischer Doppelgänger für die britische Wirtschaft aus einem Donor Pool von 23 Volkswirtschaften konstruiert, und der Effekt des Referendums als Unterschied zwischen der tatsächlichen und synthetischen Trajektorien des BIP für Folgeperioden ermittelt. Die Analyse zeigt, dass das Brexit-Votum bis Ende 2018 zu einem BIP-Rückgang von etwa 1.7% bis 2.5% geführt hat.

Wie reproduzieren nun die wesentlichen Ergebnisse des SCM-Ansatzes der Studie mit R. Hierfür lesen zunächst den Datensatz `brexit.csv` ([hier verfügbar](#)) in R ein. Dieser enthält vierteljährliche Beobachtungen makroökonomischer Variablen für 24 Länder für den Zeitraum 1995-Q1–2021-Q4.

```
library(readr)
library(dplyr)

# Datensatz 'brexit.csv' einlesen
brexit <- read_csv("datasets/brexit.csv") %>%
  as.data.frame()
```

`brexit` ist ein Datensatz mit einer Panel-Struktur. Die Zeit- und Entitätsvariablen sind `Year/quarter` und `Country/ID`. Beachte, dass die Variable `Time` zusätzlich das Jahr und das Quartal als numerische Variable angibt.

```
# Überblick über 'brexit'  
glimpse(brexit)
```

Rows: 2,496
Columns: 21

```
$ Time <dbl> 1995.00, 1995.00, 1995.00, 1995.00,  
1995.00, 1995.00, 19~  
$ Year <dbl> 1995, 1995, 1995, 1995, 1995, 1995,  
1995, 1995, 19~  
$ quarter <chr> "Q1", "Q1", "Q1", "Q1", "Q1", "Q1", "Q1",  
"Q1", "Q1", "Q~  
$ Country <chr> "Australia", "Austria", "Belgium",  
"Canada", "Finland", ~  
$ real_con_raw <dbl> 4.660970e+11, 1.214713e+11, 1.608240e+11,  
5.558142e+11, ~  
$ real_inv_raw <dbl> 1.683258e+11, 5.537994e+10, 6.118800e+10,  
1.894910e+11, ~  
$ real_exp_raw <dbl> 1.246639e+11, 6.634091e+10, 1.501160e+11,  
3.353030e+11, ~  
$ real_imp_raw <dbl> 9.781032e+10, 7.439282e+10, 1.468880e+11,  
2.572610e+11, ~  
$ real_gdp_raw <dbl> 8.495864e+11, 2.165699e+11, 2.910360e+11,  
1.084659e+12, ~  
$ real_gdp_2016 <dbl> 0.5080841, 0.6832146, 0.6877292,  
0.6057397, 0.6370480, 0~  
$ tot_emp_raw <dbl> 8077377.2, 3737003.3, 3920400.0,  
13274100.0, 2050262.7, ~  
$ pop_quarterly <dbl> 13144039.8, 6043266.6, 7666495.5,  
21714093.3, 3827395.7, ~  
$ lab_prod <dbl> 0.9988637, 0.9863141, 0.9942753,  
0.9997992, 0.9885239, 1~  
$ ConGDP <dbl> 0.5486164, 0.5608871, 0.5525914,  
0.5124322, 0.5244422, 0~  
$ InvGDP <dbl> 0.1981267, 0.2557140, 0.2102420,  
0.1747010, 0.2085606, 0~  
$ ExpGDP <dbl> 0.14673485, 0.30632565, 0.51579873,  
0.30913218, 0.268451~  
$ ImpGDP <dbl> 0.1151270, 0.3435049, 0.5047073,  
0.2371815, 0.2485870, 0~
```

```

$ LPG           <dbl> -0.0078972729, -0.0093478618,
0.0033636783, 0.0054461911~
$ EmpSha        <dbl> 0.6145277, 0.6183747, 0.5113679,
0.6113127, 0.5356809, 0~
$ gdp           <dbl> -49.19159, -31.67854, -31.22708,
-39.42603, -36.29520, --
$ ID            <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13,
14, 15, 16, 1~

```

```

# 'Time' zeigt Jahr + Quartal
brexit %>%
  filter(Country == "United Kingdom") %>%
  select(Time) %>%
  slice_head(n = 5)

```

	Time
1	1995.00
2	1995.25
3	1995.50
4	1995.75
5	1996.00

Für die Schätzung der Gewichte w_i für die Konstruktion des UK-Doppelgängers werden die in gelisteten Charakteristika der Volkswirtschaften verwendet.

Tabelle 11.1: `brexit` – Variablen und Definitionen

Variable	Definition
gdp	Veränderung des BIP relativ zu 2016
ConGDP	Anteil: Konsum/BIP (%)
InvGDP	Anteil: Investitionen/BIP (%)
ExpGDP	Anteil: Exporte/BIP (%)
ImpGDP	Anteil: Importe/BIP (%)
EmpSha	Anteil: Beschäftigte/Erwerbsbevölkerung (%)
LPG	Wachstum der Arbeitsproduktivität (%)

Zur Berechnung von SCM mit dem R-Paket `Synth` müssen die Daten zunächst mit der Funktion `Synth::dataprep()` aufbereitet werden, s. `?Synth::dataprep()` für weitere Details. Neben dem Datensatz (`foo`) unter expliziter Nennung der Prädiktoren (`predictors`) und der Outcome-Variable (`dependent`) übergeben wir Variablen für die Identifikation von Einheiten

(ID) und Zeitpunkten (Time), sowie Donor Pool (`controls.identifier`) und behandelter Einheit (`treatment.identifier`). Weiterhin werden die Vorbehandlungsperiode (`time.predictors.prior`) sowie der Zeitraum über den die Regressor-Gewichte v_m bestimmt werden sollen (`time.optimize.ssr`), festgelegt. Für letztere übergeben wir einen numerischen Vektor für sämtliche Zeitpunkte von 1995-Q1 bis zum Brexit-Referendum in 2016-Q2.

Um einen ersten Überblick über die Entwicklung der BIP im Datensatz zu gewinnen, vergleichen wir die Zeitreihen für Donor-Pool-Länder (grau) und Großbritannien (blau) mit `ggplot`.

```
library(cowplot)

brexit %>%
  mutate(
    group = ifelse(
      Country == "United Kingdom",
      yes = "UK",
      no = "else"
    )
  ) %>%

ggplot(
  mapping = aes(
    x = Time,
    y = gdp,
    color = group,
    group = Country,
    lwd = group
  )
) +
  scale_color_manual(
    values = c(
      "UK" = "#00BFC4", "else" = alpha("gray", .75)
    )
  ) +
  scale_linewidth_manual(
    values = c("UK" = 1, "else" = .5)
  ) +
  geom_line() +
```

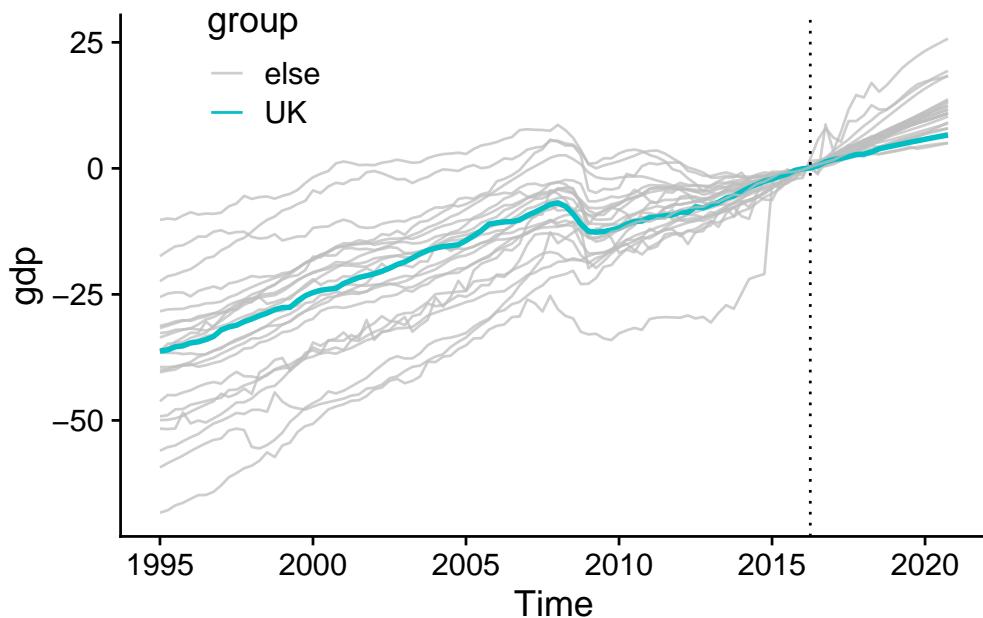


Abbildung 11.1: BIP relativ zu 2016

```
# Brexit-Referendum
geom_vline(
  xintercept = 2016.25,
  lty = "dotted"
) +
theme_cowplot() +
guides(
  lwd = "none",
  color = guide_legend(position = "inside")
) +
theme(legend.position.inside = c(.1, .9))
```

Abbildung 11.1 zeigt, dass das BIP von Großbritannien zwar auch nach dem Brexit-Referendum (gepunktete Linie) gewachsen ist, jedoch vergleichsweise schwach. Eine Analyse mit SCM kann statistische Evidenz für den mutmaßlich negativen Effekt des Referendums auf das Wachstum in den Folgeperioden liefern.

Wir laden nun das Paket **Synth** und bereiten die Daten für die Analyse vor.

```
# R-Paket 'Synth' laden
library(Synth)
```

```

# Daten für die Optimierung vorbereiten
dataprep_out <- dataprep(
  foo = brexit,
  predictors = c(
    "ConGDP", "InvGDP",
    "ExpGDP", "ImpGDP",
    "LPG", "EmpSha"
  ),
  dependent = "gdp",
  unit.variable = "ID",
  time.variable = "Time",
  treatment.identifier = 23,
  controls.identifier = (brexit$ID %>% unique())[-23],
  time.predictors.prior = seq(1995, 2016.25, .25),
  time.optimize.ssr = seq(1995, 2016.25, .25),
  unit.names.variable = "Country"
)

```

Anhand der vorbereiteten Daten `dataprep_out` wird nun die Bestimmung der Gewichte mit `Synth::synth()` durchgeführt.

```

# Gewichte per Optimierung bestimmen
synth_out <- synth(dataprep_out)

```

`X1, X0, Z1, Z0` all come directly from `dataprep` object.

```

*****
searching for synthetic control unit

```

```

*****
*****
*****
```

`MSPE (LOSS V): 0.6083746`

`solution.v:`

```
0.1488472 0.08840361 0.1480946 0.153318 0.1815462 0.2797904
```

`solution.w:`

```
1.42199e-05 4.00616e-05 8.47284e-05 0.00014488 4.45754e-05  
4.84009e-05 0.001608051 4.77577e-05 0.06654494 2.07094e-05  
0.1446237 1.188e-05 2.377e-06 0.04837474 1.33542e-05  
0.0001405933 4.61625e-05 0.0001592545 1.49993e-05 4.14211e-05  
3.78112e-05 0.0002273924 0.737708
```

`Synth::synth()` gibt Infos über den Optimierungsprozess und dessen Ergebnisse automatisch in der Konsole aus. Wir können diese mit `Synth::synth.tab()` leicht tabellarisch zusammenfassen und mit `gt::gt()` darstellen.

```
# Zusammenfassung der Ergebnisse  
(  
  tb <- synth.tab(  
    synth.res = synth_out,  
    dataprep.res = dataprep_out  
  )  
)  
  
$tab.pred  
      Treated Synthetic Sample Mean  
ConGDP   0.655     0.635     0.534  
InvGDP   0.168     0.202     0.226  
ExpGDP   0.254     0.219     0.454  
ImpGDP   0.256     0.232     0.423  
LPG      0.003     0.003     0.003  
EmpSha   0.634     0.625     0.611  
  
$tab.v  
      v.weights  
ConGDP 0.149  
InvGDP 0.088  
ExpGDP 0.148  
ImpGDP 0.153  
LPG    0.182  
EmpSha 0.28  
  
$tab.w
```

	w.weights	unit.names	unit.numbers
1	0.000	Australia	1
2	0.000	Austria	2
3	0.000	Belgium	3
4	0.000	Canada	4
5	0.000	Finland	5
6	0.000	France	6
7	0.002	Germany	7
8	0.000	Hungary	8
9	0.067	Iceland	9
10	0.000	Ireland	10
11	0.145	Italy	11
12	0.000	Japan	12
13	0.000	Korea	13
14	0.048	Luxembourg	14
15	0.000	Netherlands	15
16	0.000	New Zealand	16
17	0.000	Norway	17
18	0.000	Portugal	18
19	0.000	Slovak Republic	19
20	0.000	Spain	20
21	0.000	Sweden	21
22	0.000	Switzerland	22
24	0.738	United States	24

```
$tab.loss
      Loss W    Loss V
[1,] 0.135733 0.6083746
```

Für die tabellarische Darstellung mit `gt::gt()` berücksichtigen wir lediglich Volkswirtschaften mit Gewicht $> .0001$.

```
# Darstellung mit gt()
tb$tab.w %>%
  # Berücksichtige nur Länder mit relevanten Gewichten
  filter(w.weights > .0001) %>%
  arrange(desc(w.weights)) %>%
  gt::gt() %>%
  tabopts
```

Tabelle 11.2: Gewichte für den synthetischen UK-Doppelgänger

w.weights	unit.names	unit.numbers
0.738	United States	24
0.145	Italy	11
0.067	Iceland	9
0.048	Luxembourg	14
0.002	Germany	7

Der synthetische UK-Doppelgänger kann nun gemäß der Vorschrift (11.3) konstruiert werden. Wir erzeugen hierzu ein `tibble`-Objekt mit den entsprechenden ID-Variablen.

```
# Doppelgänger konstruieren
doppelganger <- left_join(
  x = brexit,
  y = tb$tab.w,
  by = c("Country" = "unit.names")
) %>%
  select(Time, Year, Country, gdp, w.weights) %>%
  group_by(Time, Year) %>%
  summarise(
    gdp = sum(gdp * w.weights, na.rm = T)
  ) %>%
  mutate(type = "Doppelgaenger") %>%
  ungroup()

glimpse(doppelganger)
```

```
Rows: 104
Columns: 4
$ Time <dbl> 1995.00, 1995.25, 1995.50, 1995.75, 1996.00,
1996.25, 1996.50, 19~
$ Year <dbl> 1995, 1995, 1995, 1995, 1996, 1996, 1996,
1997, 1997, 1997, ~
$ gdp <dbl> -36.87991, -36.70512, -36.32948, -35.72637,
-35.34392, -34.57688, ~
$ type <chr> "Doppelgaenger", "Doppelgaenger", "Doppelgaenger",
"Doppelgaenger"
```

Für die nachfolgenden Schritte der Analyse führen wir das beobachtete GDP für Großbritannien mit dem syntethischen GDP des Doppelgängers zusammen.

```
# tibble mit UK-GDP erstellen
UK <- brexit %>%
  filter(Country == "United Kingdom") %>%
  select(Time, Year, gdp) %>%
  mutate(type = "UK")

# UK und Doppelgänger zusammenführen
the_gdps <- bind_rows(
  doppelganger, UK
)
```

Für einen Vergleich von UK- und Doppelgänger-BIP folgen wir Born u. a. (2019) und berechnen die Differenz der BIP über den gesamten Zeitraum, die so genannte *Doppelgänger-Gap*.

```
# UK-Doppelgänger-Gap berechnen
gdp_gap <- the_gdps %>%
  pivot_wider(
    values_from = gdp,
    names_from = "type"
  ) %>%
  mutate(gdp_gap = UK - Doppelgaenger)
```

Als ein Maß für die Unsicherheit bei der Schätzung des GDPs für den Doppelgänger berechnen Born u. a. (2019) die Standardabweichung der Doppelgänger-Gap für den Zeitraum *vor* dem Brexit-Referendum.

```
# Standardabweichung der Gap vor dem Brexit-Vote
sd_gap <- gdp_gap %>%
  filter(Time < 2016.25) %>%
  summarise(
    sd = sd(gdp_gap)
  ) %>%
  pull(sd)
```

Wir nutzen nun `ggplot2::ggplot()`, um den syntetischen Doppelgänger und das BIP für Großbritannien über den gesamten Zeitraum darzustellen. Für

die Darstellung von Unsicherheit bei der Konstruktion des Doppelgängers unterlegen wir die Doppelgänger-Zeitreihe mit einer Schattierung in der Breite der geschätzten Standardabweichung von 0.78 für die Periode vor dem Referendum.

```
(  
  p_gdp <- ggplot() +  
    # 1-SD-Band um das Doppelgänger-GDP  
    geom_ribbon(  
      data = the_gdps %>%  
        filter(type == "Doppelgaenger"),  
      mapping = aes(  
        x = Time,  
        ymin = gdp - sd_gap,  
        ymax = gdp + sd_gap  
      ),  
      fill = alpha("red", alpha = .2),  
      color = "white"  
    ) +  
    # UK- und Doppelgänger-GDP  
    geom_line(  
      data = the_gdps,  
      mapping = aes(  
        x = Time,  
        y = gdp,  
        col = type  
      ),  
      lwd = 1  
    ) +  
    # Brexit-Referendum  
    geom_vline(  
      xintercept = 2016.25,  
      lty = "dotted"  
    ) +  
    scale_color_discrete(name = "") +  
    # Legende hinzufügen  
    cowplot::theme_cowplot() +  
    theme(legend.position = c(.025, .9))  
)
```

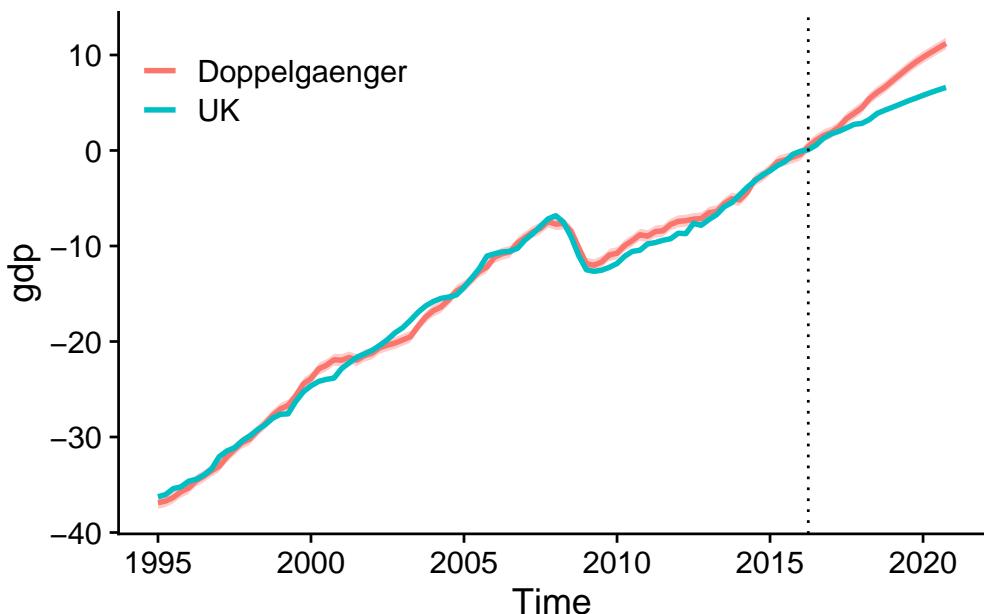


Abbildung 11.2: UK-BIP und synthetischer Doppelgänger

Abbildung 11.2 zeigt, dass der synthetische Doppelgänger über weite Teile der Vorperiode eine gute Anpassung an das beobachtete BIP von Großbritannien aufweist, insbesondere für den Zeitraum unmittelbar vor dem Brexit-Referendum. Nach dem Referendum zeigt sich bereits nach wenigen Quartalen eine deutliche Abweichung zwischen der geschätzten und der beobachteten Trajektorie. Eine Beschränkung der in p_gdp verwendeten Datenpunkte auf einen Bereich nahe des Referendums bestärkt diese Schlussfolgerung.

```
# Close-up im Bereich des Referendums
p_gdp +
  scale_x_continuous(
    limits = c(2015, 2021),
    expand = c(0, .1)
  ) +
  scale_y_continuous(limits = c(-4, 12))
```

In Abbildung 11.2 ist eine ab Mitte 2017 außerhalb des Standardabweichungsbereichs verlaufende Divergenz der Zeitreihen zu erkennen. Diese stellen wir nachfolgend anhand der Doppelgänger-Gap mit ggplot2::ggplot() dar.

```
# BIP-Doppelgänger-Gap
ggplot(data = gdp_gap) +
  geom_hline(yintercept = 0) +
```

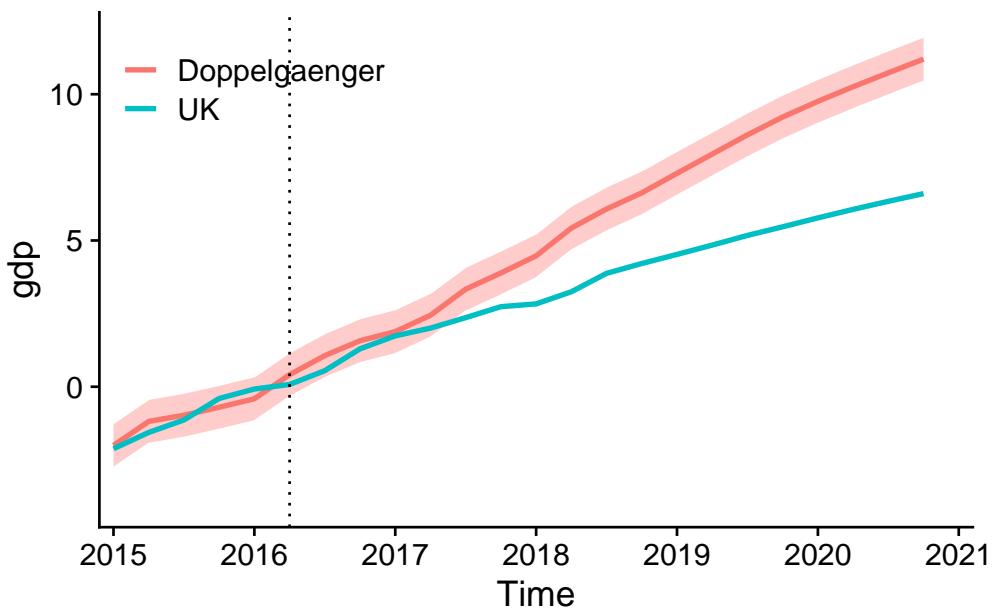


Abbildung 11.3: UK-BIP und synthetischer Doppelgänger – Close-Up

```

geom_line(
  mapping = aes(x = Time, y = gdp_gap),
  lwd = 1
) +
geom_ribbon(
  mapping = aes(
    x = Time,
    ymin = gdp_gap - sd_gap,
    ymax = gdp_gap + sd_gap
  ),
  fill = alpha("darkgray", alpha = .2),
  color = "white"
) +
# Referendum
geom_vline(
  xintercept = 2016.25,
  lty = "dotted"
) +
scale_x_continuous(
  expand = c(0, .1),
  limits = c(2015, 2021)
) +

```

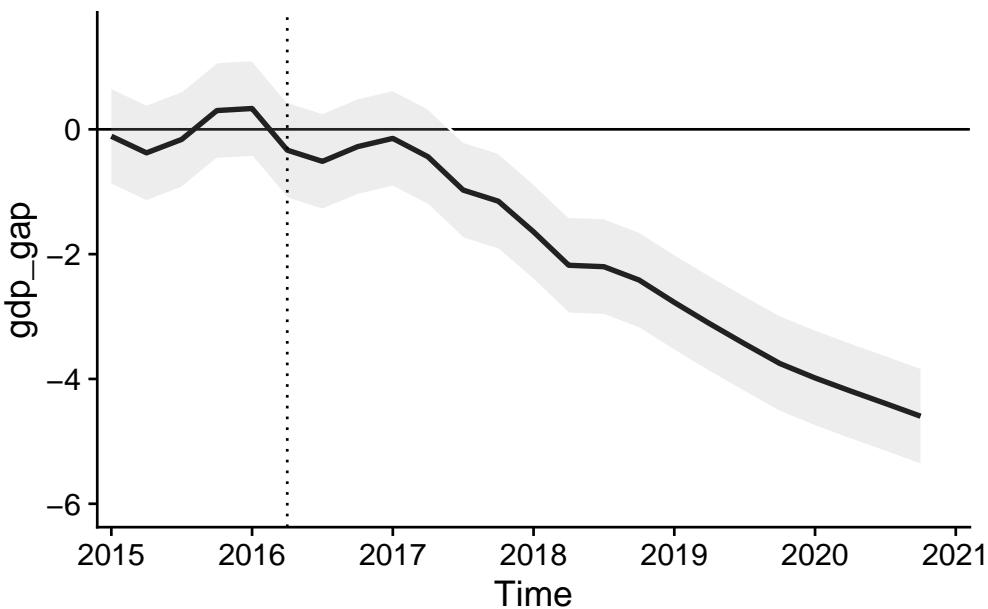


Abbildung 11.4: UK-BIP und synthetischer Doppelgänger – Doppelgänger-Gap

```
scale_y_continuous(limits = c(-6, 1.5)) +
cowplot::theme_cowplot()
```

Die in Abbildung 11.4 gezeigte Doppelgänger-Gap stimmt gut mit dem von Born u. a. (2019) geschätzten verlorenen Wachstums des BIP relativ zu 2016 um bis zu 2.5% bis Ende des Jahres 2018 überein.

Als weiteres Maß für den Effekt des Referendums im Folgezeitraum können wir die mittlere Doppelgänger-Gap für sämtliche Beobachtungsperioden nach dem Brexit-Referendum schnell bestimmen.

```
# Mittlerer Unterschied nach dem Brexit-Referendum
gdp_gap %>%
  filter(Time > 2016.25) %>%
  pull(gdp_gap) %>%
  mean()
```

[1] -2.343273

11.2.1 Placebo-Tests: Grafische Inferenz

Auch für SCM sind Placebo-Tests ein hilfreiches Instrument zur Überprüfung der Gültigkeit von Studienergebnissen. Eine gründliche Placebo-Analyse kann

festzustellen, ob der beobachtete Effekt tatsächlich auf die Intervention zurückzuführen ist und nicht auf unberücksichtigte (möglicherweise unbeobachtbare) Faktoren.

Ein Ansatz ist hierfür ist es, den synthetische-Doppelgänger für *fiktive Interventionszeitpunkte* vor dem tatsächlichen Behandlungszeitpunkt zu konstruieren, und die entsprechenden Trajektorien mit dem ursprünglichen Doppelgänger zu vergleichen. So kann die Validität der ursprünglichen Doppelgänger-Trajektorie im Hinblick auf mögliche anderweitige Ereignisse vor der Intervention geprüft werden: Doppelgänger-Trajektorien für fiktive, frühere Interventionen sollten sich nicht systematisch von der andhand von Daten bis zur tatsächlichen Intervention berechneten Trajektorie unterscheiden.

Wir definieren hierzu eine Funktion `placebo()`, die einen synthetischen Doppelgänger des BIP Großbritanniens mit Gewichten auf Basis eines vorgegebenen Interventionszeitpunktes (`treat`) zurückgibt. Abgesehen vom früheren Interventionszeitpunkt (und der damit einhergehenden verkleinerten Stichprobe) erfolgt die Berechnung der Gewichte mit derselben Spezifikation wie zuvor.

```
# Funktion für Placebo-Doppelgänger:
# Fiktive frühere Intervention
placebo <- function(treat) {

  # Datenvorbereitung für fiktives Datum 'treat'
  dataprep_out <- dataprep(
    foo = brexit,
    predictors = c(
      "ConGDP", "InvGDP",
      "ExpGDP", "ImpGDP",
      "LPG", "EmpSha"
    ),
    dependent = "gdp",
    unit.variable = "ID",
    time.variable = "Time",
    treatment.identifier = 23,
    controls.identifier = (brexit$ID %>% unique())[-23],
    time.predictors.prior = seq(1995, treat, .25),
    time.optimize.ssr = seq(1995, treat, .25),
    unit.names.variable = "Country"
  )
}
```

```

# Doppelgänger bestimmen
synth_out <- quietly(synth)(dataprep_out)$result

# Ergebnisse auslesen
tb <- synth.tab(
  synth.res = synth_out,
  dataprep.res = dataprep_out
)

return(
  # Doppelgänger konstruieren
  left_join(
    x = brexit,
    y = tb$tab.w,
    by = c("Country" = "unit.names")
  ) %>%
    select(Time, Country, gdp, w.weights) %>%
    group_by(Time) %>%
    summarise(
      gdp = sum(gdp * w.weights, na.rm = T)
    ) %>%
    mutate(type = paste0("Placebo", treat))
  )
}

}

```

Wie in Born u. a. (2019) berechnen wir nun 12 Placebo-Doppelgänger des BIP von Großbritannien für fiktive Zeitpunkte eines Referendums über sämtliche Quartale im Zeitraum 2010-Q1 bis 2016-Q1. Dies ist komfortabel durch Iteration von `placebo()` über diese Zeitpunkte mit `purrr::map_dfr()` umsetzbar.

```

# Iteration über fiktive frühere Referenden
placebos_tbl <- map_dfr(
  .x = seq(2010, 2016, .25),
  .f = \ (x) placebo(x)
)

```

`placebos_tbl` ist ein `tibble`-Objekt im tidy-Format. Wir können die Placebo-

Doppelgänger sowie den ursprünglich berechneten Doppelgänger und das tatsächliche BIP also ähnlich wie in Abbildung 11.2 mit `ggplot2::ggplot()` darstellen.

```
# Vergleich mit Placebo-Doppelgänger
(
  p_UKDG <- ggplot(
    data = placebos_tbl,
    mapping = aes(
      x = Time,
      y = gdp,
      group = type
    )
  ) +
  # Placebos (mit jitter)
  geom_line(
    lwd = .25,
    col = "gray80",
    position = position_jitter(height = .25)
  ) +
  # Ursprünglicher Doppelgänger
  geom_line(
    data = the_gdps %>%
      filter(type == "Doppelgaenger"),
    mapping = aes(col = type),
    lwd = 1
  ) +
  # Beobachtetes BIP
  geom_line(
    data = the_gdps %>%
      filter(type == "UK"),
    mapping = aes(col = type),
    lwd = 1
  ) +
  # Intikator für Referendum
  geom_vline(xintercept = 2016.25, lty = "dotted") +
  # Formatierung
  cowplot::theme_cowplot() +
  theme(legend.position = c(.05, .9))
)
```

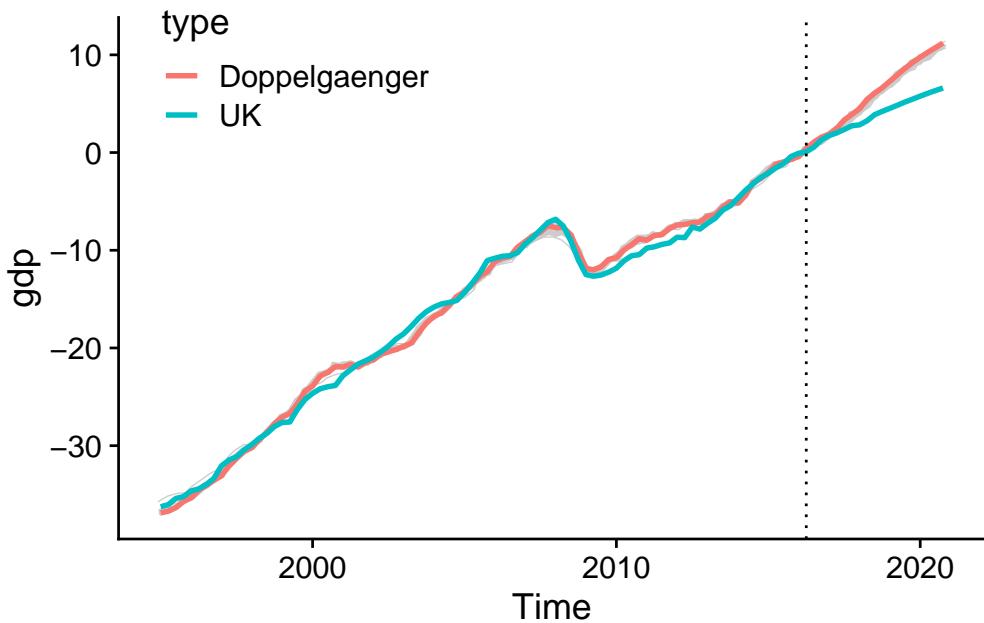


Abbildung 11.5: Placebo-Doppelgänger

```
# Close-up bei Referendum
p_UKDG +
  scale_x_continuous(
    limits = c(2015, 2021), expand = c(0, .05)
  ) +
  scale_y_continuous(
    limits = c(-3, 13), expand = c(0, 0)
  )
```

Beachte, dass `position = position_jitter(height = .25)` eine zufällige, kleine Verschiebung (`jitter`) der Trajektorien der Placebo-Doppelgänger für eine bessere Unterscheidbarkeit bewirkt. Abbildung 11.5 und Abbildung 11.6 zeigen, dass sich die Placebo-Pfade für fiktive frühere Referenden (grau) nicht systematisch vom ursprünglich berechneten synthetischen Doppelgänger (rot) unterscheiden. Insbesondere finden wir keinen Rückgang der synthetischen BIP relativ zum beobachteten BIP für Großbritannien *vor* dem Referendum. Deutliche Abweichungen vom tatsächlichen BIP ergeben sich erst jenseits der tatsächlichen Referendums. Diese Placebo-Analyse bekräftigt also die Validität der Konstruktion des “Benchmark-Doppelgängers” für die Periode bis 2016-Q2 und die Schätzung des kausalen Effekts des Referendums anhand der entsprechenden Doppelgänger-Gap.

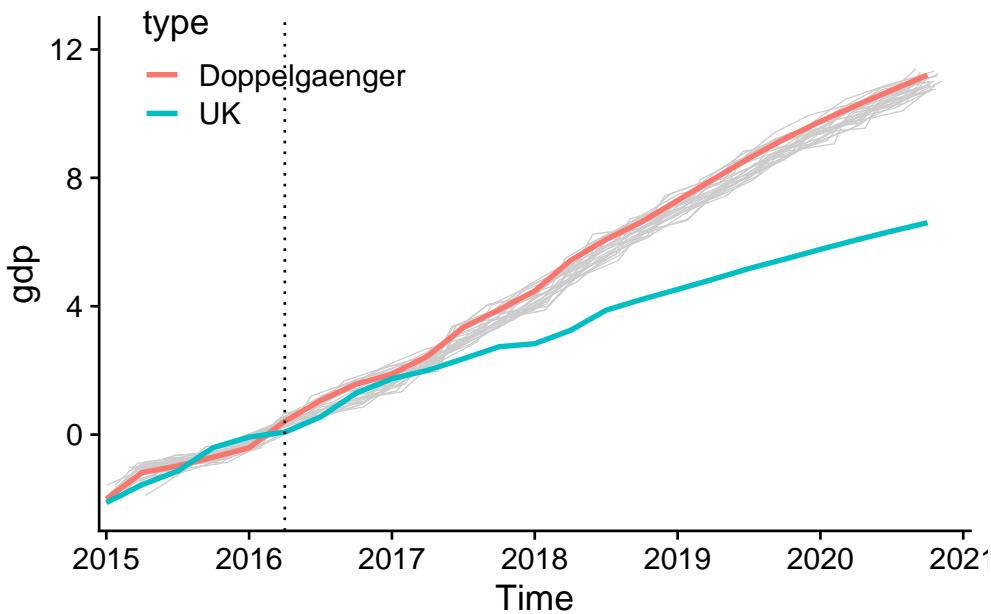


Abbildung 11.6: Placebo-Doppelgänger – Close-Up

Ein weiterer Placebo-Test in Born u. a. (2019) ist ein Vergleich der Doppelgänger-Gap Großbritanniens mit Doppelgänger-Gaps für fiktive Referenden in 2016-Q2 in Ländern mit wesentlichem Einfluss bei der Konstruktion des synthetischen Doppelgängers für Großbritannien: Die Schätzung des kausalen Effekts des Referendums auf das BIP in Großbritannien ist glaubwürdig, wenn lediglich die Doppelgänger-Gap für Großbritannien durch das Referendum beeinflusst wird, *nicht* aber die Doppelgänger-Gaps für Länder in der Kontrollgruppe.

Für diese grafische Placebo-Analyse modifizieren wir die Funktion `placebo()` entsprechend. `placebo_gap()` berechnet die Doppelgänger-Gap für das mit `treat` identifizierte Land. Das `if`-Statement zu Beginn stellt sicher, dass Großbritannien *nicht* als Kontroll-Einheit für die Placebo-Gaps verwendet wird.

```
# Funktion für Placebo-Gaps
placebo_gap <- function(treat) {

  # Kontrollgruppe definieren
  if(treat != 23) {
    controls <- (1:24)[-c(23, treat)]
  } else {
    controls <- (1:24)[-23]
  }
}
```

```

# Daten vorbereiten
dataprep_out <- dataprep(
  foo = brexit,
  predictors = c(
    "ConGDP", "InvGDP",
    "ExpGDP", "ImpGDP",
    "LPG", "EmpSha"
  ),
  dependent = "gdp",
  unit.variable = "ID",
  time.variable = "Time",
  treatment.identifier = treat,
  controls.identifier = controls,
  time.predictors.prior = seq(1995, 2016.25, .25),
  time.optimize.ssr = seq(1995, 2016.25, .25),
  unit.names.variable = "Country"
)

# Gewichte bestimmen
synth_out <- quietly(synth)(dataprep_out)$result

# Ergebnisse zusammenfassen
tb <- synth.tab(
  synth.res = synth_out,
  dataprep.res = dataprep_out
)

# Doppelgänger bestimmen
doppel <- left_join(
  x = brexit,
  y = tb$tab.w,
  by = c("Country" = "unit.names")
) %>%
  select(Time, gdp, Country, w.weights) %>%
  group_by(Time) %>%
  summarise(
    gdp_synth = sum(gdp * w.weights, na.rm = T),
  )

```

```

# Beobachtetes BIP auslesen
gdp <- brexit %>% filter(ID == treat) %>% pull(gdp)

return(
  # Doppelgänger-Gap berechnen
  doppel %>%
    mutate(
      ID = treat,
      gdp = gdp,
      gdp_gap = gdp - gdp_synth
    )
  )
}

```

Für die Berechnung der Placebo-Gaps iterieren wir über die Indizes der in Tabelle 11.2 gelisteten Volkswirtschaften der Kontrollgruppe für Großbritannien.

```

# Indizes für "Donor Countries" und UK
donors_and_UK <- brexit %>%
  select(ID, Country) %>%
  distinct() %>%
  filter(
    Country %in%
      c(
        "United States", "Italy", "Iceland",
        "Luxembourg", "Germany", "United Kingdom"
      )
  ) %>%
  pull(ID)

```

```

# Placebo-Doppelgänger-Gaps berechnen
placebo_gaps_tbl <- map_dfr(
  .x = donors_and_UK,

```

```
.f = \(x) placebo_gap(x)
)
```

Für die grafische Darstellung ergänzen wir die Variable `Country` zur Unterscheidung der Doppelgänger-Gaps für Großbritannien und die Kontroll-Länder.

```
# ID-Variable für UK und Kontroll-Länder
placebo_gaps_tbl <- placebo_gaps_tbl %>%
  mutate(
    Country = ifelse(ID == 23, "UK", "else")
  )
```

Um die Vergleichbarkeit der Doppelgänger-Gaps zu gewährleisten, standardisieren Born u. a. (2019) die Schätzungen der Gaps anhand der jeweiligen Mittelwerte für das Jahr 2015 und der Standardabweichungen im Zeitraum vor dem Brexit-Referendum. Wir berechnen diese Statistiken zunächst.

```
# Mittelwerte für 2015
means <- placebo_gaps_tbl %>%
  group_by(ID) %>%
  filter(between(Time, 2015, 2015.75)) %>%
  summarise(
    mean2015 = mean(gdp_gap)
  )

# Standardabweichungen vor Referendum
sds <- placebo_gaps_tbl %>%
  group_by(ID) %>%
  filter(Time < 2016.25) %>%
  summarise(
    thesd = sd(gdp_gap)
  )
```

Mit `dplyr::left_join()` führen wir diese Statistiken mit `placebo_gaps_tbl` zusammen und berechnen die standardisierten Doppelgänger-Gaps.

```
# Join + Standardisierung
placebo_gaps_std <-
  left_join(placebo_gaps_tbl, means) %>%
  left_join(sds) %>%
  mutate(gdp_gap_std = (gdp_gap - mean2015)/thesd)
```

Analog zum Code für Abbildung 11.4 plotten wir die Placebo-Gap-Zeitreihen mit `ggplot2::ggplot()`.

```
# Placebo-Gaps mit UK-Gap vergleichen
ggplot(
  data = placebo_gaps_std,
  mapping = aes(
    x = Time,
    y = gdp_gap_std,
    group = ID,
    lwd = Country,
    color = Country
  )
) +
# Hilfslinie bei Differenz = 0
geom_hline(yintercept = 0) +
# Gaps
geom_line() +
# Referendum
geom_vline(xintercept = 2016.25, lty = "dotted") +
# Formatierung
scale_color_manual(
  values = c("UK" = "steelblue", "else" = alpha("darkgray",
    ← .5))
) +
scale_linewidth_manual(
  values = c("UK" = 1, "else" = .5)
) +
scale_x_continuous(
  limits = c(2015, 2021), expand = c(0, .05)
) +
theme_cowplot() +
theme(legend.position = c(.05, .9))
```

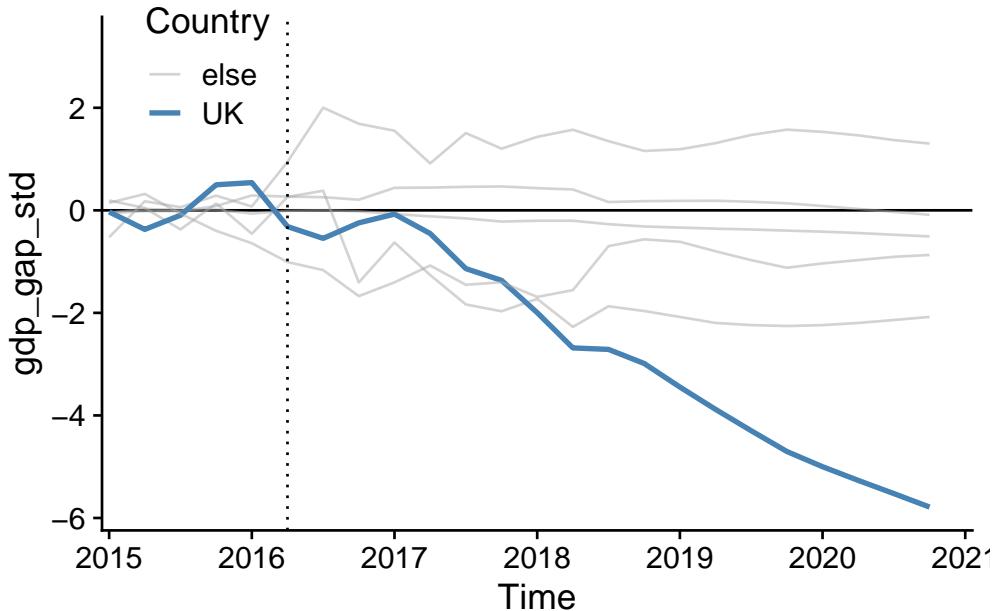


Abbildung 11.7: Placebo- und UK-Doppelgänger-Gaps

Abbildung 11.7 zeigt die standardisierten Placebo-Doppelgänger-Gaps für ein fiktives Referendum zum Zeitpunkt 2016-Q2 in den 5 Kontroll-Volkswirtschaften, die für Konstruktion des BIP-Doppelgängers von Großbritannien relevant sind (grau). Der Vergleich mit der standardisierten Doppelgänger-Gap für Großbritannien (blau). Der Verlauf der Placebo-Gaps zeigt an, dass keine Abweichungen mit negativem Trend von der Referenzlinie bei 0 (kein Unterschied zwischen beobachtetem und synthetischem BIP) nach dem Referendum vorliegen. Damit liefert die Grafik keine Hinweise auf einen Effekt fiktiver Interventionen in den Kontroll-Ländern. Für Großbritannien jedoch ist, ähnlich wie in Abbildung 11.4, ein negativer Trend nach dem Referendum deutlich erkennbar.

11.2.2 Statistische Inferenz

Die bisherigen Placebo-Tests liefern lediglich grafische Evidenz für die Signifikanz des negativen Effekts des Brexit-Referendums auf die Britische Volkswirtschaft. Methoden für statistische Inferenz für SCM sind Gegenstand aktueller Forschung. Born u. a. (2019) verwenden den End-Of-Sample Instability Test (S) von Andrews (2003). Dieses Verfahren kann für einen Test auf einen Strukturbruch gegen Ende einer Zeitreihe verwendet werden. In der vorliegenden Studie wird der Test angewendet, um zu überprüfen, ob die Verteilung der Doppelgänger-Gap Großbritanniens für die letzten m Perioden jenseits des Referendums signifikant verschieden ist von Verteilung vorheriger Perioden.

Wir zeigen nachfolgend, wie diese Analyse in R mit der Funktion `CPAT::Andrews.test()` aus dem Paket CPAT durchgeführt werden kann. Wir testen zunächst auf eine signifikante Diskrepanz der Doppelgänger-Gap in Form eines Sturkturbruchs ab 2017 und fassen die Ergebnisse tabellarisch mit `broom::tidy()` und `gt::gt()` zusammen.

```
library(CPAT)

# Andrews' (2003) Test für 2017 durchführen
Andrews.test(
  x = gdp_gap$gdp_gap,
  M = which(gdp_gap$Time == 2017)
) %>%
  broom::tidy() %>%
  gt::gt() %>%
  tabopts
```

Tabelle 11.3: Andrews' (1993) End-of-Sample Instability Test

statistic	p.value	method
14.196	0.693	Andrews' Test for Structural Change

Gem. des großen p -Werts kann die Nullhypothese (keine strukturelle Veränderung ab 2017) nicht abgelehnt werden. Wir führen den Test nun für sämtliche Zeitpunkte ab 2017 durch und plotten die p -Werte nebstd gepunkteten roten Hilfslinien für die gängigen Signifikanzniveaus (10%, 5%, 1%).

```
# Andrews' (1993) test für
# Post-Referendumsperioden
pvals_andrews <- map(seq(2017, 2020.5, .25), \(time) {
  tibble(
    Time = time,
    gap = gdp_gap %>% filter(Time == time) %>% pull(gdp_gap),
    pvalue = CPAT::Andrews.test(
      x = gdp_gap$gdp_gap,
      M = which(gdp_gap$Time == time)
    )$p.value
  )
}) %>%
  bind_rows()
```

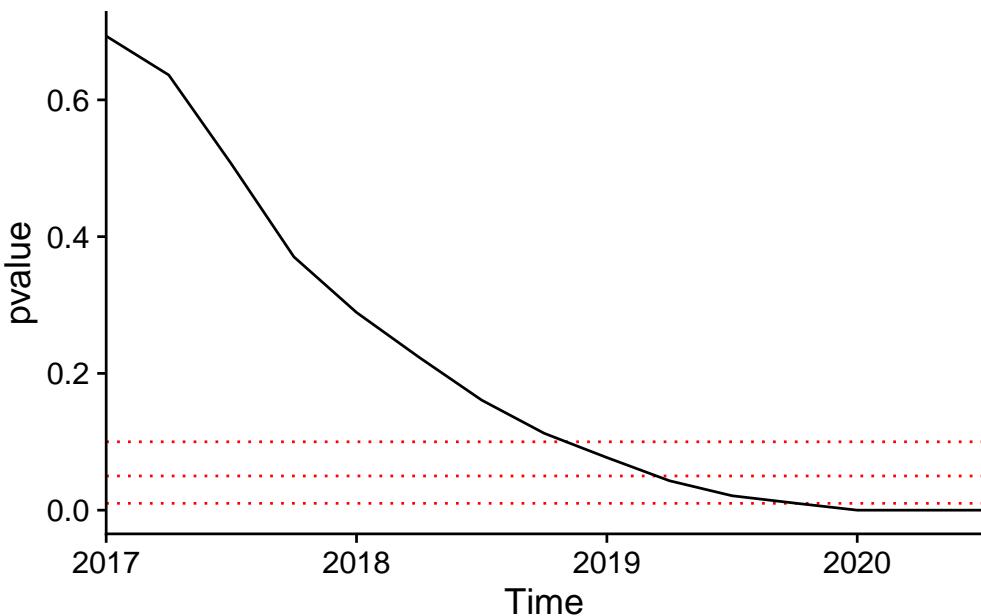


Abbildung 11.8: P-Werte für Andrews' (2003) Test

```
# p-Werte für Post-Interventionsperioden
pvals_andrews %>%
  ggplot(mapping = aes(x = Time, y = pvalue)) +
  geom_hline(
    yintercept = c(.1,.05, .01),
    lty = "dotted",
    col = "red"
  ) +
  geom_line() +
  scale_x_continuous(expand = c(0, 0)) +
  cowplot::theme_cowplot()
```

Der Verlauf der p -Werte zeigt deutlich, dass es für Zeitpunkte jenseits von 2018-Q3 Evidenz für eine strukturelle Veränderung der Doppelgänger-Gap für Großbritannien gibt. Diese Ergebnisse untermauern die Signifikanz der in Born u. a. (2019) mit SCM gefundenen negativen Effekte des Brexit-Votums auf die Britische Volkswirtschaft weiter.

Literatur

- Abadie, Alberto, Alexis Diamond, und Jens Hainmueller. 2014. „Comparative Politics and the Synthetic Control Method: COMPARATIVE POLITICS AND THE SYNTHETIC CONTROL METHOD“. *American Journal of Political Science* 59 (2): 495–510. <https://doi.org/10.1111/ajps.12116>.
- Abadie, Alberto, und Guido W. Imbens. 2008. „On the Failure of the Bootstrap for Matching Estimators.“ *Econometrica. Journal of the Econometric Society* 76 (6): 1537–57. <https://doi.org/10.3982/ECTA6474>.
- Abadie, Alberto, und Jann Spiess. 2022. „Robust Post-Matching Inference.“ *Journal of the American Statistical Association* 117 (538): 983–95. <https://doi.org/10.1080/01621459.2020.1840383>.
- Abadie, Alexis Diamond, Alberto, und Jens Hainmueller. 2010. „Synthetic Control Methods for Comparative Case Studies: Estimating the Effect of California’s Tobacco Control Program.“ *Journal of the American Statistical Association* 105 (490): 493–505. <https://doi.org/10.1198/jasa.2009.ap08746>.
- Acemoglu, Daron, Giuseppe De Feo, und Giacomo Davide De Luca. 2020. „Weak States: Causes and Consequences of the Sicilian Mafia“. *The Review of Economic Studies*. <https://doi.org/10.1093/restud/rdz009>.
- Acemoglu, Daron, Simon Johnson, James A. Robinson, und Pierre Yared. 2008a. „Income and Democracy“. *American Economic Review* 98 (3): 808–42. <https://doi.org/10.1257/aer.98.3.808>.
- . 2008b. „Replication data for: Income and Democracy“. ICPSR - Interuniversity Consortium for Political; Social Research. <https://doi.org/10.3886/E113251V1>.
- Adireksombat, Kampon. 2010. „The Effects of the 1993 Earned Income Tax Credit Expansion on the Labor Supply of Unmarried Women“. *Public Finance Review* 38 (1): 11–40. <https://doi.org/10.1177/1091142109358626>.
- Andrews, D. W. K. 2003. „End-of-Sample Instability Tests“. *Econometrica* 71 (6): 1661–94. <https://doi.org/10.1111/1468-0262.00466>.
- Austin, P. 2011. „An Introduction to Propensity Score Methods for Reducing the Effects of Confounding in Observational Studies“. *Multivariate Behavioral Research* 46 (3): 399–424. <https://doi.org/10.1080/00273171.2011.568786>.

- Austin, Peter C., und Dylan S. Small. 2014. „The use of bootstrapping when using propensity-score matching without replacement: A simulation study.“ *Statistics in Medicine* 33 (24): 4306–19. <https://doi.org/10.1002/sim.6276>.
- Austin, Peter C., und Elizabeth A. Stuart. 2017. „Estimating the Effect of Treatment on Binary Outcomes Using Full Matching on the Propensity Score.“ *Statistical Methods in Medical Research* 26 (6): 2505–25. <https://doi.org/10.1177/0962280215601134>.
- Barro, Robert J., und Jong Wha Lee. 2013. „A new data set of educational attainment in the world, 1950–2010“. *Journal of Development Economics* 104: 184–98. <https://doi.org/10.1016/j.jdeveco.2012.10.001>.
- Basten, Christoph, und Frank Betz. 2013. „Beyond work ethic: Religion, individual, and political preferences“. *American Economic Journal: Economic Policy* 5 (3): 67–91.
- Belloni, Alexandre, Daniel Chen, Victor Chernozhukov, und Christian Hansen. 2012. „Sparse models and methods for optimal instruments with an application to eminent domain“. *Econometrica* 80 (6): 2369–429.
- Belloni, Alexandre, und Victor Chernozhukov. 2013. „Least squares after model selection in high-dimensional sparse models“. *Bernoulli*, 521–47.
- Belloni, Alexandre, Victor Chernozhukov, und Christian Hansen. 2014. „High-dimensional methods and inference on structural and treatment effects“. *Journal of Economic Perspectives* 28 (2): 29–50.
- Bodory, Hugo, Lorenzo Camponovo, Martin Huber, und Michael Lechner. 2020. „The Finite Sample Performance of Inference Methods for Propensity Score Matching and Weighting Estimators.“ *Journal of Business & Economic Statistics*. <https://doi.org/10.2139/ssrn.2731969>.
- Born, Benjamin, Gernot J Müller, Moritz Schularick, und Petr Sedláček. 2019. „The Costs of Economic Nationalism: Evidence from the Brexit Experiment*“. *The Economic Journal* 129 (623): 2722–44. <https://doi.org/10.1093/ej/uez020>.
- Callaway, Brantly, und Pedro H. C. Sant'Anna. 2021. „Difference-in-Differences with Multiple Time Periods.“ *Journal of Econometrics* 225 (2): 200–230. <https://doi.org/10.1016/j.jeconom.2020.12.001>.
- Cattaneo, Matias D, Michael Jansson, und Xinwei Ma. 2020. „Simple local polynomial density estimators“. *Journal of the American Statistical Association* 115 (531): 1449–55.
- Cortez, Paulo, und Alice Maria Gonçalves Silva. 2008. „Using data mining to predict secondary school student performance“.
- Dahl, Robert Alan. 1971. *Polyarchy: Participation and Opposition: Participation and opposition*. New Haven: Yale Univ. Press.
- Di Tella, Rafael, und Ernesto Schargrodsky. 2004. „Do Police Reduce Crime?

- Estimates Using the Allocation of Police Forces After a Terrorist Attack“. *American Economic Review* 94 (1): 115–33. <https://doi.org/10.1257/000282804322970733>.
- Efron, Bradley, Trevor Hastie, Iain Johnstone, und Robert Tibshirani. 2004. „Least angle regression“.
- Eissa, N., und J. B. Liebman. 1996. „Labor Supply Response to the Earned Income Tax Credit“. *The Quarterly Journal of Economics* 111 (2): 605–37. <https://doi.org/10.2307/2946689>.
- Fearon, James D., und David D. Laitin. 2003. „Ethnicity, Insurgency, and Civil War.“ *American Political Science Review* 97 (01): 75–90. <https://doi.org/10.1017/s0003055403000534>.
- Gelman, Andrew, und Guido Imbens. 2019. „Why high-order polynomials should not be used in regression discontinuity designs“. *Journal of Business & Economic Statistics* 37 (3): 447–56.
- Goodman-Bacon, Andrew. 2021. „Difference-in-Differences with Variation in Treatment Timing.“ *Journal of Econometrics* 225 (2): 254–77. <https://doi.org/10.1016/j.jeconom.2021.03.014>.
- Hahn, P Richard, Carlos M Carvalho, David Puelz, und Jingyu He. 2018. „Regularization and confounding in linear regression for treatment effect estimation“.
- Hainmueller, Jens. 2012. „Entropy Balancing for Causal Effects: A Multivariate Reweighting Method to Produce Balanced Samples in Observational Studies“. *Political Analysis* 20 (1): 25–46. <https://doi.org/10.1093/pan/mpr025>.
- Hainmueller, Jens, Alexis Diamond, und Alberto Abadie. 2011. „Synth: An R Package for Synthetic Control Methods in Comparative Case Studies“. *Journal of Statistical Software* 42 (13): 1–17. <https://www.jstatsoft.org/v42/i13/>.
- Hájek, J. 1971. „Comment on ‚An essay on the logical foundations of survey sampling‘ by Basu, D“. *Foundations of Statistical Inference* 236.
- Hill, Jennifer, und Jerome P. Reiter. 2006. „Interval estimation for treatment effects using propensity score matching. Statistics in Medicine“. *Statistics in Medicine* 25 (13): 2230–56. <https://doi.org/10.1002/sim.2277>.
- Hirano, Keisuke, Guido Imbens, und Geert Ridder. 2003. „Efficient Estimation of Average Treatment Effects Using the Estimated Propensity Score“. *Econometrica* 71 (4): 1161–89. <https://doi.org/10.1111/1468-0262.00442>.
- Hoerl, Arthur E, und Robert W Kennard. 1970. „Ridge regression: Biased estimation for nonorthogonal problems“. *Technometrics* 12 (1): 55–67.
- Huntington, Samuel P. 1991. *The Third Wave: Democratization in the Late Twentieth Century: Democratization in the late twentieth century*. Norman, OK: Univ. of Oklahoma Press.

- Huntington-Klein, Nick. 2021. *The Effect: An Introduction to Research Design and Causality*. Chapman; Hall/CRC. <https://doi.org/10.1201/9781003226055>.
- Imbens. 2016. „Matching on the Estimated Propensity Score.“ *Econometrica* 84 (2): 781–807. <https://doi.org/10.3982/ecta11293>.
- Imbens, G. W., und Thomas Lemieux. 2008. „Regression discontinuity designs: A guide to practice“. *Journal of econometrics* 142 (2): 615–35.
- Imbens, Guido, und Karthik Kalyanaraman. 2012. „Optimal bandwidth choice for the regression discontinuity estimator“. *The Review of economic studies* 79 (3): 933–59.
- Lee, David S. 2008. „Randomized experiments from non-random selection in US House elections“. *Journal of Econometrics* 142 (2): 675–97.
- Love, Thomas. 2004. „Graphical display of covariate balance“. Presentation.
- McCrary, Justin. 2008. „Manipulation of the running variable in the regression discontinuity design: A density test“. *Journal of Econometrics* 142 (2): 698–714.
- Miguel, Edward, Shanker Satyanath, und Ernest Sergenti. 2004. „Economic Shocks and Civil Conflict: An Instrumental Variables Approach“. *Journal of Political Economy* 112 (4): 725–53. <https://doi.org/10.1086/421174>.
- Rosenbaum, Paul R., und Donald R. Rubin. 1983. „The central role of the propensity score in observational studies for causal effects“. *Biometrika* 70 (1): 170–84. <https://doi.org/10.1017/cbo9780511810725.016>.
- Rueschemeyer, Dietrich, Evelyne H. Stephens, und John D. Stephens. 1992. *Capitalist development and democracy*. Cambridge: Polity Pr.
- Tibshirani, Robert. 1996. „Regression shrinkage and selection via the lasso“. *Journal of the Royal Statistical Society Series B: Statistical Methodology* 58 (1): 267–88.
- Weber, Max. 2004. *Die protestantische Ethik und der Geist des Kapitalismus*. Bd. 1614. CH Beck.
- Wooldridge, Jeffrey. 2010. *Econometric Analysis of Cross Section and Panel Data*. Second edition. Cambridge, Massachusetts: MIT.